

GeoExtract ETL: Система интеллектуального анализа и структурирования геологической документации (Oil & Gas).

Описание проекта

Проект направлен на разработку прототипа ETL-сервиса для извлечения и структурирования данных из геологических документов (отчёты по сейсморазведке, данные скважин, геологические карты, результаты интерпретации).

Сервис автоматически:

- извлекает текст из документов различных форматов (PDF, DOCX, TXT, изображения) и выполняет OCR,
- классифицирует тип документа (ML-модель) для выбора стратегии обработки,
- разбивает документ на логические блоки (абзацы, заголовки, таблицы, списки),
- извлекает ключевые геологические параметры по regex-шаблонам (например глубина, пористость, названия пластов),
- реализует семантический поиск по извлеченным блокам,
- предсказывает пользовательские запросы на основе кластеризации извлеченного текста,
- нормализует и структурирует данные для последующей аналитики или интеграции в RAG-системы.

Ключевая особенность (DS-подход):

- В отличие от классических задач ML, здесь нет готового датасета — сами создаём синтетические или реальные тестовые документы, разрабатываем пайплайн, оцениваем его качество вручную и через метрики (скорость, точность извлечения, качество чанкинга),
- В отличие от классической ETL-задачи, здесь ETL-пайплайн — это инструмент для получения геологических инсайтов.
- Результат — очищенные, нормализованные текстовые блоки, пригодные для дальнейшей интеграции с RAG-пайплайнами, аналитическими и поисковыми системами.
- Важно: проект не ставит целью предсказание геологических параметров или классификацию месторождений.
- Фокус — на качестве и воспроизводимости ETL-пайплайна, а также на интерпретируемой оценке того, насколько хорошо извлечённые данные сохраняют исходную информацию.

Проект демонстрирует навыки Data Scientist:

- работа с неструктурированными данными (текст, сканы, изображения) и формулирование гипотез
- выбор ML-моделей с учетом жестких ограничений (CPU, время)
- построение ETL-пайплайнов обработки
- извлечение структуры из PDF (PyPDF2, pdfplumber, unstructured)
- выбор и сравнение OCR-моделей (Tesseract vs EasyOCR)
- сравнение стратегий сегментации (rule-based vs NLP)
- расчёт метрик качества (CER, WER, Precision, Recall, F1)
- извлечение признаков (Feature Extraction) из текста (regex + NLP)
- анализ ошибок модели (Error Analysis)
- классическое ML для текстовой классификации (TF-IDF + Classifier);
- кластерный анализ для генерации инсайтов (Query Suggestion);
- расчет метрик и интерпретация ошибок (Error Analysis).

Бизнес-ценность для геологии:

- В корпоративной среде большая часть данных хранится в неструктурированных документах,
- Автоматическое извлечение данных из документов — основа для поиска, анализа, обработки, создания базы знаний:
 - Автоматизация ручного ввода и парсинга документов
 - Стандартизация неструктурированных данных для дальнейшего ML/NLP-анализа,
 - Снижение time-to-insight при работе с архивами, контрактами, отчетами и сканами,
 - Подготовка данных для LLM/RAG без потери семантической целостности.
- Геологи тратят до 70% времени на чтение старых отчётов, а не на интерпретацию,
- Автоматизация извлечения параметров (пористость, глубина, пласты) ускоряет построение ML-моделей прогнозирования запасов,
- Структурированные данные из отчётов фондов позволяют выявлять паттерны успешных разведочных проектов.

Финальный результат — модульный ETL-пайплайн + REST API, принимающий документ и возвращающий структурированный JSON с блоками текста, таблицами и метаданными

Выбор метрики

Так как задача не содержит классической целевой переменной, оценка качества производится по трём группам метрик, включая DS-метрику качества.

1. Метрики качества извлечения текста (OCR):

- Используются для PDF/JPEG/PNG и сравнения OCR-моделей (например, Tesseract vs EasyOCR):
 - CER (Character Error Rate) — доля ошибочных символов (**главная метрика для сравнения OCR**);
 - WER (Word Error Rate) — доля ошибочных слов;

2. Метрики сегментации и разбиения документа на логические блоки:

- Оценивают качество структурирования документа (заголовки, абзацы, таблицы, блоки текста):
 - Precision (блоки) — доля выделенных блоков, которые действительно являются логическими единицами;
 - Recall (блоки) — доля реальных логических блоков, которые были найдены;
 - F1-score (блоки) — итоговая метрика для сравнения стратегий чанкинга

3. DS-метрика качества:

- Hit@3 — для семантического поиска (доля запросов, где правильный блок попал в топ-3);
 - Критерий релевантности для Hit@3: блок считается релевантным, если содержит ≥ 1 ключевой геологический термин из запроса и находится на той же странице/в том же разделе, что и эталонный ответ (проверяется по Golden Set).
- Accuracy (классификация) — точность определения типа геологического документа;
- Extraction Accuracy — точность извлечения числовых параметров (глубина, пористость)

Описание данных

Форматы

Формат	Библиотека	План, шт.	Особенности (геология + технические)
PDF (text-based)	pdfplumber, PyMuPDF	15–20	Отчёты, современные статьи; извлечение текста и таблиц
PDF (scanned)	pytesseract + pdf2image	5–10	Отчёты фондов; стресс-тест OCR; требуется Tesseract
doc_Word	python-docx	10–15	Интерпретации, пояснительные записки; параграфы, таблицы, стили
Table	pandas / openpyxl	5–10	Таблицы параметров скважин; ячейки, листы, структурированные данные
TXT / RTF	built-in / striprt	5–10	Текстовые отчёты, базы данных; прямое чтение или конвертация
PNG / JPEG / TIFF	pytesseract + Pillow	5–10	Геологические карты, сейсмические разрезы; OCR изображений

Документы могут содержать:

- текст,
- таблицы,
- изображения,
- заголовки,
- списки.

Планируемый объём данных:

- Всего документов: 50–100 (реальные)
- Golden Set (размеченные вручную): 10–15 документов
- Test set для OCR: 5 сканов с эталонной разметкой
- Test set для сегментации: 10 документов Golden Set

Особенности:

- Данные не размечены (нет готовых блоков) - для оценки качества разбиения потребуется вручную разметить 5–10 документов,
- Шум (OCR ошибки),
- Разная кодировка, языки (рус/анг), наличие сканов с артефактами,
- Смешанные макеты: текст + таблицы + графики + подписи,
- Возможны повреждённые файлы, пустые страницы, водяные знаки,
- Форматы имеют разную природу: текстовые vs растровые (нужен OCR):
 - разные форматы документов,
 - отсутствие структуры,
 - разное качество изображений.

Пример структуры проекта (project):

```
project/
├── api_results/
├── api_test_docs/
├── data/                                     (исходные данные)
│   ├── golden_set/
│   │   ├── annotations/
│   │   ├── gs_data/
│   │   ├── for_metadata_gs_features.txt
│   │   ├── metadata_gs_features.csv
│   │   ├── doc_labels.txt
│   │   └── doc_labels_all.txt
│   └── raw/
│       ├── pdf_text/
│       ├── pdf_scans/
│       └── doc_Word/
```

tables/	
images/	
txt/	
log/	
results/	
classification/	
metadata/	
ocr/	
segmentation/	
step1/	
step2/	
step3/	
step4/	
step5/	
step6/	
step7/	
step8/	
src/	(Python модули)
extractors/	
base.py	
docx_extractor.py	
excel_extractor.p	
image_extractor.py	
pdf_scan_extractor.py	
pdf_text_extractor.py	
rtf_extractor.py	
table_image_analyzer.py	
txt_extractor.py	
segmentation/	
headers.py	
normalization.py	
postprocess.py	
rule_based.py	
segment_doc.py	
segment_docx.py	
segment_images.py	
segment_pdf_scans.py	
segment_pdf_text.py	
segment_txt.py	
segment_xlsx.py	
utils.py	
well_log.py	
semantic_search/	
chunks.py	
embeddings.py	
faiss.py	
loaders.py	
prepare.py	
qs_table.py	
query_suggestions.py	
search.py	
suggestions.py	
classifier.py	
extract_text.py	
features.py	
final_json.py	
normalization.py	
structuring.py	
01_research_and_pipeline.ipynb	(Шаги 1-7 + 10: EDA + model selection + experiments)
02_ETL.ipynb	(Шаги 8: ETL)
03_DEMO_API.ipynb	(Шаги 9: API)
api.py	
requirements.txt	
README.md	

Рекомендуемые открытые датасеты (геология нефти и газа)

- Геологическая служба Канзаса (KGS) → <https://kgs.ku.edu/kgs-publications>:
 - отчёты по скважинам, таблицы формата PDF/XLSX
- Норвежский нефтяной директорат (NPD) → <https://www.sodir.no/en/search/?q=seismic%20interpretation%20&contentFilters=files>:
 - качественные отчёты на английском формата PDF
- Force 2020 Well Log Challenge → <https://github.com/bolgebrygg/Force-2020-Machine-Learning-competition>:
 - каротажные данные скважин Норвегии (CSV + PDF-описания), идеальны для тестирования извлечения табличных данных
- SEG ML Repository → <https://github.com/seg/tutorials-2016>:
 - Jupyter-тutorials SEG с PDF-статьями и сейсмическими данными
- PetroWiki → <https://onepetro.org/pages/petrowiki>:
 - открытая база знаний по петрофизике, геологии и нефтегазовой инженерии
- USGS (United States Geological Survey) Publications Warehouse → <https://pubs.usgs.gov>:
 - отчёты по месторождениям, геологические карты, стратиграфия формата PDF

- EIA (Energy Information Administration) → <https://www.eia.gov/>:
 - аналитические отчёты PDF (text-based) по добыче нефти и газа
- ResearchGate <https://www.researchgate.net/>:
 - отчёты по геологии PDF
- Geophysics <https://pubs.geoscienceworld.org/geophysics/list-of-years>:
 - отчёты по геофизики PDF

Структура: 50–100 документов. Из них вручную размечается Golden Set (10-15 docs) в формате JSON для расчета F1 и CER.

Технический стек

Категория	Библиотеки
PDF (text)	pdfplumber, PyMuPDF (fitz)
OCR	pytesseract, pdf2image
DOCX	python-docx
XLSX	pandas, openpyxl
Изображения	Pillow, OpenCV
Нормализация	unicodedata, chardet, langdetect
Chunking	LangChain (RecursiveCharacterTextSplitter), nltk
API	FastAPI, uvicorn
Метрики	jiwer (WER/CER), numpy
Визуализация	matplotlib, seaborn
ML/NLP	scikit-learn (TF-IDF, LogisticRegression/LinearSVC для классификации), spaCy (для NLP-чанкинга), sentence-transformers/all-MiniLM-L6-v2 (для эмбедингов)
Кластеризация/ Поиск	sklearn.cluster.KMeans, FAISS (CPU)

"Ограничения для CPU"

- all-MiniLM-L6-v2 (384-dim), spaCy small-модели,
- Tesseract 5, EasyOCR в CPU-режиме (limit_batch_size=1),
- избегать: LayoutLM, Detectron2, больших transformer'ов (> 100M параметров)

Цели исследования

MVP-цели (обязательные для завершения проекта):

1. Построить ETL-пайплайн, принимающий файл → возвращающий JSON с блоками и метаданными.
2. Сравнить 2 OCR-движка (Tesseract vs vs предобработка OpenCV+Tesseract) по по CER/WER.
3. Сравнить 2 стратегии чанкинга (rule-based vs hybrid) по F1 на Golden Set.
4. Обучить легковесную ML-модель классификации документов (Accuracy > 0.75)
5. Реализовать извлечение ≥3 геологических параметров по regex-шаблонам (глубина, пористость, пласт) и оценить точность (Extraction Accuracy).
6. Реализовать семантический поиск (Hit@3 > 0.70).
7. Внедрить механизм предсказания запросов (Query Suggestion) через кластерный анализ.

Ход исследования

Соответствие шагов исследования и ноутбуков:

Ноутбук	Какие шаги из хода исследования	Что будет реализовано
01_research_and_pipeline.ipynb	Шаг 1–7 и Шаг 10	Загрузка данных → EDA геологических документов → выбор моделей (OCR, segmentation, classification, semantic search) → проверка гипотез и экспериментальный дизайн → → извлечение текста → сегментация → нормализация → классификация → semantic search → Интерпретация результатов и выводы
02_ETL.ipynb	Шаг 8	Загрузка данных → EDA геологических документов → выбор моделей (построение полного ETL-пайплайна
03_DEMO_API.ipynb	Шаг 9	→ демонстрация API

Ограничения и допущения

- OCR-качество зависит от качества сканов (шум, наклон, низкое DPI).
- Не все PDF содержат текстовый слой — часть требует OCR.
- Таблицы в PDF могут извлекаться с ошибками (слияние ячеек, потеря структуры).
- Полноценный layout-analysis (Detectron2, LayoutLM) не используется из-за ограничений CPU; в проекте применяется rule-based + NLP segmentation.

- Нормализация текста не гарантирует 100% исправления OCR-ошибок.
- Поддержка сложных документов (много колонок, формулы, графики) ограничена.
- Мультиязычные документы требуют отдельной настройки OCR.
- Golden Set мал (10–15 документов), статистическая значимость ограничена
- ML-классификация (TF-IDF + LogisticRegression) обучается на малом Golden Set (20 документов) — возможна нестабильность при малом числе примеров на класс.
- Semantic search не проверялся на реальных пользовательских запросах
- CER/WER рассчитаны только на 5 сканах — возможна недооценка вариативности
- Отсутствует внешняя валидация (только авторская разметка Golden Set)

Ожидаемые результаты

Ключевой результат для DS-портфолио:

- Продемонстрирован полный цикл Data Science: гипотезы → эксперименты → метрики → интерпретация → выводы
- Все решения обоснованы метриками
- Показано понимание компромиссов: точность vs скорость vs сложность

- Ноутбук (Jupyter Notebook):
 - 01_research_and_pipeline.ipynb:
 - Описание проекта, целей исследования и используемых метрик
 - EDA геологических документов (анализ структуры, типов документов, визуализации)
 - Проверка исследовательских гипотез и экспериментальный дизайн
 - Сравнение OCR-моделей (Tesseract vs EasyOCR, CER, WER)
 - Итоговая таблица сравнения моделей и подходов
 - Сравнение стратегий сегментации (Rule-based vs NLP vs Hybrid, Precision / Recall / F1)
 - Выбор модели классификации документов
 - Оценка качества классификации документов (Accuracy, Confusion Matrix)
 - Выбор модели эмбедингов для semantic search
 - Оценка качества semantic search (Hit@3)
 - Практическая ценность для геологоразведки
 - Итоговый аналитический отчёт с выводами
 - Ограничения проекта и идеи для дальнейшего развития
 - 02_ETL.ipynb:
 - Реализация всех модулей ETL-пайплайна
 - 03_DEMO_API.ipynb
 - Демонстрация работы пайплайна на реальных примерах
 - Код API (FastAPI)
 - Тестирование API-эндпоинтов
- ETL-пайплайн, включающий:
 - извлечение текста,
 - OCR,
 - сегментацию,
 - нормализацию,
 - семантика
 - экспорт.
- Графики и визуализации:
 - Сравнение OCR: столбчатая диаграмма (CER по моделям),
 - Сравнение стратегий чанкинга: F1 и время обработки,
 - Confusion matrix для классификации документов,
 - График зависимости Quality Score от качества скана (DPI),
 - Пример извлечённых блоков (визуальное выделение в Jupyter),
 - ROC/PR-кривые (если добавите ML-классификацию блоков),
 - Тепловая карта ошибок сегментации по типам документов
 - График зависимости CER от качества скана (DPI)
 - Скриншот работы API (запрос/ответ).
- README с описанием архитектуры:
 - Описание проекта и бизнес-ценность,
 - Архитектура ETL-пайплайна,
 - Результаты сравнения моделей (таблица),
 - DS-метрики (Quality Score, Hit@3),
 - Инструкция по запуску,
 - Примеры запросов к API.