Structural QC_CV — кросс-плот и кросс-валидация для оценки качества структурных карт по данным скважин.

Валидация точности структурной карты против истинных глубин геологических маркеров в скважинах.

Ниже — полный план проекта Structural QC_CV, затем ноутбук, который показывает выполненные шаги 0–4 на данных скважин (движок `structural_qc_full.py`).

Для запуска нужны `structural_qc_full.py` рядом с ноутбуком и файл с данными скважин (в ноутбуке — `RAW`).

Автор: Алексей · геофизик → data scientist

Описание проекта

Streamlit-инструмент, который сравнивает эталонный параметр PARAM_1 (Z_well) и сравниваемый PARAM_2 (Z_map) в одних и тех же точках — скважинах — и проверяет, насколько один параметр предсказывается по другому. Реализованы Шаги 0–4: загрузка и QC данных, базовый QC-кросс-плот с аппроксимациями, кросс-валидация по девяти схемам с автоматическим выбором лучшей, анализ по категориям и фильтрация скважин. Инструмент обобщён на любые пары числовых параметров. Во всех шагах модель — линейная регрессия (полином степени 1).

Описание данных

Входная таблица CSV/XLSX, в которой каждая строка — пара значений PARAM_1 и PARAM_2 в точке скважины (на горизонт). Обязательные колонки: well_id, X_coord, Y_coord, PARAM_1 (Zprm_well) и PARAM_2 (Zprm_map). Опциональные: horizon_id, tectonic_zone, reservoir_flag (тип коллектора), fluid_type (тип флюида) и любые другие числовые и категориальные колонки. В приложении есть демонстрационные файлы (выбор в сайдбаре) и пример структуры из трёх скважин: well_id, X_coord, Y_coord, Z_well, Z_map, horizon_id, tectonic_zone.

Цели исследования

- Проверить согласованность структурной карты с данными скважин по глубинам горизонта (Z_map относительно Z_well).
- Оценить реальную, а не оптимистичную точность карты с помощью кросс-валидации по схемам, разбивающим данные по скважинам.
- Выявить систематические смещения (Bias, наклон регрессии) и зоны, горизонты или категории, где карта работает хуже.
- Проверить устойчивость результата к сокращению числа скважин, к отдельным наблюдениям и выбросам.

Ход исследования

- Шаг 0 — загрузка данных, QC входных данных, статистика и распределения по всем числовым колонкам, корреляционные матрицы Пирсона и Спирмена.
- Шаг 1 — базовый QC-кросс-плот, аппроксимации (17 типов), распределения, невязки, карта невязок, выбросы.
- Шаг 2 — кросс-валидация по девяти схемам, выбор лучшей по выбранному критерию (по умолчанию score = RMSE + RMSE_fold_std), детальный разбор лучшей схемы.
- Шаг 3 — диагностика по выбранной категориальной колонке.
- Шаг 4 — фильтрация скважин: ручная, случайная по проценту или выделением точек кликом.

Ожидаемые результаты

- Сравнительная таблица ошибок (RMSE, MAE, Bias) по схемам CV и по фолдам с выбором лучшей схемы.
- Оценка смещения и тренда: Bias, наклон и intercept регрессии; тренд невязки от глубины как признак ошибки скоростной модели.
- Карта невязок и список выбросов по четырём правилам с указанием зон систематических ошибок.
- Метрики по категориям и оценка устойчивости результата при фильтрации скважин.
- Вывод о том, на каких участках и горизонтах карте можно доверять, а где её нужно пересмотреть.

План проекта. Версия сверена с реализацией (app_full.py, structural_qc_full.py, app_utils.py, translations_full.py) — обновлено, чтобы не противоречить коду.

Постановка задачи

- Типичная задача валидации точности структурной поверхности (карты), построенной по данным МОГТ 2D/3D, против «истины» в скважинах — глубин геологических маркеров.
- Ключевой методологический риск: если скважины использовались при построении карты (калибровка скоростной модели, привязка ВСП, интерполяция/крайгинг с учётом скважинных данных), то проверка качества карты в этих же точках даёт завышенную, оптимистичную оценку — это классическая утечка данных (data leakage), только в геологической форме.
- Оценивается предиктивная модель (регрессия/аппроксимация), связывающая два параметра: эталонный PARAM_1 и сравниваемый PARAM_2. Для структурного QC: PARAM_1 = Z_well (истинная глубина горизонта), PARAM_2 = Z_map (глубина того же горизонта по структурной карте).
- Значения PARAM_2 на каждой итерации кросс-валидации фиксированы (не пересчитываются из данных сейсморазведки заново) — переобучается только модель связи «PARAM_2 → PARAM_1» при исключении скважины или группы скважин из обучающей выборки.

Инструмент реализован обобщённо и применим не только к паре «скважина ↔ карта», а к любой паре числовых параметров:

Сценарий	PARAM_1 (Reference) / PARAM_2 (Compared) — примеры
скважина ↔ карта	Z_well / Z_map, T_well / T_map
скважина ↔ атрибут	Z_well / Amplitude, Phi_well / AVO_Gradient
карта ↔ карта	Z_map_v1 / Z_map_v2 (сравнение версий интерпретации)
атрибут ↔ атрибут	Amplitude / Sweetness (проверка мультиколлинеарности)

Далее по тексту плана Z_well/Z_map используются как сквозной иллюстративный пример (структурный QC), но все шаги и формулы применимы к любой паре PARAM_1/PARAM_2.

Формат данных

Минимальная структура входной таблицы (CSV/XLSX):

Колонка в коде	Роль	Описание
well_id	обязательная	Идентификатор скважины
X_coord, Y_coord	обязательные	Координаты скважины
Zprm_well (= PARAM_1)	обязательная · Reference	Эталонный параметр — то, с чем сравниваем. Для структурного QC: Z_well (истинная глубина маркера).
Zprm_map (= PARAM_2)	обязательная · Compared	Сравниваемый параметр. Для структурного QC: Z_map (глубина по карте).
horizon_id	опциональная	Идентификатор горизонта — позволяет отфильтровать анализ по одному или нескольким горизонтам
tectonic_zone	опциональная	Тектоническая/геологическая зона — используется в Stratified by Zone CV и в Шаге 3
любая другая колонка	опциональная	Любая дополнительная числовая колонка — доступна для корреляционного анализа (Шаг 0); любая категориальная — доступна для анализа по категориям (Шаг 3)

- Единицы измерения PARAM_1 и PARAM_2 задаются пользователем при сопоставлении колонок (например, м, км, мс, м/с и т.п.) — используются только в подписях графиков и таблиц, не влияют на расчёт.
- При загрузке выполняется автоматическая очистка: приведение мусорных значений («NA», «NULL», «—», «?» и т.п.) к NaN, замена запятой на точку в числовых колонках, приведение типов, удаление строк с пропусками в обязательных колонках (с выводом отчёта, сколько строк удалено).
- Опциональные колонки reservoir_flag (тип коллектора) и fluid_type (тип флюида) используются как категориальные признаки для Шага 3 наравне с tectonic_zone.

Метрики кросс-плота и обозначения

Обозначение: x = PARAM_2 (сравниваемое значение), y = PARAM_1 (эталонное значение). В CV-аппроксимациях (Шаг 2) роли заданы осознанно иначе: x = Actual (PARAM_1), y = Predicted — кривая описывает прогноз модели как функцию фактического значения.

Невязка Δ — определяется по-разному в двух местах кода, это важно:

- Базовый QC-кросс-плот (Шаг 1, BasicStats): Δ = y − x = PARAM_1 − PARAM_2. Для структурного QC: Δ = Z_well − Z_map. Положительная Δ ⇒ Z_well > Z_map (карта занижает глубину); отрицательная ⇒ карта завышает глубину.
- Аппроксимации и кросс-валидация (Шаги 1–4, FitStats / fold_metrics): Δ = Predicted − Actual, то есть предсказание модели минус фактическое PARAM_1 — обратный знак по сравнению с базовым QC-кросс-плотом. Графики CV-невязок Шага 2 строятся как Actual − Predicted (PARAM_1 − Predicted), см. раздел «Шаг 2».

Таблица ниже — метрики через Δ. Δ — невязка, её определение зависит от раздела: Шаг 1 (BasicStats): Δ = y − x; аппроксимации, CV и Шаг 4 (FitStats, fold_metrics): Δ = Predicted − Actual; для R^2_lin и R^2 (Pearson) используется Δ_OLS — остаток линейной регрессии, для которого $r^2 = 1 - \Sigma(\Delta_OLS)^2 / \Sigma(y - \bar{y})^2$. Коэффициенты корреляции r и ρ — не R^2 и через Δ не выражаются. $\bar{\Delta}$ — среднее невязки (= Bias).

Метрика	Формула	Где используется
Коэффициент корреляции Пирсона r	$r = \dfrac{\mathrm{cov}(a,b)}{\sigma_a\,\sigma_b}$ — для любого выбранного набора числовых колонок	Шаг 0: матрицы корреляции и таблицы пар
Коэффициент корреляции Спирмена ρ	Пирсон на рангах; любая монотонная связь	Шаг 0
R^2_lin (коэффициент детерминации / квадрат корреляции)	$R^2_{lin} = 1 - \dfrac{\sum(\Delta_{OLS})^2}{\sum(y-\bar y)^2} = r^2$; $\Delta_{OLS} = y - (a + b\,x)$, x = PARAM_2, y = PARAM_1; a, b — из `linregress`	Шаг 1: «Метрики кросс-плота»; Шаг 4: до/после фильтрации
R^2_fit (коэффициент детерминации)	$R^2_{fit} = 1 - \dfrac{\sum(\Delta)^2}{\sum(y-\bar y)^2}$; $\Delta = Predicted - Actual = model(PARAM_2) - PARAM_1$, y = PARAM_1	Шаг 1: таблица аппроксимаций (17 типов, для квантильной — τ = 0.1/0.5/0.9); Шаг 3: по категориям; Шаг 4: аппроксимации до/после фильтрации
R^2_fit (CV-аппроксимации)	$R^2_{fit} = 1 - \dfrac{\sum(\Delta)^2}{\sum(y-\bar y)^2}$; $\Delta = model(Actual) - Predicted$; x = Actual (PARAM_1), y = Predicted; роли намеренно отличаются от Шага 1	Шаг 2: «Аппроксимации» для лучшей схемы
R^2 (Pearson, Predicted vs Actual)	$R^2 = 1 - \dfrac{\sum(\Delta_{OLS})^2}{\sum(Actual-\bar{Actual})^2} = r^2$; $\Delta_{OLS} = Actual - (a + b\,Predicted)$, OLS по out-of-fold прогнозам; равно $corrcoef(Actual, Predicted)^2$	Шаг 2: «Метрики кросс-плота» по всем схемам и карточка лучшей схемы; столбец pooled в «Таблице R^2 (Pearson) по фолдам»

Метрика	Формула	Где используется
R^2 (Pearson) по фолдам	то же, что выше, внутри каждого фолда; нужно не меньше 3 точек и ненулевая дисперсия	Шаг 2: «Таблица R^2 (Pearson) по фолдам» (`r2_fold_*`) и boxplot
R^2 (Actual = Predicted)	$R^2 = 1 - \dfrac{\sum(\Delta)^2}{\sum(Actual-\bar{Actual})^2}$; $\Delta = Predicted - Actual$; по out-of-fold прогнозам	Шаг 2: «Сравнение схем CV»
R^2 (Pearson), in-sample	$R^2 = 1 - \dfrac{\sum(\Delta_{OLS})^2}{\sum(PARAM_1-\bar{PARAM_1})^2} = corrcoef(PARAM_2, PARAM_1)^2$; $\Delta_{OLS} = PARAM_1 - (a + b\,PARAM_2)$, OLS по оставшимся скважинам	Шаг 4.5
R^2 (Pearson), out-of-sample	$r^2 = corrcoef(PARAM_1, pred)^2$ на исключённых скважинах, $pred = a + b\,PARAM_2$ по оставшимся; через Δ не выражается, так как линия обучена на другой выборке	Шаг 4.5

Ошибки и смещение

Метрика	Формула
RMSE (среднеквадратичная ошибка)	$\mathrm{RMSE} = \sqrt{\dfrac{1}{N}\sum(\Delta)^2}$
MSE (среднеквадратичная ошибка)	$\mathrm{MSE} = \dfrac{1}{N}\sum(\Delta)^2$
MAE (абсолютная погрешность)	$\mathrm{MAE} = \dfrac{1}{N}\sum\lvert\Delta\rvert$
Bias (систематическое смещение)	$\mathrm{Bias} = \dfrac{1}{N}\sum(\Delta)$
Std (стандартное отклонение невязок)	$\mathrm{Std} = \sqrt{\dfrac{1}{N-1}\sum(\Delta_i-\bar\Delta)^2}$
Variance (дисперсия невязок)	$\mathrm{Var} = \dfrac{1}{N-1}\sum(\Delta_i-\bar\Delta)^2$
MAPE, % (средняя абсолютная ошибка в процентах)	$\mathrm{MAPE} = \dfrac{100}{N}\sum\dfrac{\lvert\Delta\rvert}{\max(\lvert y\rvert,\,10^{-9})}$
P-value (значимость линейной корреляции)	$t = r\sqrt{\dfrac{N-2}{1-r^2}}$, $p = 2\left(1-F_{t,\,N-2}(\lvert t\rvert)\right)$
Уравнение линейной регрессии	$y = a + bx$; наклон b и intercept a — из `linregress`

P-value отвечает на вопрос: насколько вероятно получить настолько же сильную (или сильнее) линейную связь между PARAM_1 и PARAM_2 случайно, если на самом деле никакой связи нет (нулевая гипотеза H_0: истинный наклон регрессии b = 0). Чем меньше p-value, тем менее правдоподобно, что найденная зависимость — случайность; порогом значимости обычно считают p < 0.05. Считается для базового QC-кросс-плота (Шаг 1) и для кросс-плота Шага 2 (по out-of-fold прогнозам), через `scipy.stats.linregress`.

В проекте два разных R^2 — разведены по названию, чтобы не путать. R^2_lin (BasicStats.r2, Шаг 1, базовый QC-кросс-плот) = квадрат коэффициента корреляции Пирсона (`scipy.stats.linregress`) — корректен только как мера силы линейной связи. R^2_fit (FitStats.r2, все 17 типов аппроксимации, Шаги 1–4) = `sklearn.metrics.r2_score` = $1 - \Sigma(\Delta)^2 / \Sigma(y - \bar{y})^2$, Δ = Predicted − Actual — честная доля объяснённой дисперсии, корректна для кривой любой формы. Для линейной OLS оба совпадают численно, для остальных 16 типов — нет. Сравнивать R^2_lin и R^2_fit напрямую нельзя — это разные метрики, а не одна и та же величина, посчитанная дважды. В Шаге 2 к ним добавляются ещё два варианта: R^2 (Actual = Predicted) — формула R^2_fit, применённая к out-of-fold прогнозам кросс-валидации (`r2_score`), и R^2 (Pearson, Predicted vs Actual) — квадрат корреляции Пирсона между прогнозом и фактом (`linregress`). Оба считаются по прогнозам кросс-валидации и не равны R^2_lin базового кросс-плота.

Коэффициенты линейной регрессии (наклон / intercept) показывают систематический тренд — например, «карта занижает глубину с ростом глубины» (b < 1) — типичный признак ошибки скоростной модели.

Статистика параметров (Шаг 0)

Для PARAM_1 и PARAM_2 отдельно считается расширенная описательная статистика:

Статистика	Формула / определение
Count	N — число непустых значений
μ (mean)	$\mu = \dfrac{1}{N}\sum x_i$ — среднее арифметическое
median	медиана — значение, делящее выборку пополам (50-й перцентиль)
mode	мода — наиболее часто встречающееся значение
σ (std)	$\sigma = \sqrt{\dfrac{1}{N-1}\sum(x_i-\mu)^2}$
variance	$\sigma^2 = \dfrac{1}{N-1}\sum(x_i-\mu)^2$
CV, %	$\dfrac{\sigma}{\mu}\times 100\%$ — коэффициент вариации (разброс относительно среднего)
min	минимальное значение
Q05	5-й перцентиль
Q25	25-й перцентиль (первый квартиль)
Q75	75-й перцентиль (третий квартиль)
Q95	95-й перцентиль
max	максимальное значение
range	$\max - \min$
IQR	$Q75 - Q25$ — межквартильный размах

Типы линий аппроксимации

На кросс-плоте, помимо базовой линейной регрессии, доступен выбор из 17 вариантов аппроксимации (10 полиномов 1–10 степени + 7 прочих методов) и квантильной регрессии (τ = 0.1 / 0.5 / 0.9), которая выводится отдельными строками:

Метод	Общий вид уравнения	Пример
Линейная	$y = a + b\cdot x$	$y = 12.4 + 0.85\cdot x$
Квадратичная	$y = a + b\cdot x + c\cdot x^2$	$y = 5.1 + 0.62\cdot x + 0.014\cdot x^2$
Кубическая	$y = a + b\cdot x + c\cdot x^2 + d\cdot x^3$	$y = 3.7 + 0.41\cdot x + 0.021\cdot x^2 - 0.0006\cdot x^3$
Полином n-й степени (4–10)	$y = a_0 + a_1\cdot x + a_2\cdot x^2 + \dots + a_n\cdot x^n$	n=4: $y = 2.0 + 0.30\cdot x + 0.05\cdot x^2 - 0.002\cdot x^3 + 0.00004\cdot x^4$
Степенная	$y = a\cdot x^b$ ($x, y > 0$)	$y = 1.8\cdot x^{0.63}$
Экспонента	$y = a\cdot e^{b\cdot x}$ ($y > 0$)	$y = 4.2\cdot e^{0.015\cdot x}$
Логарифмическая	$y = a + b\cdot\ln x$ ($x > 0$)	$y = -3.5 + 6.2\cdot\ln x$
Robust (Huber)	$y = a + b\cdot x$; a, b минимизируют $\sum L_\delta(y_i - \hat y_i)$	$L_\delta(r) = \tfrac12 r^2$ при $\lvert r\rvert \le \delta$; $\delta(\lvert r\rvert - \tfrac12\delta)$ при $\lvert r\rvert > \delta$
Theil–Sen	$y = a + b\cdot x$; $b = \mathrm{median}\left\{\dfrac{y_j-y_i}{x_j-x_i}\right\}$, $i<j$	медиана всех попарных наклонов между точками
RANSAC	$y = a + b\cdot x$; коэффициенты — по максимальному числу inlier-точек	точка — inlier, если $\lvert\text{остаток}\rvert < \varepsilon$ (порог задаётся)
LOWESS	$\hat y(x_0)$ — локальная регрессия в окне вокруг x_0	вес $w_i = (1 - \lvert x_i - x_0\rvert^3/h^3)^3$ (tricube kernel)
Квантильная регрессия	$y = a_\tau + b_\tau\cdot x$; минимизирует $\sum \rho_\tau(y_i - \hat y_i)$	$\rho_\tau(u) = u\,(\tau - \mathbb{1}[u<0])$; τ = 0.1 / 0.5 / 0.9

Пояснения

- Huber, Theil-Sen, RANSAC — не новые формы кривой, а альтернативные способы оценки коэффициентов той же линейной модели, устойчивые к выбросам. Уравнение по-прежнему $y = a + b\cdot x$, но a и b посчитаны иначе, чем в обычном МНК (OLS).
- LOWESS — не даёт единого уравнения: локальная модель, результат — кривая (набор предсказаний в каждой точке), а не формула с фиксированными коэффициентами. В реализации используется `statsmodels` lowess с frac = 0.3; значения в точках x получаются линейной интерполяцией кривой.
- Квантильная регрессия — даёт разные a_τ, b_τ для τ = 0.1 / 0.5 / 0.9; на графике — веер из трёх линий. Метрики считаются отдельно для каждой τ (`compute_quantile_stats`, оценка через `statsmodels` QuantReg): на графике аппроксимаций и в таблице метрик выводятся строки для τ = 0.1, 0.5 и 0.9. Для τ = 0.1 и 0.9 R^2_fit может быть отрицательным — такие кривые оцениваются по Equation и Bias, а не по R^2. В общей таблице аппроксимаций (`compute_fit_stats`) учитывается только τ = 0.5.
- Для степенной и логарифмической аппроксимации область определения ограничена ($x > 0$, и для степенной также $y > 0$); значения вне домена не участвуют в подгонке коэффициентов, а при отрисовке кривой заменяются на NaN вместо падения графика.
- Метрики кривых аппроксимации (R^2_fit, RMSE, MSE, MAE, Bias, Std, Variance, MAPE %, уравнение) считаются по невязке Predicted − Actual = model(x) − y, то есть между предсказанием модели и фактическим эталонным значением PARAM_1 — отдельно от метрик базового QC-кросс-плота (Residual = y − x, см. выше).

Типы кросс-валидации (от худшего к лучшему)

Метод	Суть (как считается в коде)	Когда применять
Random K-Fold	`sklearn.KFold(shuffle=True)`. Скважины случайно перемешиваются и делятся на k равных частей (k = min(заданное k, n)). По очереди каждая часть — тест, обучение — на остальных k−1 частях.	НЕЛЬЗЯ как основной метод — даёт иллюзию точности (игнорирует пространственную корреляцию). Оставлен в сравнении как заведомо оптимистичная база для контраста с остальными схемами.
Random K-Fold (buffered)	Тот же случайный KFold с тем же сидом, то есть те же тестовые фолды, что и у Random K-Fold. Из обучения удаляются скважины, чьё расстояние до ближайшей тестовой скважины ≤ buffer.	Случайные фолды без утечки соседних скважин. Сравнение с обычным Random K-Fold показывает, насколько тот был завышен.
Leave-One-Well-Out (LOWO)	`sklearn.LeaveOneGroupOut` по `well_id`. Поочерёдно вся скважина целиком (все её строки/горизонты) исключается и становится тестом; обучение — на всех остальных скважинах.	Стандарт при малом числе скважин (<20–30).
Block CV	Площадь делится регулярной сеткой grid_n×grid_n по X_coord/Y_coord (линейные границы от min до max). Поочерёдно весь блок — тест, обучение — на скважинах вне блока. Блок пропускается, если в обучении остаётся меньше degree + 2 (3 при линейной модели) точек.	Для равномерной сетки скважин. Размер сетки рекомендуется автоматически по медианному расстоянию между скважинами.
Buffered CV	Как Block CV, но из обучения дополнительно убираются скважины, чьё минимальное расстояние до ближайшей тестовой точки блока ≤ buffer.	Снижает остаточную пространственную корреляцию на границе блока по сравнению с обычным Block CV.
Leave-P-Out	На каждом из repeats повторов случайно (без возврата) выбирается p_percent% скважин — тест, обучение — на остальных. Итоговый прогноз скважины — среднее по всем повторам, где она попадала в тест (preds_sum/preds_count).	Более жёсткая проверка устойчивости, чем k-fold — оценивает разброс качества при разном случайном составе тестовой выборки.
Spatial Leave-P-Out	На каждом из repeats повторов случайно выбирается скважина-центр; все скважины в радиусе ≤ radius от неё — тест, остальные — train. Прогноз усредняется по повторам так же, как в Leave-P-Out.	Максимально приближено к реальному сценарию прогноза новой необуренной области. Требует достаточного пространственного покрытия площади скважинами.

Метод	Суть (как считается в коде)	Когда применять
Stratified by Zone	`sklearn.LeaveOneGroupOut` по выбранной колонке зоны (по умолчанию `tectonic_zone`, если её нет — `horizon_id`; другую колонку можно выбрать в сайдбаре). Поочерёдно вся зона целиком — тест, обучение — на скважинах из остальных зон.	Лучший вариант для оценки переносимости модели на новую зону. Требует колонку с ≥2 уникальными значениями, иначе схема пропускается.
Distance-based exclusion CV	Для каждой скважины i по очереди: из обучения исключаются все скважины на расстоянии ≤ excl_radius от неё (excl_radius = медиана попарных расстояний между скважинами × variogram_factor), тест — только скважина i. Если в обучении остаётся меньше degree + 2 точек, фолд отмечается как пропущенный (прогноз NaN).	По сути — LOWO с пространственным буфером вокруг тестовой точки. См. пояснение ниже, как оценивается радиус.

Как устроена Distance-based exclusion CV. Схема не выполняет полноценную подгонку модели вариограммы (nugget/sill/range) — радиус пространственной корреляции оценивается упрощённо, как медианное попарное расстояние между скважинами (`median_pairwise_distance`), масштабируемое множителем `variogram_factor`. Для тестовой скважины из обучения исключаются все точки ближе этого радиуса. Переименование в Distance-based exclusion CV точнее отражает, что метод делает на самом деле — это практичная эвристика на расстояниях, а не геостатистическая вариограмма.

Автоматический подбор рекомендуемых параметров CV

Реализован в сайдбаре на основе числа скважин (n_wells) и медианного расстояния между ними (median_dist):

- k для Random K-Fold: 5 при n<20; 7 при n<50; 10 при n<150; иначе 12.
- Сетка N×N для Block/Buffered CV: 5×5 при median_dist<300 м; 4×4 при <600 м; 3×3 при <1000 м; иначе 2×2.
- Buffer (Buffered CV): 0.5 × median_dist.
- Число повторов (cv_repeats) для Leave-P-Out / Spatial Leave-P-Out: 100 при n<30; 50 при n<100; 30 при n<300; иначе 20.
- Радиус пространственного исключения (Spatial Leave-P-Out): ≈ median_dist.
- Множитель радиуса корреляции (Distance-based exclusion CV factor, `variogram_factor` в коде): слайдер 0.25–3.00, шаг 0.25, по умолчанию 1.0; значения: 0.5 — мягкая фильтрация; 1.0 — рекомендуемое значение; 1.5 — строгая; 2.0–3.0 — очень строгая, почти независимые скважины.

Все рекомендованные значения доступны для ручной корректировки через слайдеры в сайдбаре.

Выбор лучшей схемы CV

После расчёта всех схем автоматически определяется схема с наилучшим сочетанием точности и устойчивости:

score = RMSE + RMSE_fold_std → min

Критерий выбора задаётся в сайдбаре: RMSE + RMSE_fold_std (по умолчанию), RMSE, MAE, максимальный R^2 (Actual = Predicted), RMSE + |Bias| или вручную выбранная схема. Все схемы, включая Random K-Fold, участвуют в выборе.

Схема с минимальным score считается лучшей; для неё повторяется часть Шага 1 (кросс-плот Predicted vs Actual, аппроксимации, распределения, карта невязок, анализ выбросов).

Ход исследований

Загрузка данных

QC входных данных

- Полные дубликаты строк
- Дубликаты well_id (для нескольких горизонтов на одну скважину это ожидаемо; реальное дублирование — только при совпадении well_id и horizon_id)
- Совпадающие координаты скважин (X_coord, Y_coord) в пределах одного горизонта
- Пропуски по колонкам
- Строки, удалённые при очистке (с превью первых 20 строк)

Типы данных по колонкам

- Для каждой колонки: тип (Numeric / Date & Time / Boolean / String), pandas dtype, число непустых/пустых значений, число уникальных значений.
- Отдельно — список уникальных значений для каждой категориальной колонки (до 20 значений с указанием общего числа).

Статистика параметров PARAM_1, PARAM_2

- Полный набор статистик и их формулы — см. раздел «Статистика параметров (Шаг 0)» ниже.

Корреляционный анализ выбранных параметров

- Две матрицы корреляции для любого набора числовых колонок: Пирсона (только линейная связь) и Спирмена (любая монотонная связь — экспонента, логарифм, степенная) (не только PARAM_1/PARAM_2 — пользователь выбирает набор).
- Pairplot: Seaborn (статический, с KDE/histogram на диагонали) или Plotly (интерактивный scatter-matrix).
- Для Pairplot и для блока корреляционного анализа рекомендуется не более 10 параметров (предупреждение в интерфейсе). KDE и гистограммы на диагонали доступны только в Seaborn; Plotly даёт интерактивность и hover, но диагональ в ней не выводится.
- Статистика по каждому числовому параметру (кроме well_id; PARAM_1 и PARAM_2 показаны выше): таблица статистик, гистограмма с KDE, средним, медианой и ±3σ, boxplot. Число бинов и тип нормировки гистограммы задаются отдельно для каждого параметра.

Шаг 1: Базовый QC-кросс-плот

Классический QC cross-plot

- Ось X: PARAM_2 (сравниваемое значение).
- Ось Y: PARAM_1 (эталонное значение).
- Диагональ: линия идеального совпадения Y = X.
- Линия линейной регрессии (OLS, степень 1).

Метрики раздела «Метрики кросс-плота и обозначения» выше (R^2_lin, RMSE, MSE, MAE, Bias, Std, Variance, MAPE %, P-value, уравнение регрессии).

Кросс-плот с кривыми аппроксимации

- На тот же кросс-плот накладываются выбранные пользователем типы аппроксимации (из 17, см. раздел выше).
- Для каждой выбранной кривой — отдельная строка в сравнительной таблице метрик (R^2_fit = sklearn `r2_score`, см. предупреждение про два R^2 выше).

Распределения параметров PARAM_1 и PARAM_2

- Гистограммы с KDE, линиями Mean/Median/±3σ (опционально).
- Boxplot с линиями Mean/Median.
- Настраиваемое число бинов и тип нормализации гистограммы (none/density/probability/percent).

Распределение невязок Δ = PARAM_1 − PARAM_2

- График невязки от PARAM_1 — ищем тренд (признак ошибки скоростной модели), а не просто разброс.
- Расширенная таблица статистик невязок: Count, μ, median, mode, σ, variance, CV %, RMSE, min, Q05/Q25/Q75/Q95, max, range, IQR (+ границы), μ±3σ.
- Гистограмма и boxplot невязок.
- Карта невязок в плане (X_coord, Y_coord, цвет — величина невязки) — показывает зоны систематического смещения (качество сейсмики, тектонические осложнения, латеральные изменения скоростей), а не просто общую статистику.

Анализ выбросов по невязкам

Выбросы оцениваются четырьмя независимыми методами одновременно:

- Sigma rule: $\lvert\text{Residual}\rvert > \sigma_{thr}\cdot\sigma$ (порог σ_{thr}: 1.0–6.0, по умолчанию 2.0).
- IQR rule: за пределами $[Q1 - k\cdot IQR,\ Q3 + k\cdot IQR]$; k — слайдер 1.0–3.0, по умолчанию 1.5 (границы IQR при k = 1.5 выводятся в статистике невязок, Шаги 1–2).
- Modified Z-score rule: $\lvert 0.6745\,(x - \mathrm{median})/\mathrm{MAD}\rvert > 3.5$.
- Percentile rule: за пределами $[P_{low},\ P_{high}]$; P_{low} — 0–20%, по умолчанию 5%; P_{high} — 80–100%, по умолчанию 95%.

Шаг 2: Кросс-валидация

Запускаются все схемы CV из раздела «Типы кросс-валидации» (Stratified by Zone пропускается, если выбранная колонка зоны — по умолчанию `tectonic_zone`, иначе `horizon_id` — отсутствует или содержит меньше двух уникальных значений).

Для каждой схемы CV

- Cross-plot Predicted vs Actual.
- Метрики кросс-плота: R^2 (Pearson, Predicted vs Actual), RMSE, MSE, MAE, Bias, Std, Variance, MAPE %, P-value, уравнение регрессии. R^2 (Actual = Predicted) выводится в сравнительной таблице схем.
- Статистика по фолдам: rmse_fold_mean, median, min, max, std, range.

Сравнение схем

- Сводная таблица всех схем с метриками по фолдам.
- Bar chart RMSE по схемам CV.
- Bar chart среднего RMSE по фолдам (rmse_fold_mean) по схемам CV.
- Boxplot разброса RMSE по фолдам для каждой схемы: медиана — сплошная линия, среднее — пунктир, выбросы — точки. Порядок схем совпадает с таблицей.
- Автоматический выбор лучшей схемы по выбранному критерию (см. раздел «Выбор лучшей схемы CV»).
- Таблицы фолдов для каждой схемы: номер фолда, n_train, n_test, RMSE, MAE, Bias. Пропущенные фолды (n_train < degree + 2) показаны строками с n = 0 и пустыми метриками и не попадают на боксплот.
- Сравнительная таблица содержит n_pred (число точек с прогнозом); если схемы покрывают разное число точек, выводится предупреждение.
- Сид случайных схем по умолчанию 42 и меняется кнопками в сайдбаре; влияет на Random K-Fold, Random K-Fold (buffered), Leave-P-Out и Spatial Leave-P-Out.

Детальный разбор лучшей схемы (повтор части Шага 1)

- Cross-plot Predicted vs Actual для лучшей модели + кривые аппроксимации.
- Метрики cross-plot и сравнение аппроксимаций.

- Распределение CV-невязок (Residual = PARAM_1 − Predicted): график от PARAM_1, таблица статистик, гистограмма, boxplot.
- Анализ выбросов CV-невязок — теми же 4 методами, что и в Шаге 1.

Важно: при исключении скважины из фолда пересчитываются коэффициенты модели; значения PARAM_2 остаются неизменными — фиксированные входные данные, извлечённые один раз (например, из структурной карты).

Шаг 3: Диагностика по категориям

Работает для любой категориальной колонки датасета (не только tectonic_zone) — пользователь выбирает, по какой колонке анализировать.

- Круговая и столбчатая диаграммы количества скважин по категориям.
- Статистика PARAM_1 и PARAM_2 по каждой категории (в раскрывающихся блоках).
- Boxplot распределения PARAM_1 и PARAM_2 по категориям.
- Наложенные гистограммы по категориям для PARAM_1 и PARAM_2: каждая категория — своим цветом, полупрозрачно.
- Общий кросс-плот по всем категориям сразу (с индивидуальными цветами точек/линий на категорию) + отдельно по выбранному подмножеству категорий.
- Кросс-плот и аппроксимации отдельно для каждой категории.
- Сравнительная таблица метрик аппроксимаций по категориям.

Шаг 4: Фильтрация скважин

Реализовано (не только запланировано). Четыре режима:

- Без фильтра.
- Ручное исключение: мультиселект конкретных well_id.
- Случайное исключение (%): слайдер 0–95%, кнопка «Новый набор» для пересэмплирования (фиксированный seed сохраняется в session_state до нажатия кнопки).
- Выделение кликом по точкам на cross-plot: клик по точке (Shift+клик — несколько), рамка (Box) или лассо (Lasso); режимы переключаются иконками в правом верхнем углу графика. Выбранные точки фиксируются кнопкой «Применить исключение», «Сбросить всё» очищает выбор. В сводке показывается строка «Исключено кликом».

После фильтрации пересчитываются: QC cross-plot, аппроксимации, полная таблица метрик, сравнение «до / после фильтрации» (n скважин, R^2_lin и R^2_fit для выбранных кривых, RMSE, MSE, MAE, Bias, Std, Variance, MAPE %).

Шаг 4.5 — серия случайного исключения: уровни от 5% до 95% с шагом 5%, на каждом уровне — заданное в сайдбаре число наборов (50–2000, по умолчанию 500). Для каждого набора считается R^2 (Pearson): in-sample — по оставшимся скважинам и out-of-sample — линия по оставшимся, R^2 по исключённым. Показываются распределения обоих значений по уровням.

Это позволяет оценивать устойчивость модели к сокращению числа скважин и влияние отдельных наблюдений/их групп на качество зависимости.

Важные нюансы для сейсмики

Пространственная зависимость

- Если скважины кластеризованы (например, куст на одной структуре), обычный LOWO даёт слишком оптимистичную оценку — соседняя скважина «утекает» информацию.
- Лучше — Block/Buffered/Spatial CV: исключать не одну скважину, а группу скважин в радиусе корреляции (аналог GroupKFold по пространственным кластерам).

Размер выборки

- Скважин мало (<15–20): LOWO практически безальтернативен.
- Скважин больше 30–50: можно k-fold (5–10 фолдов), но желательно с равномерным пространственным покрытием в каждом фолде, иначе один фолд может остаться без скважин на краю площади (для этого в проекте есть Block/Buffered CV).

Важно: разбивать по скважинам, а не по отдельным точкам одной скважины — иначе модель «подглядывает» в соседние точки того же профиля/куста.

Известные ограничения и статус реализации

- R^2_lin и R^2_fit — два разных по смыслу R^2 в разных частях таблиц метрик, разведены по названию — см. предупреждение в разделе «Метрики кросс-плота и обозначения».
- Distance-based exclusion CV (ранее Variogram-Aware CV) — упрощённая эвристика на расстояниях, не полноценная geostatistics-вариограмма — см. пояснение в разделе «Типы кросс-валидации».
- Известная проблема (не исправлено): Random K-Fold участвует в автоматическом выборе лучшей схемы по score = RMSE + RMSE_fold_std. Оптимистичная схема может быть выбрана «лучшей»; в текущей версии этот выбор не исключает её.
- Известная проблема (не исправлено): при выборе нескольких горизонтов Random K-Fold, Random K-Fold (buffered), Leave-P-Out и Spatial Leave-P-Out разбивают записи «скважина — горизонт», а не скважины целиком, поэтому одна скважина может попасть одновременно в обучение и в тест. Для строгой оценки используйте один горизонт или схемы LOWO, Block CV, Buffered CV.
- Известная ошибка (не исправлено): при случайном исключении процент считается от числа строк (скважина × горизонт), а исключаются скважины; при нескольких горизонтах может быть запрошено больше скважин, чем есть, и расчёт завершится ошибкой.
- Исправлено: степенная и логарифмическая аппроксимации могли давать NaN/падать при отрисовке кривой на участке $x \le 0$ — добавлено ограничение домена (`x_line_safe`) в коде отрисовки (`app_utils`).

- Добавлено кэширование (`@st.cache_data`) для `sq.run_all_cv` — кросс-валидация (включая Leave-P-Out/Spatial Leave-P-Out с десятками повторов) больше не пересчитывается при каждом взаимодействии с сайдбаром (например, смене цвета точек), а только при изменении данных или параметров CV.
- Реализован двуязычный интерфейс RU/EN (переключатель Language в сайдбаре; тексты в `translations_full` , примеры в `ui_examples_full_ru` и `ui_examples_full_en`). Планируется: разбиение `app_full.py` (~4900 строк) на модули (sidebar / step1–step4 / plotting).

Практическая схема пайплайна

- Сбор данных: well_id, X_coord, Y_coord, PARAM_1, PARAM_2, horizon_id, tectonic_zone (опционально).
- Базовый анализ: глобальные RMSE/MAE/Bias, общий cross-plot, карта невязок (Шаг 0–1).
- K-fold CV по скважинам: разбить на k фолдов, перестроить модель без тестового фолда, посчитать ошибки, свести в таблицу.
- LOWO / Block / Buffered / Spatial Leave-P-Out / Distance-based exclusion / Stratified by Zone CV — полный набор схем для оценки устойчивости (Шаг 2).
- Диагностика по категориям — выявление зон систематических ошибок (Шаг 3).
- Фильтрация и стресс-тест выборки — оценка устойчивости к сокращению числа скважин (Шаг 4).
- Интерпретация: сравнить ошибки разных схем CV, выделить зоны/горизонты систематических ошибок, использовать для доработки глубинного преобразования, скоростной модели, интерпретации разломов.

Содержание:

- Загрузка данных
- Шаг 1: Базовый QC-кросс-плот
- Шаг 2: Кросс-валидация
- Шаг 3: Диагностика по категориям
- Шаг 4: Фильтрация скважин
- Выводы

Выполнение проекта

In [1]:
```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import matplotlib as mpl

import structural_qc_full as sq

mpl.rcParams.update({
    "figure.facecolor": "white",
    "axes.facecolor": "white",
    "axes.edgecolor": "#333333",
    "axes.grid": True,
    "grid.color": "#E5E5E5",
    "font.size": 11,
})
RED, BLUE = "#C23A22", "#2F5FA8"
```

Загрузка данных

Ожидаемый формат файла: `well_id, X, Y, Z_well, Z_map` , опционально `horizon_id` , `tectonic_zone` , `quality_flag` .

Движок работает с именами колонок `well_id, X_coord, Y_coord, Zprm_well, Zprm_map` , поэтому при загрузке колонки переименовываются. Очистка повторяет логику приложения: мусорные значения («NA», «NULL», «—», «?») → NaN, запятая → точка, удаление строк с пропусками в обязательных колонках.

In [2]:
```
RAW = r"data/structural_wells_100_linear.csv"
REQUIRED = ["well_id", "X_coord", "Y_coord", "Zprm_well", "Zprm_map"]

raw = pd.read_csv(RAW, na_values=["NA", "NULL", "—", "?", ""], dtype=str)
raw.columns = raw.columns.str.strip()
df = raw.rename(columns={"X": "X_coord", "Y": "Y_coord",
                         "Z_well": "Zprm_well", "Z_map": "Zprm_map"})

for c in ["X_coord", "Y_coord", "Zprm_well", "Zprm_map"]:
    df[c] = pd.to_numeric(df[c].str.replace(",", ".", regex=False), errors="coerce")
for c in [c for c in ["T_well", "T_map"] if c in df.columns]:
    df[c] = pd.to_numeric(df[c].str.replace(",", ".", regex=False), errors="coerce")

n_before = len(df)
df = df.dropna(subset=REQUIRED).reset_index(drop=True)
print(f"n = {len(df)} строк, удалено при очистке: {n_before - len(df)}")
df.head()
```

```
n = 200 строк, удалено при очистке: 0
```

Out[2]:

	well_id	X_coord	Y_coord	Zprm_well	Zprm_map	horizon_id	tectonic_zone	well_category	reservoir_flag	fluid_type	T_well	T_map
0	W-001	7501.1	9671.5	2319.03	2304.07	Top_Reservoir	Central_Graben	production	non_reservoir	non_reservoir	1713.24	1791.03
1	W-001	7501.1	9671.5	2260.24	2241.90	Top_Seal	Central_Graben	production	non_reservoir	non_reservoir	1669.81	1742.84
2	W-002	10766.6	6577.6	2485.68	2463.86	Top_Reservoir	South_Block	production	reservoir	water	1768.15	1781.45
3	W-002	10766.6	6577.6	2449.96	2428.13	Top_Seal	South_Block	production	reservoir	water	1742.74	1757.54
4	W-003	9308.2	4282.2	2538.94	2555.91	Top_Reservoir	South_Block	production	reservoir	water	1866.42	1821.17

QC входных данных и статистика (Шаг 0)

In [3]:
```
print("Полных дублей строк:", df.duplicated().sum())
print("Строк с повторяющимся well_id:", df["well_id"].duplicated(keep=False).sum())
key = ["well_id"] + (["horizon_id"] if "horizon_id" in df.columns else [])
print("Реальных дублей (" + " + ".join(key) + "):", df.duplicated(subset=key).sum())
print("Уникальных скважин:", df["well_id"].nunique())
```

```
Полных дублей строк: 0
Строк с повторяющимся well_id: 200
Реальных дублей (well_id + horizon_id): 0
Уникальных скважин: 100
```

In [4]:
```
if "quality_flag" in df.columns:
    print(df["quality_flag"].value_counts(dropna=False))
df.groupby("tectonic_zone")["Zprm_well"].agg(["count", "mean", "std"]).round(1)
```

Out[4]:

tectonic_zone	count	mean	std
Central_Graben	76	2394.3	68.5
North_Block	72	2296.7	71.5
South_Block	52	2470.5	60.0

In [5]:
```
rows = []
for c in df.columns:
    s = df[c]
    if pd.api.types.is_bool_dtype(s):
        t = "Boolean"
    elif pd.api.types.is_numeric_dtype(s):
        t = "Numeric"
    elif pd.api.types.is_datetime64_any_dtype(s):
        t = "Date & Time"
    else:
        t = "String"
    rows.append({"колонка": c, "тип": t, "dtype": str(s.dtype), "непустых": int(s.notna().sum()),
                 "пустых": int(s.isna().sum()), "уникальных": int(s.nunique())})
display(pd.DataFrame(rows))

for c in df.select_dtypes(exclude="number").columns:
    vals = df[c].dropna().unique()
    print(f"{c} — {len(vals)} значений: {list(vals[:20])}")
```

	колонка	тип	dtype	непустых	пустых	уникальных
0	well_id	String	object	200	0	100
1	X_coord	Numeric	float64	200	0	100
2	Y_coord	Numeric	float64	200	0	100
3	Zprm_well	Numeric	float64	200	0	200
4	Zprm_map	Numeric	float64	200	0	199
5	horizon_id	String	object	200	0	2
6	tectonic_zone	String	object	200	0	3
7	well_category	String	object	200	0	3
8	reservoir_flag	String	object	200	0	2
9	fluid_type	String	object	200	0	4
10	T_well	Numeric	float64	200	0	200
11	T_map	Numeric	float64	200	0	200

```
well_id — 100 значений: ['W-001', 'W-002', 'W-003', 'W-004', 'W-005', 'W-006', 'W-007', 'W-008', 'W-009', 'W-010', 'W-011', 'W-012', 'W-01
3', 'W-014', 'W-015', 'W-016', 'W-017', 'W-018', 'W-019', 'W-020']
horizon_id — 2 значений: ['Top_Reservoir', 'Top_Seal']
tectonic_zone — 3 значений: ['Central_Graben', 'South_Block', 'North_Block']
well_category — 3 значений: ['production', 'exploration', 'appraisal']
reservoir_flag — 2 значений: ['non_reservoir', 'reservoir']
fluid_type — 4 значений: ['non_reservoir', 'water', 'gas', 'oil']
```

In [6]:
```
def param_stats(s):
    s = pd.Series(s).dropna().astype(float)
    mu, sd = s.mean(), s.std(ddof=1)
```

```
    q05, q25, q50, q75, q95 = s.quantile([0.05, 0.25, 0.5, 0.75, 0.95])
    iqr = q75 - q25
    mode = s.round(2).mode()
    return {
        "Count": len(s), "μ (mean)": mu, "median": q50,
        "mode": mode.iloc[0] if len(mode) else np.nan,
        "σ (std)": sd, "variance": sd ** 2, "CV, %": sd / mu * 100,
        "min": s.min(), "Q05": q05, "Q25": q25, "Q75": q75, "Q95": q95, "max": s.max(),
        "range": s.max() - s.min(), "IQR": iqr,
        "IQR lower bound": q25 - 1.5 * iqr, "IQR upper bound": q75 + 1.5 * iqr,
    }

pd.DataFrame({"Z_well (PARAM_1)": param_stats(df["Zprm_well"]),
              "Z_map (PARAM_2)": param_stats(df["Zprm_map"])}).round(2)
```

Out[6]:

	Z_well (PARAM_1)	Z_map (PARAM_2)
Count	200.00	200.00
μ (mean)	2379.01	2372.47
median	2383.47	2363.07
mode	2187.35	2361.29
σ (std)	96.17	101.29
variance	9248.74	10259.88
CV, %	4.04	4.27
min	2187.35	2176.58
Q05	2216.59	2214.66
Q25	2304.45	2285.76
Q75	2457.67	2452.31
Q95	2536.23	2546.34
max	2571.26	2618.79
range	383.91	442.21
IQR	153.22	166.55
IQR lower bound	2074.63	2035.95
IQR upper bound	2687.49	2702.13

In [7]:
```
corr_cols = ["Zprm_well", "Zprm_map", "X_coord", "Y_coord"]
print("Пирсон (только линейная связь):")
display(df[corr_cols].corr(method="pearson").round(2))
print("\nСпирмен (любая монотонная связь):")
display(df[corr_cols].corr(method="spearman").round(2))
```

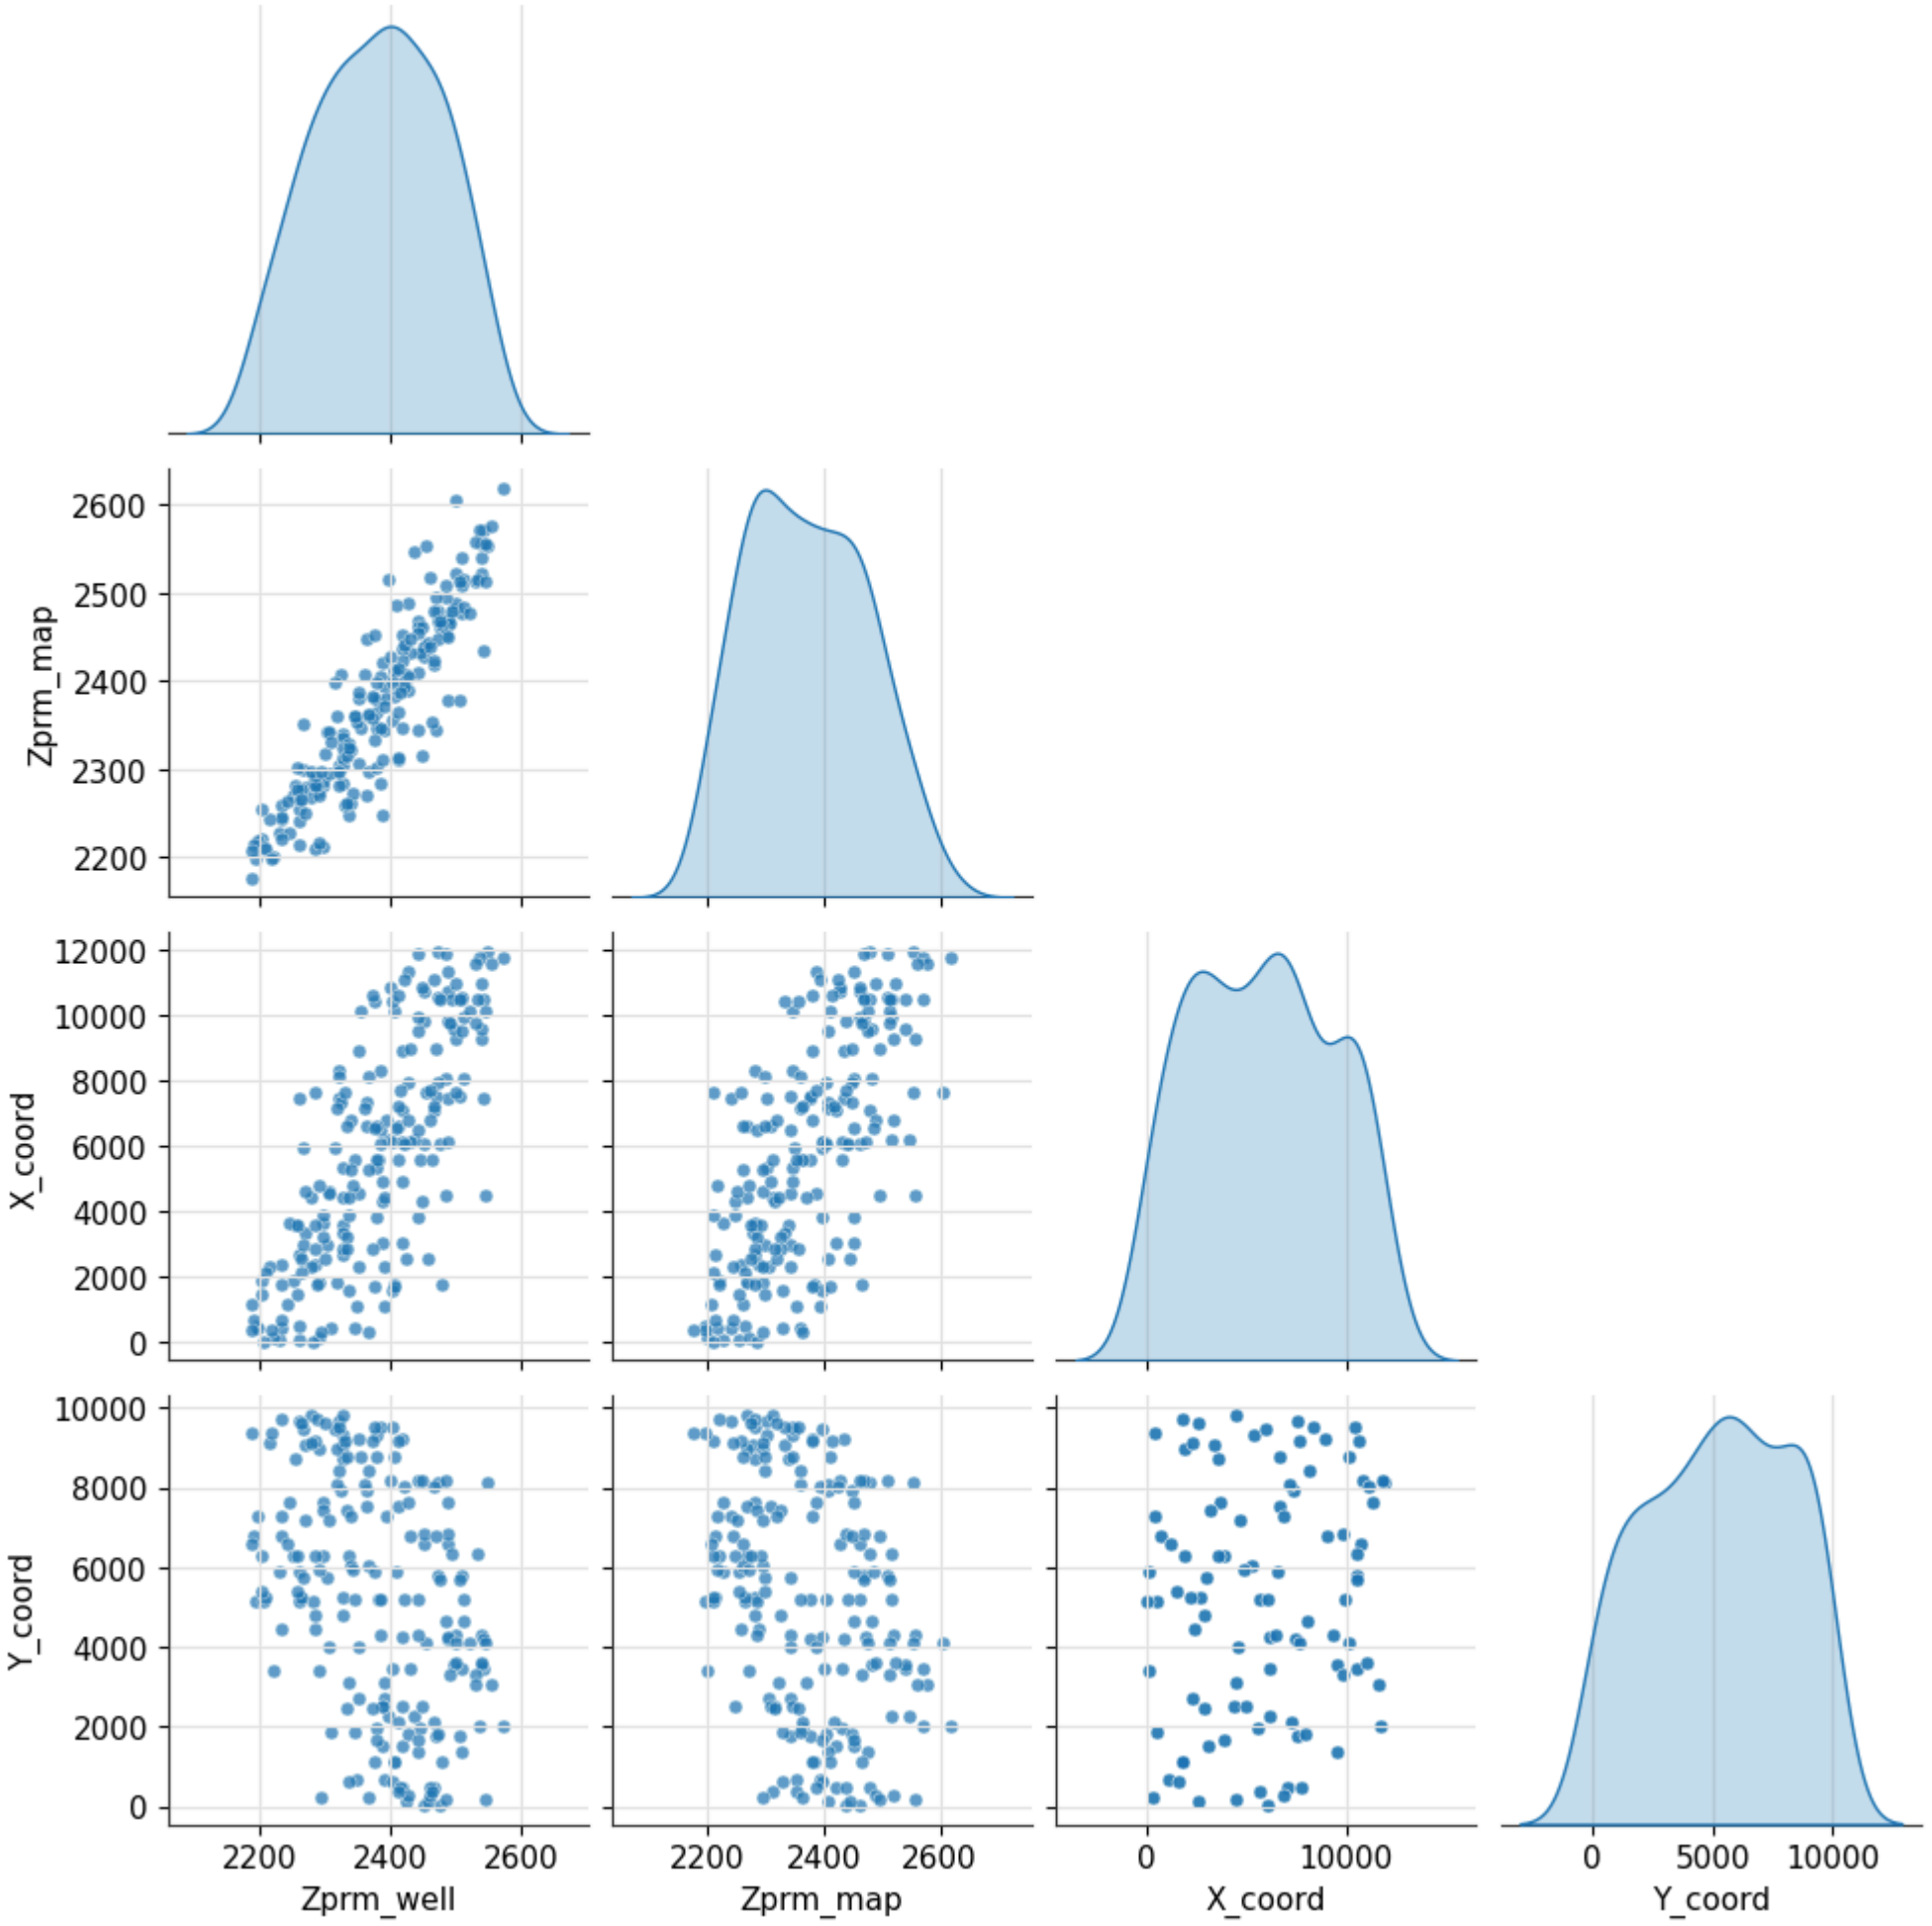
```
Пирсон (только линейная связь):
```

	Zprm_well	Zprm_map	X_coord	Y_coord
Zprm_well	1.00	0.90	0.75	-0.41
Zprm_map	0.90	1.00	0.69	-0.36
X_coord	0.75	0.69	1.00	0.13
Y_coord	-0.41	-0.36	0.13	1.00

```
Спирмен (любая монотонная связь):
```

	Zprm_well	Zprm_map	X_coord	Y_coord
Zprm_well	1.00	0.90	0.73	-0.42
Zprm_map	0.90	1.00	0.68	-0.37
X_coord	0.73	0.68	1.00	0.13
Y_coord	-0.42	-0.37	0.13	1.00

In [8]:
```
try:
    import seaborn as sns
    g = sns.pairplot(df[["Zprm_well", "Zprm_map", "X_coord", "Y_coord"]],
                     diag_kind="kde", corner=True, plot_kws={"s": 25, "alpha": .7})
    plt.show()
except ImportError:
    print("seaborn не установлен — pairplot пропущен (в приложении доступны Seaborn и Plotly)")
```



In [9]:
```python
from scipy.stats import gaussian_kde

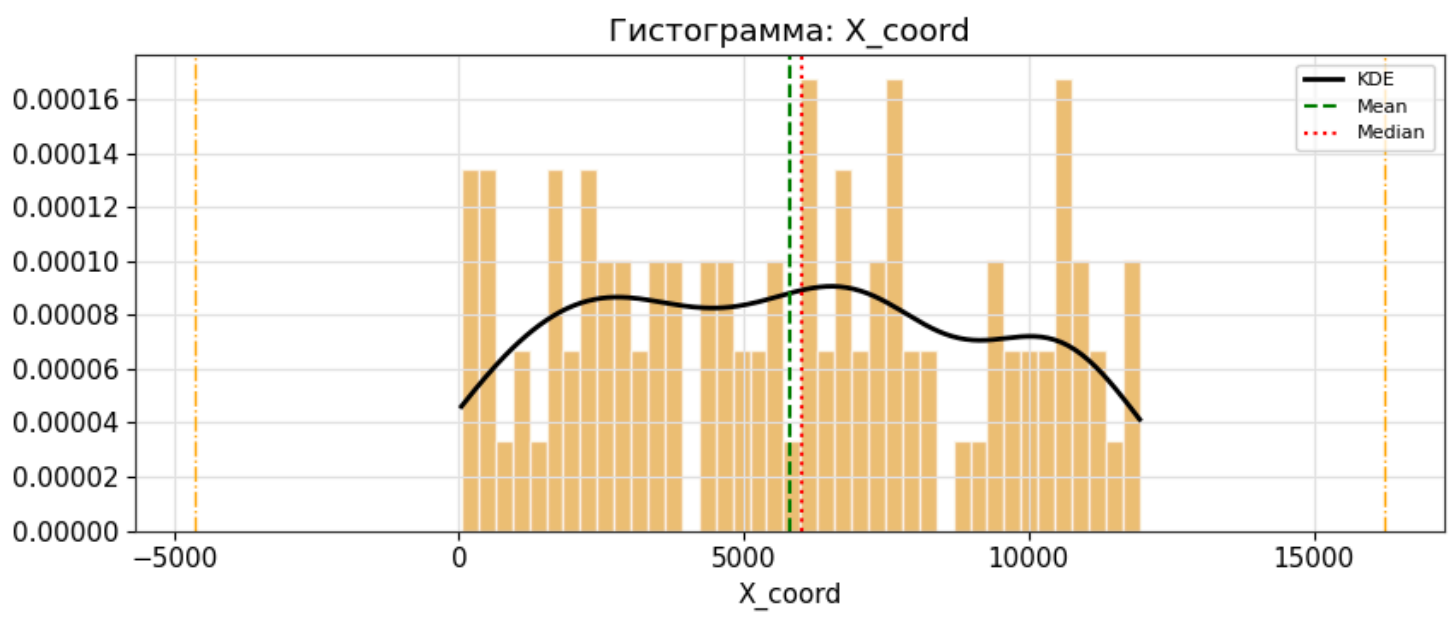
# Все числовые колонки, кроме well_id и Zprm_* (их статистика выведена выше)
num_cols = [c for c in df.select_dtypes(include="number").columns
            if c not in ("well_id", "Zprm_well", "Zprm_map")]

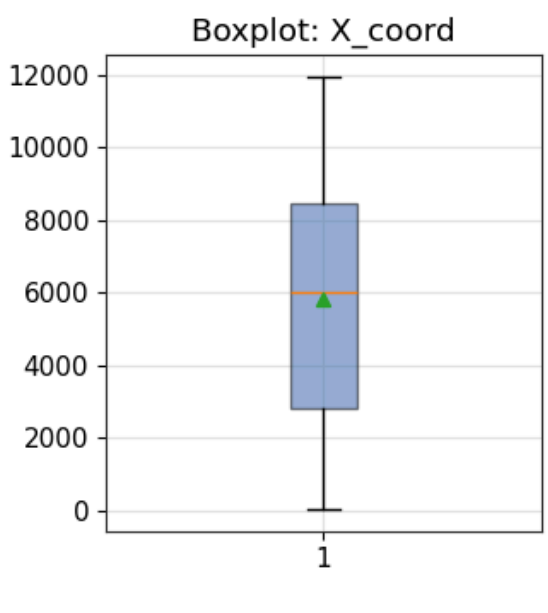
for col in num_cols:
    vals = df[col].to_numpy(float)
    vals = vals[np.isfinite(vals)]

    fig, (ax_h, ax_b) = plt.subplots(1, 2, figsize=(12, 3.8),
                                     gridspec_kw={"width_ratios": [3, 1]})
    ax_h.hist(vals, bins=40, density=True, color="#E8A33D", alpha=.7, edgecolor="white")
    if len(np.unique(vals)) > 1:
        xs = np.linspace(vals.min(), vals.max(), 200)
        ax_h.plot(xs, gaussian_kde(vals)(xs), color="black", lw=2, label="KDE")
    m, md, sd = vals.mean(), np.median(vals), vals.std(ddof=1)
    ax_h.axvline(m, color="green", ls="--", label="Mean")
    ax_h.axvline(md, color="red", ls=":", label="Median")
    for k in (-3, 3):
        ax_h.axvline(m + k * sd, color="orange", ls="-.", lw=1)
    ax_h.set_title(f"Гистограмма: {col}")
    ax_h.set_xlabel(col)
    ax_h.legend(fontsize=8)

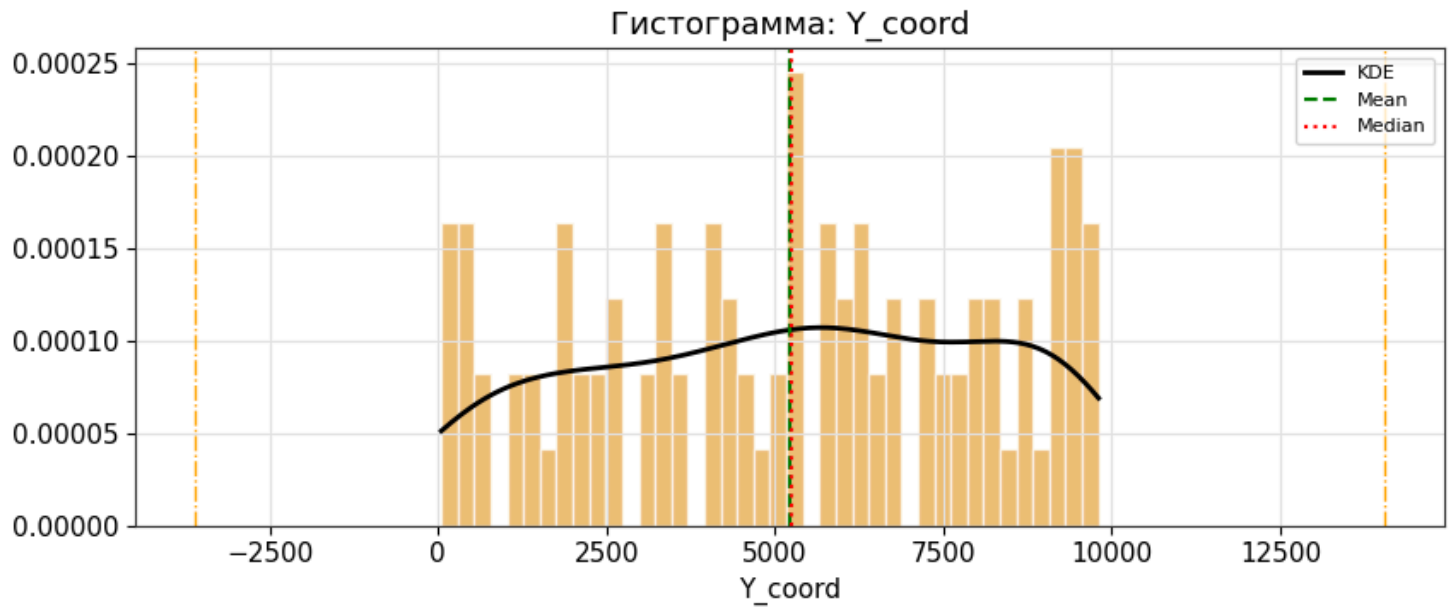
    ax_b.boxplot(vals, showmeans=True, patch_artist=True, boxprops=dict(facecolor=BLUE, alpha=.5))
    ax_b.set_title(f"Boxplot: {col}")

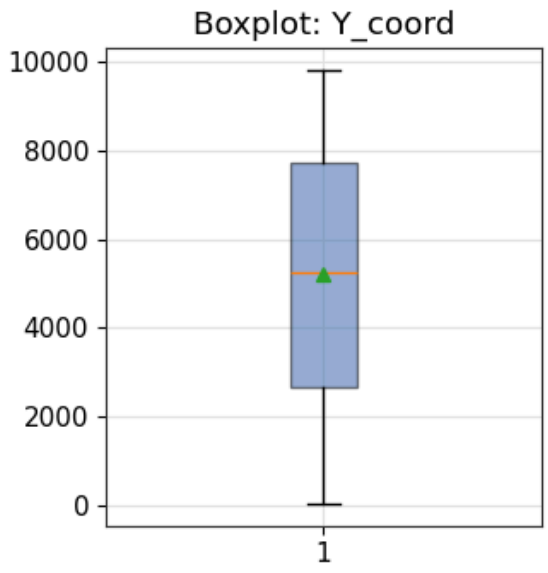
    plt.tight_layout(); plt.show()
    display(pd.DataFrame({col: param_stats(vals)}).round(2))
```



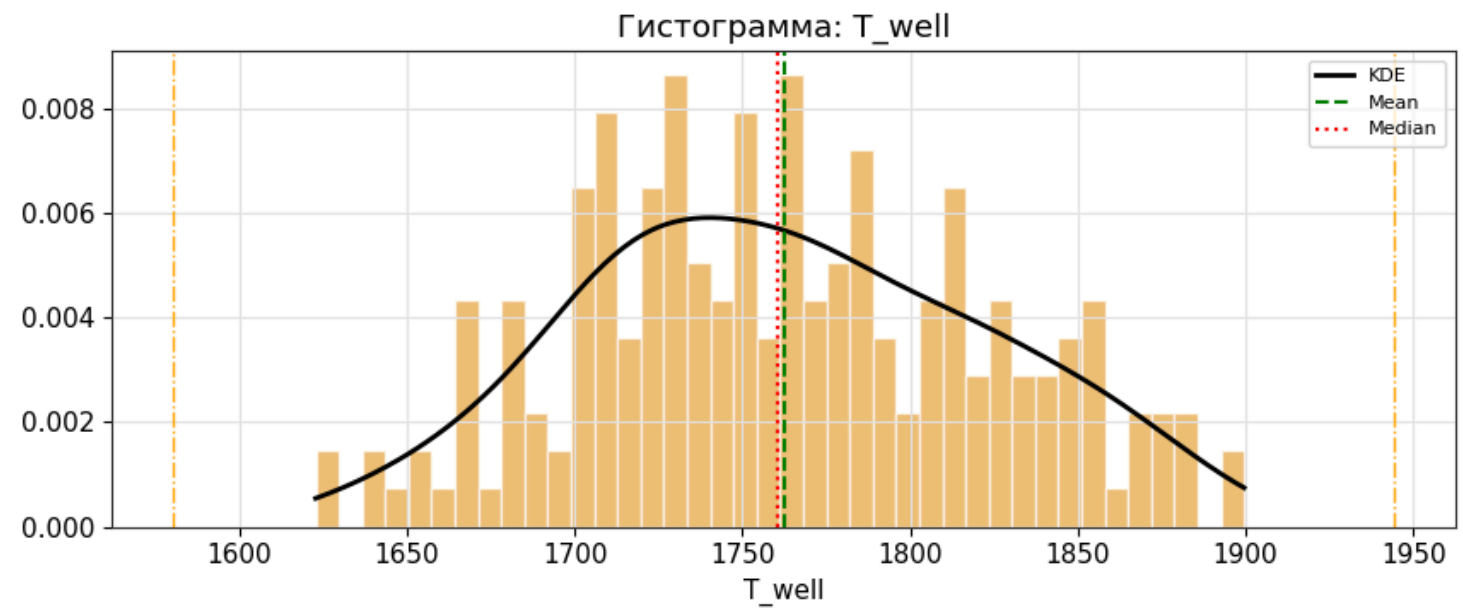


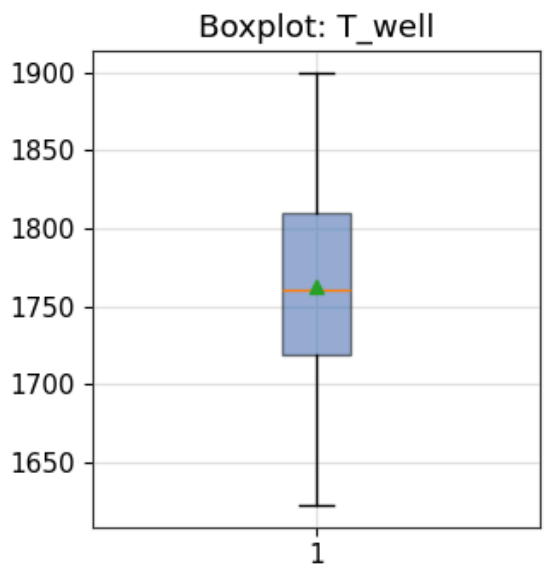
	X_coord
Count	200.00
μ (mean)	5806.58
median	6008.55
mode	44.80
σ (std)	3476.71
variance	12087541.31
CV, %	59.88
min	44.80
Q05	425.00
Q25	2831.05
Q75	8453.62
Q95	11145.12
max	11946.00
range	11901.20
IQR	5622.58
IQR lower bound	-5602.81
IQR upper bound	16887.49



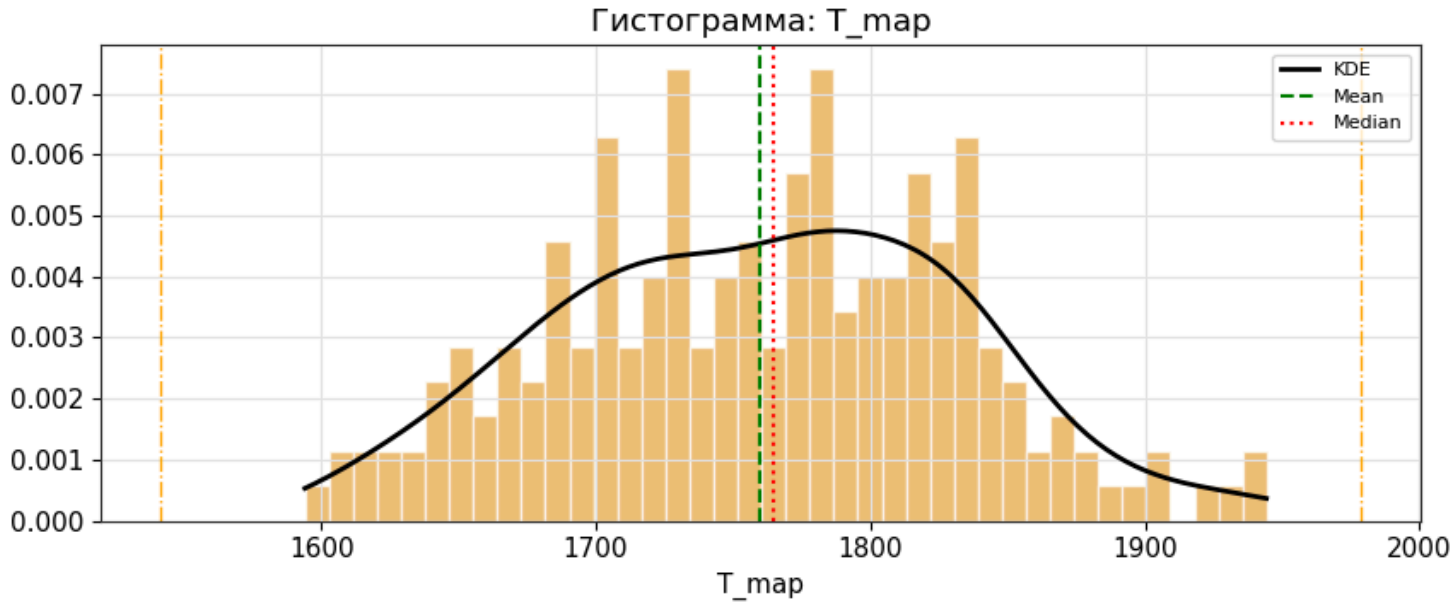


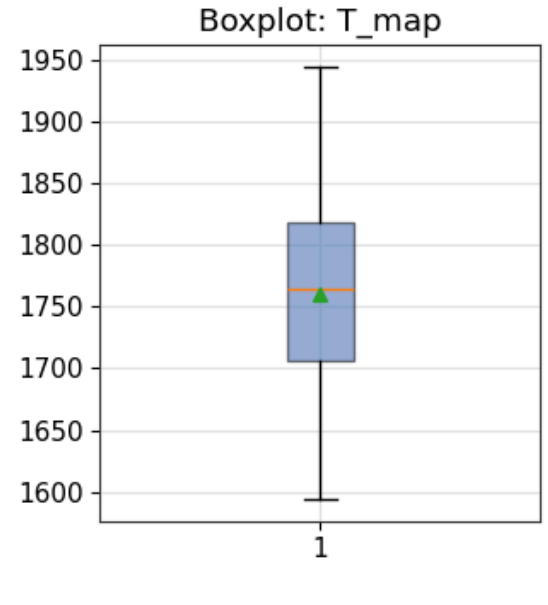
	Y_coord
Count	200.00
μ (mean)	5220.19
median	5235.20
mode	51.80
σ (std)	2940.27
variance	8645198.26
CV, %	56.32
min	51.80
Q05	385.55
Q25	2668.32
Q75	7721.92
Q95	9509.95
max	9803.90
range	9752.10
IQR	5053.60
IQR lower bound	-4912.08
IQR upper bound	15302.32





	T_well
Count	200.00
μ (mean)	1762.34
median	1760.30
mode	1622.88
σ (std)	60.66
variance	3679.24
CV, %	3.44
min	1622.88
Q05	1667.30
Q25	1719.27
Q75	1809.42
Q95	1866.46
max	1899.55
range	276.67
IQR	90.15
IQR lower bound	1584.04
IQR upper bound	1944.65





	T_map
Count	200.00
μ (mean)	1760.05
median	1764.85
mode	1594.11
σ (std)	72.79
variance	5299.06
CV, %	4.14
min	1594.11
Q05	1642.49
Q25	1705.67
Q75	1817.86
Q95	1870.48
max	1944.29
range	350.18
IQR	112.20
IQR lower bound	1537.37
IQR upper bound	1986.16

*** к содержанию**

Шаг 1: **Базовый QC-кросс-плот**

Z_well (эталон) против Z_map (сравниваемое значение). Невязка: `Δ = Z_well − Z_map`. Положительная Δ — карта занижает глубину, отрицательная — завышает.

In [10]:
```
basic = sq.basic_crossplot_stats(df)
print(f"R²_lin  = {basic.r2:.3f}")
print(f"slope   = {basic.slope:.3f}   intercept = {basic.intercept:+.2f} м")
print(f"p-value = {basic.p_value:.2e}")
print(f"RMSE    = {basic.rmse:.2f} м")
print(f"MAE     = {basic.mae:.2f} м")
print(f"Bias    = {basic.bias:+.2f} м")
print(f"Std     = {basic.std:.2f} м")
print(f"MAPE    = {basic.mape_pct:.2f} %")
```

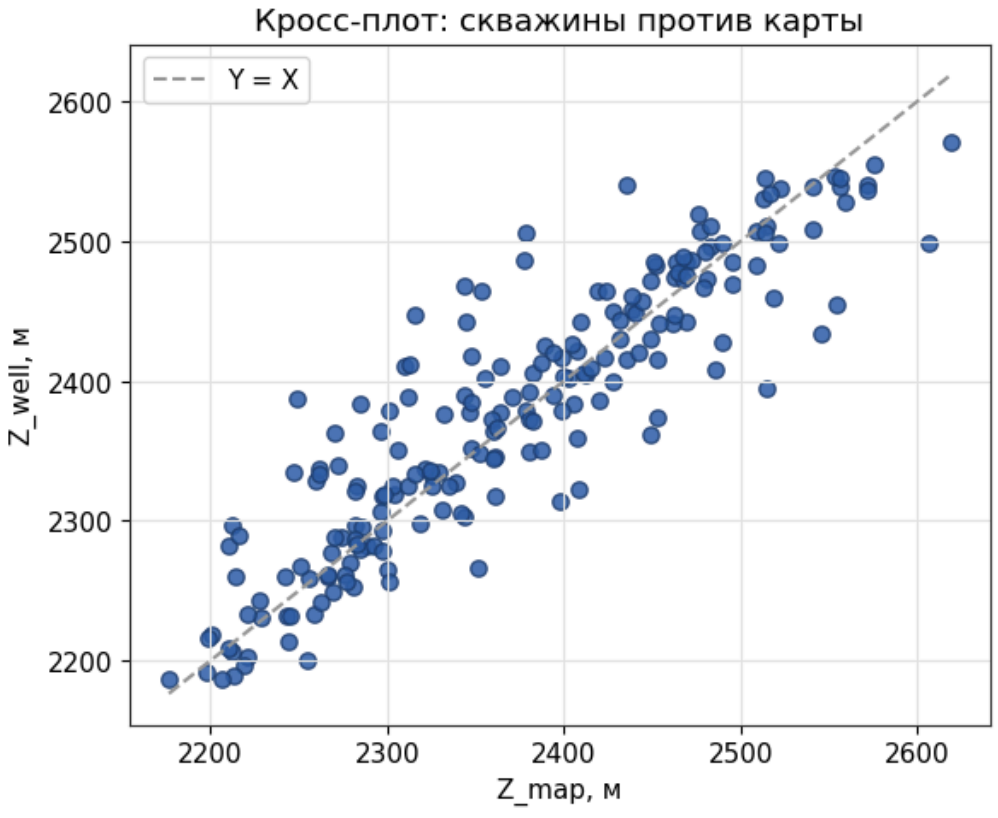
```
R²_lin  = 0.810
slope   = 0.855   intercept = +351.61 м
p-value = 2.36e-73
RMSE    = 44.79 м
MAE     = 32.08 м
Bias    = +6.54 м
Std     = 44.42 м
MAPE    = 1.34 %
```

In [11]:
```
fig, axes = plt.subplots(1, 2, figsize=(12, 5))

lo = df[["Zprm_well", "Zprm_map"]].min().min()
hi = df[["Zprm_well", "Zprm_map"]].max().max()
axes[0].plot([lo, hi], [lo, hi], "--", color="#999", label="Y = X")
axes[0].scatter(df["Zprm_map"], df["Zprm_well"], c=BLUE, edgecolor="#1F3F70", s=45, alpha=.85)
axes[0].set_xlabel("Z_map, м"); axes[0].set_ylabel("Z_well, м")
axes[0].set_title("Кросс-плот: скважины против карты")
axes[0].legend()
```

```
axes[1].axhline(0, ls=":", color="#999")
axes[1].scatter(df["Zprm_well"], basic.residuals, c=RED, s=45, alpha=.85)
axes[1].set_xlabel("Z_well, м"); axes[1].set_ylabel("Δ = Z_well − Z_map, м")
axes[1].set_title("Невязка от глубины (проверка на тренд)")

plt.tight_layout()
plt.show()
```

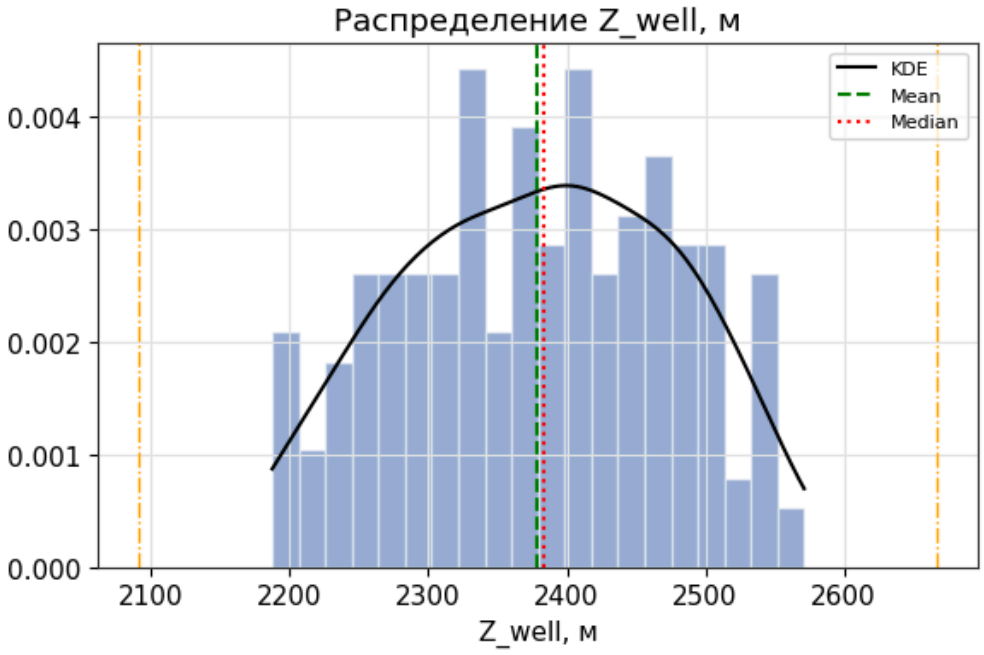


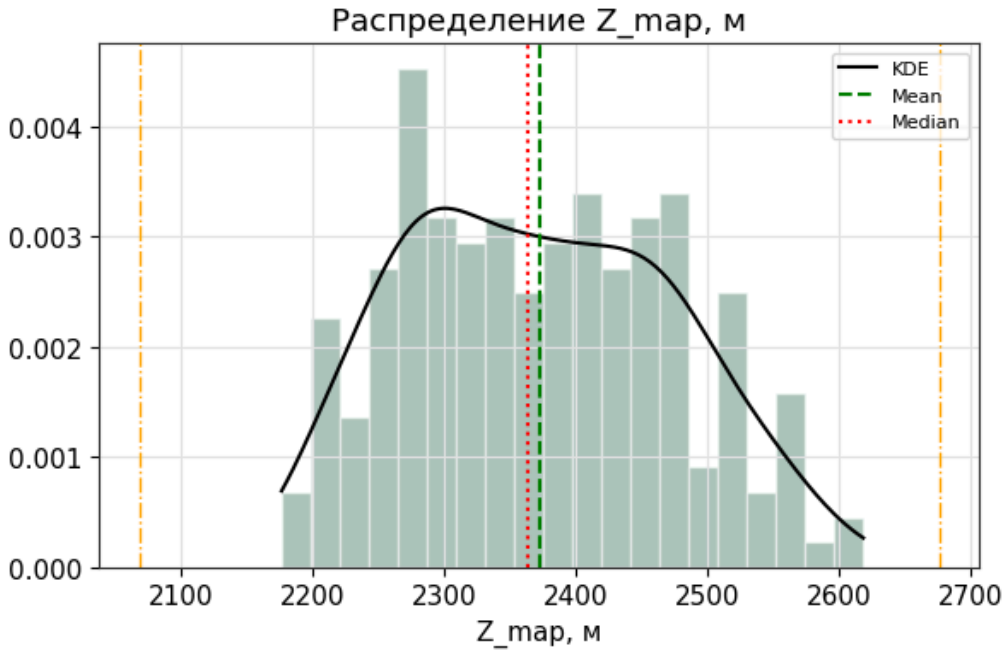


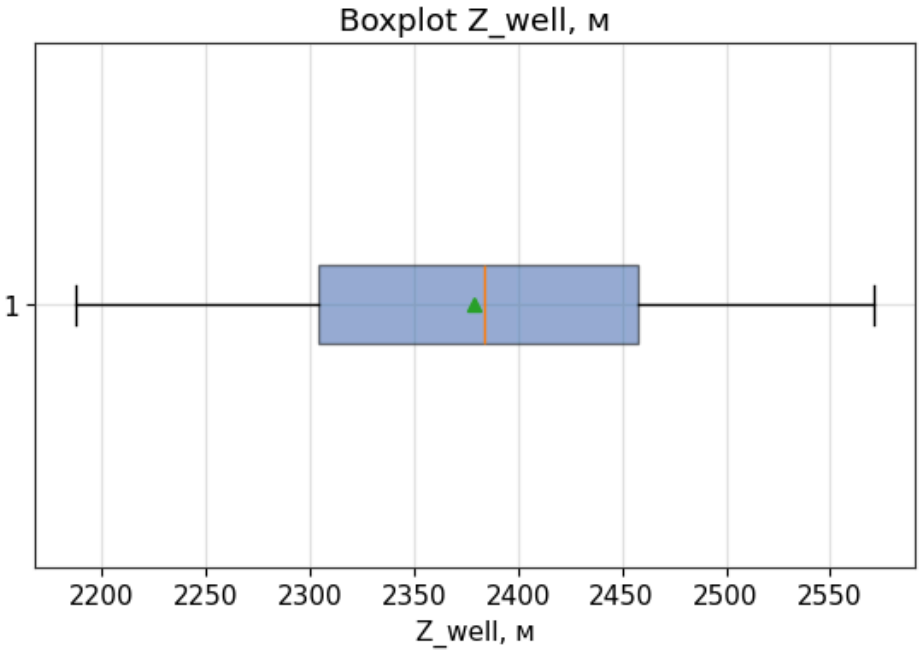
Наблюдение: если невязка растёт с глубиной — это признак ошибки скоростной модели при глубинном преобразовании, а не случайного шума. Это стоит проверить отдельно от общего RMSE.

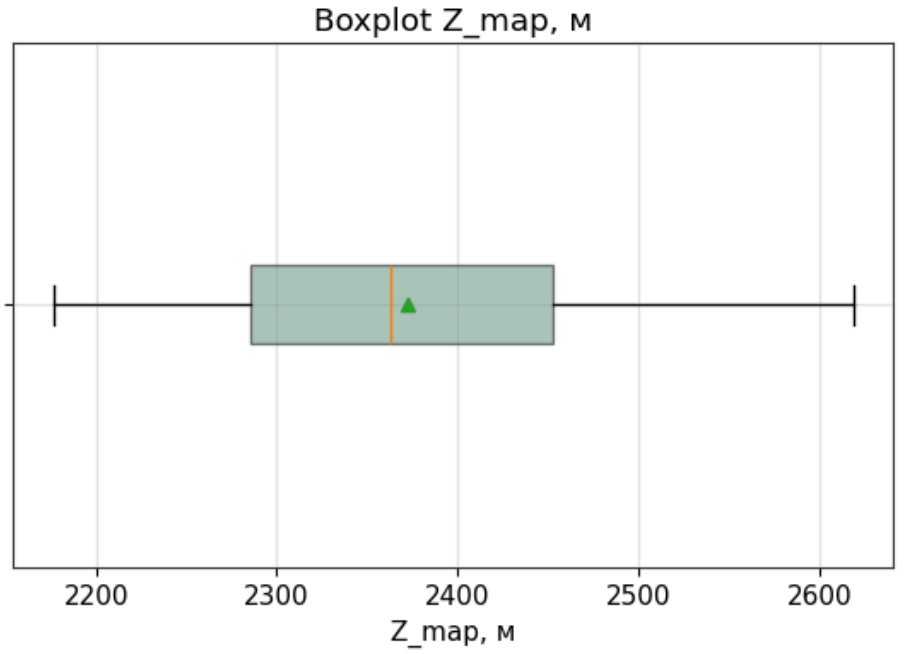
In [12]:
```
from scipy.stats import gaussian_kde

fig, axes = plt.subplots(2, 2, figsize=(12, 8))
for j, (col, label, colr) in enumerate([("Zprm_well", "Z_well, м", BLUE),
                                        ("Zprm_map", "Z_map, м", "#5C8A7A")]):
    s = df[col].to_numpy(float)
    ax = axes[0, j]
    ax.hist(s, bins=20, density=True, color=colr, alpha=.5, edgecolor="white")
    xs = np.linspace(s.min(), s.max(), 200)
    ax.plot(xs, gaussian_kde(s)(xs), color="black", label="KDE")
    m, md, sd = s.mean(), np.median(s), s.std(ddof=1)
    ax.axvline(m, color="green", ls="--", label="Mean")
    ax.axvline(md, color="red", ls=":", label="Median")
    for k in (-3, 3):
        ax.axvline(m + k * sd, color="orange", ls="-.", lw=1)
    ax.set_title(f"Распределение {label}"); ax.set_xlabel(label); ax.legend(fontsize=8)
    bp = axes[1, j].boxplot(s, vert=False, showmeans=True, patch_artist=True,
                            boxprops=dict(facecolor=colr, alpha=.5))
    axes[1, j].set_title(f"Boxplot {label}"); axes[1, j].set_xlabel(label)
plt.tight_layout(); plt.show()
```









Аппроксимации и квантильная регрессия (Шаг 1)

В приложении на кросс-плот накладываются 17 типов кривых. Здесь — сравнительная таблица для части из них. Метрики считаются по невязке `Predicted – Actual`.

In [13]:
```python
x = df["Zprm_map"].to_numpy(float)
y = df["Zprm_well"].to_numpy(float)

approx_list = (["Linear", "Quadratic", "Cubic"]
               + [f"Polynomial Degree {n}" for n in range(4, 11)]
               + ["Power Law", "Exponential", "Logarithmic",
                  "Robust (Huber)", "Theil-Sen", "RANSAC", "LOWESS"])   # 17 типов

rows = []
for a in approx_list:
    s = sq.compute_fit_stats(x, y, a)
    rows.append({"Аппроксимация": a, "R²_fit": s.r2, "RMSE": s.rmse,
                 "MAE": s.mae, "Bias": s.bias, "Уравнение": s.equation})
pd.DataFrame(rows).round(3)
```

```
E:\projects\My_project\ML_Geophysics\structural_qc_project\structural_qc_full.py:327: RankWarning: Polyfit may be poorly conditioned
  coeffs = np.polyfit(x, y, degree)
E:\projects\My_project\ML_Geophysics\structural_qc_project\structural_qc_full.py:327: RankWarning: Polyfit may be poorly conditioned
  coeffs = np.polyfit(x, y, degree)
```

Out[13]:

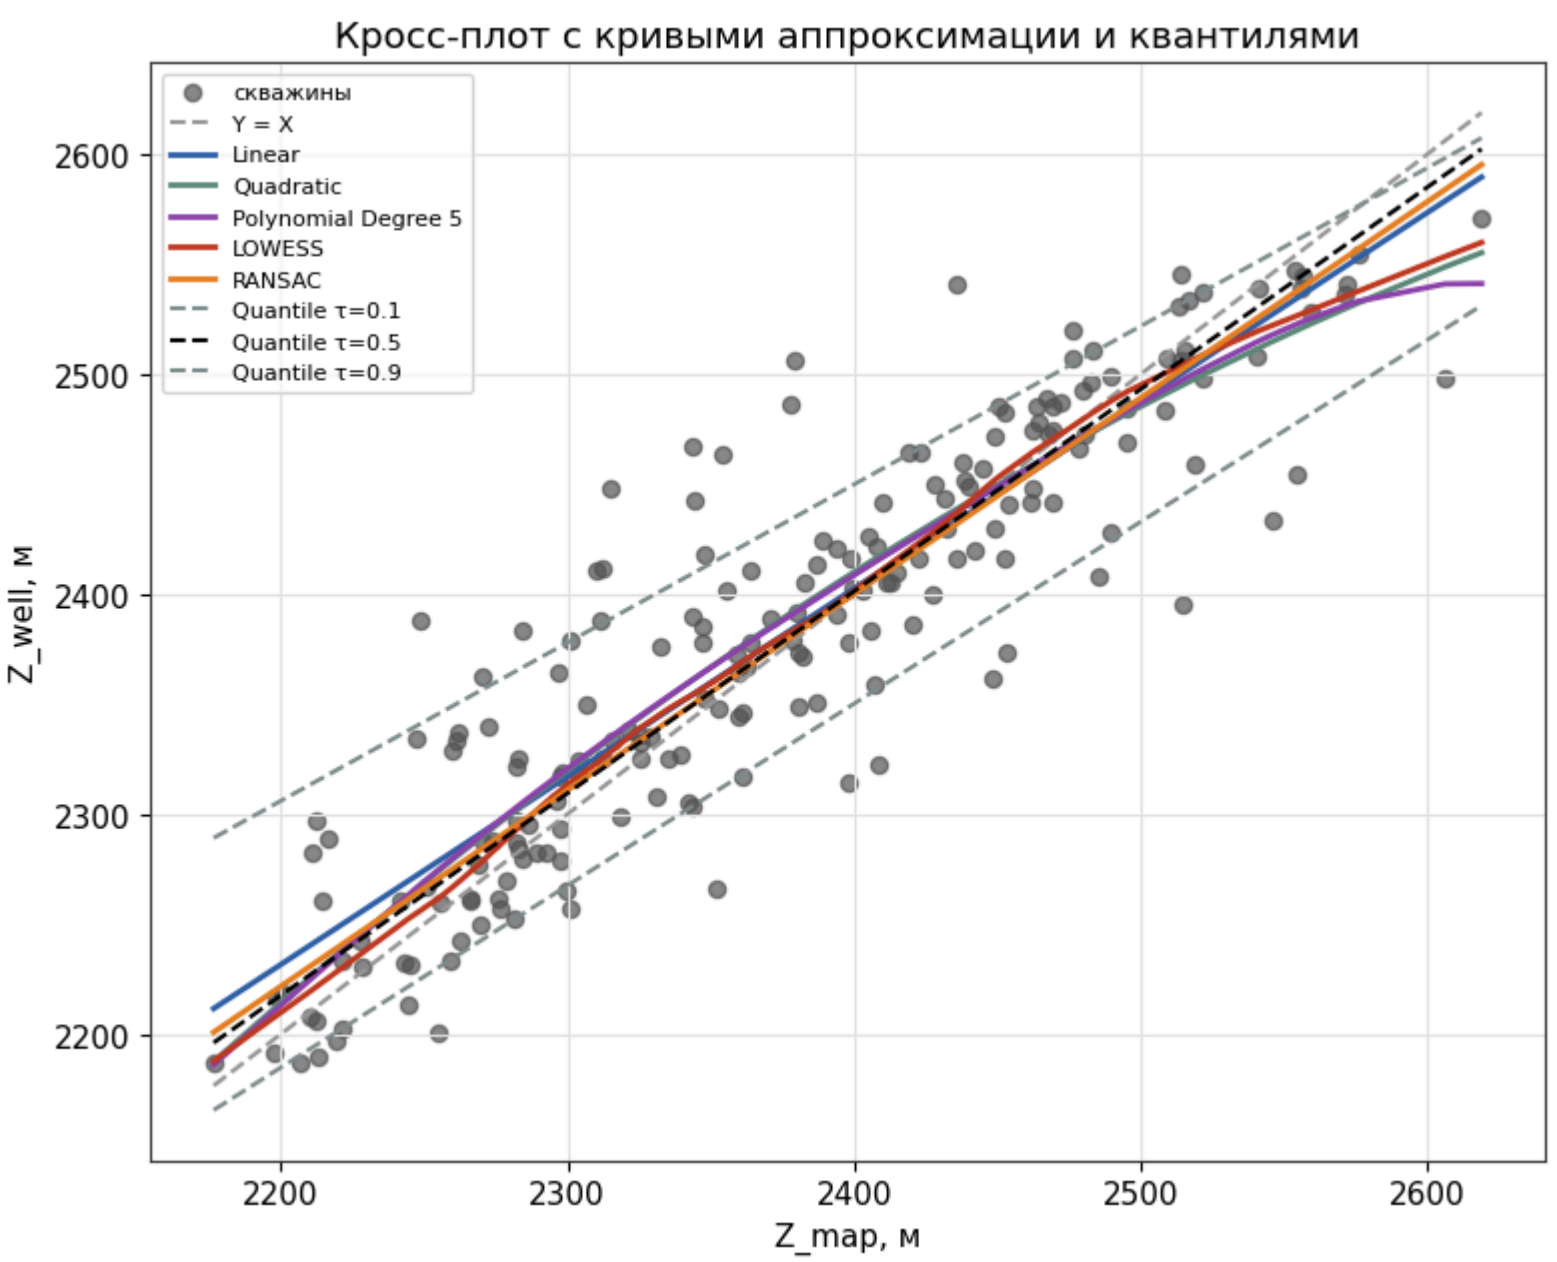
	Аппроксимация	R^2_fit	RMSE	MAE	Bias	Уравнение
0	Linear	0.810	41.804	31.825	-0.000	y = 0.85455·x + 351.61268
1	Quadratic	0.817	41.013	31.272	-0.000	y = -0.00075·x^2 + 4.44498·x - 3917.40229
2	Cubic	0.817	41.013	31.265	0.000	y = -0.00000·x^3 + 0.00001·x^2 + 2.62317·x - 2...
3	Polynomial Degree 4	0.817	40.989	31.307	-0.000	y = -0.00000·x^4 + 0.00009·x^3 - 0.33598·x^2 +...
4	Polynomial Degree 5	0.818	40.980	31.256	-0.000	y = -0.00000·x^5 + 0.00000·x^4 - 0.00281·x^3 +...
5	Polynomial Degree 6	0.818	40.938	31.319	0.000	y = 0.00000·x^6 - 0.00000·x^5 + 0.00008·x^4 - ...
6	Polynomial Degree 7	0.818	40.884	31.245	0.000	y = 0.00000·x^7 - 0.00000·x^6 + 0.00000·x^5 - ...
7	Polynomial Degree 8	0.819	40.855	31.263	0.003	y = -0.00000·x^8 + 0.00000·x^7 - 0.00000·x^6 +...
8	Polynomial Degree 9	0.819	40.855	31.262	0.000	y = -0.00000·x^9 + 0.00000·x^8 - 0.00000·x^7 +...
9	Polynomial Degree 10	0.819	40.855	31.262	0.000	y = -0.00000·x^10 + 0.00000·x^9 - 0.00000·x^8 ...
10	Power Law	0.811	41.757	31.659	-0.361	y = 3.03047·x^0.85769
11	Exponential	0.807	42.162	32.000	-0.367	y = 1012.41590·exp(0.00036·x)
12	Logarithmic	0.813	41.475	31.537	-0.000	y = 2036.46790·ln(x) - 13445.94274
13	Robust (Huber)	0.785	44.478	31.933	-3.377	y = 1.00110·x + 0.55748
14	Theil-Sen	0.806	42.199	31.067	-1.084	y = 0.91052·x + 217.75217
15	RANSAC	0.807	42.119	31.063	-3.507	y = 0.89173·x + 259.90623
16	LOWESS	0.813	41.536	30.193	-3.491	LOWESS (locally weighted regression)

In [14]:
```
q_rows = []
for tau in [0.1, 0.5, 0.9]:
    s = sq.compute_quantile_stats(x, y, tau)
    q_rows.append({"τ": tau, "R²_fit": s.r2, "RMSE": s.rmse,
                   "MAE": s.mae, "Bias": s.bias, "Уравнение": s.equation})
pd.DataFrame(q_rows).round(3)
```

Out[14]:

	τ	R^2_fit	RMSE	MAE	Bias	Уравнение
0	0.1	0.520	66.432	55.312	-51.554	y = 0.82688·x + 365.71653
1	0.5	0.805	42.405	30.939	-2.987	y = 0.91845·x + 197.01432
2	0.9	0.506	67.391	56.502	51.062	y = 0.71934·x + 723.44714

In [15]:
```
order = np.argsort(x)
fig, ax = plt.subplots(figsize=(8, 6.5))
ax.scatter(x, y, s=35, c="#555", alpha=.7, label="скважины")
lo, hi = min(x.min(), y.min()), max(x.max(), y.max())
ax.plot([lo, hi], [lo, hi], "--", color="#999", label="Y = X")
# FitStats.residuals = Predicted − Actual, поэтому Predicted = residuals + y
for a, colr in [("Linear", BLUE), ("Quadratic", "#5C8A7A"), ("Polynomial Degree 5", "#8E44AD"),
                ("LOWESS", RED), ("RANSAC", "#E67E22")]:
    s = sq.compute_fit_stats(x, y, a)
    ax.plot(x[order], (s.residuals + y)[order], color=colr, lw=2, label=a)
for tau, colr in [(0.1, "#7F8C8D"), (0.5, "black"), (0.9, "#7F8C8D")]:
    s = sq.compute_quantile_stats(x, y, tau)
    ax.plot(x[order], (s.residuals + y)[order], ls="--", color=colr, lw=1.5, label=f"Quantile τ={tau}")
ax.set_xlabel("Z_map, м"); ax.set_ylabel("Z_well, м")
ax.set_title("Кросс-плот с кривыми аппроксимации и квантилями")
ax.legend(fontsize=8)
plt.tight_layout(); plt.show()
```

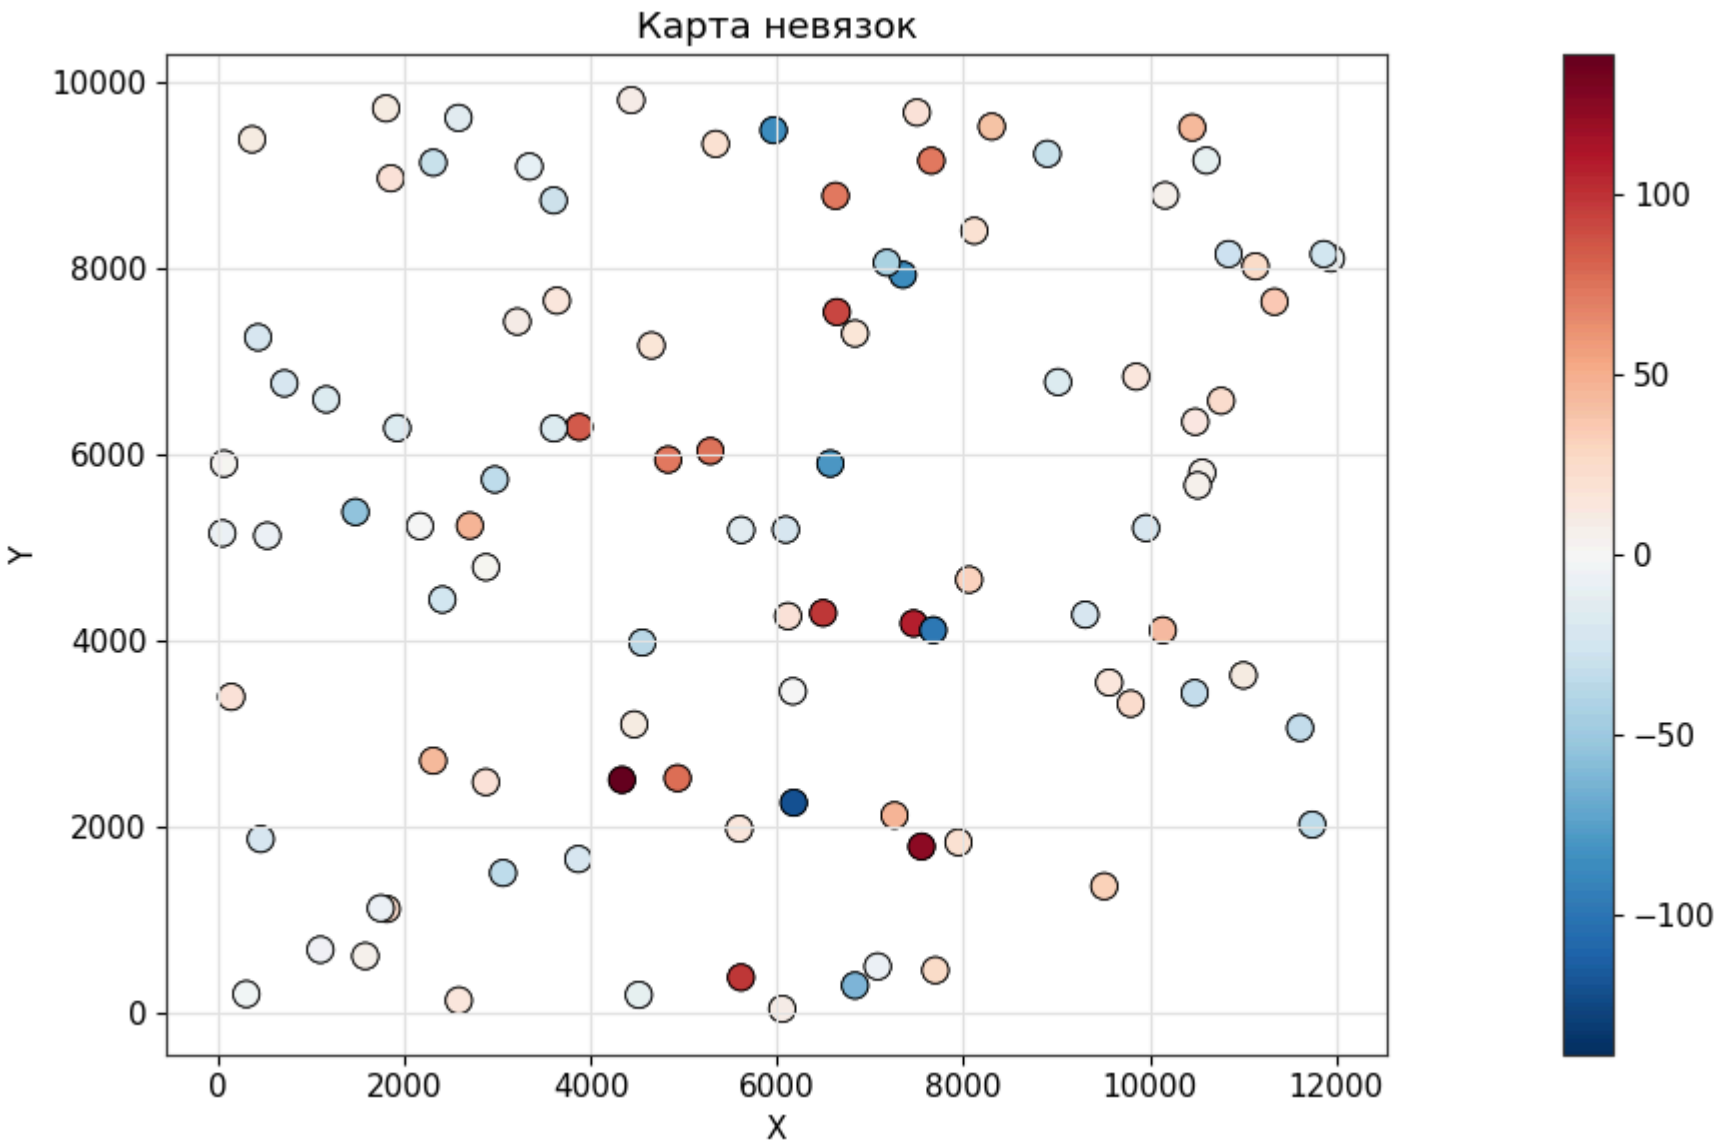


Важно: для τ = 0.1 и 0.9 R^2_fit может быть отрицательным — это нормально. Квантильная регрессия описывает границы разброса, поэтому такие кривые оцениваются по уравнению и Bias, а не по R^2.

Карта невязок и выбросы (Шаг 1)

Карта невязок в плане показывает зоны систематического смещения (качество сейсмики, тектонические осложнения).

In [16]:
```
fig, ax = plt.subplots(figsize=(18, 6))
vmax = np.abs(basic.residuals).max()
sc = ax.scatter(df["X_coord"], df["Y_coord"], c=basic.residuals, cmap="RdBu_r",
                vmin=-vmax, vmax=vmax, s=90, edgecolor="black", linewidth=.6)
plt.colorbar(sc, label="Δ = Z_well − Z_map, м")
ax.set_xlabel("X"); ax.set_ylabel("Y"); ax.set_aspect("equal")
ax.set_title("Карта невязок")
plt.tight_layout()
plt.show()
```



Выбросы оцениваются четырьмя независимыми правилами одновременно: sigma (|r| > σ_thr·σ, σ_thr: 1.0–6.0, по умолчанию 2.0), IQR ([Q1 − k·IQR, Q3 + k·IQR], k: 1.0–3.0, по умолчанию 1.5), modified z-score (|0.6745·(r − median)/MAD| > 3.5) и перцентили (вне [P_low, P_high], по умолчанию 5% и 95%; настраиваются 0–20% и 80–100%).

In [17]:
```python
def detect_outliers(r, sigma_thr=2.0, iqr_k=1.5, pct_low=5.0, pct_high=95.0):
    r = np.asarray(r, dtype=float)
    med = np.median(r)
    sd = r.std(ddof=1)
    q25, q75 = np.quantile(r, [0.25, 0.75])
    q05, q95 = np.quantile(r, [pct_low / 100, pct_high / 100])
    iqr = q75 - q25
    mad = np.median(np.abs(r - med))
    modz = 0.6745 * (r - med) / mad if mad > 0 else np.zeros_like(r)
    return {
        "sigma": np.abs(r) > sigma_thr * sd,
        "IQR": (r < q25 - iqr_k * iqr) | (r > q75 + iqr_k * iqr),
        "modified z": np.abs(modz) > 3.5,
        "P05–P95": (r < q05) | (r > q95),
    }

masks = detect_outliers(basic.residuals)
print({k: int(v.sum()) for k, v in masks.items()})

flags = pd.DataFrame(masks)
flags["methods"] = flags.sum(axis=1)
out = df.loc[flags["methods"] > 0, ["well_id", "X_coord", "Y_coord", "Zprm_well", "tectonic_zone"]].copy() \
        if "tectonic_zone" in df.columns else df.loc[flags["methods"] > 0, ["well_id", "X_coord", "Y_coord", "Zprm_well"]].copy()
out["Δ, м"] = basic.residuals[flags["methods"] > 0]
out["методов"] = flags.loc[flags["methods"] > 0, "methods"].to_numpy()
out.sort_values("методов", ascending=False)
```

```
{'sigma': 16, 'IQR': 22, 'modified z': 7, 'P05–P95': 20}
```

Out[17]:

	well_id	X_coord	Y_coord	Zprm_well	tectonic_zone	Δ, м	методов
88	W-045	7676.6	4116.5	2498.00	Central_Graben	-107.97	4
101	W-051	4335.2	2510.0	2387.89	Central_Graben	139.04	4
100	W-051	4335.2	2510.0	2447.70	Central_Graben	132.47	4
50	W-026	6178.7	2264.2	2433.75	Central_Graben	-112.22	4
51	W-026	6178.7	2264.2	2395.04	Central_Graben	-119.78	4
56	W-029	7550.7	1794.1	2505.89	Central_Graben	126.97	4
57	W-029	7550.7	1794.1	2467.49	Central_Graben	124.00	4
89	W-045	7676.6	4116.5	2454.42	Central_Graben	-99.74	3
185	W-093	5612.8	389.9	2411.32	Central_Graben	98.84	3
184	W-093	5612.8	389.9	2463.77	Central_Graben	110.03	3
95	W-048	6493.7	4300.0	2383.16	Central_Graben	98.67	3
30	W-016	6642.0	7529.8	2410.58	Central_Graben	100.48	3
37	W-019	7466.2	4189.0	2485.79	Central_Graben	108.16	3
36	W-019	7466.2	4189.0	2540.63	Central_Graben	105.08	3
31	W-016	6642.0	7529.8	2362.32	Central_Graben	92.33	2
61	W-031	5962.5	9481.2	2265.75	Central_Graben	-85.91	2
94	W-048	6493.7	4300.0	2442.24	Central_Graben	97.89	2
60	W-031	5962.5	9481.2	2314.11	Central_Graben	-84.04	2
45	W-023	7350.5	7930.2	2322.59	Central_Graben	-85.89	2
44	W-023	7350.5	7930.2	2361.49	Central_Graben	-86.98	2
108	W-055	3876.4	6296.2	2334.20	North_Block	86.83	1
109	W-055	3876.4	6296.2	2296.63	North_Block	84.11	1
186	W-094	6571.6	5903.9	2408.28	Central_Graben	-77.11	1
187	W-094	6571.6	5903.9	2373.43	Central_Graben	-79.82	1

*** к содержанию**

Шаг 2: Кросс-валидация

Строим суррогатную поверхность `Z_well ~ f(X, Y)` и валидируем её **процесс построения**. Это иллюстрация того, как следовало бы кросс-валидировать сам метод построения карты, если бы он использовал скважины в калибровке.

Запускаются все схемы движка. Random K-Fold включён как заведомо оптимистичная база для контраста и, как и в приложении, участвует в выборе лучшей схемы — это известное ограничение, отмеченное в плане. Stratified by <колонка> появляется только при наличии колонки зоны (по умолчанию `tectonic_zone`) с двумя и более значениями.

In [18]:
```
from scipy.spatial.distance import pdist

coords = df[["X_coord", "Y_coord"]].to_numpy(float)
y_true = df["Zprm_well"].to_numpy(float)
n_wells = df["well_id"].nunique()
median_dist = float(np.median(pdist(coords)))

def recommend_cv(n, md):
    return {
        "k (Random K-Fold)": 5 if n < 20 else 7 if n < 50 else 10 if n < 150 else 12,
        "grid_n (Block/Buffered)": 5 if md < 300 else 4 if md < 600 else 3 if md < 1000 else 2,
        "buffer, м (Buffered)": 0.5 * md,
        "cv_repeats (Leave-P-Out)": 100 if n < 30 else 50 if n < 100 else 30 if n < 300 else 20,
        "radius, м (Spatial LPO)": md,
    }

print(f"скважин: {n_wells}, медианное расстояние между скважинами: {median_dist:.0f} м")
pd.Series(recommend_cv(n_wells, median_dist), name="рекомендовано").round(1).to_frame()
```

```
скважин: 100, медианное расстояние между скважинами: 5657 м
```

Out[18]:

	рекомендовано
k (Random K-Fold)	10.0
grid_n (Block/Buffered)	2.0
buffer, м (Buffered)	2828.7
cv_repeats (Leave-P-Out)	30.0
radius, м (Spatial LPO)	5657.5

In [19]:
```
rows = []
for f in [0.5, 1.0, 1.5, 2.0, 3.0]:
    preds, _ = sq.cv_distance_exclusion(df, degree=1, variogram_factor=f)
    m = ~np.isnan(preds)
    rows.append({"variogram_factor": f,
                 "радиус исключения, м": sq.median_pairwise_distance(coords) * f,
                 "RMSE, м": np.sqrt(np.mean((preds[m] - y_true[m]) ** 2)),
                 "скважин с прогнозом": int(m.sum())})
pd.DataFrame(rows).round(2)
```

```
E:\envs\py310\lib\site-packages\numpy\core\fromnumeric.py:3504: RuntimeWarning: Mean of empty slice.
  return _methods._mean(a, axis=axis, dtype=dtype,
E:\envs\py310\lib\site-packages\numpy\core\_methods.py:129: RuntimeWarning: invalid value encountered in scalar divide
  ret = ret.dtype.type(ret / rcount)
```

Out[19]:

	variogram_factor	радиус исключения, м	RMSE, м	скважин с прогнозом
0	0.5	2828.74	45.84	200
1	1.0	5657.47	52.41	200
2	1.5	8486.21	52.77	174
3	2.0	11314.95	45.58	60
4	3.0	16972.42	NaN	0

In [20]:
```
results, comparison = sq.run_all_cv(df, degree=1, k=5, grid_n=3)
comparison.round(2)
```

Out[20]:

CV scheme	n_pred	n_test_min	n_test_max	r2_lin	rmse	mae	bias	rmse_fold_mean	rmse_fold_median	rmse_fold_min	rmse_fold_max	rmse_fold_s
Random K-Fold	200.0	40.0	40.0	0.81	42.09	32.25	0.10	41.99	42.97	37.85	45.88	3
Random K-Fold (buffered)	200.0	40.0	40.0	0.80	42.53	32.78	0.86	42.44	43.33	38.69	46.24	3
Leave-One-Well-Out	200.0	2.0	2.0	0.80	42.60	32.44	0.09	32.95	25.23	2.32	118.58	27
Block CV	200.0	6.0	28.0	0.78	44.91	34.89	1.08	40.17	41.76	20.04	65.81	17
Buffered CV	200.0	6.0	28.0	0.78	44.91	34.89	1.08	40.17	41.76	20.04	65.81	17
Leave-P-Out	200.0	20.0	20.0	0.81	42.25	32.15	0.04	42.80	44.07	24.84	56.81	7
Spatial Leave-P-Out	152.0	2.0	12.0	0.77	45.64	35.72	-1.40	43.26	32.88	9.03	81.53	20
Stratified by tectonic_zone	200.0	52.0	76.0	0.67	54.91	43.91	6.65	50.53	59.29	28.74	63.56	18
Distance-based exclusion CV	200.0	1.0	1.0	0.70	52.41	41.30	7.18	41.30	33.46	0.35	130.91	32

In [21]:
```
comparison = comparison.copy()
comparison["score"] = comparison["rmse"] + comparison["rmse_fold_std"]
# Выбор как в приложении: min по всем схемам, включая Random K-Fold (см. известное ограничение в плане)
best = comparison["score"].idxmin()
print(f"Лучшая схема по score = RMSE + RMSE_fold_std: {best}")
comparison.sort_values("score")[["rmse", "rmse_fold_std", "score"]].round(2)
```

```
Лучшая схема по score = RMSE + RMSE_fold_std: Random K-Fold
```

Out[21]:

CV scheme	rmse	rmse_fold_std	score
Random K-Fold	42.09	3.15	45.24
Random K-Fold (buffered)	42.53	3.09	45.62
Leave-P-Out	42.25	7.43	49.68
Block CV	44.91	17.10	62.01
Buffered CV	44.91	17.10	62.01
Spatial Leave-P-Out	45.64	20.68	66.32
Leave-One-Well-Out	42.60	27.13	69.74
Stratified by tectonic_zone	54.91	18.99	73.90
Distance-based exclusion CV	52.41	32.35	84.76

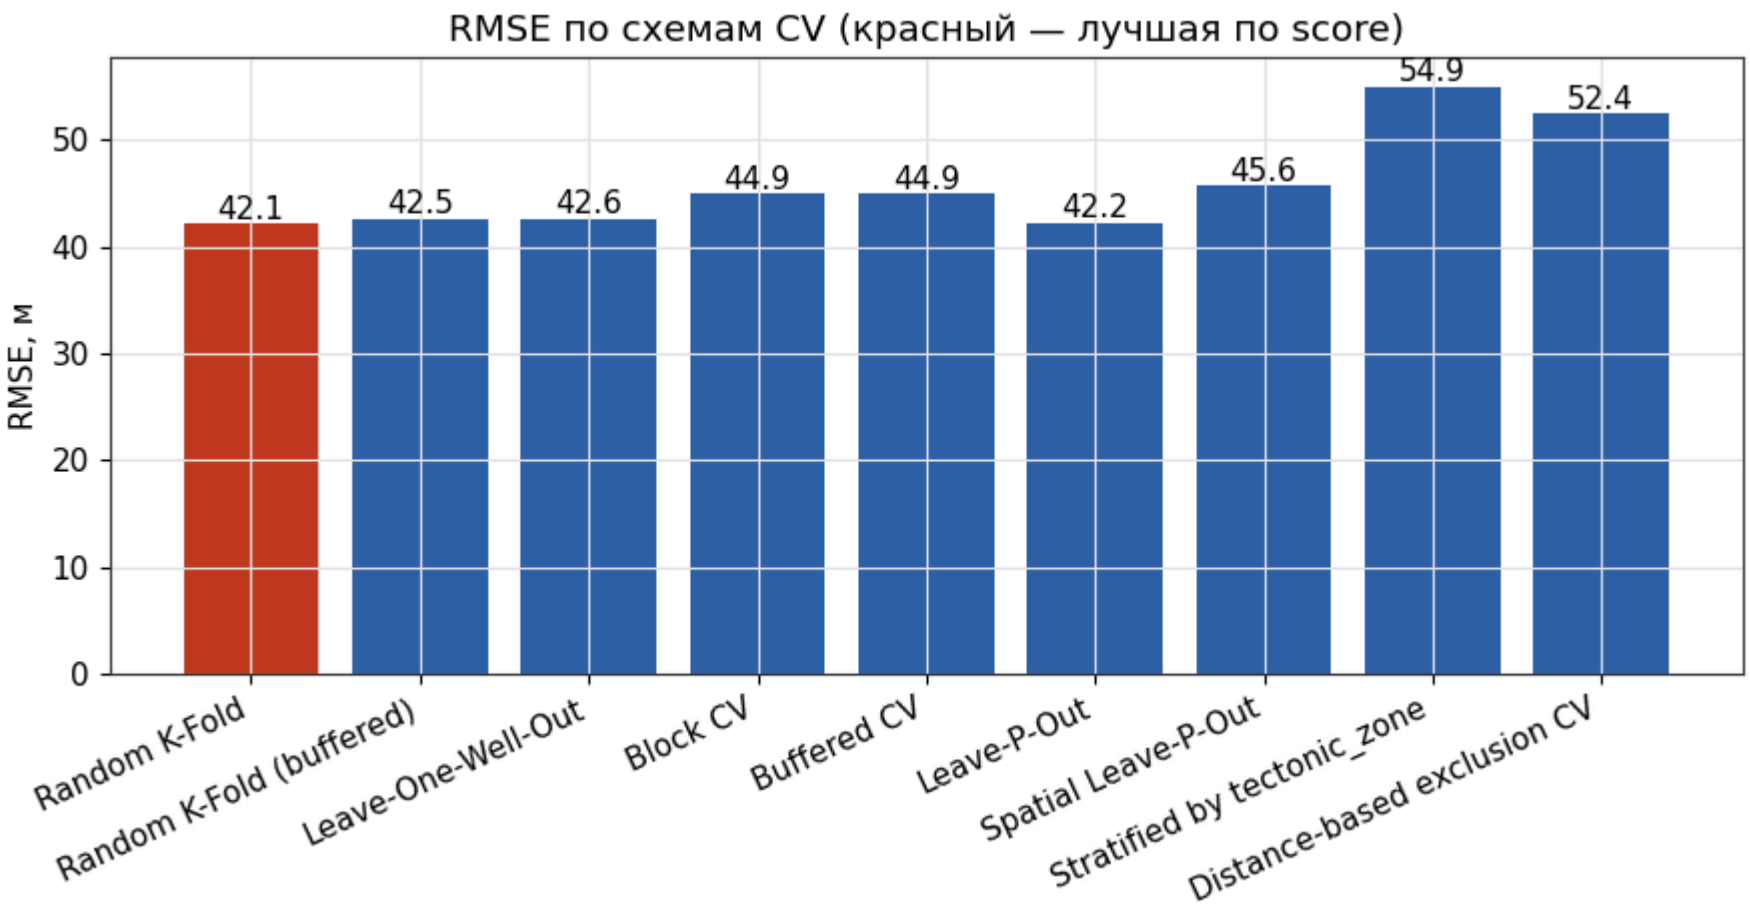
In [22]:
```
print("Схемы с разным числом прогнозов (n_pred):", comparison["n_pred"].nunique() > 1)
print(comparison["n_pred"].astype(int).to_string())
skipped = {name: int(r["folds"]["fold"].astype(str).str.contains("skipped").sum())
           for name, r in results.items() if r.get("folds") is not None and len(r["folds"])}
print("Пропущенных фолдов по схемам:", {k: v for k, v in skipped.items() if v})
```

```
Схемы с разным числом прогнозов (n_pred): True
CV scheme
Random K-Fold                  200
Random K-Fold (buffered)       200
Leave-One-Well-Out             200
Block CV                       200
Buffered CV                    200
Leave-P-Out                    200
Spatial Leave-P-Out            152
Stratified by tectonic_zone    200
Distance-based exclusion CV    200
Пропущенных фолдов по схемам: {}
```

In [23]:
```
fig, ax = plt.subplots(figsize=(9, 4.8))
colors = [RED if i == best else ("#999999" if i == "Random K-Fold" else BLUE)
          for i in comparison.index]
bars = ax.bar(comparison.index, comparison["rmse"], color=colors)
for b, v in zip(bars, comparison["rmse"]):
    ax.text(b.get_x() + b.get_width() / 2, v + 0.5, f"{v:.1f}", ha="center")
ax.set_ylabel("RMSE, м")
ax.set_title("RMSE по схемам CV (красный — лучшая по score)")
plt.xticks(rotation=25, ha="right")
plt.tight_layout()
plt.show()

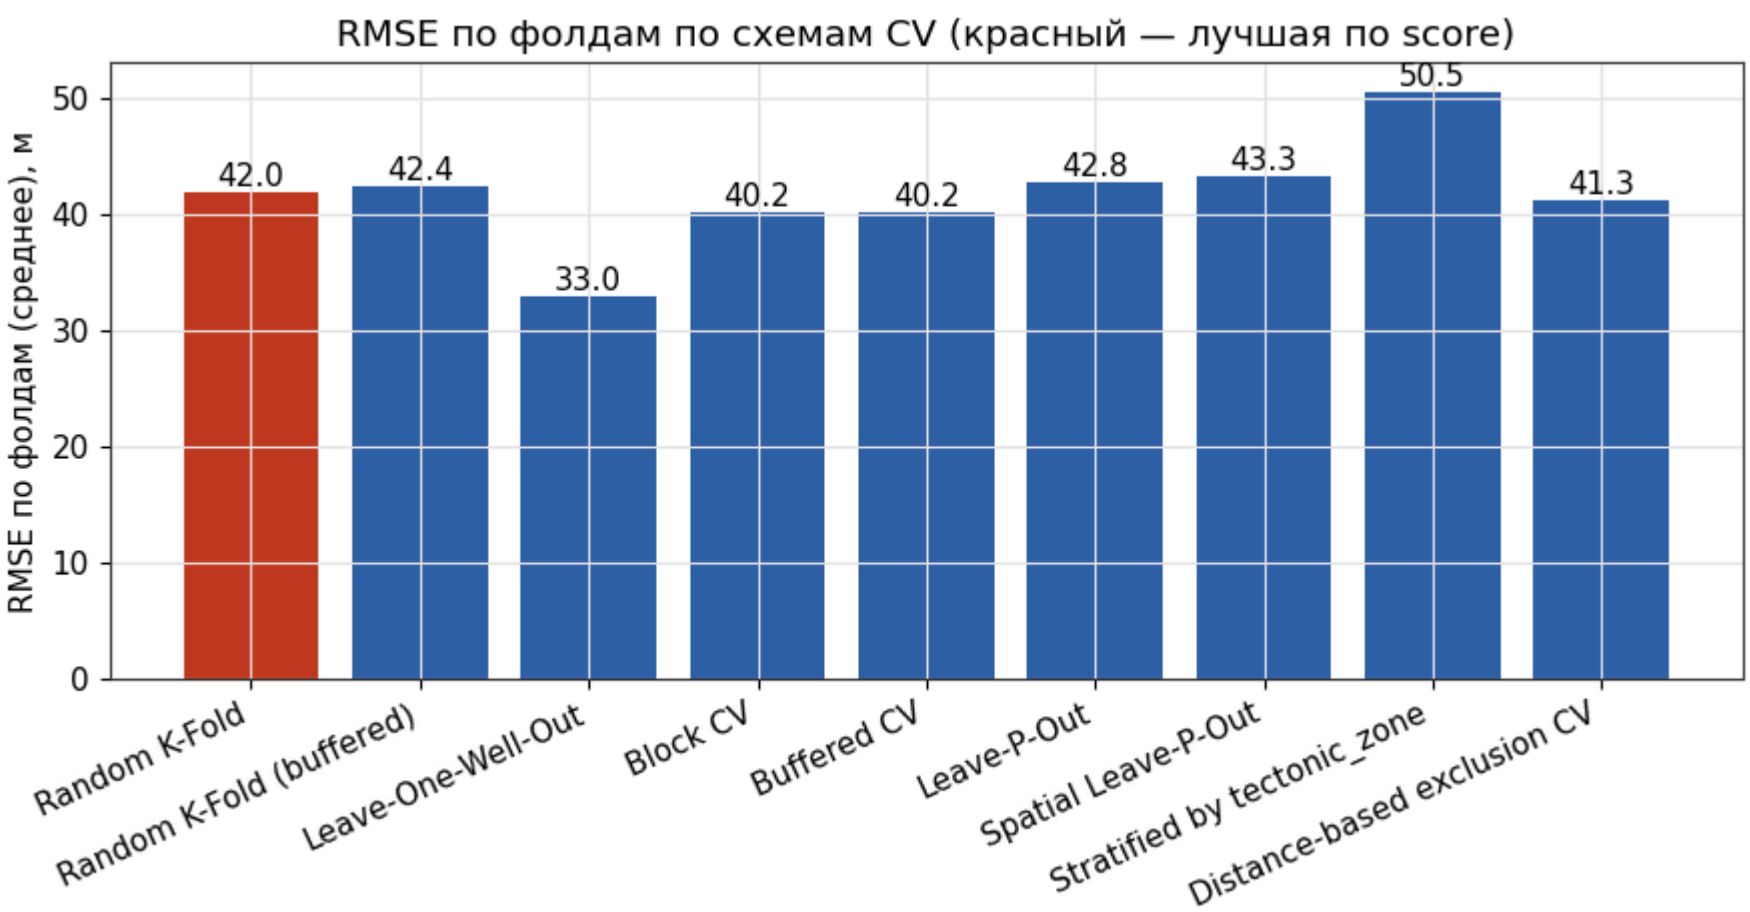
gap = comparison.loc["Random K-Fold", "rmse"]
worst = comparison.drop(index="Random K-Fold")["rmse"].max()
```

```
print(f"Random K-Fold RMSE = {gap:.1f} м, наихудшая из пространственных схем = {worst:.1f} м "
      f"(разница {worst - gap:.1f} м — мера оптимизма случайного разбиения)")
```




```
Random K-Fold RMSE = 42.1 м, наихудшая из пространственных схем = 54.9 м (разница 12.8 м — мера оптимизма случайного разбиения)
```

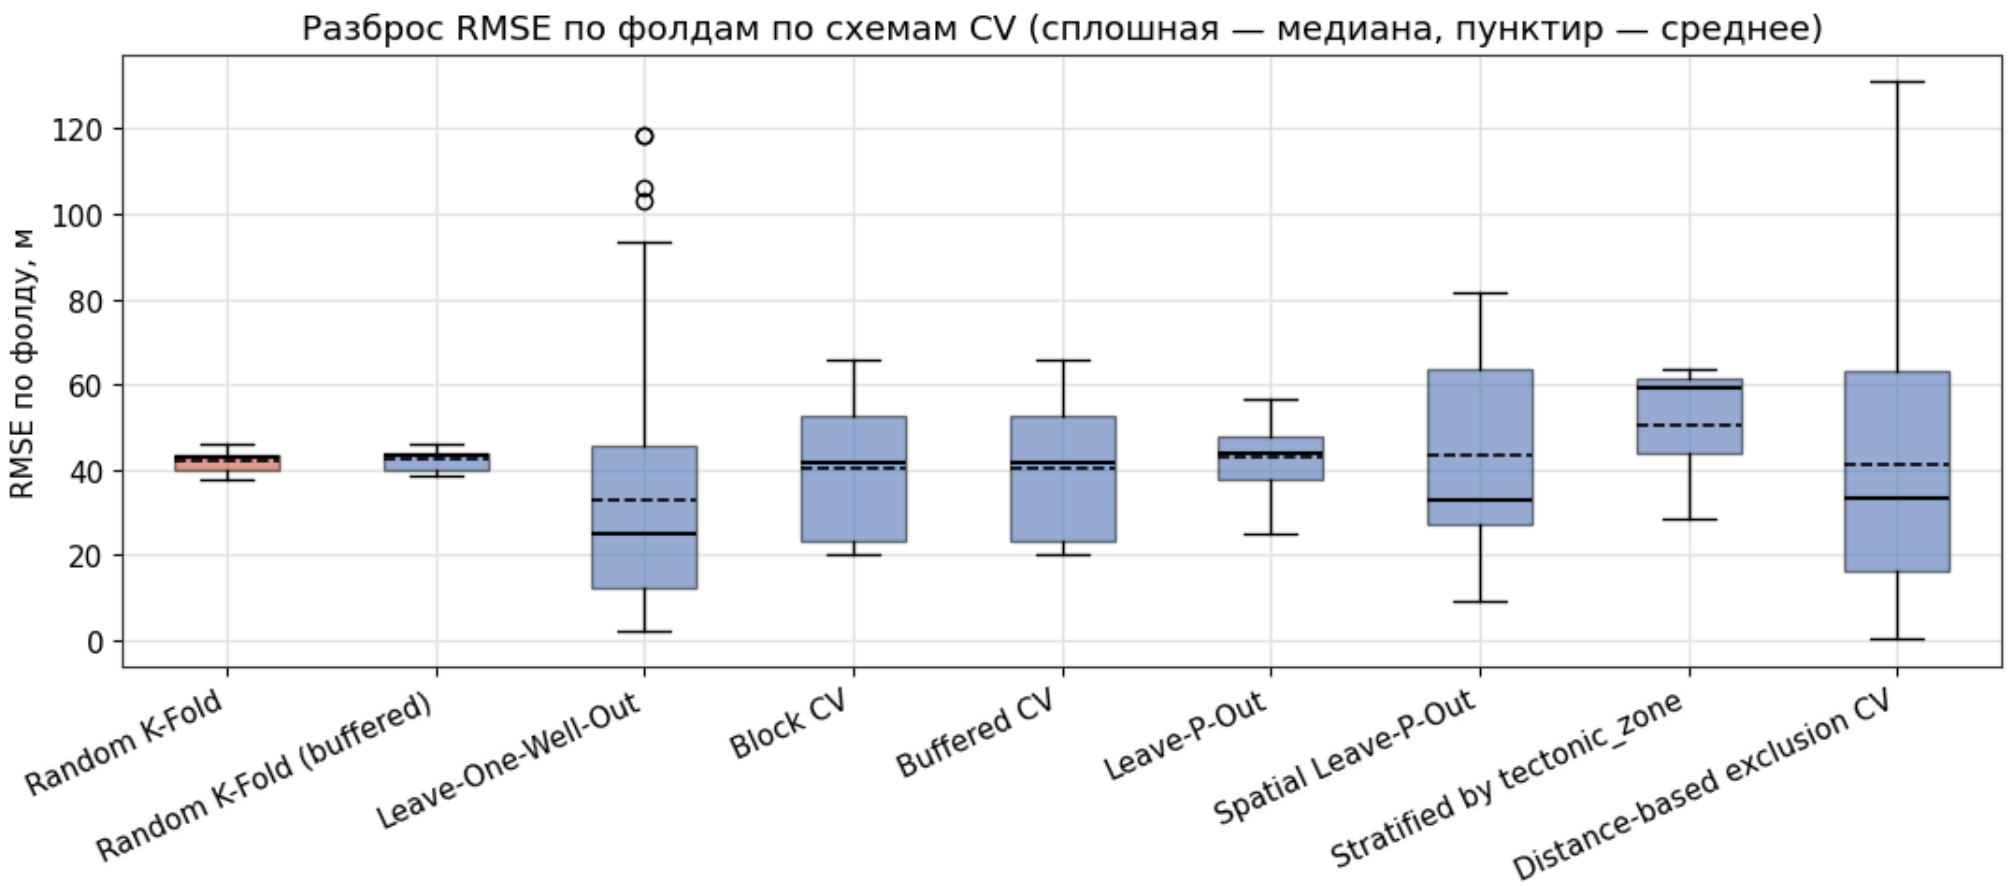
In [24]:
```
# Столбчатая диаграмма: среднее RMSE по фолдам для каждой схемы CV
fig, ax = plt.subplots(figsize=(9, 4.8))
colors = [RED if i == best else ("#999999" if i == "Random K-Fold" else BLUE)
          for i in comparison.index]
bars = ax.bar(comparison.index, comparison["rmse_fold_mean"], color=colors)
for b, v in zip(bars, comparison["rmse_fold_mean"]):
    ax.text(b.get_x() + b.get_width() / 2, v + 0.5, f"{v:.1f}", ha="center")
ax.set_ylabel("RMSE по фолдам (среднее), м")
ax.set_title("RMSE по фолдам по схемам CV (красный — лучшая по score)")
plt.xticks(rotation=25, ha="right")
plt.tight_layout()
plt.show()
```



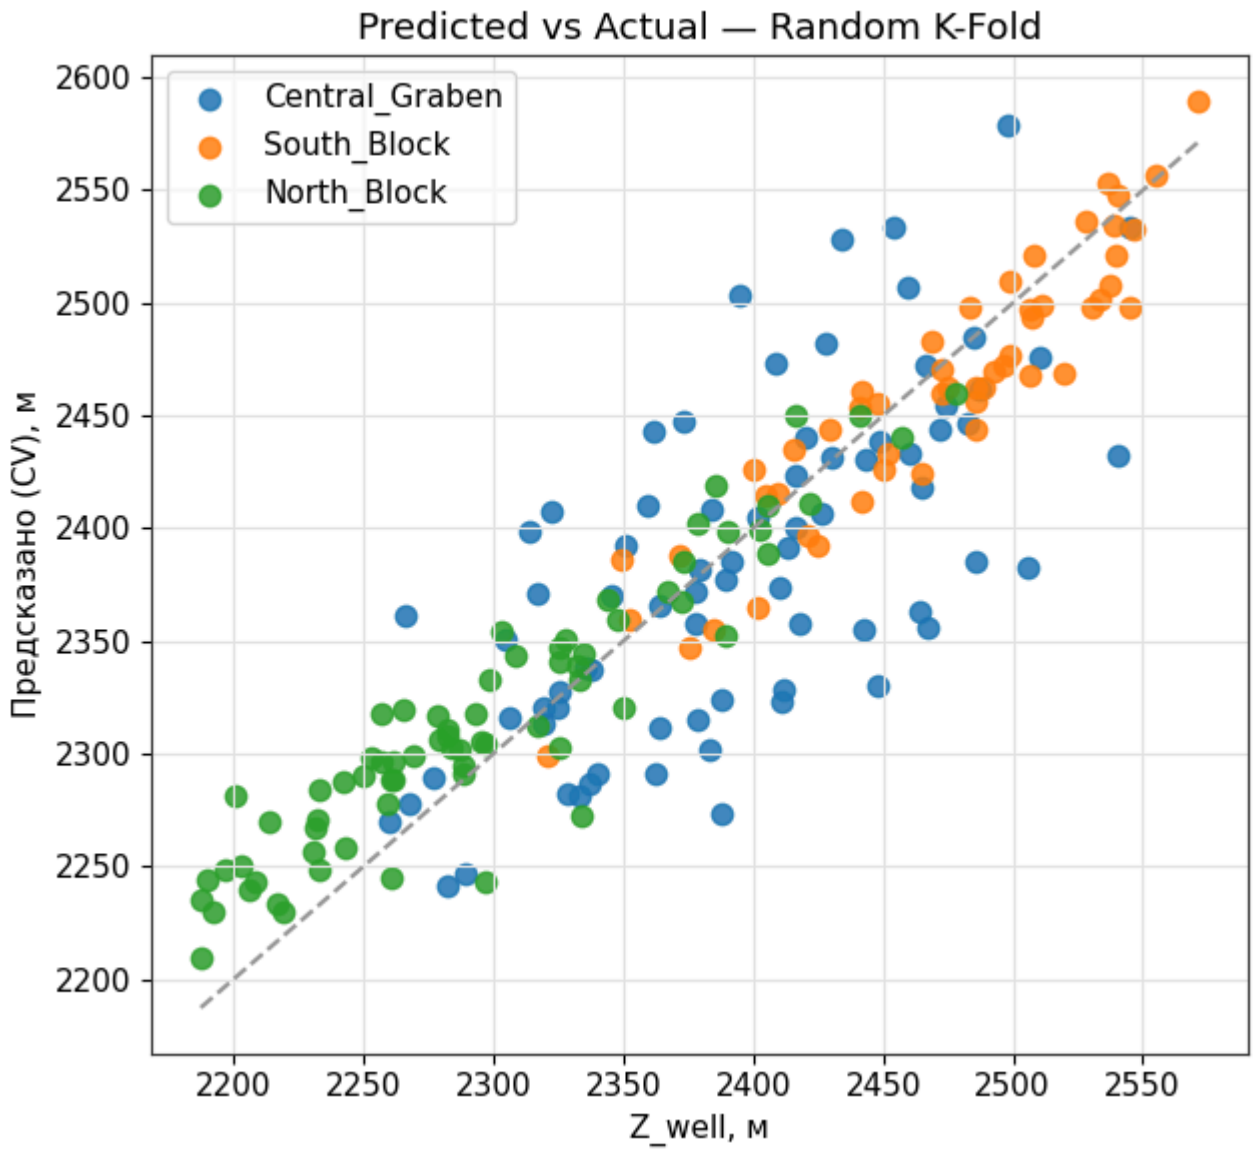
In [25]:
```
# Boxplot разброса RMSE по фолдам: медиана — сплошная, среднее — пунктир, выбросы — точки
labels, data, colors = [], [], []
for name in comparison.index:
    f = results[name].get("folds")
    vals = f["rmse"].dropna().to_numpy(float) if f is not None and len(f) else np.array([])
    if len(vals) == 0:
        continue
    labels.append(name)
    data.append(vals)
    colors.append(RED if name == best else ("#999999" if name == "Random K-Fold" else BLUE))

fig, ax = plt.subplots(figsize=(11, 5))
bp = ax.boxplot(data, patch_artist=True, showmeans=True, meanline=True,
                medianprops=dict(color="black", linewidth=1.5),
                meanprops=dict(color="black", linestyle="--", linewidth=1.2))
for patch, c in zip(bp["boxes"], colors):
    patch.set_facecolor(c)
    patch.set_alpha(0.5)
ax.set_xticks(range(1, len(labels) + 1))
```

```
ax.set_xticklabels(labels, rotation=25, ha="right")
ax.set_ylabel("RMSE по фолду, м")
ax.set_title("Разброс RMSE по фолдам по схемам CV (сплошная — медиана, пунктир — среднее)")
plt.tight_layout()
plt.show()
```

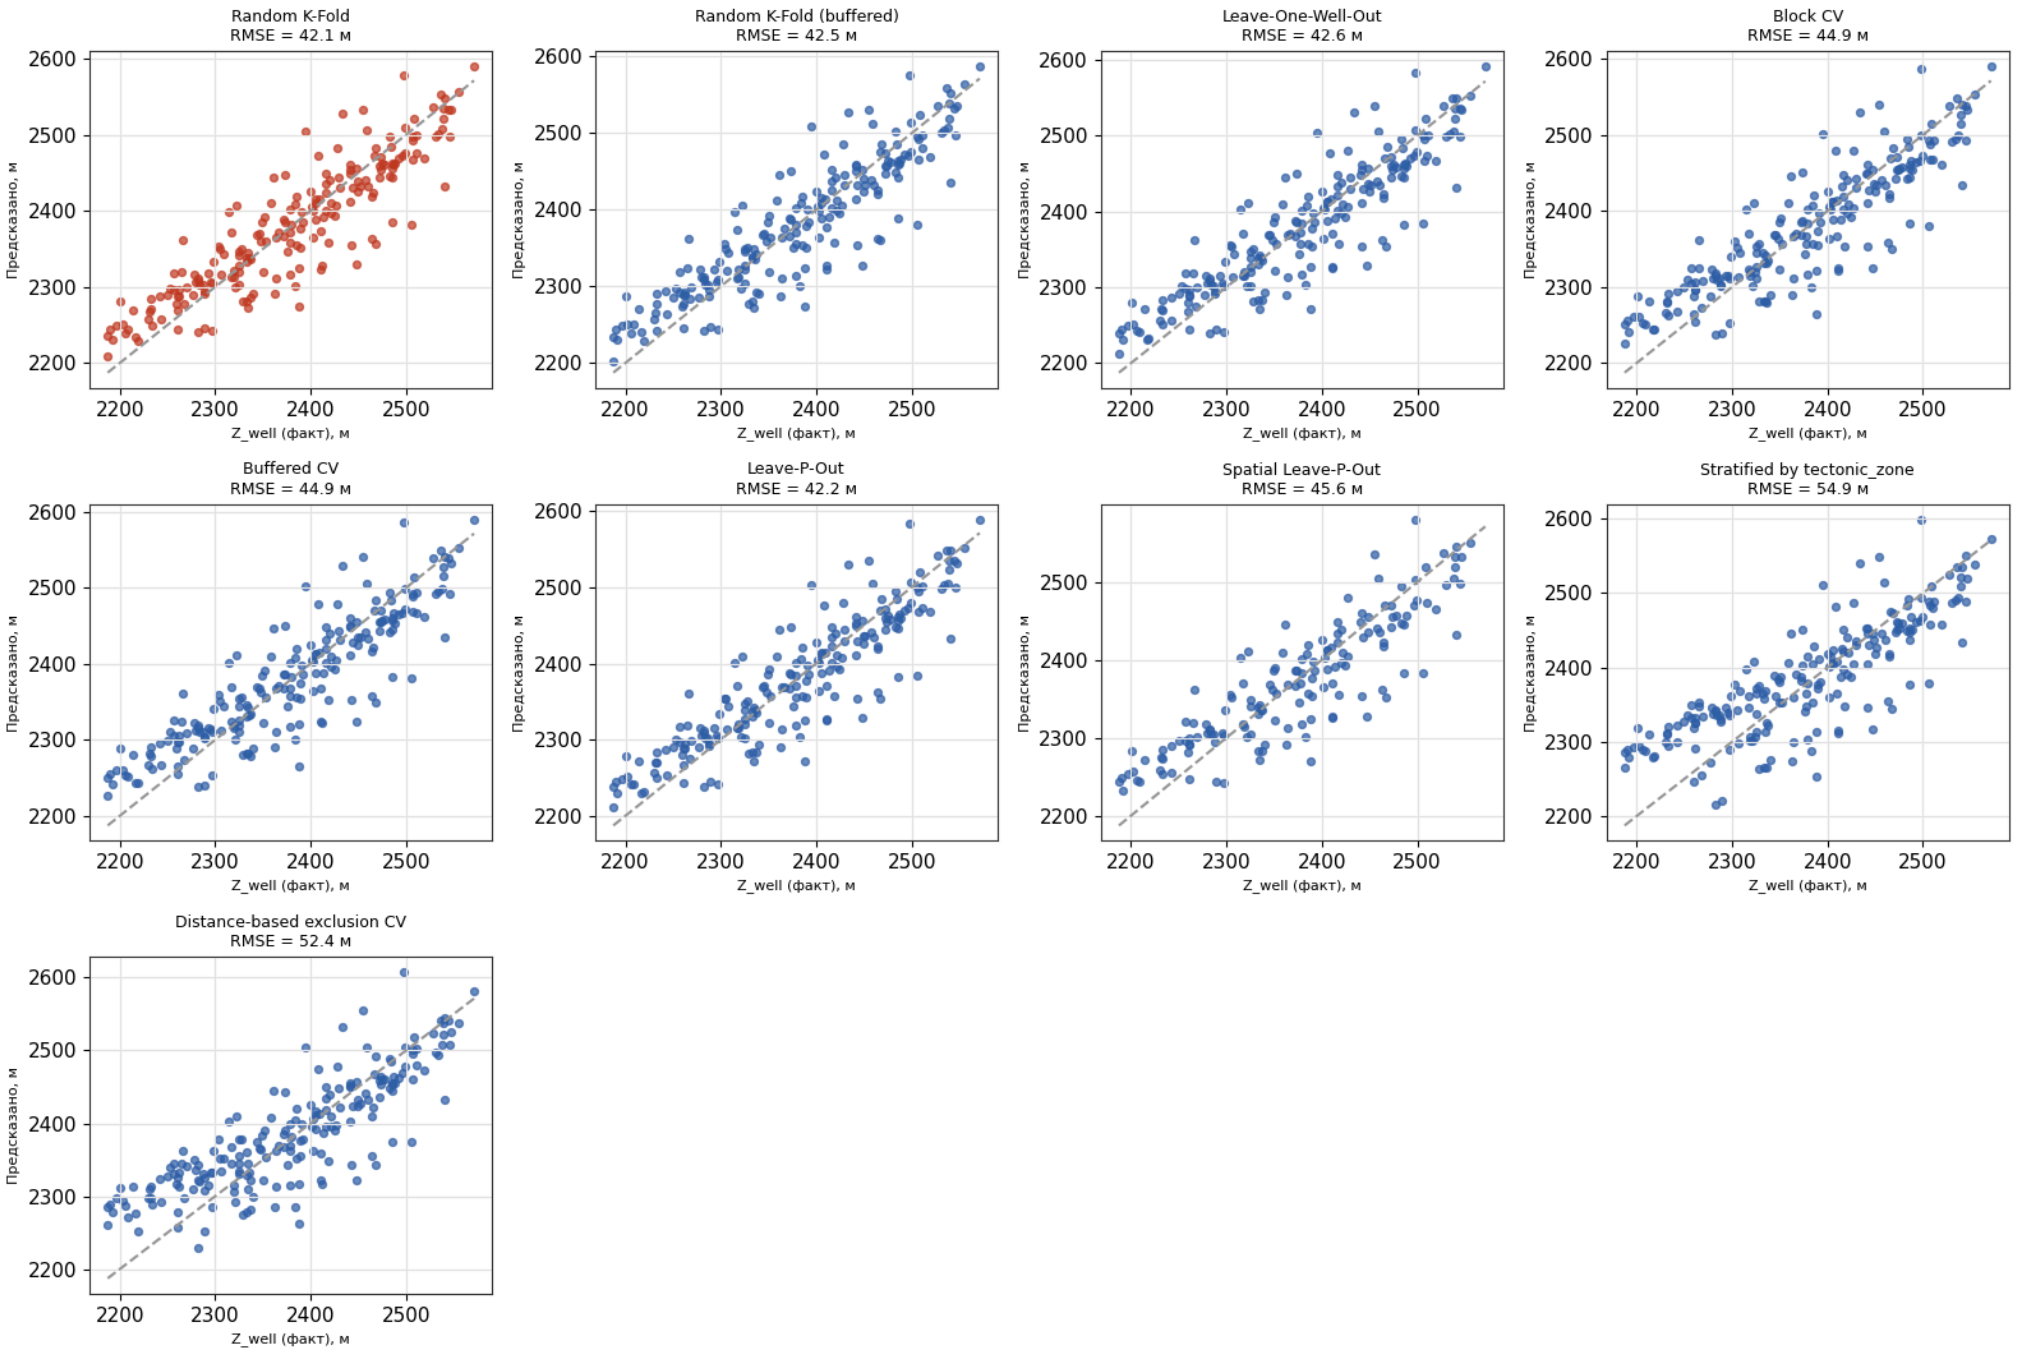


In [26]:
```
fig, ax = plt.subplots(figsize=(6.5, 6))
preds = results[best]["preds"]
zones = df["tectonic_zone"] if "tectonic_zone" in df.columns else pd.Series("all", index=df.index)
palette = plt.cm.tab10.colors
for i, zone in enumerate(zones.unique()):
    m = (zones == zone).to_numpy()
    ax.scatter(df.loc[m, "Zprm_well"], preds[m], label=str(zone), s=55, alpha=.85,
               color=palette[i % len(palette)])
lo, hi = df["Zprm_well"].min(), df["Zprm_well"].max()
ax.plot([lo, hi], [lo, hi], "--", color="#999")
ax.set_xlabel("Z_well, м"); ax.set_ylabel("Предсказано (CV), м")
ax.legend(); ax.set_title(f"Predicted vs Actual — {best}")
plt.tight_layout()
plt.show()
```



In [27]:
```
names = list(comparison.index)
ncol = 4
nrow = int(np.ceil(len(names) / ncol))
fig, axes = plt.subplots(nrow, ncol, figsize=(4 * ncol, 3.6 * nrow), squeeze=False)
for ax, name in zip(axes.ravel(), names):
    p = results[name]["preds"]
    m = ~np.isnan(p)
    ax.scatter(y_true[m], p[m], s=18, alpha=.7, color=RED if name == best else BLUE)
    lo_, hi_ = y_true.min(), y_true.max()
```

```
    ax.plot([lo_, hi_], [lo_, hi_], "--", color="#999")
    ax.set_title(f"{name}\nRMSE = {comparison.loc[name, 'rmse']:.1f} м", fontsize=9)
    ax.set_xlabel("Z_well (факт), м", fontsize=8); ax.set_ylabel("Предсказано, м", fontsize=8)
for ax in axes.ravel()[len(names):]:
    ax.axis("off")
plt.tight_layout(); plt.show()
```

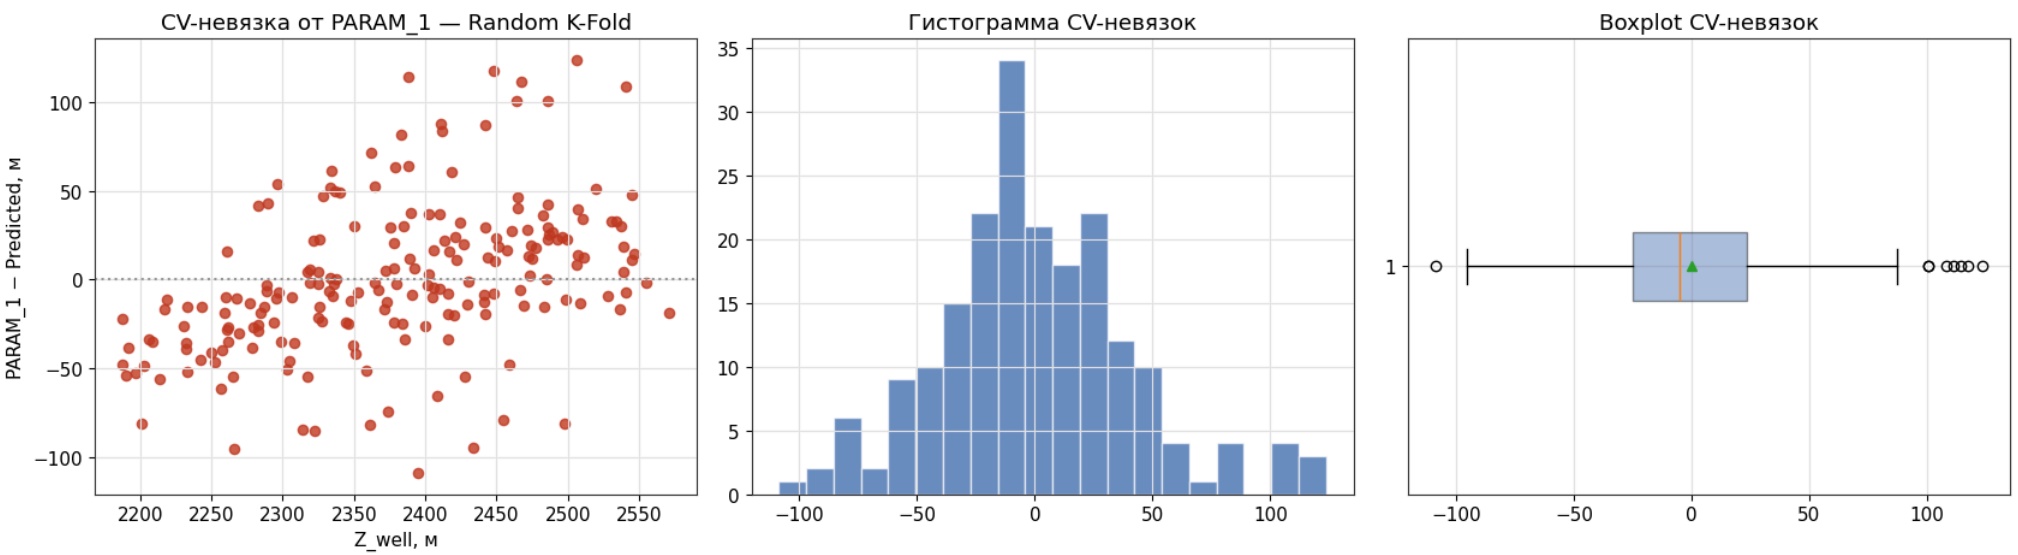


In [28]:

```
best_preds = results[best]["preds"]
m = ~np.isnan(best_preds)
cv_res = y_true[m] - best_preds[m]            # PARAM_1 – Predicted (как на графике CV-невязок)
p1 = y_true[m]

fig, axes = plt.subplots(1, 3, figsize=(17, 4.8))
axes[0].scatter(p1, cv_res, s=35, color=RED, alpha=.8)
axes[0].axhline(0, ls=":", color="#999")
axes[0].set_xlabel("Z_well, м"); axes[0].set_ylabel("PARAM_1 – Predicted, м")
axes[0].set_title(f"CV-невязка от PARAM_1 — {best}")
axes[1].hist(cv_res, bins=20, color=BLUE, alpha=.7, edgecolor="white")
axes[1].set_title("Гистограмма CV-невязок")
axes[2].boxplot(cv_res, vert=False, showmeans=True, patch_artist=True,
                boxprops=dict(facecolor=BLUE, alpha=.4))
axes[2].set_title("Boxplot CV-невязок")
plt.tight_layout(); plt.show()

display(pd.DataFrame({"CV-невязка": param_stats(cv_res)}).round(2))
cv_m = detect_outliers(cv_res)
print("выбросы по методам:", {k: int(v.sum()) for k, v in cv_m.items()})
```



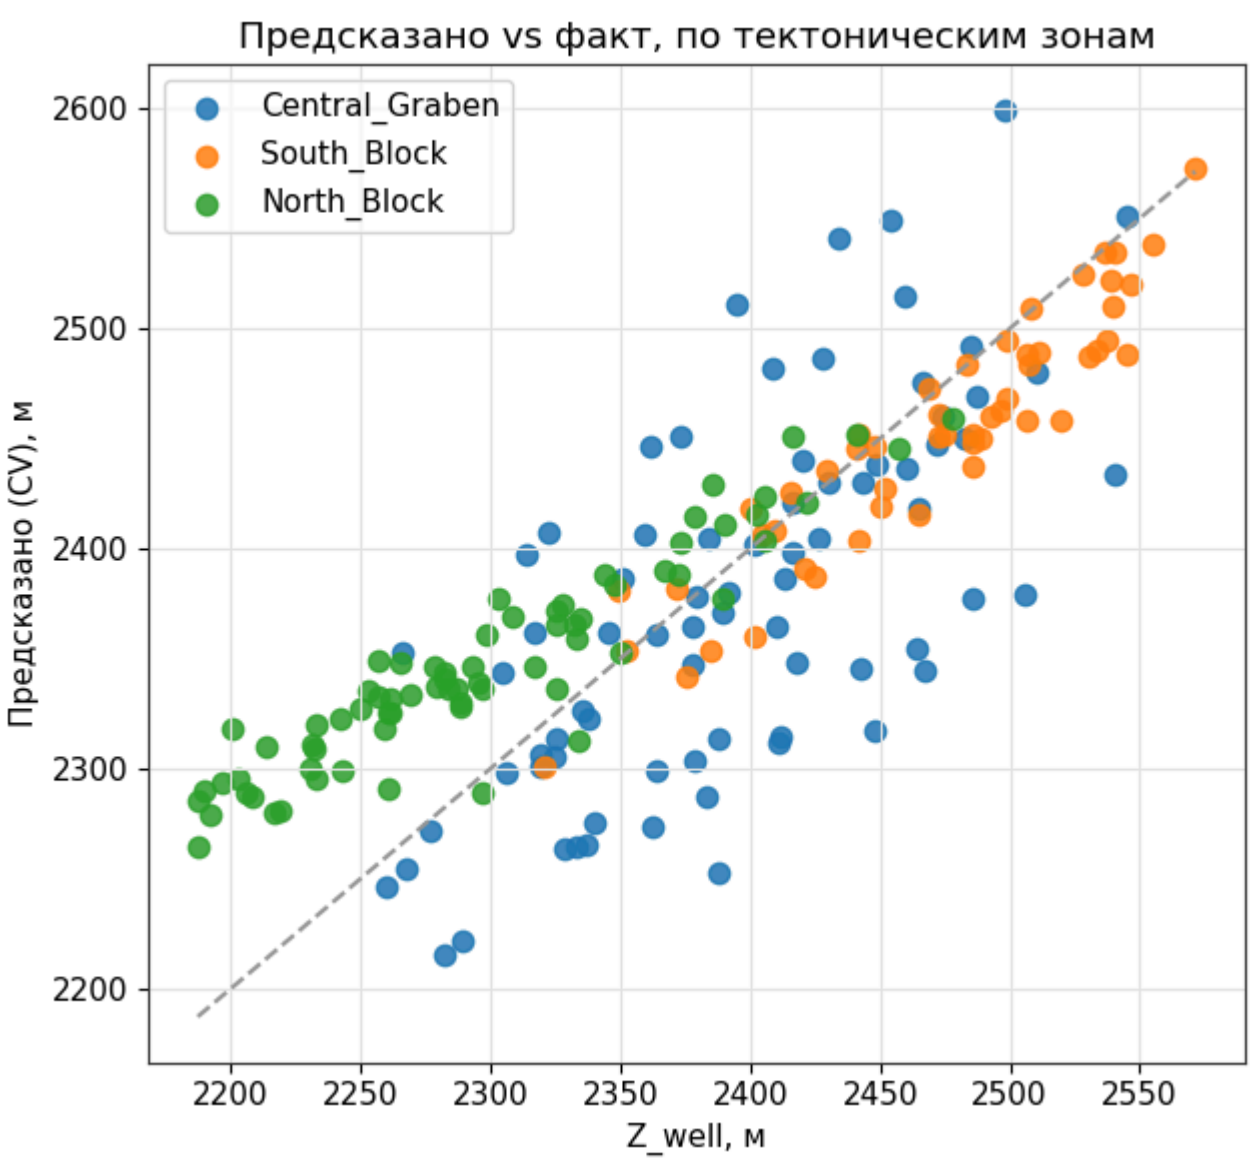
	CV-невязка
Count	200.00
μ (mean)	-0.10
median	-5.00
mode	-108.74
σ (std)	42.19
variance	1780.08
CV, %	-41520.12
min	-108.74
Q05	-65.43
Q25	-24.91
Q75	23.68
Q95	81.85
max	123.71
range	232.46
IQR	48.59
IQR lower bound	-97.79
IQR upper bound	96.56

```
выбросы по методам: {'sigma': 14, 'IQR': 8, 'modified z': 0, 'P05–P95': 20}
```

Разбор по фолдам и тектоническим зонам (Шаг 2, детально)

In [29]:
```
strat_name = next((k for k in results if k.startswith("Stratified by ")), None)
if strat_name is not None:
    results[strat_name]["folds"]
else:
    print("Stratified by ... пропущена: нет колонки зоны с двумя и более значениями")
```

In [30]:
```
strat_name = next((k for k in results if k.startswith("Stratified by ")), None)
if strat_name is not None:
    fig, ax = plt.subplots(figsize=(6.5, 6))
    preds = results[strat_name]["preds"]
    zones = df["tectonic_zone"]
    for i, zone in enumerate(zones.unique()):
        m = (zones == zone).to_numpy()
        ax.scatter(df.loc[m, "Zprm_well"], preds[m], label=str(zone), s=55, alpha=.85,
                   color=plt.cm.tab10.colors[i % 10])
    lo, hi = df["Zprm_well"].min(), df["Zprm_well"].max()
    ax.plot([lo, hi], [lo, hi], "--", color="#999")
    ax.set_xlabel("Z_well, м"); ax.set_ylabel("Предсказано (CV), м")
    ax.legend(); ax.set_title("Предсказано vs факт, по тектоническим зонам")
    plt.tight_layout()
    plt.show()
```



In [31]:
```
comparison[["rmse_fold_mean", "rmse_fold_median", "rmse_fold_min",
            "rmse_fold_max", "rmse_fold_std", "rmse_fold_range"]].round(2)
```

Out[31]:

CV scheme	rmse_fold_mean	rmse_fold_median	rmse_fold_min	rmse_fold_max	rmse_fold_std	rmse_fold_range
Random K-Fold	41.99	42.97	37.85	45.88	3.15	8.03
Random K-Fold (buffered)	42.44	43.33	38.69	46.24	3.09	7.56
Leave-One-Well-Out	32.95	25.23	2.32	118.58	27.13	116.26
Block CV	40.17	41.76	20.04	65.81	17.10	45.78
Buffered CV	40.17	41.76	20.04	65.81	17.10	45.78
Leave-P-Out	42.80	44.07	24.84	56.81	7.43	31.97
Spatial Leave-P-Out	43.26	32.88	9.03	81.53	20.68	72.50
Stratified by tectonic_zone	50.53	59.29	28.74	63.56	18.99	34.82
Distance-based exclusion CV	41.30	33.46	0.35	130.91	32.35	130.55

Наблюдение: зона, которая даёт систематически больший разброс, — кандидат на проблему скоростной модели или зону разломов / потери когерентности сейсмики. Конкретная зона зависит от данных; проверьте по таблице выше.

Выбросы в кросс-валидации (LOWO)

In [32]:
```
preds_lowo = results["Leave-One-Well-Out"]["preds"]
cv_resid = df["Zprm_well"].to_numpy() - preds_lowo      # PARAM_1 – Predicted (как на графике CV-невязок)
cv_masks = detect_outliers(cv_resid)
print({k: int(v.sum()) for k, v in cv_masks.items()})

sel = cv_masks["sigma"]
out_cv = df.loc[sel, ["well_id", "X_coord", "Y_coord", "Zprm_well"]].copy()
out_cv["Predicted_LOWO"] = preds_lowo[sel]
out_cv["Residual"] = cv_resid[sel]
out_cv
```

```
{'sigma': 14, 'IQR': 8, 'modified z': 0, 'P05–P95': 20}
```

Out[32]:

	well_id	X_coord	Y_coord	Zprm_well	Predicted_LOWO	Residual
30	W-016	6642.0	7529.8	2410.58	2324.527541	86.052459
36	W-019	7466.2	4189.0	2540.63	2431.621877	109.008123
37	W-019	7466.2	4189.0	2485.79	2382.336520	103.453480
45	W-023	7350.5	7930.2	2322.59	2410.808107	-88.218107
50	W-026	6178.7	2264.2	2433.75	2531.055580	-97.305580
51	W-026	6178.7	2264.2	2395.04	2503.942247	-108.902247
56	W-029	7550.7	1794.1	2505.89	2383.342831	122.547169
57	W-029	7550.7	1794.1	2467.49	2353.022257	114.467743
60	W-031	5962.5	9481.2	2314.11	2401.876846	-87.766846
61	W-031	5962.5	9481.2	2265.75	2362.143151	-96.393151
94	W-048	6493.7	4300.0	2442.24	2354.002132	88.237868
100	W-051	4335.2	2510.0	2447.70	2328.314658	119.385342
101	W-051	4335.2	2510.0	2387.89	2270.897212	116.992788
184	W-093	5612.8	389.9	2463.77	2362.005842	101.764158

*** к содержанию**

Шаг 3: Диагностика по категориям

Та же пара параметров, но по любой категориальной колонке: тектоническая зона, горизонт, флаг качества.

In [33]:
```
cat_cols = [c for c in ["tectonic_zone", "horizon_id", "well_category",
                        "reservoir_flag", "fluid_type", "quality_flag"] if c in df.columns]
for col in cat_cols:
    rows = []
    for k, s in df.groupby(col):
        r = s["Zprm_well"] - s["Zprm_map"]
        rows.append({col: k, "n": len(s), "RMSE, м": np.sqrt((r ** 2).mean()),
                     "Bias, м": r.mean()})
    print(f"--- по {col} ---")
    print(pd.DataFrame(rows).round(2).to_string(index=False), "\n")
```

```
--- по tectonic_zone ---
 tectonic_zone  n  RMSE, м  Bias, м
Central_Graben 76    65.12    16.68
   North_Block 72    25.18    -1.36
   South_Block 52    25.31     2.66

--- по horizon_id ---
   horizon_id   n  RMSE, м  Bias, м
Top_Reservoir 100    44.43     6.93
     Top_Seal 100    45.15     6.15

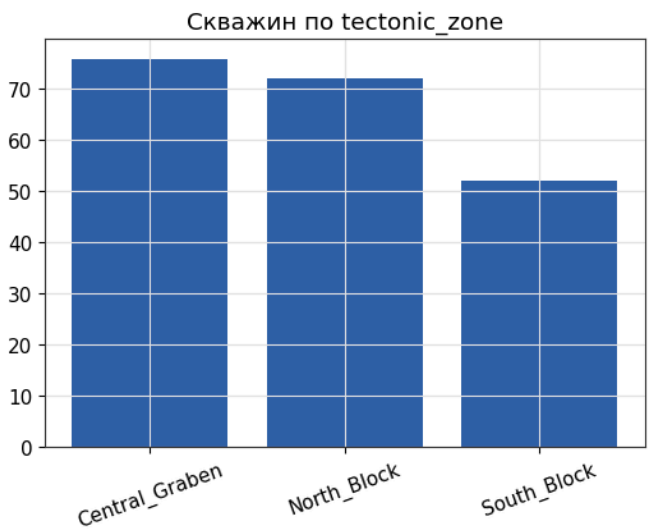
--- по well_category ---
well_category   n  RMSE, м  Bias, м
    appraisal  44    61.06    22.10
  exploration  22    22.81    -0.72
   production 134    41.05     2.62

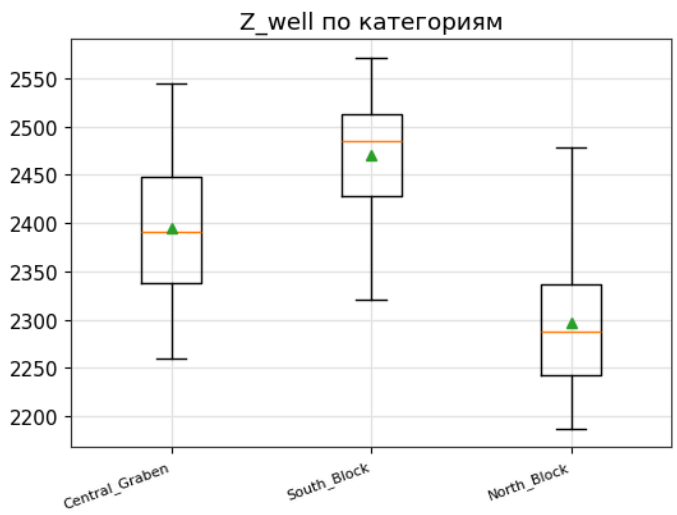
--- по reservoir_flag ---
reservoir_flag   n  RMSE, м  Bias, м
 non_reservoir  58    46.45     8.42
     reservoir 142    44.10     5.77

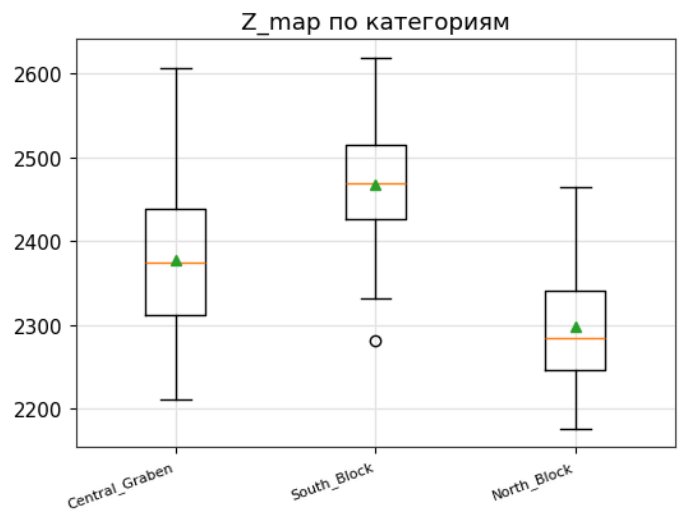
--- по fluid_type ---
   fluid_type  n  RMSE, м  Bias, м
          gas 26    31.55    18.68
non_reservoir 58    46.45     8.42
          oil 66    48.35     6.21
        water 50    43.80    -1.53
```

In [34]:
```
for col in [c for c in ["tectonic_zone", "well_category", "reservoir_flag", "fluid_type"] if c in df.columns]:
    cats = list(df[col].dropna().unique())
    fig, axes = plt.subplots(1, 3, figsize=(16, 4.4))
    cnt = df[col].value_counts()
    axes[0].bar(cnt.index.astype(str), cnt.values, color=BLUE)
    axes[0].set_title(f"Скважин по {col}")
    for ax, pcol, lbl in [(axes[1], "Zprm_well", "Z_well"), (axes[2], "Zprm_map", "Z_map")]:
        ax.boxplot([df.loc[df[col] == c, pcol] for c in cats], showmeans=True)
        ax.set_xticks(range(1, len(cats) + 1))
        ax.set_xticklabels([str(c) for c in cats], rotation=20, ha="right", fontsize=8)
        ax.set_title(f"{lbl} по категориям")
    axes[0].tick_params(axis="x", rotation=20)
    plt.tight_layout(); plt.show()
```

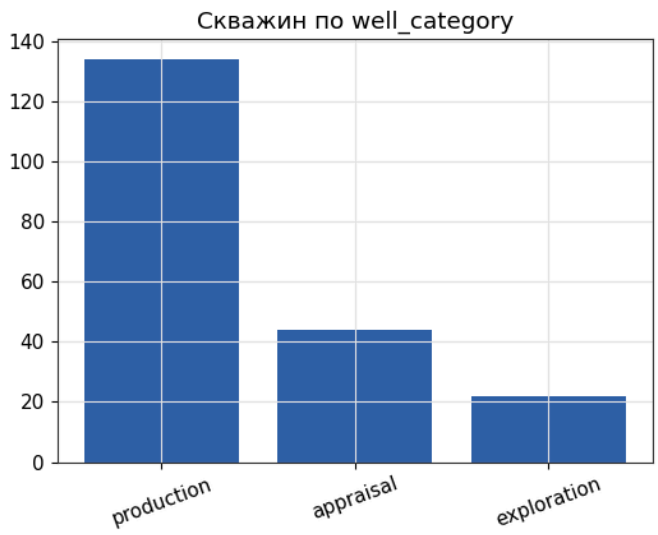
```
stat_rows = []
for c in cats:
    s = df[df[col] == c]
    stat_rows.append({col: c, "n": len(s),
                      "Z_well μ": s["Zprm_well"].mean(), "Z_well σ": s["Zprm_well"].std(ddof=1),
                      "Z_map μ": s["Zprm_map"].mean(), "Z_map σ": s["Zprm_map"].std(ddof=1)})
display(pd.DataFrame(stat_rows).round(2))
```

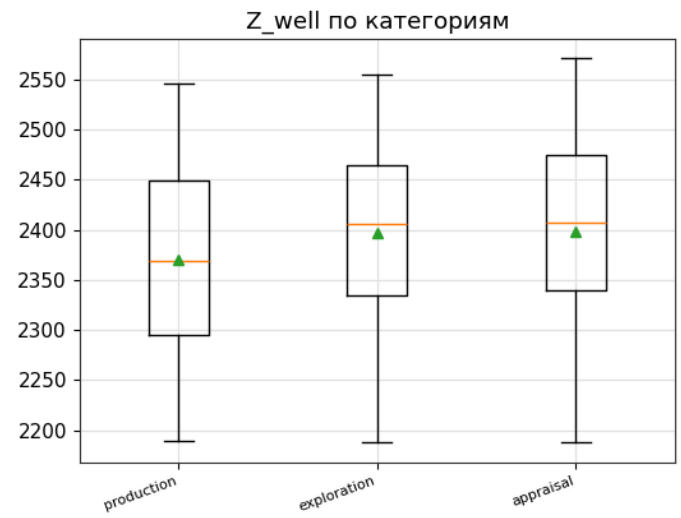


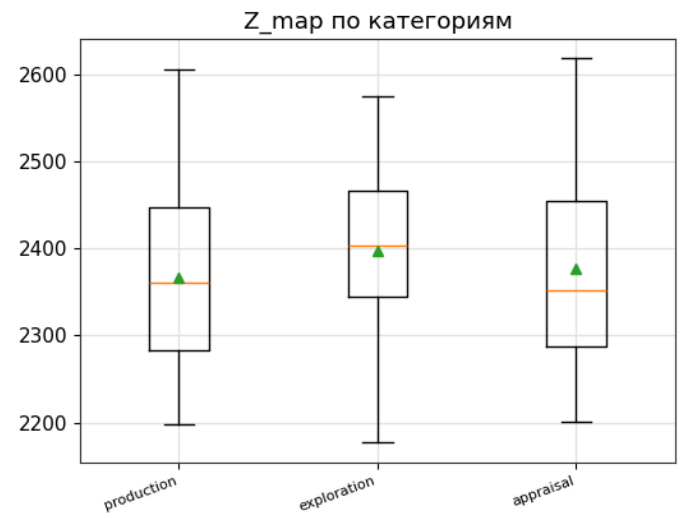




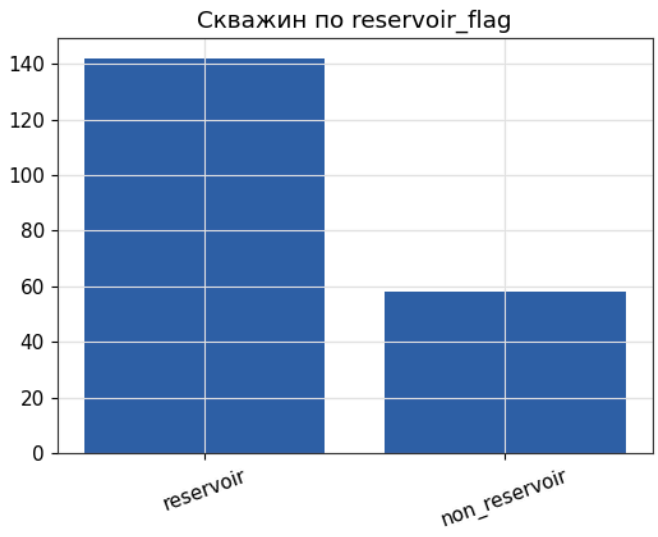
	tectonic_zone	n	Z_well μ	Z_well σ	Z_map μ	Z_map σ
0	Central_Graben	76	2394.35	68.52	2377.67	87.11
1	South_Block	52	2470.54	60.04	2467.88	70.04
2	North_Block	72	2296.71	71.54	2298.08	70.06

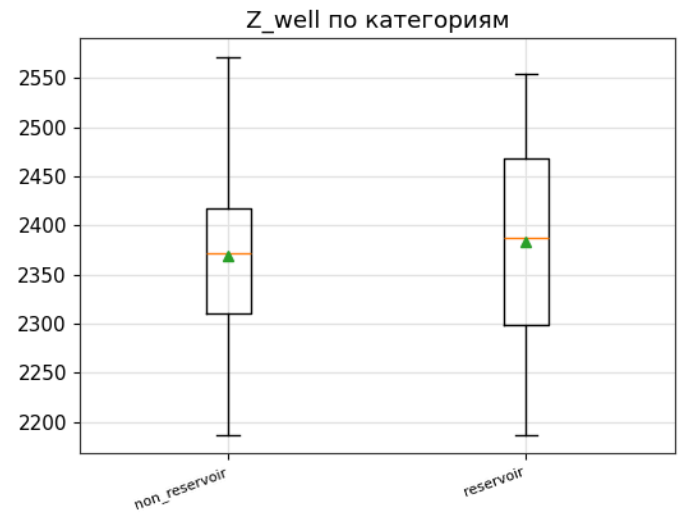


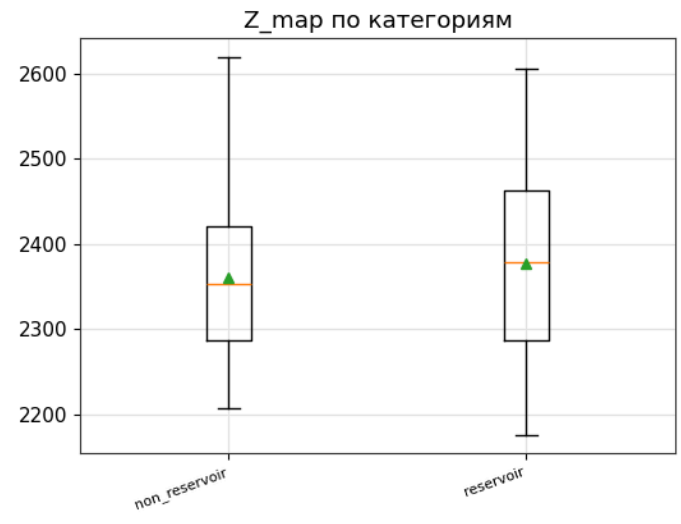




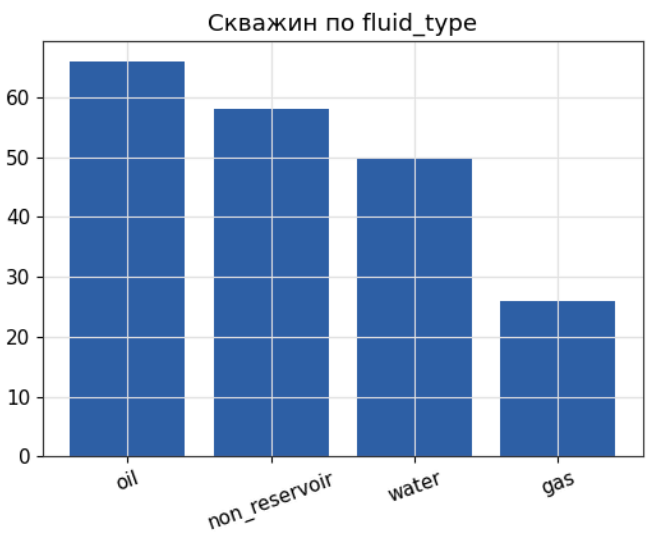
	well_category	n	Z_well μ	Z_well σ	Z_map μ	Z_map σ
0	production	134	2369.69	93.32	2367.07	99.47
1	exploration	22	2396.73	101.00	2397.45	101.23
2	appraisal	44	2398.54	100.32	2376.44	106.98

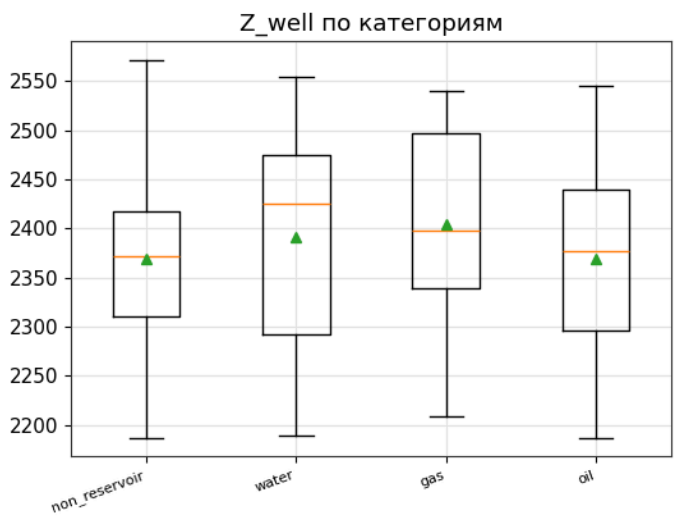


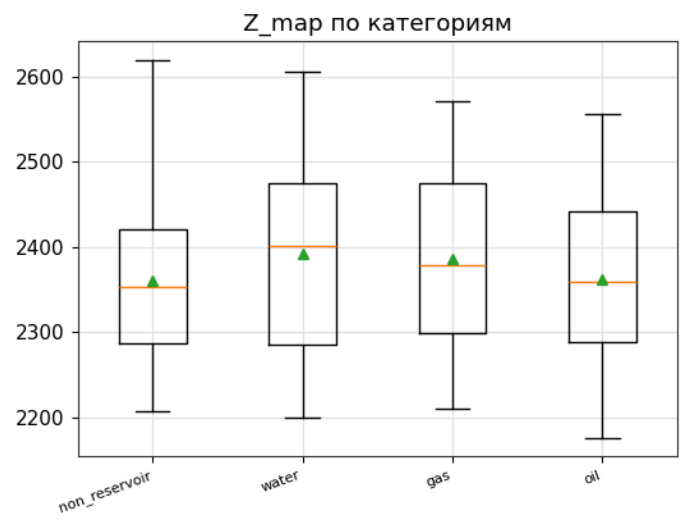




	reservoir_flag	n	Z_well μ	Z_well σ	Z_map μ	Z_map σ
0	non_reservoir	58	2368.96	84.49	2360.54	94.59
1	reservoir	142	2383.11	100.54	2377.34	103.83



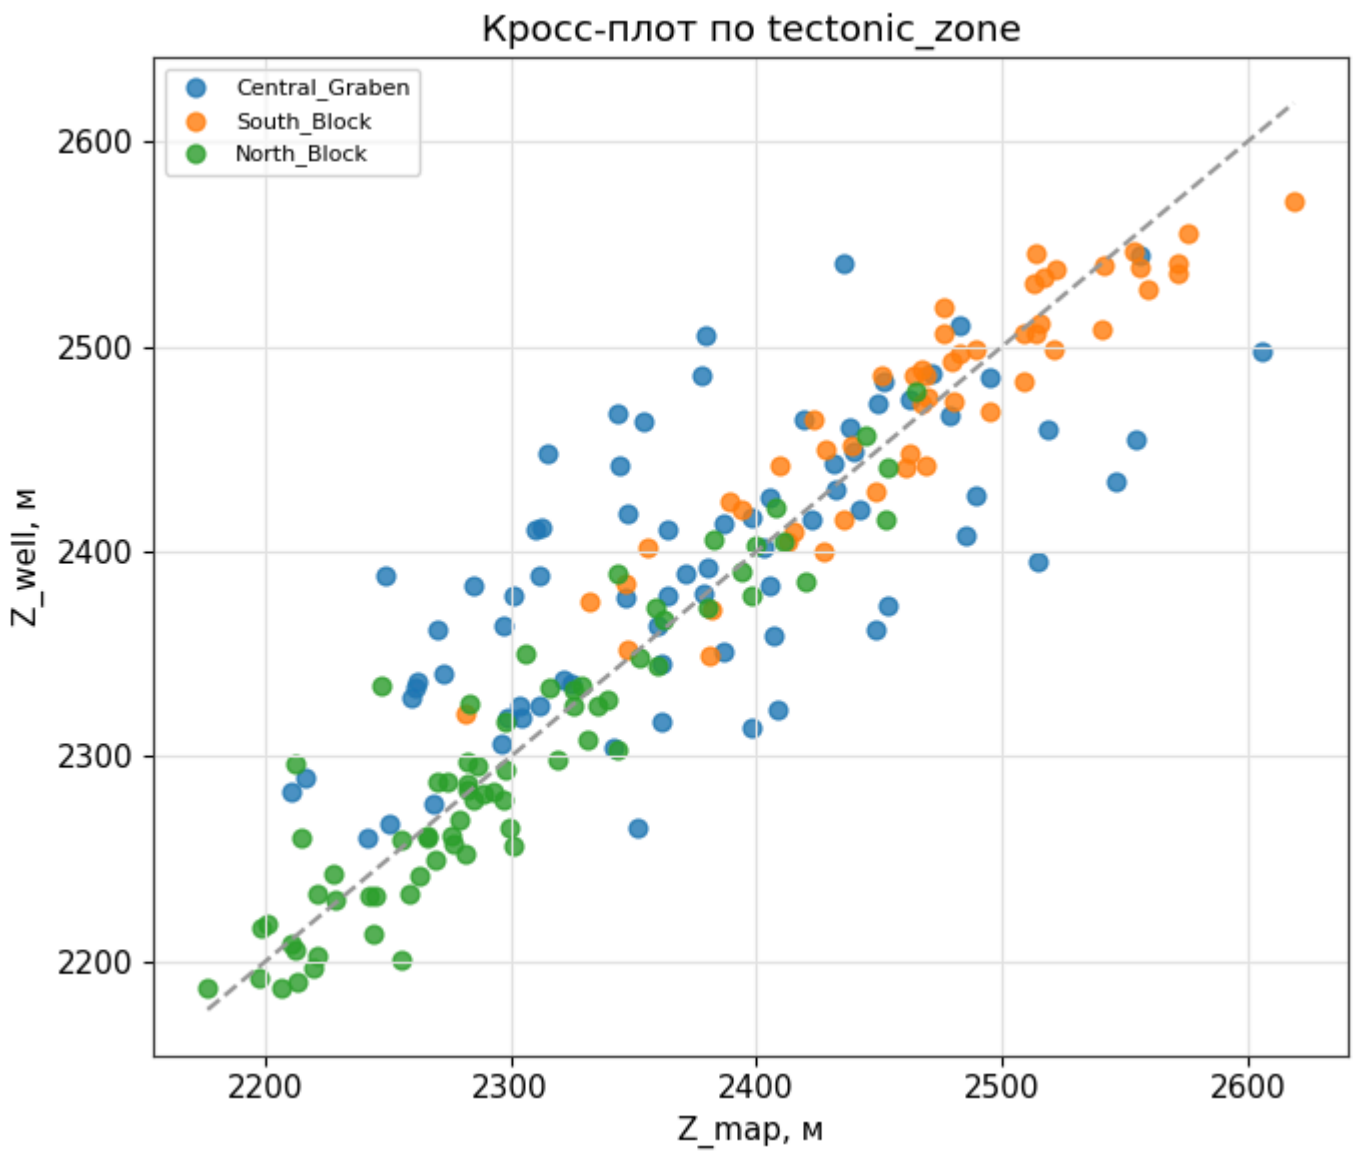




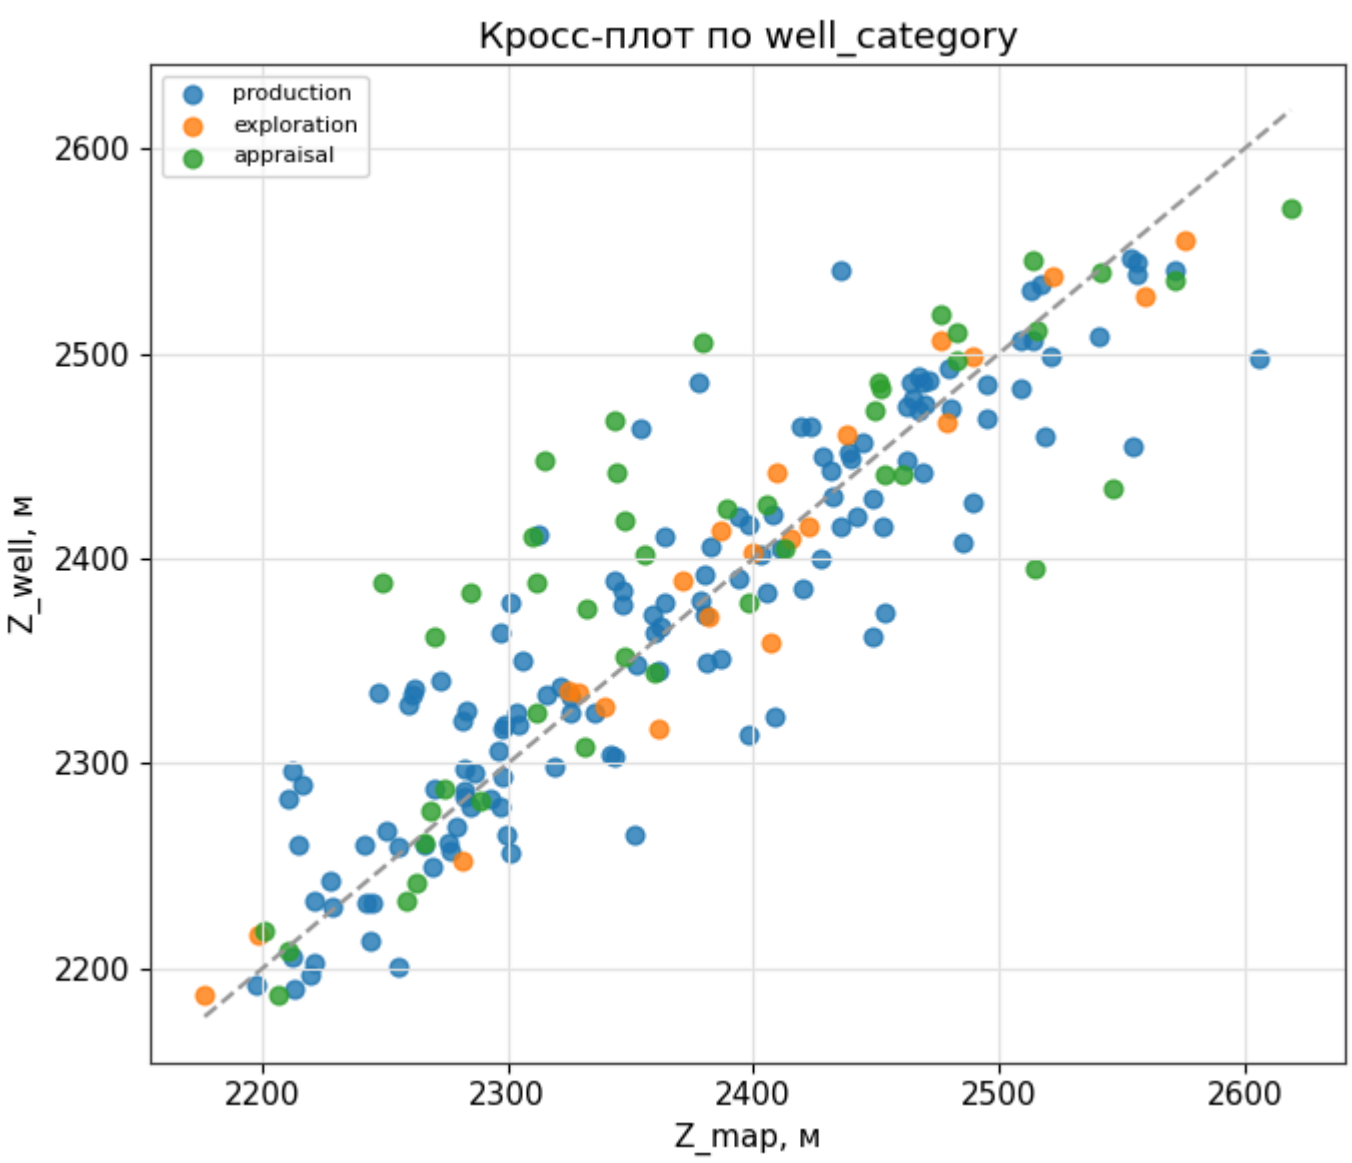
	fluid_type	n	Z_well μ	Z_well σ	Z_map μ	Z_map σ
0	non_reservoir	58	2368.96	84.49	2360.54	94.59
1	water	50	2390.78	108.53	2392.31	112.35
2	gas	26	2404.51	98.10	2385.82	102.94
3	oil	66	2368.88	94.41	2362.67	96.83

In [35]:
```
for col in [c for c in ["tectonic_zone", "well_category"] if c in df.columns]:
    cats = list(df[col].dropna().unique())
    fig, ax = plt.subplots(figsize=(7, 6))
    for i, c in enumerate(cats):
        m = (df[col] == c).to_numpy()
        ax.scatter(df.loc[m, "Zprm_map"], df.loc[m, "Zprm_well"], s=40, alpha=.8,
                   color=plt.cm.tab10.colors[i % 10], label=str(c))
    lo_, hi_ = min(df["Zprm_map"].min(), df["Zprm_well"].min()), max(df["Zprm_map"].max(), df["Zprm_well"].max())
    ax.plot([lo_, hi_], [lo_, hi_], "--", color="#999")
    ax.set_xlabel("Z_map, м"); ax.set_ylabel("Z_well, м"); ax.legend(fontsize=8)
    ax.set_title(f"Кросс-плот по {col}")
    plt.tight_layout(); plt.show()

    rows = []
    for c in cats:
        d = df[df[col] == c]
        if len(d) < 3:
            continue
        s = sq.compute_fit_stats(d["Zprm_map"].to_numpy(float), d["Zprm_well"].to_numpy(float), "Linear")
        rows.append({col: c, "n": len(d), "R²_fit": s.r2, "RMSE, м": s.rmse,
                     "Bias, м": s.bias, "Уравнение": s.equation})
    print(f"--- линейная аппроксимация по {col} ---")
    print(pd.DataFrame(rows).round(3).to_string(index=False), "\n")
```

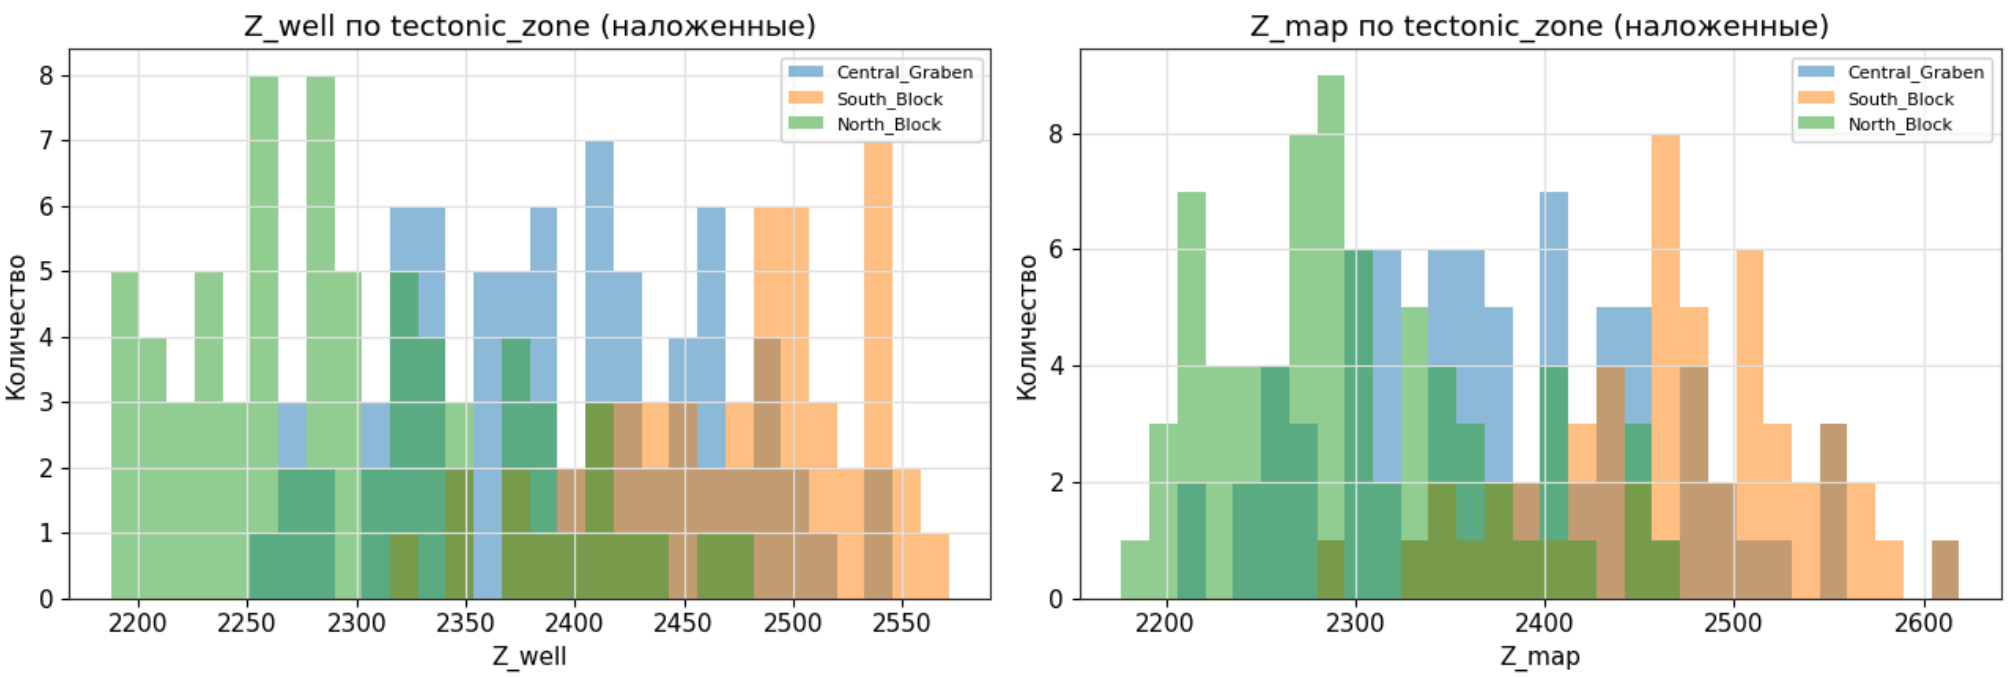


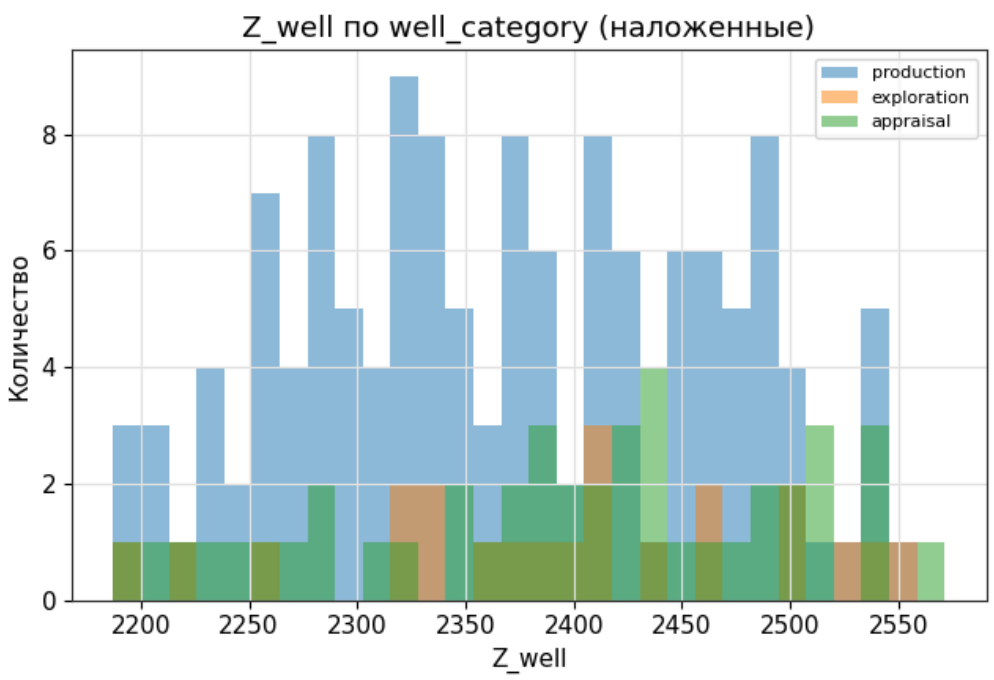

```
--- линейная аппроксимация по tectonic_zone ---
 tectonic_zone  n  R²_fit  RMSE, м  Bias, м                 Уравнение
Central_Graben 76   0.480   49.101      0.0 y = 0.54479·x + 1099.01861
   South_Block 52   0.874   21.079     -0.0  y = 0.80159·x + 492.31443
   North_Block 72   0.877   24.954     -0.0   y = 0.95601·x + 99.72282
```

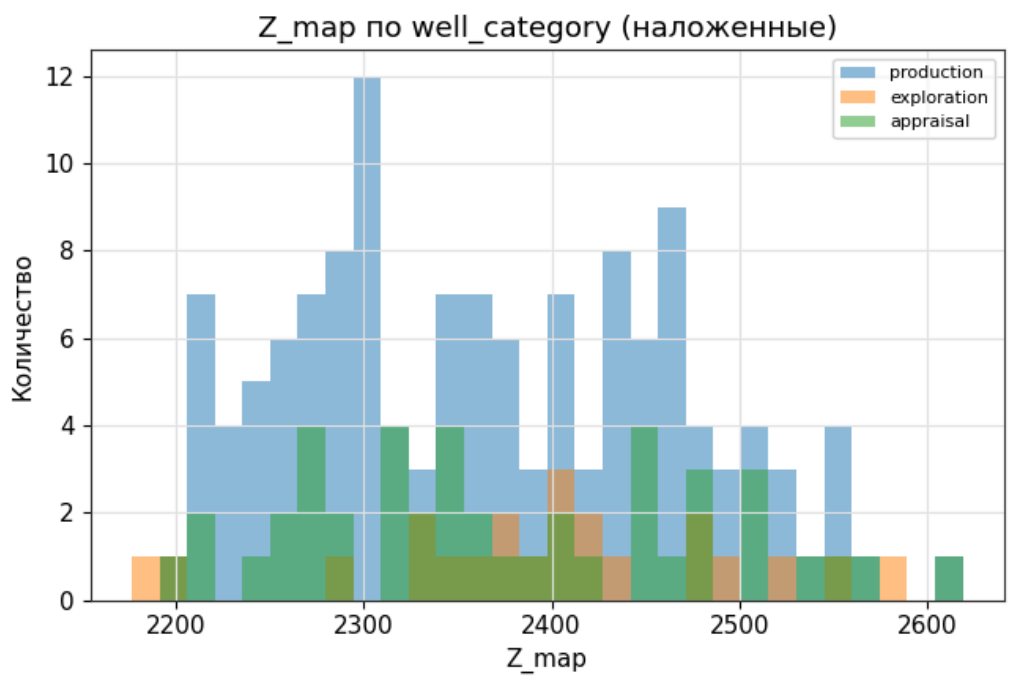



```
--- линейная аппроксимация по well_category ---
well_category   n  R²_fit  RMSE, м  Bias, м                Уравнение
   production 134   0.830   38.346      0.0 y = 0.85460·x + 346.79155
  exploration  22   0.947   22.616      0.0  y = 0.97115·x + 68.46079
    appraisal  44   0.718   52.622      0.0 y = 0.79483·x + 509.68208
```

In [36]:
```python
for col in [c for c in ["tectonic_zone", "well_category"] if c in df.columns]:
    cats = list(df[col].dropna().unique())
    fig, axes = plt.subplots(1, 2, figsize=(13, 4.5))
    for ax, pcol, lbl in [(axes[0], "Zprm_well", "Z_well"), (axes[1], "Zprm_map", "Z_map")]:
        edges = np.histogram_bin_edges(df[pcol].dropna(), bins=30)   # общие интервалы для всех категорий
        for i, c in enumerate(cats):
            part = df.loc[df[col] == c, pcol].dropna()
            if part.empty:
                continue
            ax.hist(part, bins=edges, alpha=.5, label=str(c), color=plt.cm.tab10.colors[i % 10])
        ax.set_title(f"{lbl} по {col} (наложенные)")
        ax.set_xlabel(lbl); ax.set_ylabel("Количество")
        ax.legend(fontsize=8)
    plt.tight_layout(); plt.show()
```







*** к содержанию**

Шаг 4: Фильтрация скважин

Проверяем устойчивость результата к сокращению выборки. В приложении доступны четыре режима:

- ручное исключение конкретных `well_id` (мультиселект);
- случайное исключение заданного процента (0–95%, с пересэмплированием);
- выделение точек кликом на cross-plot (Shift+клик, рамка Box, лассо Lasso), с кнопками «Применить исключение» и «Сбросить всё»;
- без фильтра.

В ноутбуке интерактивное выделение не воспроизводится, поэтому имитируем рамку: исключаем скважины, попадающие в заданный диапазон Z_well.

In [37]:
```
rng = np.random.default_rng(42)
wells = df["well_id"].unique()

manual_excl = list(wells[:5])                                    # ручной список
random_excl = list(rng.choice(wells, size=int(0.2 * len(wells)), replace=False))  # 20 %
z_lo, z_hi = df["Zprm_well"].quantile([0.8, 1.0])
box_excl = list(df.loc[df["Zprm_well"].between(z_lo, z_hi), "well_id"].unique())  # «рамка»

def row(name, d):
    s = sq.basic_crossplot_stats(d)
    return {"сценарий": name, "n": s.n, "R²_lin": s.r2, "slope": s.slope,
            "RMSE, м": s.rmse, "Bias, м": s.bias, "p-value": s.p_value}

scen = [
    row("Без фильтра", df),
    row("Ручное: 5 скважин", df[~df["well_id"].isin(manual_excl)]),
    row("Случайно: 20 %", df[~df["well_id"].isin(random_excl)]),
    row("Рамка: верхние 20 % по Z_well", df[~df["well_id"].isin(box_excl)]),
]
pd.DataFrame(scen).round(3)
```

Out[37]:

	сценарий	n	R²_lin	slope	RMSE, м	Bias, м	p-value
0	Без фильтра	200	0.810	0.855	44.792	6.538	0.0
1	Ручное: 5 скважин	190	0.801	0.852	45.543	6.435	0.0
2	Случайно: 20 %	160	0.803	0.863	45.523	4.865	0.0
3	Рамка: верхние 20 % по Z_well	148	0.696	0.779	45.158	5.837	0.0

In [38]:
```
stab = []
for seed in range(1, 6):
    r = np.random.default_rng(seed)
    excl = list(r.choice(wells, size=int(0.2 * len(wells)), replace=False))
    s = sq.basic_crossplot_stats(df[~df["well_id"].isin(excl)])
    stab.append({"seed": seed, "n": s.n, "R²_lin": s.r2, "slope": s.slope,
                 "RMSE, м": s.rmse, "Bias, м": s.bias})
stab = pd.DataFrame(stab)
display(stab.round(3))
print("Сводка по 5 наборам (по 20 % скважин исключено):")
stab[["R²_lin", "slope", "RMSE, м", "Bias, м"]].agg(["mean", "std", "min", "max"]).round(3)
```

	seed	n	R^2_lin	slope	RMSE, м	Bias, м
0	1	160	0.819	0.853	44.324	10.973
1	2	160	0.802	0.853	45.200	7.527
2	3	160	0.809	0.858	44.638	10.497
3	4	160	0.806	0.856	44.584	7.058
4	5	160	0.818	0.894	43.675	11.107

```
Сводка по 5 наборам (по 20 % скважин исключено):
```

Out[38]:

	R^2_lin	slope	RMSE, м	Bias, м
mean	0.811	0.863	44.484	9.433
std	0.008	0.018	0.554	1.974
min	0.802	0.853	43.675	7.058
max	0.819	0.894	45.200	11.107

In [39]:
```
after = df[~df["well_id"].isin(random_excl)]
rows = []
for label, d in [("до фильтрации", df), ("после: случайно 20 %", after)]:
    xx = d["Zprm_map"].to_numpy(float)
    yy = d["Zprm_well"].to_numpy(float)
    for a in ["Linear", "Polynomial Degree 5", "LOWESS"]:
        s = sq.compute_fit_stats(xx, yy, a)
        rows.append({"набор": label, "n": len(d), "кривая": a, "R²_fit": s.r2,
                     "RMSE": s.rmse, "MAE": s.mae, "Bias": s.bias, "MAPE, %": s.mape_pct})
pd.DataFrame(rows).round(3)
```

Out[39]:

	набор	n	кривая	R^2_fit	RMSE	MAE	Bias	MAPE, %
0	до фильтрации	200	Linear	0.810	41.804	31.825	-0.000	1.342
1	до фильтрации	200	Polynomial Degree 5	0.818	40.980	31.256	-0.000	1.316
2	до фильтрации	200	LOWESS	0.813	41.536	30.193	-3.491	1.269
3	после: случайно 20 %	160	Linear	0.803	43.096	31.799	0.000	1.341
4	после: случайно 20 %	160	Polynomial Degree 5	0.815	41.837	31.207	-0.000	1.314
5	после: случайно 20 %	160	LOWESS	0.808	42.577	30.139	-3.758	1.267

Сравнивайте не только RMSE, но и изменение наклона и Bias: если они заметно «плывут» при исключении нескольких скважин, результат зависит от отдельных наблюдений.

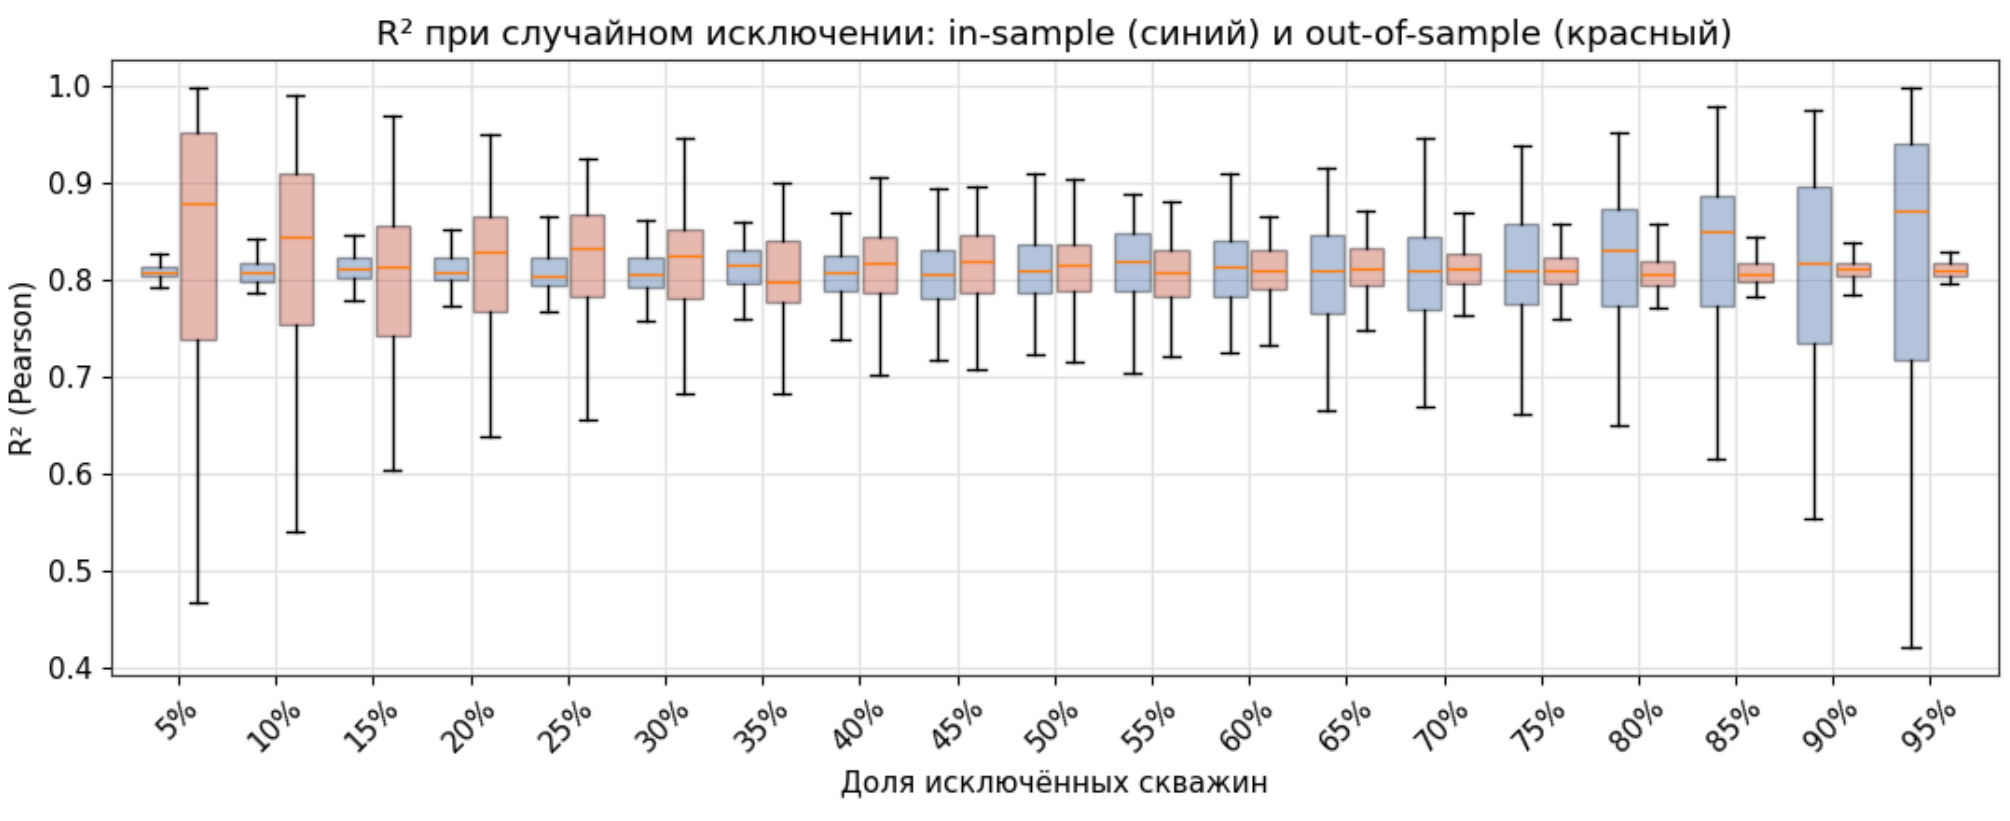
Шаг 4.5: серия случайного исключения

Для каждого уровня исключения от 5% до 95% (шаг 5%) формируется заданное число случайных наборов скважин. Для каждого набора считаются R^2 (Pearson): in-sample — по оставшимся скважинам, out-of-sample — линия по оставшимся, R^2 по исключённым. Здесь для краткости 100 наборов на уровень (в приложении по умолчанию 500, диапазон 50–2000).

In [40]:
```
lvl_long, lvl_summary = sq.random_exclusion_series(df, n_repeats=100, seed=42)
display(lvl_summary[["mode", "level_pct", "n_excluded", "n_remaining", "n_sets", "status", "median"]].round(3))
```

	mode	level_pct	n_excluded	n_remaining	n_sets	status	median
0	in	5	5	95	100	ok	0.808
1	out	5	5	95	100	ok	0.879
2	in	10	10	90	100	ok	0.807
3	out	10	10	90	100	ok	0.843
4	in	15	15	85	100	ok	0.812
5	out	15	15	85	100	ok	0.813
6	in	20	20	80	100	ok	0.808
7	out	20	20	80	100	ok	0.828
8	in	25	25	75	100	ok	0.803
9	out	25	25	75	100	ok	0.832
10	in	30	30	70	100	ok	0.805
11	out	30	30	70	100	ok	0.825
12	in	35	35	65	100	ok	0.815
13	out	35	35	65	100	ok	0.799
14	in	40	40	60	100	ok	0.807
15	out	40	40	60	100	ok	0.816
16	in	45	45	55	100	ok	0.805
17	out	45	45	55	100	ok	0.819
18	in	50	50	50	100	ok	0.810
19	out	50	50	50	100	ok	0.814
20	in	55	55	45	100	ok	0.819
21	out	55	55	45	100	ok	0.808
22	in	60	60	40	100	ok	0.813
23	out	60	60	40	100	ok	0.810
24	in	65	65	35	100	ok	0.810
25	out	65	65	35	100	ok	0.812
26	in	70	70	30	100	ok	0.808
27	out	70	70	30	100	ok	0.812
28	in	75	75	25	100	ok	0.810
29	out	75	75	25	100	ok	0.809
30	in	80	80	20	100	ok	0.831
31	out	80	80	20	100	ok	0.806
32	in	85	85	15	100	ok	0.849
33	out	85	85	15	100	ok	0.806
34	in	90	90	10	100	ok	0.816
35	out	90	90	10	100	ok	0.812
36	in	95	95	5	100	ok	0.870
37	out	95	95	5	100	ok	0.809

In [41]:
```
levels = sorted(lvl_long["level_pct"].unique())
pos = np.arange(len(levels))
fig, ax = plt.subplots(figsize=(11, 4.5))
for col, colr, shift in [("r2_in", BLUE, -0.2), ("r2_out", RED, 0.2)]:
    data = [lvl_long.loc[lvl_long["level_pct"] == L, col].dropna().to_numpy() for L in levels]
    bp = ax.boxplot(data, positions=pos + shift, widths=0.35, patch_artist=True, showfliers=False)
    for b in bp["boxes"]:
        b.set_facecolor(colr); b.set_alpha(.35)
ax.set_xticks(pos); ax.set_xticklabels([f"{L}%" for L in levels], rotation=45)
ax.set_xlabel("Доля исключённых скважин"); ax.set_ylabel("R² (Pearson)")
ax.set_title("R² при случайном исключении: in-sample (синий) и out-of-sample (красный)")
plt.tight_layout(); plt.show()
```



Знак CV-невязки здесь `PARAM_1 - Predicted`, как на графике CV-невязок в приложении и в ячейке выше. Состав выбросов не зависит от знака.

Обобщение: та же процедура для другой пары параметров

Инструмент работает с любой парой числовых параметров. Здесь PARAM_1 = `T_well` (время по скважине), PARAM_2 = `T_map` (время по карте).

In [42]:
```python
if {"T_well", "T_map"}.issubset(df.columns):
    dT = df.dropna(subset=["T_well", "T_map"]).copy()
    dT["Zprm_well"] = dT["T_well"]     # PARAM_1
    dT["Zprm_map"] = dT["T_map"]       # PARAM_2
    sT = sq.basic_crossplot_stats(dT)
    print(f"PARAM_1 = T_well, PARAM_2 = T_map: n = {sT.n}, R²_lin = {sT.r2:.3f}, "
          f"slope = {sT.slope:.3f}, RMSE = {sT.rmse:.2f}, Bias = {sT.bias:+.2f} (ед. измерения колонок)")
else:
    print("В данных нет колонок T_well / T_map — пример обобщения пропущен")
```

```
PARAM_1 = T_well, PARAM_2 = T_map: n = 200, R²_lin = 0.428, slope = 0.545, RMSE = 56.50, Bias = +2.29 (ед. измерения колонок)
```

Выводы

- Существующая карта (`Z_map`) сходится со скважинами с RMSE в первые метры–десятки метров (раздел 3). Это **in-sample** оценка: она не учитывает возможную калибровку карты по тем же скважинам.
- Честная кросс-валидация суррогатной поверхности даёт заметно большую ошибку. Это ожидаемо, так как скважинная интерполяция не воспроизводит детальную структуру, видимую в сейсмике.
- **Random K-Fold систематически оптимистичнее** пространственных схем и не должен использоваться для пространственно коррелированных геологических данных.
- Выбор схемы, зон и выбросов зависит от данных: выводы из разделов 6–10 нужно проверять на реальном наборе скважин.

Тот же движок лежит в основе интерактивного приложения `app_full.py` (Streamlit), где доступны все шаги, выбор аппроксимаций, двуязычный интерфейс RU/EN и выделение точек кликом.

*** к содержанию**
