Structural QC — cross-plot & cross-validation

Название проекта

Structural QC_CV — кросс-плот и кросс-валидация для оценки качества структурных карт по данным скважин.

Описание проекта

Streamlit-инструмент, который сравнивает эталонный параметр PARAM_1 (Z_well) и сравниваемый PARAM_2 (Z_map) в одних и тех же точках — скважинах — и проверяет, насколько один параметр предсказывается по другому. Реализованы Шаги 0–4: загрузка и QC данных, базовый QC-кросс-плот с аппроксимациями, кросс-валидация по девяти схемам с автоматическим выбором лучшей, анализ по категориям и фильтрация скважин. Инструмент обобщён на любые пары числовых параметров. Во всех шагах модель — линейная регрессия (полином степени 1).

Описание данных

Входная таблица CSV/XLSX, в которой каждая строка — пара значений PARAM_1 и PARAM_2 в точке скважины (на горизонт). Обязательные колонки: well_id, X_coord, Y_coord, PARAM_1 (Zprm_well) и PARAM_2 (Zprm_map). Опциональные: horizon_id, tectonic_zone, reservoir_flag (тип коллектора), fluid_type (тип флюида) и любые другие числовые и категориальные колонки. В приложении есть демонстрационные файлы (выбор в сайдбаре) и пример структуры из трёх скважин: well_id, X_coord, Y_coord, Z_well, Z_map, horizon_id, tectonic_zone.

Цели исследования

- Проверить согласованность структурной карты с данными скважин по глубинам горизонта (Z_map относительно Z_well).
- Оценить реальную, а не оптимистичную точность карты с помощью кросс-валидации по схемам, разбивающим данные по скважинам.
- Выявить систематические смещения (Bias, наклон регрессии) и зоны, горизонты или категории, где карта работает хуже.
- Проверить устойчивость результата к сокращению числа скважин, к отдельным наблюдениям и выбросам.

Ход исследования

- Шаг 0 — загрузка данных, QC входных данных, статистика и распределения по всем числовым колонкам, корреляционные матрицы Пирсона и Спирмена.
- Шаг 1 — базовый QC-кросс-плот, аппроксимации (17 типов), распределения, невязки, карта невязок, выбросы.
- Шаг 2 — кросс-валидация по девяти схемам, выбор лучшей по выбранному критерию (по умолчанию score = RMSE + RMSE_fold_std), детальный разбор лучшей схемы.
- Шаг 3 — диагностика по выбранной категориальной колонке.
- Шаг 4 — фильтрация скважин: ручная, случайная по проценту или выделением точек кликом.

Ожидаемые результаты

- Сравнительная таблица ошибок (RMSE, MAE, Bias) по схемам CV и по фолдам с выбором лучшей схемы.
- Оценка смещения и тренда: Bias, наклон и intercept регрессии; тренд невязки от глубины как признак ошибки скоростной модели.
- Карта невязок и список выбросов по четырём правилам с указанием зон систематических ошибок.
- Метрики по категориям и оценка устойчивости результата при фильтрации скважин.
- Вывод о том, на каких участках и горизонтах карте можно доверять, а где её нужно пересмотреть.

Текущая структура кода: app_full.py, app_utils.py, structural_qc_full.py, translations_full.py, ui_examples_full_ru.py, ui_examples_full_en.py.

Постановка задачи

- Типичная задача валидации точности структурной поверхности (карты), построенной по данным МОГТ 2D/3D, против «истины» в скважинах — глубин геологических маркеров.
- Ключевой методологический риск: если скважины использовались при построении карты (калибровка скоростной модели, привязка ВСП, интерполяция/крайгинг с учётом скважинных данных), то проверка качества карты в этих же точках даёт завышенную, оптимистичную оценку — это классическая утечка данных (data leakage), только в геологической форме.
- Оценивается предиктивная модель (регрессия/аппроксимация), связывающая два параметра: эталонный PARAM_1 и сравниваемый PARAM_2. Для структурного QC: PARAM_1 = Z_well (истинная глубина горизонта), PARAM_2 = Z_map (глубина того же горизонта по структурной карте).
- Значения PARAM_2 на каждой итерации кросс-валидации фиксированы (не пересчитываются из данных сейсморазведки заново) — переобучается только модель связи «PARAM_2 → PARAM_1» при исключении скважины или группы скважин из обучающей выборки.

Инструмент реализован обобщённо и применим не только к паре «скважина ↔ карта», а к любой паре числовых параметров:

Сценарий	PARAM_1 (Reference) / PARAM_2 (Compared) — примеры
скважина ↔ карта	Z_well / Z_map, T_well / T_map
скважина ↔ атрибут	Z_well / Amplitude, Phi_well / AVO_Gradient
карта ↔ карта	Z_map_v1 / Z_map_v2 (сравнение версий интерпретации)
атрибут ↔ атрибут	Amplitude / Sweetness (проверка мультиколлинеарности)

Далее по тексту плана Z_well/Z_map используются как сквозной иллюстративный пример (структурный QC), но все шаги и формулы применимы к любой паре PARAM_1/PARAM_2.

Формат данных

Минимальная структура входной таблицы (CSV/XLSX):

Колонка в коде	Роль	Описание
well_id	обязательная	Идентификатор скважины
X_coord, Y_coord	обязательные	Координаты скважины
Zprm_well (= PARAM_1)	обязательная · Reference	Эталонный параметр — то, с чем сравниваем. Для структурного QC: Z_well (истинная глубина маркера).
Zprm_map (= PARAM_2)	обязательная · Compared	Сравниваемый параметр. Для структурного QC: Z_map (глубина по карте).
horizon_id	опциональная	Идентификатор горизонта — позволяет отфильтровать анализ по одному или нескольким горизонтам
tectonic_zone	опциональная	Тектоническая/геологическая зона — используется в Stratified by Zone CV и в Шаге 3
любая другая колонка	опциональная	Любая дополнительная числовая колонка — доступна для корреляционного анализа (Шаг 0); любая категориальная — доступна для анализа по категориям (Шаг 3)

- Единицы измерения PARAM_1 и PARAM_2 задаются пользователем при сопоставлении колонок (например, м, км, мс, м/с и т.п.) — используются только в подписях графиков и таблиц, не влияют на расчёт.
- При загрузке выполняется автоматическая очистка: приведение мусорных значений («NA», «NULL», «—», «?» и т.п.) к NaN, замена запятой на точку в числовых колонках, приведение типов, удаление строк с пропусками в обязательных колонках (с выводом отчёта, сколько строк удалено).

- Опциональные колонки reservoir_flag (тип коллектора) и fluid_type (тип флюида) используются как категориальные признаки для Шага 3 наравне с tectonic_zone.

Метрики кросс-плота и обозначения

Обозначение: x = PARAM_2 (сравниваемое значение), y = PARAM_1 (эталонное значение). В CV-аппроксимациях (Шаг 2) роли заданы осознанно иначе: x = Actual (PARAM_1), y = Predicted — кривая описывает прогноз модели как функцию фактического значения.

Невязка Δ — определяется по-разному в двух местах кода, это важно:

- Базовый QC-кросс-плот (Шаг 1, BasicStats): Δ = y − x = PARAM_1 − PARAM_2. Для структурного QC: Δ = Z_well − Z_map. Положительная Δ ⇒ Z_well > Z_map (карта занижает глубину); отрицательная ⇒ карта завышает глубины.
- Аппроксимации и кросс-валидация (Шаги 1–3, FitStats / fold_metrics): Δ = Predicted − Actual, то есть предсказание модели минус фактическое PARAM_1 — обратный знак по сравнению с базовым QC-кросс-плотом. Графики CV-невязок Шага 2 строятся как Actual − Predicted (PARAM_1 − Predicted), см. раздел «Шаг 2».

Таблица ниже — метрики через Δ. Δ — невязка, её определение зависит от раздела: Шаг 1 (BasicStats): Δ = y − x; аппроксимации, CV и Шаг 4 (FitStats, fold_metrics): Δ = Predicted − Actual; для R^2_lin и R^2 (Pearson) используется Δ_OLS — остаток линейной регрессии, для которого $r^2 = 1 - \Sigma(\Delta_OLS)^2 / \Sigma(y - \bar{y})^2$. Коэффициенты корреляции r и ρ — не R^2 и через Δ не выражаются. $\bar{\Delta}$ — среднее невязки (= Bias).

Метрика	Формула
Коэффициенты корреляции	
Коэффициент корреляции Пирсона r: - Шаг 0: матрицы корреляции и таблицы пар	r = cov(a, b) / ($\sigma_a \cdot \sigma_b$) для любого выбранного набора числовых колонок
Коэффициент корреляции Спирмена ρ: - Шаг 0: матрицы корреляции и таблицы пар	Пирсон на рангах. Любая монотонная связь
R^2_lin (коэффициент детерминации / квадрат корреляции): - Шаг 1: «Метрики кросс-плота» - Шаг 4: до/после фильтрации	$R^2_lin = 1 - \Sigma(\Delta_OLS)^2 / \Sigma(y - \bar{y})^2 = r^2$ (Пирсон, linregress) Δ_OLS = y − (a + b·x), x = PARAM_2, y = PARAM_1; a, b — из linregress
R^2_fit (коэффициент детерминации) : - Шаг 1: таблица аппроксимаций (17 типов, для квантильной — τ = 0.1/0.5/0.9) - Шаг 3: таблица аппроксимаций по категориям - Шаг 4: аппроксимации до/после фильтрации	$R^2_fit = 1 - \Sigma(\Delta)^2 / \Sigma(y - \bar{y})^2$ Δ = Predicted − Actual = model(PARAM_2) − PARAM_1, y = PARAM_1
R^2_fit (CV-аппроксимации): Шаг 2: «Аппроксимации» для лучшей схемы Роли x и y намеренно отличаются от Шага 1: x = Actual (PARAM_1), y = Predicted	$R^2_fit = 1 - \Sigma(\Delta)^2 / \Sigma(y - \bar{y})^2$ Δ = model(Actual) − Predicted, x = Actual (PARAM_1), y = Predicted
R^2 (Pearson, Predicted vs Actual): - Шаг 2: «Метрики кросс-плота» по всем схемам CV и карточка лучшей схемы; - столбец pooled в «Таблице R^2 (Pearson) по фолдам»	R^2 (Pearson) = $1 - \Sigma(\Delta_OLS)^2 / \Sigma(Actual - \bar{Y})^2$ Δ_OLS = Actual − (a + b·Predicted), a, b — OLS по out-of-fold прогнозам; равно corrcoef(Actual, Predicted)²
R^2 (Pearson) по фолдам:	R^2 (Pearson) = $1 - \Sigma(\Delta_OLS)^2 / \Sigma(Actual - \bar{Y})^2$ внутри фолда Δ_OLS = Actual − (a + b·Predicted), a, b — OLS внутри фолда; равно corrcoef² фолда. Нужно не меньше 3 точек и ненулевая дисперсия

- Шаг 2: «Таблица R^2 (Pearson) по фолдам» (r2_fold_*) и boxplot	
R^2 (Actual = Predicted): Шаг 2: «Сравнение схем CV»	R^2 (Actual = Predicted) = $1 - \Sigma(\Delta)^2 / \Sigma(\text{Actual} - \bar{Y})^2$ Δ = Predicted − Actual, $\bar{Y}$ — среднее Actual; по out-of-fold прогнозам
R^2 (Pearson), in-sample и R^2 (Pearson), out-of-sample: - Шаг 4.5	• In-sample: R^2 (Pearson) = $1 - \Sigma(\Delta_OLS)^2 / \Sigma(PARAM_1 - \bar{Y})^2$, $\Delta_OLS = PARAM_1 - (a + b \cdot PARAM_2)$, a, b — OLS по оставшимся скважинам; равно corrcoef(PARAM_2, PARAM_1)² • Out-of-sample: r^2 = corrcoef(PARAM_1, pred)² на исключённых скважинах, pred = a + b·PARAM_2 по оставшимся; через Δ не выражается, так как линия обучена на другой выборке
Ошибки и смещение	
RMSE (среднеквадратичная ошибка)	$RMSE = \sqrt{[\ (1/N) \cdot \Sigma(\Delta)^2\ ]}$
MSE (среднеквадратичная ошибка)	$MSE = (1/N) \cdot \Sigma(\Delta)^2$
MAE (абсолютная погрешность)	$MAE = (1/N) \cdot \Sigma\lvert\Delta\rvert$
Bias (систематическое смещение)	$Bias = (1/N) \cdot \Sigma(\Delta)$
Std (стандартное отклонение невязок)	$Std = \sqrt{[\ (1/(N-1)) \cdot \Sigma(\Delta_i - \bar{\Delta})^2\ ]}$
Variance (дисперсия невязок)	$Var = (1/(N-1)) \cdot \Sigma(\Delta_i - \bar{\Delta})^2$
MAPE, % (средняя абсолютная ошибка в процентах)	$MAPE = (100/N) \cdot \Sigma\ [\ \lvert\Delta\rvert / \max(\lvert y\rvert, 10^{-9})\ ]$
P-value (значимость линейной корреляции)	$t = r \cdot \sqrt{[\ (N-2)/(1-r^2)\ ]}$, $p = 2 \cdot (1 - F_t,N-2(\lvert t\rvert))$
Уравнение линейной регрессии	y = a + b·x; наклон b и intercept a — из linregress

P-value отвечает на вопрос: насколько вероятно получить настолько же сильную (или сильнее) линейную связь между PARAM_1 и PARAM_2 случайно, если на самом деле никакой связи нет (нулевая гипотеза H_0: истинный наклон регрессии b = 0). Чем меньше p-value, тем менее правдоподобно, что найденная зависимость — случайность; порогом значимости обычно считают p < 0.05. Считается только для базового QC-кросс-плота (Шаг 1), через scipy.stats.linregress.

В проекте два разных R^2 — разведены по названию, чтобы не путать. R^2_lin (BasicStats.r2, Шаг 1, базовый QC-кросс-плот) = квадрат коэффициента корреляции Пирсона (scipy.stats.linregress) — корректен только как мера силы *линейной* связи. R^2_fit (FitStats.r2, все 17 типов аппроксимации, Шаги 1–3) = sklearn.metrics.r2_score = $1 - \Sigma(\Delta)^2 / \Sigma(y - \bar{y})^2$, Δ = Predicted − Actual — честная доля объяснённой дисперсии, корректна для кривой любой формы. Для линейной OLS оба совпадают численно, для остальных 16 типов — нет. **Сравнивать R^2_lin и R^2_fit напрямую нельзя — это разные метрики, а не одна и та же величина, посчитанная дважды.**

В Шаге 2 к ним добавляются ещё два варианта: R^2 (Actual = Predicted) — формула R^2_fit (sklearn r2_score), применённая к out-of-fold прогнозам кросс-валидации, и R^2 (Pearson, Predicted vs Actual) — квадрат корреляции Пирсона между прогнозом и фактом (linregress). Оба считаются по прогнозам кросс-валидации и не равны R^2_lin базового кросс-плота.

Коэффициенты линейной регрессии (наклон / intercept) показывают систематический тренд — например, «карта занижает глубину с ростом глубины» (b < 1) — типичный признак ошибки скоростной модели.

Статистика параметров (Шаг 0)

Для PARAM_1 и PARAM_2 отдельно считается расширенная описательная статистика:

Статистика	**Формула / определение**
Count	N — число непустых значений
μ (mean)	$\mu = (1/N) \cdot \Sigma x_i$ — среднее арифметическое

median	медиана — значение, делящее выборку пополам (50-й перцентиль)
mode	мода — наиболее часто встречающееся значение
σ (std)	$\sigma = \sqrt{[\ (1/(N-1))\cdot\Sigma(x_i-\mu)^2\ ]}$
variance	$\sigma^2 = (1/(N-1))\cdot\Sigma(x_i-\mu)^2$
CV, %	$(\sigma/\mu)\cdot 100\%$ — коэффициент вариации (разброс относительно среднего)
min	минимальное значение
Q05	5-й перцентиль
Q25	25-й перцентиль (первый квартиль)
Q75	75-й перцентиль (третий квартиль)
Q95	95-й перцентиль
max	максимальное значение
range	max − min
IQR	Q75 − Q25 — межквартильный размах

Типы линий аппроксимации

На кросс-плоте, помимо базовой линейной регрессии, доступен выбор из 17 вариантов аппроксимации (10 полиномов 1–10 степени + 7 прочих методов) и квантильной регрессии (τ = 0.1 / 0.5 / 0.9), которая выводится отдельными строками:

Метод	**Общий вид уравнения**	**Пример**
Линейная	$y = a + b\cdot x$	$y = 12.4 + 0.85\cdot x$
Квадратичная	$y = a + b\cdot x + c\cdot x^2$	$y = 5.1 + 0.62\cdot x + 0.014\cdot x^2$
Кубическая	$y = a + b\cdot x + c\cdot x^2 + d\cdot x^3$	$y = 3.7 + 0.41\cdot x + 0.021\cdot x^2 - 0.0006\cdot x^3$
Полином n-й степени (4–10)	$y = a_0 + a_1\cdot x + a_2\cdot x^2 + \ldots + a_n\cdot x^n$	n=4: $y = 2.0 + 0.30\cdot x + 0.05\cdot x^2 - 0.002\cdot x^3 + 0.00004\cdot x^4$
Степенная	y = a·x^b (x, y > 0)	y = 1.8·x^0.63
Экспонента	y = a·e^(b·x) (y > 0)	y = 4.2·e^(0.015·x)
Логарифмическая	y = a + b·ln(x) (x > 0)	y = −3.5 + 6.2·ln(x)
Robust (Huber)	y = a + b·x; a, b минимизируют Σ $L\delta(y_i - \hat{y}_i)$	$L\delta(r) = \frac{1}{2}r^2$ при $\lvert r\rvert\le\delta$; $\delta(\lvert r\rvert - \frac{1}{2}\delta)$ при $\lvert r\rvert>\delta$
Theil–Sen	y = a + b·x; b = median{$(y_j-y_i)/(x_j-x_i)$}, i<j	b = медиана всех попарных наклонов между точками
RANSAC	y = a + b·x; коэффициенты — по максимальному числу inlier-точек	точка — inlier, если |остаток| < ε (порог задаётся)
LOWESS	$\hat{y}(x_0)$ — локальная регрессия в окне вокруг x_0	вес $w_i = (1 - \lvert x_i-x_0\rvert^3/h^3)^3$ (tricube kernel)
Квантильная регрессия	y = a_q + b_q·x; минимизирует Σ $\rho_q(y_i - \hat{y}_i)$	$\rho_q(u) = u\cdot(q - \mathbb{1}[u<0])$; τ = 0.1 / 0.5 / 0.9

Пояснения

- **Huber, Theil-Sen, RANSAC —** не новые формы кривой, а альтернативные способы оценки коэффициентов той же линейной модели, устойчивые к выбросам. Уравнение по-прежнему y = a + b·x, но a и b посчитаны иначе, чем в обычном МНК (OLS).

- **LOWESS —** не даёт единого уравнения: локальная модель, результат — кривая (набор предсказаний в каждой точке), а не формула с фиксированными коэффициентами. В реализации используется statsmodels lowess с frac = 0.3; значения в точках x получаются линейной интерполяцией кривой.
- **Квантильная регрессия —** даёт разные a_q, b_q для τ = 0.1 / 0.5 / 0.9; на графике — веер из трёх линий. Метрики считаются отдельно для каждой τ (compute_quantile_stats, оценка через statsmodels QuantReg): на графике аппроксимаций и в таблице метрик выводятся строки для τ = 0.1, 0.5 и 0.9. Для τ = 0.1 и 0.9 R^2_fit может быть отрицательным — такие кривые оцениваются по Equation и Bias, а не по R^2. В общей таблице аппроксимаций (compute_fit_stats) учитывается только τ = 0.5.

Для степенной и логарифмической аппроксимации область определения ограничена (x > 0, и для степенной также y > 0); значения вне домена не участвуют в подгонке коэффициентов, а при отрисовке кривой заменяются на NaN вместо падения графика.

Метрики кривых аппроксимации (R^2_fit, RMSE, MSE, MAE, Bias, Std, Variance, MAPE %, уравнение) считаются по невязке Predicted − Actual = model(x) − y, то есть между предсказанием модели и фактическим эталонным значением PARAM_1 — отдельно от метрик базового QC-кросс-плота (Residual = y − x, см. выше).

Типы кросс-валидации (от худшего к лучшему)

Метод	Суть (как считается в коде)	Когда применять
Random K-Fold	sklearn.KFold(shuffle=True). Скважины случайно перемешиваются и делятся на k равных частей (k = min(заданное k, n)). По очереди каждая часть — тест, обучение — на остальных k−1 частях.	НЕЛЬЗЯ как основной метод — даёт иллюзию точности (игнорирует пространственную корреляцию). Оставлен в сравнении как заведомо оптимистичная база для контраста с остальными схемами.
Random K-Fold (buffered)	Тот же случайный KFold с тем же сидом, то есть те же тестовые фолды, что и у Random K-Fold. Из обучения удаляются скважины, чьё расстояние до ближайшей тестовой скважины ≤ buffer.	Случайные фолды без утечки соседних скважин. Сравнение с обычным Random K-Fold показывает, насколько тот был завышен.
Leave-One-Well-Out (LOWO)	sklearn.LeaveOneGroupOut по well_id. Поочерёдно вся скважина целиком (все её строки/горизонты) исключается и становится тестом; обучение — на всех остальных скважинах.	Стандарт при малом числе скважин (<20–30).
Block CV	Площадь делится регулярной сеткой grid_n×grid_n по X_coord/Y_coord (линейные границы от min до max). Поочерёдно весь блок — тест, обучение — на скважинах вне блока. Блок пропускается, если в обучении остаётся меньше degree + 2 (3 при линейной модели) точек.	Для равномерной сетки скважин. Размер сетки рекомендуется автоматически по медианному расстоянию между скважинами.
Buffered CV	Как Block CV, но из обучения дополнительно убираются скважины, чьё минимальное расстояние до ближайшей тестовой точки блока ≤ buffer.	Снижает остаточную пространственную корреляцию на границе блока по сравнению с обычным Block CV.
Leave-P-Out	На каждом из repeats повторов случайно (без возврата) выбирается p_percent% скважин — тест, обучение — на остальных. Итоговый прогноз скважины — среднее по всем повторам, где она попадала в тест (preds_sum/preds_count).	Более жёсткая проверка устойчивости, чем k-fold — оценивает разброс качества при разном случайном составе тестовой выборки.
Spatial Leave-P-Out	На каждом из repeats повторов случайно выбирается скважина-центр; все скважины в радиусе ≤ radius от неё — тест, остальные — train. Прогноз усредняется по повторам так же, как в Leave-P-Out.	Максимально приближено к реальному сценарию прогноза новой необуренной области. Требует достаточного пространственного покрытия площади скважинами.

Stratified by Zone	sklearn.LeaveOneGroupOut по выбранной колонке зоны (по умолчанию tectonic_zone, если её нет — horizon_id; другую колонку можно выбрать в сайдбаре). Поочерёдно вся зона целиком — тест, обучение — на скважинах из остальных зон.	Лучший вариант для оценки переносимости модели на новую зону. Требует колонку с ≥2 уникальными значениями, иначе схема пропускается.
Distance-based exclusion CV	Для каждой скважины i по очереди: из обучения исключаются все скважины на расстоянии ≤ excl_radius от неё (excl_radius = медиана попарных расстояний между скважинами × variogram_factor), тест — только скважина i. Если в обучении остаётся меньше degree + 2 точек, фолд отмечается как пропущенный (прогноз NaN).	По сути — LOWO с пространственным буфером вокруг тестовой точки. См. пояснение ниже, как оценивается радиус.

Как устроена Distance-based exclusion CV. Схема не выполняет полноценную подгонку модели вариограммы (nugget/sill/range) — радиус пространственной корреляции оценивается упрощённо, как медианное попарное расстояние между скважинами (median_pairwise_distance), масштабируемое множителем variogram_factor. Для тестовой скважины из обучения исключаются все точки ближе этого радиуса. Переименование в Distance-based exclusion CV точнее отражает, что метод делает на самом деле — это практичная эвристика на расстояниях, а не геостатистическая вариограмма.

Автоматический подбор рекомендуемых параметров CV

Реализован в сайдбаре на основе числа скважин (n_wells) и медианного расстояния между ними (median_dist):

- **k для Random K-Fold:** 5 при n<20; 7 при n<50; 10 при n<150; иначе 12.
- **Сетка N×N для Block/Buffered CV:** 5×5 при median_dist<300 м; 4×4 при <600 м; 3×3 при <1000 м; иначе 2×2.
- **Buffer (Buffered CV):** 0.5 × median_dist.
- **Число повторов (cv_repeats) для Leave-P-Out / Spatial Leave-P-Out:** 100 при n<30; 50 при n<100; 30 при n<300; иначе 20.
- **Радиус пространственного исключения (Spatial Leave-P-Out):** ≈ median_dist.
- **Множитель радиуса корреляции (Distance-based exclusion CV factor, variogram_factor в коде):** слайдер 0.25–3.00, шаг 0.25, по умолчанию 1.0; значения: 0.5 — мягкая фильтрация; 1.0 — рекомендуемое значение; 1.5 — строгая; 2.0–3.0 — очень строгая, почти независимые скважины.

Все рекомендованные значения доступны для ручной корректировки через слайдеры в сайдбаре.

Выбор лучшей схемы CV

После расчёта всех схем автоматически определяется схема с наилучшим сочетанием точности и устойчивости:

$$score = RMSE + RMSE_fold_std \rightarrow min$$

Критерий выбора задаётся в сайдбаре: RMSE + RMSE_fold_std (по умолчанию), RMSE, MAE, максимальный R^2 (Actual = Predicted), RMSE + |Bias| или вручную выбранная схема. Все схемы, включая Random K-Fold, участвуют в выборе.

Схема с минимальным score считается лучшей; для неё повторяется часть Шага 1 (кросс-плот Predicted vs Actual, аппроксимации, распределения, карта невязок, анализ выбросов).

Шаг 0 · Загрузка данных

QC входных данных

- Полные дубликаты строк
- Дубликаты well_id (для нескольких горизонтов на одну скважину это ожидаемо; реальное дублирование — только при совпадении well_id и horizon_id)
- Совпадающие координаты скважин (X_coord, Y_coord) в пределах одного горизонта
- Пропуски по колонкам
- Строки, удалённые при очистке (с превью первых 20 строк)

Типы данных по колонкам

- Для каждой колонки: тип (Numeric / Date & Time / Boolean / String), pandas dtype, число непустых/пустых значений, число уникальных значений.
- Отдельно — список уникальных значений для каждой категориальной колонки (до 20 значений с указанием общего числа).

Статистика параметров PARAM_1, PARAM_2

- Полный набор статистик и их формулы — см. раздел «Статистика параметров (Шаг 0)» ниже.

Корреляционный анализ выбранных параметров

- Две матрицы корреляции для любого набора числовых колонок: Пирсона (только линейная связь) и Спирмена (любая монотонная связь — экспонента, логарифм, степенная) (не только PARAM_1/PARAM_2 — пользователь выбирает набор).
- Pairplot: Seaborn (статический, с KDE/histogram на диагонали) или Plotly (интерактивный scatter-matrix).
- Для Pairplot и для блока корреляционного анализа рекомендуется не более 10 параметров (предупреждение в интерфейсе). KDE и гистограммы на диагонали доступны только в Seaborn; Plotly даёт интерактивность и hover, но диагональ в ней не выводится.
- Статистика по каждому числовому параметру (кроме well_id; PARAM_1 и PARAM_2 показаны выше): таблица статистик, гистограмма с KDE, средним, медианой и ±3σ, boxplot. Число бинов и тип нормировки гистограммы задаются отдельно для каждого параметра.

Шаг 1 · Базовый QC-кросс-плот (обязательный шаг)

Классический QC cross-plot

- Ось X: PARAM_2 (сравниваемое значение).
- Ось Y: PARAM_1 (эталонное значение).
- Диагональ: линия идеального совпадения Y = X.
- Линия линейной регрессии (OLS, степень 1).

Метрики раздела «Метрики кросс-плота и обозначения» выше (R^2_lin, RMSE, MSE, MAE, Bias, Std, Variance, MAPE %, P-value, уравнение регрессии).

Кросс-плот с кривыми аппроксимации

- На тот же кросс-плот накладываются выбранные пользователем типы аппроксимации (из 17, см. раздел выше).
- Для каждой выбранной кривой — отдельная строка в сравнительной таблице метрик (R^2_fit = sklearn r2_score, см. предупреждение про два R^2 выше).

Распределения параметров PARAM_1 и PARAM_2

- Гистограммы с KDE, линиями Mean/Median/±3σ (опционально).
- Boxplot с линиями Mean/Median.
- Настраиваемое число бинов и тип нормализации гистограммы (none/density/probability/percent).

Распределение невязок Δ = PARAM_1 − PARAM_2

- График невязки от PARAM_1 — ищем тренд (признак ошибки скоростной модели), а не просто разброс.
- Расширенная таблица статистик невязок: Count, μ, median, mode, σ, variance, CV %, RMSE, min, Q05/Q25/Q75/Q95, max, range, IQR (+ границы), μ±3σ.
- Гистограмма и boxplot невязок.
- Карта невязок в плане (X_coord, Y_coord, цвет — величина невязки) — показывает зоны систематического смещения (качество сейсмики, тектонические осложнения, латеральные изменения скоростей), а не просто общую статистику.

Анализ выбросов по невязкам

Выбросы оцениваются четырьмя независимыми методами одновременно:

- Sigma rule: |Residual| > σ_thr·σ (порог σ_thr: 1.0–6.0, по умолчанию 2.0).
- IQR rule: за пределами [Q1 − k·IQR, Q3 + k·IQR]; k — слайдер 1.0–3.0, по умолчанию 1.5 (границы IQR при k = 1.5 выводятся в статистике невязок, Шаги 1–2).

- Modified Z-score rule: $|0.6745 \cdot (x - \text{median})/\text{MAD}| > 3.5$.
- Percentile rule: за пределами [P_low, P_high]; P_low — 0–20%, по умолчанию 5%; P_high — 80–100%, по умолчанию 95%.

Шаг 2 · Кросс-валидация

Запускаются все схемы CV из раздела «Типы кросс-валидации» (Stratified by Zone пропускается, если выбранная колонка зоны — по умолчанию tectonic_zone, иначе horizon_id — отсутствует или содержит меньше двух уникальных значений).

Для каждой схемы CV

- Cross-plot Predicted vs Actual.
- Метрики кросс-плота: R^2 (Pearson, Predicted vs Actual), RMSE, MSE, MAE, Bias, Std, Variance, MAPE %, P-value, уравнение регрессии. R^2 (Actual = Predicted) выводится в сравнительной таблице схем.
- Статистика по фолдам: rmse_fold_mean, median, min, max, std, range.

Сравнение схем

- Сводная таблица всех схем с метриками по фолдам.
- Bar chart RMSE по схемам CV.
- Bar chart среднего RMSE по фолдам (rmse_fold_mean) по схемам CV.
- Boxplot разброса RMSE по фолдам для каждой схемы: медиана — сплошная линия, среднее — пунктир, выбросы — точки. Порядок схем совпадает с таблицей.
- Автоматический выбор лучшей схемы по выбранному критерию (см. раздел «Выбор лучшей схемы CV»).
- Таблицы фолдов для каждой схемы: номер фолда, n_train, n_test, RMSE, MAE, Bias. Пропущенные фолды (n_train < degree + 2) показаны строками с n = 0 и пустыми метриками и не попадают на боксплот.
- Сравнительная таблица схем содержит n_pred (число точек с прогнозом); если схемы покрывают разное число точек, выводится предупреждение.
- Сид случайных схем по умолчанию 42 и меняется кнопками в сайдбаре; влияет на Random K-Fold, Random K-Fold (buffered), Leave-P-Out и Spatial Leave-P-Out.

Детальный разбор лучшей схемы (повтор части Шага 1)

- Cross-plot Predicted vs Actual для лучшей модели + кривые аппроксимации.
- Метрики cross-plot и сравнение аппроксимаций.
- Распределение CV-невязок (Residual = PARAM_1 − Predicted): график от PARAM_1, таблица статистик, гистограмма, boxplot.
- Анализ выбросов CV-невязок — теми же 4 методами, что и в Шаге 1.

Важно: при исключении скважины из фолда пересчитываются коэффициенты модели; значения PARAM_2 остаются неизменными — фиксированные входные данные, извлечённые один раз (например, из структурной карты).

Шаг 3 · Диагностика по категориям

Работает для любой категориальной колонки датасета (не только tectonic_zone) — пользователь выбирает, по какой колонке анализировать.

- Круговая и столбчатая диаграммы количества скважин по категориям.
- Статистика PARAM_1 и PARAM_2 по каждой категории (в раскрывающихся блоках).
- Boxplot распределения PARAM_1 и PARAM_2 по категориям.
- Наложенные гистограммы по категориям для PARAM_1 и PARAM_2: каждая категория — своим цветом, полупрозрачно.
- Общий кросс-плот по всем категориям сразу (с индивидуальными цветами точек/линий на категорию) + отдельно по выбранному подмножеству категорий.
- Кросс-плот и аппроксимации отдельно для каждой категории.
- Сравнительная таблица метрик аппроксимаций по категориям.

Шаг 4 · Фильтрация скважин

Реализовано (не только запланировано). Четыре режима:

- Без фильтра.
- **Ручное исключение:** мультиселект конкретных well_id.
- **Случайное исключение (%):** слайдер 0–95%, кнопка «Новый набор» для пересэмплирования (фиксированный seed сохраняется в session_state до нажатия кнопки).
- Выделение кликом по точкам на cross-plot: клик по точке (Shift+клик — несколько), рамка (Box) или лассо (Lasso); режимы переключаются иконками в правом верхнем углу графика. Выбранные точки фиксируются кнопкой «Применить исключение», «Сбросить всё» очищает выбор. В сводке показывается строка «Исключено кликом».

После фильтрации пересчитываются: QC cross-plot, аппроксимации, полная таблица метрик, сравнение «до / после фильтрации» (n скважин, R^2_lin и R^2_fit для выбранных кривых, RMSE, MSE, MAE, Bias, Std, Variance, MAPE %).

Шаг 4.5 — серия случайного исключения: уровни от 5% до 95% с шагом 5%, на каждом уровне — заданное в сайдбаре число наборов (50–2000, по умолчанию 500). Для каждого набора считается R^2 (Pearson): in-sample — по оставшимся скважинам и out-of-sample — линия по оставшимся, R^2 по исключённым. Показываются распределения обоих значений по уровням.

Это позволяет оценивать устойчивость модели к сокращению числа скважин и влияние отдельных наблюдений/их групп на качество зависимости.

Важные нюансы для сейсмики

Пространственная зависимость

- Если скважины кластеризованы (например, куст на одной структуре), обычный LOWO даёт слишком оптимистичную оценку — соседняя скважина «утекает» информацию.
- Лучше — Block/Buffered/Spatial CV: исключать не одну скважину, а группу скважин в радиусе корреляции (аналог GroupKFold по пространственным кластерам).

Размер выборки

- Скважин мало (<15–20): LOWO практически безальтернативен.
- Скважин больше 30–50: можно k-fold (5–10 фолдов), но желательно с равномерным пространственным покрытием в каждом фолде, иначе один фолд может остаться без скважин на краю площади (для этого в проекте есть Block/Buffered CV).

Важно: разбивать по скважинам, а не по отдельным точкам одной скважины — иначе модель «подглядывает» в соседние точки того же профиля/куста.

Известные ограничения и статус реализации

- R^2_lin и R^2_fit — два разных по смыслу R^2 в разных частях таблиц метрик, разведены по названию — см. предупреждение в разделе «Метрики кросс-плота и обозначения».
- Distance-based exclusion CV (ранее Variogram-Aware CV) — упрощённая эвристика на расстояниях, не полноценная geostatistics-вариограмма — см. пояснение в разделе «Типы кросс-валидации».
- Известная проблема (не исправлено): Random K-Fold участвует в автоматическом выборе лучшей схемы по score = RMSE + RMSE_fold_std. Оптимистичная схема может быть выбрана «лучшей»; в текущей версии этот выбор не исключает её.
- Известная проблема (не исправлено): при выборе нескольких горизонтов Random K-Fold, Random K-Fold (buffered), Leave-P-Out и Spatial Leave-P-Out разбивают записи «скважина — горизонт», а не скважины целиком, поэтому одна скважина может попасть одновременно в обучение и в тест. Для строгой оценки используйте один горизонт или схемы LOWO, Block CV, Buffered CV.
- Известная ошибка (не исправлено): при случайном исключении процент считается от числа строк (скважина × горизонт), а исключаются скважины; при нескольких горизонтах может быть запрошено больше скважин, чем есть, и расчёт завершится ошибкой.
- Исправлено: степенная и логарифмическая аппроксимации могли давать NaN/падать при отрисовке кривой на участке $x \leq 0$ — добавлено ограничение домена (x_line_safe) в коде отрисовки (app_utils).
- Добавлено кэширование (@st.cache_data) для sq.run_all_cv — кросс-валидация (включая Leave-P-Out/Spatial Leave-P-Out с десятками повторов) больше не пересчитывается при каждом взаимодействии с сайдбаром (например, смене цвета точек), а только при изменении данных или параметров CV.

- **Реализован двуязычный интерфейс RU/EN (переключатель Language в сайдбаре; тексты в translations_full, примеры в ui_examples_full_ru и ui_examples_full_en). Планируется: разбиение app_full.py (~4900 строк) на модули (sidebar / step1–step4 / plotting).**

Практическая схема пайплайна

1. Сбор данных: well_id, X_coord, Y_coord, PARAM_1, PARAM_2, horizon_id, tectonic_zone (опционально).
2. Базовый анализ: глобальные RMSE/MAE/Bias, общий cross-plot, карта невязок (Шаг 0–1).
3. K-fold CV по скважинам: разбить на k фолдов, перестроить модель без тестового фолда, посчитать ошибки, свести в таблицу.
4. LOWO / Block / Buffered / Spatial Leave-P-Out / Distance-based exclusion / Stratified by Zone CV — полный набор схем для оценки устойчивости (Шаг 2).
5. Диагностика по категориям — выявление зон систематических ошибок (Шаг 3).
6. Фильтрация и стресс-тест выборки — оценка устойчивости к сокращению числа скважин (Шаг 4).
7. Интерпретация: сравнить ошибки разных схем CV, выделить зоны/горизонты систематических ошибок, использовать для доработки глубинного преобразования, скоростной модели, интерпретации разломов.