

Structural QC — cross-plot & cross-validation

Название проекта

Structural QC_CV — кросс-плот и кросс-валидация для оценки качества структурных карт по данным скважин.

Описание проекта

Streamlit-инструмент, который сравнивает эталонный параметр `PARAM_1` (`Z_well`) и сравниваемый `PARAM_2` (`Z_map`) в одних и тех же точках — скважинах — и проверяет, насколько один параметр предсказывается по другому. Реализованы Шаги 0–4: загрузка и QC данных, базовый QC-кросс-плот с аппроксимациями, кросс-валидация по восьми схемам с автоматическим выбором лучшей, анализ по категориям и фильтрация скважин. Инструмент обобщён на любые пары числовых параметров.

Описание данных

Входная таблица CSV/XLSX, в которой каждая строка — пара значений `PARAM_1` и `PARAM_2` в точке скважины (на горизонт). Обязательные колонки: `well_id`, `X_coord`, `Y_coord`, `PARAM_1` (`Zprm_well`) и `PARAM_2` (`Zprm_map`). Опциональные: `horizon_id`, `tectonic_zone`, `reservoir_flag` (тип коллектора), `fluid_type` (тип флюида) и любые другие числовые и категориальные колонки. В приложении есть демонстрационные файлы (выбор в сайдбаре) и пример структуры из трёх скважин: `well_id`, `X_coord`, `Y_coord`, `Z_well`, `Z_map`, `horizon_id`, `tectonic_zone`.

Цели исследования

- Проверить согласованность структурной карты с данными скважин по глубинам горизонта (`Z_map` относительно `Z_well`).
- Оценить реальную, а не оптимистичную точность карты с помощью кросс-валидации по схемам, разбивающим данные по скважинам.
- Выявить систематические смещения (Bias, наклон регрессии) и зоны, горизонты или категории, где карта работает хуже.
- Проверить устойчивость результата к сокращению числа скважин, к отдельным наблюдениям и выбросам.

Ход исследования

- Шаг 0 — загрузка данных, QC входных данных, статистика параметров, корреляционные матрицы Пирсона и Спирмена.
- Шаг 1 — базовый QC-кросс-плот, аппроксимации (17 типов), распределения, невязки, карта невязок, выбросы.
- Шаг 2 — кросс-валидация по восьми схемам, выбор лучшей по $\text{score} = \text{RMSE} + \text{RMSE_fold_std}$, детальный разбор лучшей схемы.
- Шаг 3 — диагностика по выбранной категориальной колонке.
- Шаг 4 — фильтрация скважин: ручная, случайная по проценту или выделением точек кликом.

Ожидаемые результаты

- Сравнительная таблица ошибок (RMSE, MAE, Bias) по схемам CV и по фолдам с выбором лучшей схемы.
- Оценка смещения и тренда: Bias, наклон и intercept регрессии; тренд невязки от глубины как признак ошибки скоростной модели.
- Карта невязок и список выбросов по четырём правилам с указанием зон систематических ошибок.

- Метрики по категориям и оценка устойчивости результата при фильтрации скважин.
- Вывод о том, на каких участках и горизонтах карте можно доверять, а где её нужно пересмотреть.

План проекта. Версия сверена с реализацией (app_full.py, structural_qc_full.py, app_utils.py, translations_full.py) — обновлено, чтобы не противоречить коду.

Постановка задачи

- Типичная задача валидации точности структурной поверхности (карты), построенной по данным МОГТ 2D/3D, против «истины» в скважинах — глубин геологических маркеров.
- Ключевой методологический риск: если скважины использовались при построении карты (калибровка скоростной модели, привязка ВСП, интерполяция/крайгинг с учётом скважинных данных), то проверка качества карты в этих же точках даёт завышенную, оптимистичную оценку — это классическая утечка данных (data leakage), только в геологической форме.
- Оценивается предиктивная модель (регрессия/аппроксимация), связывающая два параметра: эталонный PARAM_1 и сравниваемый PARAM_2. Для структурного QC: PARAM_1 = Z_well (истинная глубина горизонта), PARAM_2 = Z_map (глубина того же горизонта по структурной карте).
- Значения PARAM_2 на каждой итерации кросс-валидации фиксированы (не пересчитываются из сейсмоки заново) — переобучается только модель связи «PARAM_2 → PARAM_1» при исключении скважины или группы скважин из обучающей выборки.

Инструмент реализован обобщённо и применим не только к паре «скважина ↔ карта», а к любой паре числовых параметров:

Сценарий	PARAM_1 (Reference) / PARAM_2 (Compared) — примеры
скважина ↔ карта	Z_well / Z_map, T_well / T_map
скважина ↔ атрибут	Z_well / Amplitude, Phi_well / AVO_Gradient
карта ↔ карта	Z_map_v1 / Z_map_v2 (сравнение версий интерпретации)
атрибут ↔ атрибут	Amplitude / Sweetness (проверка мультиколлинеарности)

Далее по тексту плана Z_well/Z_map используются как сквозной иллюстративный пример (структурный QC), но все шаги и формулы применимы к любой паре PARAM_1/PARAM_2.

Формат данных

Минимальная структура входной таблицы (CSV/XLSX):

Колонка в коде	Роль	Описание
well_id	обязательная	Идентификатор скважины
X_coord, Y_coord	обязательные	Координаты скважины
Zprm_well (= PARAM_1)	обязательная · Reference	Эталонный параметр — то, с чем сравниваем. Для структурного QC: Z_well (истинная глубина маркера).
Zprm_map (= PARAM_2)	обязательная · Compared	Сравниваемый параметр. Для структурного QC: Z_map (глубина по карте).
horizon_id	опциональная	Идентификатор горизонта — позволяет отфильтровать анализ по одному или нескольким горизонтам

tectonic_zone	опциональная	Тектоническая/геологическая зона — используется в Stratified by Zone CV и в Шаге 3
любая другая колонка	опциональная	Любая дополнительная числовая колонка — доступна для корреляционного анализа (Шаг 0); любая категориальная — доступна для анализа по категориям (Шаг 3)

- Единицы измерения PARAM_1 и PARAM_2 задаются пользователем при сопоставлении колонок (например, м, км, мс, м/с и т.п.) — используются только в подписях графиков и таблиц, не влияют на расчёт.
- При загрузке выполняется автоматическая очистка: приведение мусорных значений («NA», «NULL», «—», «?» и т.п.) к NaN, замена запятой на точку в числовых колонках, приведение типов, удаление строк с пропусками в обязательных колонках (с выводом отчёта, сколько строк удалено).
- Опциональные колонки reservoir_flag (тип коллектора) и fluid_type (тип флюида) используются как категориальные признаки для Шага 3 наравне с tectonic_zone.

Метрики кросс-плота и обозначения

Обозначение: $x = \text{PARAM_2}$ (сравниваемое значение), $y = \text{PARAM_1}$ (эталонное значение).

Невязка Δ — определяется по-разному в двух местах кода, это важно:

- Базовый QC-кросс-плот (Шаг 1, BasicStats): $\Delta = y - x = \text{PARAM_1} - \text{PARAM_2}$. Для структурного QC: $\Delta = Z_{\text{well}} - Z_{\text{map}}$. Положительная $\Delta \Rightarrow Z_{\text{well}} > Z_{\text{map}}$ (карта занижает глубину); отрицательная $\Rightarrow$ карта завышает глубину.
- Аппроксимации и кросс-валидация (Шаги 1–3, FitStats / fold_metrics): $\Delta = \text{Predicted} - \text{Actual}$, то есть предсказание модели минус фактическое PARAM_1 — обратный знак по сравнению с базовым QC-кросс-плотом.

Таблица ниже — общая форма метрик через Δ ; какое именно Δ подставляется, зависит от раздела (см. выше). $\bar{\Delta}$ — среднее невязки (= Bias).

Метрика	Формула
R^2 (коэффициент детерминации / квадрат корреляции)	$R^2_{\text{lin}} = r^2$ (Пирсон, linregress) · $R^2_{\text{fit}} = 1 - \Sigma(\Delta)^2 / \Sigma(y - \bar{y})^2$
RMSE (среднеквадратичная ошибка)	$\text{RMSE} = \sqrt{[(1/N) \cdot \Sigma(\Delta)^2]}$
MSE (среднеквадратичное отклонение)	$\text{MSE} = (1/N) \cdot \Sigma(\Delta)^2$
MAE (абсолютная погрешность)	$\text{MAE} = (1/N) \cdot \Sigma \Delta $
Bias (систематическое смещение)	$\text{Bias} = (1/N) \cdot \Sigma(\Delta)$
Std (стандартное отклонение невязок)	$\text{Std} = \sqrt{[(1/(N-1)) \cdot \Sigma(\Delta_i - \bar{\Delta})^2]}$
Variance (дисперсия невязок)	$\text{Var} = (1/(N-1)) \cdot \Sigma(\Delta_i - \bar{\Delta})^2$
MAPE, % (средняя абсолютная ошибка в процентах)	$\text{MAPE} = (100/N) \cdot \Sigma [\Delta / \max(y , 10^{-9})]$
P-value (значимость линейной корреляции)	$t = r \cdot \sqrt{(N-2)/(1-r^2)}$, $p = 2 \cdot (1 - F_{t,N-2}(t))$
Уравнение линейной регрессии	$y = a + b \cdot x$; наклон b и intercept a — из linregress

P-value отвечает на вопрос: насколько вероятно получить настолько же сильную (или сильнее) линейную связь между PARAM_1 и PARAM_2 случайно, если на самом деле никакой связи нет (нулевая гипотеза H_0 : истинный наклон регрессии $b = 0$). Чем меньше p-value, тем менее правдоподобно, что найденная

зависимость — случайность; порогом значимости обычно считают $p < 0.05$. Считается только для базового QC-кросс-плота (Шаг 1), через `scipy.stats.linregress`.

Статистика параметров (Шаг 0)

Для PARAM_1 и PARAM_2 отдельно считается расширенная описательная статистика:

Статистика	Формула / определение
Count	N — число непустых значений
μ (mean)	$\mu = (1/N) \cdot \sum x_i$ — среднее арифметическое
median	медиана — значение, делящее выборку пополам (50-й перцентиль)
mode	мода — наиболее часто встречающееся значение
σ (std)	$\sigma = \sqrt{(1/(N-1)) \cdot \sum (x_i - \mu)^2}$
variance	$\sigma^2 = (1/(N-1)) \cdot \sum (x_i - \mu)^2$
CV, %	$(\sigma/\mu) \cdot 100\%$ — коэффициент вариации (разброс относительно среднего)
min	минимальное значение
Q05	5-й перцентиль
Q25	25-й перцентиль (первый квартиль)
Q75	75-й перцентиль (третий квартиль)
Q95	95-й перцентиль
max	максимальное значение
range	max – min
IQR	Q75 – Q25 — межквартильный размах
IQR lower bound	Q25 – 1.5·IQR — нижняя граница правила IQR
IQR upper bound	Q75 + 1.5·IQR — верхняя граница правила IQR

В проекте два разных R^2 — разведены по названию, чтобы не путать. R^2_{lin} (BasicStats.r2, Шаг 1, базовый QC-кросс-плот) = квадрат коэффициента корреляции Пирсона (`scipy.stats.linregress`) — корректен только как мера силы *линейной* связи. R^2_{fit} (FitStats.r2, все 17 типов аппроксимации, Шаги 1–3) = `sklearn.metrics.r2_score = 1 – SS_res/SS_tot` — честная доля объяснённой дисперсии, корректна для кривой любой формы. Для линейной OLS оба совпадают численно, для остальных 16 типов — нет. **Сравнивать R^2_{lin} и R^2_{fit} напрямую нельзя — это разные метрики, а не одна и та же величина, посчитанная дважды.**

Коэффициенты линейной регрессии (наклон / intercept) показывают систематический тренд — например, «карта занижает глубину с ростом глубины» ($b < 1$) — типичный признак ошибки скоростной модели.

Типы линий аппроксимации

На кросс-плоте, помимо базовой линейной регрессии, доступен выбор из 17 вариантов аппроксимации (10 полиномов 1–10 степени + 7 прочих методов):

Метод	Общий вид уравнения	Пример
Линейная	$y = a + b \cdot x$	$y = 12.4 + 0.85 \cdot x$
Квадратичная	$y = a + b \cdot x + c \cdot x^2$	$y = 5.1 + 0.62 \cdot x + 0.014 \cdot x^2$

Кубическая	$y = a + b \cdot x + c \cdot x^2 + d \cdot x^3$	$y = 3.7 + 0.41 \cdot x + 0.021 \cdot x^2 - 0.0006 \cdot x^3$
Полином n-й степени (4–10)	$y = a_0 + a_1 \cdot x + a_2 \cdot x^2 + \dots + a_n \cdot x^n$	$n=4: y = 2.0 + 0.30 \cdot x + 0.05 \cdot x^2 - 0.002 \cdot x^3 + 0.00004 \cdot x^4$
Степенная	$y = a \cdot x^b \ (x, y > 0)$	$y = 1.8 \cdot x^{0.63}$
Экспонента	$y = a \cdot e^{(b \cdot x)} \ (y > 0)$	$y = 4.2 \cdot e^{(0.015 \cdot x)}$
Логарифмическая	$y = a + b \cdot \ln(x) \ (x > 0)$	$y = -3.5 + 6.2 \cdot \ln(x)$
Robust (Huber)	$y = a + b \cdot x$; a, b минимизируют $\sum L\delta(y_i - \hat{y}_i)$	$L\delta(r) = \frac{1}{2}r^2$ при $ r \leq \delta$; $\delta(r - \frac{1}{2}\delta)$ при $ r > \delta$
Theil–Sen	$y = a + b \cdot x$; $b = \text{median}\{(y_j - y_i)/(x_j - x_i)\}, i < j$	b = медиана всех попарных наклонов между точками
RANSAC	$y = a + b \cdot x$; коэффициенты — по максимальному числу inlier-точек	точка — inlier, если $ \text{остаток} < \varepsilon$ (порог задаётся)
LOWESS	$\hat{y}(x_0)$ — локальная регрессия в окне вокруг x_0	вес $w_i = (1 - x_i - x_0 ^3/h^3)^3$ (tricube kernel)
Квантильная регрессия	$y = a_q + b_q \cdot x$; минимизирует $\sum \rho_q(y_i - \hat{y}_i)$	$\rho_q(u) = u \cdot (q - \mathbb{1}[u < 0])$; $\tau = 0.1 / 0.5 / 0.9$

Пояснения

- Huber, Theil-Sen, RANSAC** — не новые формы кривой, а альтернативные способы оценки коэффициентов той же линейной модели, устойчивые к выбросам. Уравнение по-прежнему $y = a + b \cdot x$, но a и b посчитаны иначе, чем в обычном МНК (OLS).
- LOWESS** — не даёт единого уравнения: локальная модель, результат — кривая (набор предсказаний в каждой точке), а не формула с фиксированными коэффициентами. В реализации используется statsmodels lowess с `frac = 0.3`; значения в точках x получаются линейной интерполяцией кривой.
- Квантильная регрессия** — даёт разные a_q, b_q для $\tau = 0.1 / 0.5 / 0.9$; на графике — все из трёх линий. Метрики считаются отдельно для каждой τ (compute_quantile_stats, оценка через statsmodels QuantReg); на графике аппроксимаций и в таблице метрик выводятся строки для $\tau = 0.1, 0.5$ и 0.9 . Для $\tau = 0.1$ и 0.9 R^2_fit может быть отрицательным — такие кривые оцениваются по Equation и Bias, а не по R^2 . В общей таблице аппроксимаций (compute_fit_stats) учитывается только $\tau = 0.5$.

Для степенной и логарифмической аппроксимации область определения ограничена ($x > 0$, и для степенной также $y > 0$); значения вне домена не участвуют в подгонке коэффициентов, а при отрисовке кривой заменяются на NaN вместо падения графика.

Метрики кривых аппроксимации (R^2_fit , RMSE, MSE, MAE, Bias, Std, Variance, MAPE %, уравнение) считаются по невязке $\text{Predicted} - \text{Actual} = \text{model}(x) - y$, то есть между предсказанием модели и фактическим эталонным значением PARAM_1 — отдельно от метрик базового QC-кросс-плота (Residual = $y - x$, см. выше).

Типы кросс-валидации (от худшего к лучшему)

Метод	Суть (как считается в коде)	Когда применять
Random K-Fold	sklearn.KFold(shuffle=True). Скважины случайно перемешиваются и делятся на k равных частей ($k = \min(\text{заданное } k, n)$). По очереди каждая часть — тест, обучение — на остальных $k-1$ частях.	НЕЛЬЗЯ как основной метод — даёт иллюзию точности (игнорирует пространственную корреляцию). Оставлен в сравнении как заведомо

		оптимистичная база для контраста с остальными схемами.
Leave-One-Well-Out (LOWO)	sklearn.LeaveOneGroupOut по well_id. Поочерёдно вся скважина целиком (все её строки/горизонты) исключается и становится тестом; обучение — на всех остальных скважинах.	Стандарт при малом числе скважин (<20–30).
Block CV	Площадь делится регулярной сеткой grid_n×grid_n по X_coord/Y_coord (линейные границы от min до max). Поочерёдно весь блок — тест, обучение — на скважинах вне блока. Блок пропускается, если в нём <3 обучающих скважин.	Для равномерной сетки скважин. Размер сетки рекомендуется автоматически по медианному расстоянию между скважинами.
Buffered CV	Как Block CV, но из обучения дополнительно убираются скважины, чьё минимальное расстояние до ближайшей тестовой точки блока $\leq$ buffer.	Снижает остаточную пространственную корреляцию на границе блока по сравнению с обычным Block CV.
Leave-P-Out	На каждом из repeats повторов случайно (без возврата) выбирается p_percent% скважин — тест, обучение — на остальных. Итоговый прогноз скважины — среднее по всем повторам, где она попадала в тест (preds_sum/preds_count).	Более жёсткая проверка устойчивости, чем k-fold — оценивает разброс качества при разном случайном составе тестовой выборки.
Spatial Leave-P-Out	На каждом из repeats повторов случайно выбирается скважина-центр; все скважины в радиусе $\leq$ radius от неё — тест, остальные — train. Прогноз усредняется по повторам так же, как в Leave-P-Out.	Максимально приближено к реальному сценарию прогноза новой необуренной области. Требует достаточного пространственного покрытия площади скважинами.
Stratified by Zone	sklearn.LeaveOneGroupOut по tectonic_zone. Поочерёдно вся зона целиком — тест, обучение — на скважинах из остальных зон.	Лучший вариант для оценки переносимости модели на новую зону. Требует наличия колонки tectonic_zone с ≥ 2 уникальными значениями, иначе схема пропускается.
Distance-based exclusion CV	Для каждой скважины i по очереди: из обучения исключаются все скважины на расстоянии $\leq$ range_corr от неё (range_corr = медиана попарных расстояний между скважинами $\times$ variogram_factor), тест — только скважина i.	По сути — LOWO с пространственным буфером вокруг тестовой точки. См. пояснение ниже, как оценивается радиус.

Как устроена Distance-based exclusion CV. Схема не выполняет полноценную подгонку модели вариограммы (nugget/sill/range) — радиус пространственной корреляции оценивается упрощённо, как медианное попарное расстояние между скважинами (estimate_variogram_range), масштабируемое множителем variogram_factor. Для тестовой скважины из обучения исключаются все точки ближе этого радиуса. Переименование в Distance-based exclusion CV точнее отражает, что метод делает на самом деле — это практическая эвристика на расстояниях, а не геостатистическая вариограмма.

Автоматический подбор рекомендуемых параметров CV

Реализован в сайдбаре на основе числа скважин (n_wells) и медианного расстояния между ними (median_dist):

- **k для Random K-Fold:** 5 при $n < 20$; 7 при $n < 50$; 10 при $n < 150$; иначе 12.

- **Сетка N×N для Block/Buffered CV:** 5×5 при median_dist<300 м; 4×4 при <600 м; 3×3 при <1000 м; иначе 2×2.
- **Buffer (Buffered CV):** $0.5 \times \text{median_dist}$.
- **Число повторов (cv_repeats) для Leave-P-Out / Spatial Leave-P-Out:** 100 при n<30; 50 при n<100; 30 при n<300; иначе 20.
- **Радиус пространственного исключения (Spatial Leave-P-Out):** $\approx \text{median_dist}$.
- **Множитель радиуса корреляции (Distance-based exclusion CV factor, variogram_factor в коде):** 0.5 — мягкая фильтрация; 1.0 — рекомендуемое значение; 1.5 — строгая; 2.0–3.0 — очень строгая, почти независимые скважины.

Все рекомендованные значения доступны для ручной корректировки через слайдеры в сайдбаре.

Выбор лучшей схемы CV

После расчёта всех схем автоматически определяется схема с наилучшим сочетанием точности и устойчивости:

$$\text{score} = \text{RMSE} + \text{RMSE_fold_std} \rightarrow \min$$

Схема с минимальным score считается лучшей; для неё повторяется часть Шага 1 (кросс-плот Predicted vs Actual, аппроксимации, распределения, карта невязок, анализ выбросов).

Шаг 0 · Загрузка данных

QC входных данных

- Полные дубликаты строк
- Дубликаты well_id (для нескольких горизонтов на одну скважину это ожидаемо; реальное дублирование — только при совпадении well_id и horizon_id)
- Совпадающие координаты скважин (X_coord, Y_coord)
- Пропуски по колонкам
- Строки, удалённые при очистке (с превью первых 20 строк)

Типы данных по колонкам

- Для каждой колонки: тип (Numeric / Date & Time / Boolean / String), pandas dtype, число непустых/пустых значений, число уникальных значений.
- Отдельно — список уникальных значений для каждой категориальной колонки (до 20 значений с указанием общего числа).

Статистика параметров PARAM_1, PARAM_2

- Полный набор статистик и их формулы — см. раздел «Статистика параметров (Шаг 0)» ниже.

Корреляционный анализ выбранных параметров

- Две матрицы корреляции для любого набора числовых колонок: Пирсона (только линейная связь) и Спирмена (любая монотонная связь — экспонента, логарифм, степенная) (не только PARAM_1/PARAM_2 — пользователь выбирает набор).
- Pairplot: Seaborn (статический, с KDE/histogram на диагонали) или Plotly (интерактивный scatter-matrix).
- Для Pairplot рекомендуется не более 6 параметров (предупреждение в интерфейсе), для блока корреляционного анализа — не более 10. KDE и гистограммы на диагонали доступны только в Seaborn; Plotly даёт интерактивность и hover.
- Статистика по каждому выбранному параметру — в отдельных раскрывающихся блоках.

Шаг 1 · Базовый QC-кросс-плот (обязательный шаг)

Классический QC cross-plot

- Ось X: PARAM_2 (сравниваемое значение).
- Ось Y: PARAM_1 (эталонное значение).
- Диагональ: линия идеального совпадения $Y = X$.
- Линия линейной регрессии (OLS, степень 1).

Метрики раздела «Метрики кросс-плота и обозначения» выше (R^2_{lin} , RMSE, MSE, MAE, Bias, Std, Variance, MAPE %, P-value, уравнение регрессии).

Кросс-плот с кривыми аппроксимации

- На тот же кросс-плот накладываются выбранные пользователем типы аппроксимации (из 17, см. раздел выше).
- Для каждой выбранной кривой — отдельная строка в сравнительной таблице метрик ($R^2_{fit} = \text{sklearn } r2_score$, см. предупреждение про два R^2 выше).

Распределения параметров PARAM_1 и PARAM_2

- Гистограммы с KDE, линиями Mean/Median/ $\pm 3\sigma$ (опционально).
- Boxplot с линиями Mean/Median.
- Настраиваемое число бинов и тип нормализации гистограммы (none/density/probability/percent).

Распределение невязок $\Delta = \text{PARAM}_1 - \text{PARAM}_2$

- График невязки от PARAM_1 — ищем тренд (признак ошибки скоростной модели), а не просто разброс.
- Расширенная таблица статистик невязок: Count, μ , median, mode, σ , variance, CV %, RMSE, min, Q05/Q25/Q75/Q95, max, range, IQR (+ границы), $\mu \pm 3\sigma$.
- Гистограмма и boxplot невязок.
- Карта невязок в плане (X_coord, Y_coord, цвет — величина невязки) — показывает зоны систематического смещения (качество сейсмики, тектонические осложнения, латеральные изменения скоростей), а не просто общую статистику.

Анализ выбросов по невязкам

Выбросы оцениваются четырьмя независимыми методами одновременно:

- Sigma rule: $|\text{Residual}| > \sigma_{thr} \cdot \sigma$ (порог σ_{thr} настраивается, по умолчанию 2.0).
- IQR rule: за пределами $[Q1 - 1.5 \cdot IQR, Q3 + 1.5 \cdot IQR]$.
- Modified Z-score rule: $|0.6745 \cdot (x - \text{median}) / \text{MAD}| > 3.5$.
- Percentile rule: за пределами $[Q05, Q95]$.

Шаг 2 · Кросс-валидация

Запускаются все схемы CV из раздела «Типы кросс-валидации» (Stratified by Zone пропускается, если в данных нет колонки tectonic_zone с ≥ 2 уникальными значениями).

Для каждой схемы CV

- Cross-plot Predicted vs Actual.
- Метрики: R^2_{fit} , RMSE, MSE, MAE, Bias, Std, Variance, MAPE %, P-value, уравнение регрессии.
- Статистика по фолдам: rmse_fold_mean, median, min, max, std, range.

Сравнение схем

- Сводная таблица всех схем с метриками по фолдам.
- Bar chart RMSE по схемам CV.
- Автоматический выбор лучшей схемы по $\text{score} = \text{RMSE} + \text{RMSE_fold_std}$ (см. раздел выше).

Детальный разбор лучшей схемы (повтор части Шага 1)

- Cross-plot Predicted vs Actual для лучшей модели + кривые аппроксимации.
- Метрики cross-plot и сравнение аппроксимаций.
- Распределение CV-невязок ($\text{Residual} = \text{PARAM_1} - \text{Predicted}$): график от PARAM_1, таблица статистик, гистограмма, boxplot.
- Анализ выбросов CV-невязок — теми же 4 методами, что и в Шаге 1.

Важно: при исключении скважины из фолда пересчитываются коэффициенты модели; значения PARAM_2 остаются неизменными — фиксированные входные данные, извлечённые один раз (например, из структурной карты).

Шаг 3 · Диагностика по категориям

Работает для любой категориальной колонки датасета (не только tectonic_zone) — пользователь выбирает, по какой колонке анализировать.

- Круговая и столбчатая диаграммы количества скважин по категориям.
- Статистика PARAM_1 и PARAM_2 по каждой категории (в раскрывающихся блоках).
- Boxplot распределения PARAM_1 и PARAM_2 по категориям.
- Общий кросс-плот по всем категориям сразу (с индивидуальными цветами точек/линий на категорию) + отдельно по выбранному подмножеству категорий.
- Кросс-плот и аппроксимации отдельно для каждой категории.
- Сравнительная таблица метрик аппроксимаций по категориям.

Шаг 4 · Фильтрация скважин

Реализовано (не только запланировано). Четыре режима:

- Без фильтра.
- **Ручное исключение:** мультиселект конкретных well_id.
- **Случайное исключение (%):** слайдер 0–95%, кнопка «Новый набор» для пересэмплирования (фиксированный seed сохраняется в session_state до нажатия кнопки).
- Выделение кликом по точкам на cross-plot: клик по точке (Shift+клик — несколько), рамка (Box) или лассо (Lasso); режимы переключаются иконками в правом верхнем углу графика. Выбранные точки фиксируются кнопкой «Применить исключение», «Сбросить всё» очищает выбор. В сводке показывается строка «Исключено кликом».

После фильтрации пересчитываются: QC cross-plot, аппроксимации, полная таблица метрик, сравнение «до / после фильтрации» (n скважин, R^2_{lin} и R^2_{fit} для выбранных кривых, RMSE, MSE, MAE, Bias, Std, Variance, MAPE %).

Это позволяет оценивать устойчивость модели к сокращению числа скважин и влияние отдельных наблюдений/их групп на качество зависимости.

Важные нюансы для сеймики

Пространственная зависимость

- Если скважины кластеризованы (например, куст на одной структуре), обычный LOWO даёт слишком оптимистичную оценку — соседняя скважина «утекает» информацию.
- Лучше — Block/Buffered/Spatial CV: исключать не одну скважину, а группу скважин в радиусе корреляции (аналог GroupKFold по пространственным кластерам).

Размер выборки

- Скважин мало (<15–20): LOWO практически безальтернативен.
- Скважин больше 30–50: можно k-fold (5–10 фолдов), но желательно с равномерным пространственным покрытием в каждом фолде, иначе один фолд может остаться без скважин на краю площади (для этого в проекте есть Block/Buffered CV).

Важно: разбивать по скважинам, а не по отдельным точкам одной скважины — иначе модель «подглядывает» в соседние точки того же профиля/куста.

Известные ограничения и статус реализации

- R^2_{lin} и R^2_{fit} — два разных по смыслу R^2 в разных частях таблиц метрик, разведены по названию — см. предупреждение в разделе «Метрики кросс-плота и обозначения».
- Distance-based exclusion CV (ранее Variogram-Aware CV) — упрощённая эвристика на расстояниях, не полноценная geostatistics-вариограмма — см. пояснение в разделе «Типы кросс-валидации».
- Исправлено: степенная и логарифмическая аппроксимации могли давать NaN/падать при отрисовке кривой на участке $x \leq 0$ — добавлено ограничение домена (`x_line_safe`) как в структурном QC-движке, так и в коде отрисовки Streamlit.
- Добавлено кэширование (`@st.cache_data`) для `sq.run_all_cv` — кросс-валидация (включая Leave-P-Out/Spatial Leave-P-Out с десятками повторов) больше не пересчитывается при каждом взаимодействии с сайдбаром (например, смене цвета точек), а только при изменении данных или параметров CV.
- Реализован двуязычный интерфейс RU/EN (переключатель **Language** в сайдбаре; тексты в `translations_full`, примеры в `ui_examples_full_ru` и `ui_examples_full_en`). Планируется: разбиение `app_full.py` (~3500 строк) на модули (`sidebar` / `step1–step4` / `plotting`).

Практическая схема пайплайна

1. Сбор данных: `well_id`, `X_coord`, `Y_coord`, `PARAM_1`, `PARAM_2`, `horizon_id`, `tectonic_zone` (опционально).
2. Базовый анализ: глобальные RMSE/MAE/Bias, общий cross-plot, карта невязок (Шаг 0–1).
3. K-fold CV по скважинам: разбить на k фолдов, перестроить модель без тестового фолда, посчитать ошибки, свести в таблицу.
4. LOWO / Block / Buffered / Spatial Leave-P-Out / Distance-based exclusion / Stratified by Zone CV — полный набор схем для оценки устойчивости (Шаг 2).
5. Диагностика по категориям — выявление зон систематических ошибок (Шаг 3).
6. Фильтрация и стресс-тест выборки — оценка устойчивости к сокращению числа скважин (Шаг 4).
7. Интерпретация: сравнить ошибки разных схем CV, выделить зоны/горизонты систематических ошибок, использовать для доработки глубинного преобразования, скоростной модели, интерпретации разломов.