Language

RU

Данные

Выбрать демонстрационный файл

structural_wells_100_linear.csv

Сопоставление колонок DEMO-файла

DEMO: well_id

well_id

DEMO: X_coord

X

DEMO: Y_coord

Y

DEMO: Параметр 1 (эталонный)

Z_well

DEMO: Параметр 2 (сравниваемый)

Z_map

DEMO: Единицы параметра 1

m

DEMO: Единицы параметра 2

m

DEMO: horizon_id

horizon_id

DEMO: tectonic_zone

tectonic_zone

Загрузить CSV/XLSX

Drag and drop file here

Limit 200MB per file • CSV, XLS, XLSX

Browse files

Содержание

- Загрузка данных
  - Первичный обзор данных
  - Категориальные признаки
  - Анализ выбранных параметров
- Шаг 1 · QC-анализ зависимости между параметрами
  - QC кросс-плот
  - Распределение параметров
  - Невязки
  - Анализ выбросов невязок
- Шаг 2 · Кросс-валидация
  - Выбор лучшей CV
  - QC кросс-плот лучшей CV
  - Невязки CV
  - Анализ выбросов невязок CV
- Шаг 3 · Анализ параметров по категориям
  - Распределение параметров по категориям
  - QC кросс-плот по категориям
- Шаг 4 · Фильтрация скважин на кросс-плоте

Выбор горизонта

Все горизонты

Горизонты

Top_Reservoir ×

Выбрано горизонтов: 1 из 2

Круговая диаграмма

Палетка для диаграммы категорий

Plotly

Прозрачность

1.00

0.10 1.00

Граница секторов

Толщина линии

0

0 5

black

Столбчатая диаграмма

Что считать на столбцах

Количество скважин

Загрузка данных: категориальные признаки

Палетка для Bar chart по категориям

Plotly

Направление

Вертикальное

Горизонтальное

Граница столбцов

Толщина линии

0

0 5

black

Прозрачность

1.00

0.10 1.00

Что считать на столбцах

Количество скважин

Количество скважин

Минимум

Максимум

Медиана

Среднее

Стандартное отклонение

Шаг 2: RMSE по фолдам

Палетка для Bar chart RMSE для CV

Plotly

Направление

Вертикальное

Горизонтальное

Граница столбцов

Толщина линии

0

0 5

black

Прозрачность

1.00

0.10 1.00

Шаг 2: RMSE по схемам CV

Палетка для Bar chart RMSE для CV

Plotly

Направление

Вертикальное

Горизонтальное

Граница столбцов

Толщина линии

0

0 5

black

Прозрачность

1.00

0.10 1.00

Что считать на столбцах

Количество скважин

Шаг 3: количество скважин по категориям

Палетка для Bar chart по категориям

Plotly

Направление

Вертикальное

Горизонтальное

Граница столбцов

Толщина линии

0

0 5

black

Прозрачность

1.00

0.10 1.00

Круговые диаграммы по нескольким категориям

Палетка для Bar chart по категориям

Plotly

Прозрачность

1.00

0.10 1.00

Граница секторов

Толщина линии

0

0 5

black

Столбчатая диаграмма по нескольким категориям

Палетка для Bar chart по категориям

Plotly

Что считать на столбцах

Количество скважин

Направление

- Вертикальное
- Горизонтальное

Прозрачность

1.00

0.10 1.00

Граница столбцов

Толщина линии

0

0 5

black

Что считать на столбцах

Количество скважин

- Количество скважин
- Минимум
- Максимум
- Медиана
- Среднее
- Стандартное отклонение

Матрица корреляции и Pairplot

Палитра матрицы корреляции

RdBu

Цвет точек Pairplot

steelblue

Размер точек Pairplot

5

2 20

Прозрачность точек Pairplot

0.70

0.10 1.00

Категория для цвета точек (опционально)

tectonic_zone

Цвета категорий (Pairplot)

Central_Graben

black

North_Block

blue

South_Block

brown

Тип Pairplot

Plotly Pairplot (interactive)

Тип Pairplot

Seaborn Pairplot (static)

Тип диагонали Seaborn Pairplot

kde

Толщина линии

1.50

1.00 10.00

Тип линии

solid

Масштаб Seaborn Pairplot

1.00

0.50 6.00

Размер Seaborn Pairplot

1.80

0.80 6.00

Отображать только нижний треугольник (Corner)

Цвет гистограмм Seaborn Pairplot

orange

Цвет KDE-кривой Seaborn Pairplot

black

Гистограмма

Цвет заливки гистограмм

orange

Прозрачность гистограммы

0.85

0.10 1.00

Обводка столбцов

Включить обводку

black

Толщина линии

1

0 5

Кривая KDE

black

solid

Толщина линии

3

1 10

Линия среднего значения (Mean)

green

dash

Толщина линии

2

1 10

Линия медианы (Median)

red

dot

Толщина линии

2

1 10

Линии ±σ

orange

dash

Толщина линии

2

1 10

Множитель σ

3

1 3

Boxplot

Цвет заливки boxplot

royalblue

Прозрачность бокспплота

0.60

0.10 — 1.00

Направление

- (•) Вертикальное
- ( ) Горизонтальное

Контур бокспплота

Толщина линии

2

0 — 6

royalblue

Линия среднего значения Mean на boxplot

green

dash

Толщина линии

2

1 — 10

Линия медианы Median на boxplot

red

dot

Толщина линии

2

1 — 10

Кросс-плот

Точки на основных cross-plot

black

Размер точек

7

3 — 20

Прозрачность точек

0.80

0.10 — 1.00

Точки на графиках аппроксимаций

brown

Размер точек аппроксимации

7

3 — 20

Прозрачность точек аппроксимации

0.80

0.10 — 1.00

Линия регрессии для кросс-плота

Линия регрессии для QC и CV

orange

Толщина линии регрессии

3

1 — 8

Тип линии регрессии

solid

Линия Y = X для cross-plot

Линия Y = X

lightgray

Толщина линии Y = X

3

1 — 8

Тип линии Y = X

dash

График невязок

Цвет точек на графике невязок

black

Размер точек

8

3 — 20

Прозрачность точек

0.85

0.10 — 1.00

Карта невязок

Палетка для карты невязок Δ

RdBu

Размер точек карты

12

3 — 30

Прозрачность точек карты

0.90

0.10 — 1.00

Категория на карте

tectonic_zone

Подсветить значение

Без подсветки

Яркость подсвеченной категории

1.00

0.10 — 1.00

Яркость остальных точек

0.15

0.05 — 1.00

Корреляционный анализ

☑ Все параметры

Параметры для анализа

Z_well × Z_map × T_well × T_map × X_coord × Y_coord ×

Порог КК (|КК| ≥)

0.70

0.00 — 1.00

Типы аппроксимации

Выбор типов

Типы аппроксимации (Шаг 1 и Шаг 4)

Все линии аппроксимации (Шаг 1 и Шаг 4)

Типы аппроксимации (Шаг 1 и Шаг 4)

Linear × Cubic ×

Типы аппроксимаций для графиков кросс-валидации (Шаг 2)

Все линии аппроксимации (Шаг 2)

Типы аппроксимаций для графиков кросс-валидации (Шаг 2)

Linear × Quadratic ×

Типы аппроксимаций по категориям (Шаг 3)

Все линии аппроксимации (Шаг 3)

Типы аппроксимаций по категориям (Шаг 3)

Linear × Power Law ×

Цвета линий аппроксимаций

Linear

orange

solid

Толщина линии

3

1 10

Quadratic

green

solid

Толщина линии

3

1 10

Cubic

purple

solid

Толщина линии

3

1 10

Polynomial Degree 4

darkgreen

solid

Толщина линии

3

1 10

Polynomial Degree 5

darkred

solid

Толщина линии

3

1 10

Polynomial Degree 6

black

solid

Толщина линии

3

1 10

Polynomial Degree 7

blue

solid

Толщина линии

3

1 10

Polynomial Degree 8

brown

solid

Толщина линии

3

1 10

Polynomial Degree 9

cadetblue

solid

Толщина линии

3

1 10

Polynomial Degree 10

coral

solid

Толщина линии

3

1 10

Power Law

magenta

solid

Толщина линии

3

Exponential

red

solid

Толщина линии

3

1 10

Logarithmic

brown

solid

Толщина линии

3

1 10

Robust (Huber)

black

solid

Толщина линии

3

1 10

Theil-Sen

darkcyan

solid

Толщина линии

3

1 10

RANSAC

darkmagenta

solid

Толщина линии

3

1 10

LOWESS

cyan

solid

Толщина линии

3

1 10

Quantile Regression (τ = 0.1 / 0.5 / 0.9)

τ=0.1

darkred

solid

Толщина линии

3

1 10

τ=0.5

black

solid

Толщина линии

3

1 10

τ=0.9

darkgreen

solid

Толщина линии

3

1 10

Анализ выбросов по невязкам (Шаги 1 и 2)

Порог выбросов по правилу σ

2.00

1.00 6.00

Множитель IQR (правило IQR)

1.50

1.00 3.00

Нижний перцентиль (правило перцентилей), %

5.00

0.00 20.00

Верхний перцентиль (правило перцентилей), %

95.00

80.00 100.00

Параметры валидации (Шаг 2)

Random seed: Random K-Fold, Random K-Fold (buffered), Leave-P-Out, Spatial Leave-P-Out (Шаг 2)

Текущий seed: 42

Новый seed

Сбросить seed

Случайное разбиение заданного seed. Влияет только на Random K-Fold, Leave-P-Out и Spatial Leave-P-Out. Остальные схемы CV детерминированы и от seed не зависят.

Random K-Fold / Random K-Fold (buffered)

Рекомендуемое k: 10 (скважин: 100)

k влияет на стабильность и достоверность оценки модели.

k для Random K-Fold

10

3 20

Block / Buffered Cross Validation

Рекомендуемая сетка: 2×2 (медианное расстояние между скважинами: 5677 м)

Сетка должна соответствовать плотности скважин.

Сетка для Block CV (N×N)

2

2 10

Buffered Cross Validation / Random K-Fold (buffered)

Рекомендуемый buffer: 2838 м (основано на медианном расстоянии между скважинами)

Buffer исключает точки рядом с тестовым блоком, снижая пространственную зависимость между обучением и тестом. Координаты X_coord и Y_coord — в метрах.

Буферная зона Buffer zone (м)

2838

64 11353

Leave-P-Out / Spatial Leave-P-Out

Рекомендуемое количество повторов: 30

Число повторов CV

30

5 200

Используется для Leave-P-Out и Spatial Leave-P-Out. Метрики усредняются по нескольким случайным разбиениям.

Leave-P-Out

Leave-P-Out test size (%)

10

1 50

На каждом повторе случайно исключается P% скважин для проверки модели.

Spatial Leave-P-Out

Рекомендуемый радиус пространственного исключения: 5676 м

Скважины внутри радиуса вокруг тестовой точки исключаются из обучения. Координаты X_coord и Y_coord — в метрах.

Радиус пространственного исключения Spatial exclusion radius (м)

5676

64 14067

Колонка для Stratified by Zone (CV)

Колонка для Stratified by Zone (CV)

tectonic_zone

Distance-based exclusion CV

Способ задания радиуса исключения

- Множитель медианного межскважинного расстояния
- Абсолютный радиус (м)

Множитель медианного межскважинного расстояния (Distance-based exclusion CV)

1.00

0.25 3.00

0.5 — мягкая пространственная фильтрация

1.0 — рекомендуемое значение

1.5 — строгая пространственная фильтрация

2.0–3.0 — очень строгая проверка, почти независимые скважины

Анализ по категориям (Шаг 3)

Категориальный параметр

tectonic_zone

Размер точек

7

3 20

Прозрачность точек

0.80

0.10 1.00

Central_Graben (38 скв.)

Цвет точек

black

Цвет линии

black

North_Block (36 скв.)

Цвет точек

blue

Цвет линии

blue

South_Block (26 скв.)

Цвет точек

brown

Цвет линии

brown

Фильтрация скважин (Шаг 4)

Режим фильтрации

- Без фильтра
- Ручное исключение
- Случайное исключение (%)
- Выделение кликом по точке

Текущий режим: Без фильтра

Новый seed

Сбросить seed

Текущий набор: 42

Число наборов на уровень

500

50 2000

Structural QC — cross-plot & cross-validation

CROSSPL✳T↔CROSS⊗VALIDATION

Данные обрабатываются в памяти сессии и не записываются на диск приложения.

© А.С.Поздняков 2026

📖 О проекте и логика работы

В геологии и сейсморазведке регулярно возникает задача оценки согласованности альтитудных отметок горизонта по скважинам со структурной картой, построенной по данным сейсморазведки МОГТ 2D/3D, — такая проверка является неотъемлемой частью контроля качества структурных построений при интерпретации. Именно эта задача легла в основу проекта. Однако использованный методологический аппарат — кросс-плот, набор кривых аппроксимации и схемы кросс-валидации — не специфичен для пары «скважина — карта» и в равной степени применим к оценке связи между любыми двумя количественными параметрами.

▶️ **С чего начать:** загрузите свой CSV/XLSX в сайдбаре слева — или выберите готовый пример из выпадающего списка «Выбрать демонстрационный файл» (не нужно ничего готовить заранее, чтобы посмотреть, как это работает). Дальше всё устроено по шагам, они описаны ниже.

Structural QC — cross-plot & cross-validation технически сравнивает два числовых ряда в одних и тех же точках (скважинах) — `PARAM_1` (эталонное значение) и `PARAM_2` (сравниваемое значение) — и честно проверяет, насколько один можно предсказать по другому.

Пример из геологии: **Z_well** (глубина горизонта по скважине) и **Z_map** (глубина того же горизонта по структурной карте). Далее везде для наглядности используются обозначения Z_well / Z_map — но все шаги и формулы одинаково применимы к любой паре PARAM_1/PARAM_2:

Сценарий	Пример PARAM_1 / PARAM_2
скважина ↔ карта	Z_well / Z_map
скважина ↔ атрибут	Z_well / Amplitude
карта ↔ карта	Z_map_v1 / Z_map_v2
атрибут ↔ атрибут	Amplitude / Sweetness

Как это устроено, по шагам

Шаг 0 · Загрузка данных. Импорт CSV/XLSX, сопоставление колонок, автоматическая очистка (пропуски, дубли, мусорные значения, типы данных), корреляционный анализ выбранных параметров (матрицы Пирсона и Спирмена с таблицей пар выше заданного порога), описательная статистика, гистограммы и боксплоты по каждой числовой колонке, а также сгруппированная диаграмма по двум категориям («кросс-таблица»). Для Pairplot рекомендуется выбирать не более 10 параметров. Большинство таблиц можно скачать в Excel.

Шаг 1 · Базовый QC-кросс-плот. Z_well (эталон) против Z_map (сравниваемое): диагональ Y=X, линейная регрессия + набор кривых аппроксимации на выбор, полный набор метрик качества, распределения, анализ невязок и карта невязок, детекция выбросов. Во всех шагах моделью является линейная регрессия (полином степени 1).

Шаг 2 · Кросс-валидация. Та же линейная модель (степень 1), но честно проверенная: обучаем на части скважин, предсказываем на оставшихся, повторяем по разным схемам разбиения — чтобы увидеть реальную, а не «подогнанную» точность. Лучшая схема выбирается автоматически по критерию, который задаётся в сайдбаре: RMSE + RMSE_fold_std (по умолчанию), RMSE, MAE, максимальный R^2 (Actual = Predicted), RMSE + |Bias| или ручной выбор. В выборе участвуют все схемы, включая Random K-Fold и Random K-Fold (buffered). Разброс RMSE по фолдам показан столбчатыми диаграммами и боксплотом для каждой схемы, а полные данные по фолдам — отдельными таблицами для каждой схемы: номер фолда, n_train, n_test, RMSE, MAE и Bias. Результаты воспроизводимы: сид случайных операций по умолчанию 42 и меняется кнопками в сайдбаре; он влияет на Random K-Fold, Random K-Fold (buffered), Leave-P-Out и Spatial Leave-P-Out. Если для фолда в обучении остаётся меньше degree + 2 точек, он отмечается в таблице фолдов как пропущенный: в колонке Fold указаны причина и число обучающих точек, n = 0, метрики пусты; такие фолды на боксплоте не отображаются. В таблице сравнения схем указано число точек с прогнозом (n_pred); если схемы покрывают разное число точек, приложение выводит предупреждение.

Шаг 3 · Анализ по категориям. Та же пара параметров — но отдельно по горизонтам, тектоническим зонам, типу коллектора, типу флюида или любой другой категориальной колонке. Позволяет увидеть, не «едет» ли точность в конкретной зоне или горизонте. Для каждой зоны есть таблица статистики, боксплоты и наложенные гистограммы с собственными бинами, нормировкой и прозрачностью.

Шаг 4 · Фильтрация скважин. Ручное исключение конкретных скважин или случайное исключение заданного процента (0–95%, с пересэмплированием) — чтобы проверить, насколько устойчив результат к сокращению числа скважин и к отдельным наблюдениям. При заданном сиде случайный набор воспроизводим, а кнопка формирует следующий. Отдельный блок (4.5) повторяет случайное исключение на уровнях от 5% до 95% с шагом 5%, по 50–2000 наборов на уровень (по умолчанию 500, задаётся в сайдбаре); для каждого набора считается R^2 (Pearson) in-sample — по оставшимся скважинам и out-of-sample — линия по оставшимся, R^2 по исключённым, и показываются распределения обоих значений.

(Помимо варианта без фильтрации, Шаг 4 поддерживает три режима фильтрации: ручное исключение скважин по списку, случайное исключение заданного процента скважин с пересэмплированием, а также интерактивное выделение скважин на кросс-плоте — кликом по точке (одна за клик, несколько через Shift+клик) или рамкой (Box) либо лассо (Lasso); переключение режимов — иконками в правом верхнем углу графика.)

☝🏻 **Дальше — подробный справочник** (зачем нужна кросс-валидация, все схемы CV, все кривые аппроксимации, все метрики с формулами). Для первого знакомства достаточно прочитать до этого места — остальное пригодится по ходу работы с конкретными шагами.

Зачем вообще кросс-валидация, а не просто регрессия

Если просто построить регрессию по всем скважинам и посчитать R^2/RMSE на них же — результат будет обманчиво хорошим: модель могла «подсмотреть» все точки при обучении. Кросс-валидация честно исключает часть скважин из обучения и проверяет предсказание на них. Схемы ниже отличаются тем, **как именно** выбираются исключаемые скважины — это особенно важно для пространственных данных (соседние скважины «похожи» друг на друга, и случайное разбиение это игнорирует).

Типы кросс-валидации (от самой оптимистичной к самой честной)

Метод	Суть	Когда применять	Пример (100 скважин)
Random K-Fold	`sklearn.KFold(shuffle=True)` : скважины случайно перемешиваются и делятся на k равных частей (если заданное k превышает число точек n, оно автоматически уменьшается до n); каждая часть по очереди становится тестом, обучение — на остальных частях	⚠️ Не для пространственных данных — даёт завышенную точность	5 фолдов по ~20 скважин: в каждом обучение на ~80 скважинах, в таблице фолдов n_test ≈ 20, n_train ≈ 80. Соседние скважины регулярно оказываются одновременно в обучении и тесте
Random K-Fold (buffered)	Тот же случайный KFold с тем же сидом, то есть те же тестовые фолды, что и у Random K-Fold. Перед обучением из обучающей выборки удаляются скважины, чьё расстояние до ближайшей тестовой скважины ≤ buffer; обучение остаётся на скважинах дальше buffer	Случайные фолды без утечки соседних скважин; сравнение с обычным Random K-Fold показывает, насколько тот был завышен	Тот же разбив 20/80: n_test совпадает с Random K-Fold, а n_train ≈ 80, если соседи дальше buffer. При плотной сети n_train может упасть до 40–60, это видно в колонке n_train таблицы фолдов
Leave-One-Well-Out (LOWO)	`LeaveOneGroupOut` по `well_id` : поочерёдно вся скважина целиком (все её строки/горизонты) исключается из обучения и становится единственным тестом — так проверяется каждая скважина по разу	Стандарт при малом числе скважин (<20–30)	100 фолдов по одной скважине: n_test = 1, n_train = 99
Block CV	Площадь делится регулярной сеткой grid_n×grid_n по X_coord/Y_coord; весь блок по очереди становится тестом, обучение — на скважинах вне блока (блок пропускается, если для обучения остаётся меньше degree + 2 точек, то есть меньше 3 при линейной модели)	Равномерная сетка скважин	сетка 3×3 даёт до 9 блоков, примерно по 11 скважин в каждом: n_test ≈ 11, n_train ≈ 89
Buffered CV	Как Block CV, но дополнительно из обучения убираются скважины, чьё минимальное расстояние до ближайшей тестовой точки блока ≤ buffer	Снижает утечку через границу блока	та же сетка 3×3: n_test ≈ 11, а n_train меньше 89 на число скважин, попавших в буфер вокруг блока
Leave-P-Out	На каждом из repeats повторов случайно (без возврата) выбирается p_percent% скважин — тест, обучение — на остальных; итоговый прогноз скважины — среднее по всем повторам, где она попадала в тест; скважины, которые ни разу не попали в тест, получают пустой прогноз (NaN)	Оценка разброса устойчивости при разном случайном составе теста	50 повторов по 10 случайных скважин в тесте: n_test = 10, n_train = 90. Скважины, которые ни разу не попали в тест, без прогноза, поэтому n_pred < 100
Spatial Leave-P-Out	На каждом из repeats повторов случайно выбирается скважина-центр; все скважины в радиусе ≤ radius от неё — тест, остальные — train; прогноз усредняется по повторам так же, как в Leave-P-Out	Ближе всего к реальному прогнозу новой необуренной площади	центр — случайная скважина, радиус 1000 м: в тест попадают все скважины внутри круга, их число меняется от повтора к повтору; n_train — остальные
Stratified by Zone	`LeaveOneGroupOut` по `tectonic_zone` : поочерёдно вся тектоническая зона целиком становится тестом, обучение — на скважинах из остальных зон (по умолчанию колонка `tectonic_zone` , если её нет — `horizon_id` ; другую колонку можно выбрать в сайдбаре; нужны минимум две уникальные категории)	Проверка, переносится ли модель на новую зону	4 тектонические зоны дают 4 фолда: n_test — число скважин в зоне, n_train — все остальные

Метод	Суть	Когда применять	Пример (100 скважин)
Distance-based exclusion CV	Для каждой скважины i по очереди: из обучения исключаются все скважины на расстоянии ≤ excl_radius от неё (excl_radius = медиана попарных расстояний между скважинами × variogram_factor), тест — только скважина i. Фолды одиночные, поэтому std RMSE по фолдам — это разброс абсолютных остатков по точкам; если в обучении остаётся меньше degree + 2 (3) точек, скважина пропускается: фолд отмечается в таблице как пропущенный, прогноз — NaN	Самая строгая проверка на пространственную утечку — по сути LOWO с буфером	100 фолдов по одной скважине: n_train — скважины дальше excl_radius от неё. У скважин в плотном центре облака n_train мал, такие фолды помечаются как пропущенные

Параметры k, grid_n, buffer, p_percent, radius, variogram_factor и repeats — это не константы, а слайдеры в сайдбаре; для каждого там же показано рекомендуемое значение. Рекомендуемый buffer равен 0.5 × медианное расстояние между скважинами и общий для Buffered CV и Random K-Fold (buffered). excl_radius для Distance-based задаётся либо как медиана × variogram_factor, либо абсолютным значением в метрах (режим absolute). Координаты X_coord и Y_coord предполагаются заданными в метрах; buffer, radius и excl_radius задаются в тех же единицах. При выборе нескольких горизонтов одновременно Random K-Fold, Random K-Fold (buffered), Leave-P-Out и Spatial Leave-P-Out разбивают отдельные записи «скважина–горизонт», а не скважины целиком, поэтому одна и та же скважина может попасть и в обучение, и в тест; Leave-One-Well-Out сохраняет все записи скважины вместе.

Кривые аппроксимации

Помимо прямой линии, на кросс-плот можно наложить одну из 17 кривых — от простых полиномов до устойчивых к выбросам методов:

Метод	Общий вид уравнения	Когда полезен
Linear	$y = a + bx$	Базовая линейная связь
Quadratic	$y = a + bx + cx^2$	Связь с одним изгибом
Cubic	$y = a + bx + cx^2 + dx^3$	Связь с точкой перегиба
Polynomial Degree 4–10	$y = a_0 + a_1x + \cdots + a_nx^n$	Более сложная, но реже оправданная форма связи
Power Law	$y = ax^b$ $(x, y > 0)$	Степенная зависимость
Exponential	$y = ae^{bx}$ $(y > 0)$	Экспоненциальный рост/спад
Logarithmic	$y = a + b\ln x$ $(x > 0)$	Насыщение/замедление роста
Robust (Huber)	$y = a + bx$; коэффициенты минимизируют функцию потерь Хьюбера	Линейная связь, устойчивая к выбросам
Theil-Sen	$y = a + bx; b = \text{median}\left(\frac{y_j - y_i}{x_j - x_i}\right)$	Линейная связь, устойчивая к выбросам
RANSAC	$y = a + bx$; подбор по максимальному числу inlier-точек	Линейная связь при сильных выбросах/аномалиях
LOWESS	без единой формулы — локальная регрессия в скользящем окне	Повторяет форму облака точек без предположений о форме связи
Quantile Regression (τ=0.1/0.5/0.9)	$y = a_\tau + b_\tau x$	Три линии для нижней/средней/верхней границы разброса

Для кривых τ=0.1 и τ=0.9 метрика R^2 может быть отрицательной — это нормально. Quantile regression оптимизирует не квадрат ошибки (как линейная регрессия), а «pinball loss», поэтому её кривые описывают границы разброса, а не центр облака точек. Для оценки качества таких кривых ориентируйтесь на Equation и Bias, а не на R^2.

Метрики кросс-плота и обозначения

Обозначим Δ — невязку (разницу между двумя значениями). На базовом QC-кросс-плоте (Шаг 1) Δ = Z_well − Z_map; на кривых аппроксимации (Шаги 1 и 3) Δ = Predicted − Actual; в кросс-валидации (Шаг 2) Δ = Actual − Predicted, то есть Z_well − Predicted, как в коде. Квадратичные и абсолютные метрики (RMSE, MSE, MAE, R^2) от знака не зависят, а знаковый Bias меняет знак при смене соглашения.

Метрика	Формула
R^2_lin (коэффициент детерминации, Шаг 1)	$R^2_{lin} = r^2$ (квадрат корреляции Пирсона, только линейная связь)

Метрика	Формула
R^2_fit (кривые аппроксимации)	$R^2_{fit} = 1 - \frac{\sum(\Delta)^2}{\sum(y - \bar{y})^2}$ (любая форма кривой)
R^2 (Actual = Predicted), CV	формула R^2_{fit}, применённая к out-of-fold прогнозам (`r2_score`)
R^2 (Pearson, Predicted vs Actual), таблица метрик Шага 2	r^2 между Predicted и Actual (`linregress`)
RMSE (среднеквадратичная ошибка)	$\sqrt{\frac{1}{N}\sum(\Delta)^2}$
MSE (среднеквадратичная ошибка)	$\frac{1}{N}\sum(\Delta)^2$
MAE (абсолютная погрешность)	$\frac{1}{N}\sum\lvert\Delta\rvert$
Bias (систематическое смещение)	$\frac{1}{N}\sum(\Delta)$
Std (стандартное отклонение невязок)	$\sqrt{\frac{1}{N-1}\sum(\Delta_i - \bar{\Delta})^2}$
Variance (дисперсия невязок)	$\frac{1}{N-1}\sum(\Delta_i - \bar{\Delta})^2$
MAPE, % (ошибка в процентах)	$\frac{100}{N}\sum\frac{\lvert\Delta\rvert}{\max(\lvert y\rvert,\ 10^{-9})}$
P-value (значимость линейной корреляции)	$t = r\sqrt{\frac{N-2}{1-r^2}},\ p = 2\,(1 - F_{t,\,N-2}(\lvert t\rvert))$
Уравнение линейной регрессии	$y = a + bx$; наклон b и intercept a — из `linregress`

P-value отвечает на вопрос: насколько вероятно получить наблюдаемую линейную связь между PARAM_1 и PARAM_2 (или более сильную) случайно, если на самом деле линейной зависимости нет (нулевая гипотеза H_0: истинный наклон регрессии b = 0). Чем меньше p-value, тем меньше оснований считать, что наблюдаемая зависимость возникла случайно. Обычно связь считают статистически значимой при p < 0.05. Показатель рассчитывается только для базового QC-кросс-плота (Шаг 1) с использованием `scipy.stats.linregress` .

Детекция выбросов

Выбросы ищутся в невязках Δ (Шаг 1 и Шаг 2) четырьмя независимыми правилами. Каждая точка проверяется по каждому правилу отдельно, поэтому результаты можно сравнивать между собой:

Правило	Условие выброса	Параметр в сайдбаре
Сигма	$\lvert\Delta\rvert > k\sigma$, где σ — выборочное стандартное отклонение невязок (ddof = 1)	k = 1.0–6.0, по умолчанию 2.0
IQR	$\Delta < Q25 - k \cdot IQR$ или $\Delta > Q75 + k \cdot IQR$	k = 1.0–3.0, по умолчанию 1.5
Modified z-score	$\lvert 0.6745\,(\Delta - \tilde{\Delta})/MAD\rvert > 3.5$, где $\tilde{\Delta}$ — медиана невязок, MAD — медианное абсолютное отклонение; устойчиво к экстремальным значениям	фиксированный порог 3.5
Квантильное	$\Delta < P_{low}$ или $\Delta > P_{high}$ — хвосты за пределами выбранных перцентилей	P_low 0–20%, по умолчанию 5%; P_high 80–100%, по умолчанию 95%

Если σ или MAD равны нулю, соответствующее правило не помечает ни одной точки.

Статистика параметров

Для PARAM_1 и PARAM_2 отдельно считается расширенная описательная статистика — вот что означает каждая величина:

Статистика	Формула / определение
Count	N — число непустых значений
μ (mean)	$\mu = \frac{1}{N}\sum x_i$ — среднее арифметическое
median	медиана — значение, делящее выборку пополам (50-й перцентиль)
mode	мода — наиболее часто встречающееся значение
σ (std)	$\sigma = \sqrt{\frac{1}{N-1}\sum (x_i - \mu)^2}$
variance	$\sigma^2 = \frac{1}{N-1}\sum (x_i - \mu)^2$
CV, %	$\frac{\sigma}{\mu} \times 100\%$ — коэффициент вариации (разброс относительно среднего)
min	минимальное значение
Q05	5-й перцентиль
Q25	25-й перцентиль (первый квартиль)
Q75	75-й перцентиль (третий квартиль)
Q95	95-й перцентиль
max	максимальное значение
range	$\max - \min$
IQR	$Q75 - Q25$ — межквартильный размах
IQR lower bound	$Q25 - 1.5 \cdot IQR$ — нижняя граница для правила IQR
IQR upper bound	$Q75 + 1.5 \cdot IQR$ — верхняя граница для правила IQR
RMSE	$\sqrt{\frac{1}{N}\sum x_i^2}$ — корень из среднего квадрата; для невязок это RMSE относительно нуля
μ+3σ	$\mu + 3\sigma$ — верхняя граница ±3σ
μ−3σ	$\mu - 3\sigma$ — нижняя граница ±3σ

Границы IQR в таблице статистики фиксированы при k = 1.5. Для детекции выбросов коэффициент k задаётся слайдером в сайдбаре (1.0–3.0, по умолчанию 1.5). RMSE и μ±3σ — это статистика невязок (Шаги 1 и 2), для PARAM_1 и PARAM_2 они не выводятся.

Подробная методика, формулы и обоснование каждой схемы CV — в проектной документации.

📁 Формат входного файла

Обязательные колонки

- **well_id** — идентификатор скважины
- **X_coord** — координата X (в метрах)
- **Y_coord** — координата Y (в метрах)
- **Параметр 1** — эталонный параметр (скважина, карта, атрибут и т.д.)

- **Параметр 2** — сравниваемый параметр (скважина, карта, атрибут и т.д.)

- Возможные примеры параметров:

  - Z_well
  - Z_map
  - T_well
  - T_map
  - Vint_well
  - Vint_map
  - Vav_well
  - Vav_map
  - ΔT_well
  - ΔT_map
  - ΔZ_well
  - ΔZ_map
  - любой другой числовой атрибут

Дополнительные колонки

- **horizon_id** — идентификатор горизонта
- **tectonic_zone** — тектоническая зона
- **reservoir_flag** — тип коллектора
- **fluid_type** — тип флюида
- **well_category** — категория скважины (используется в Шаге 3)
- любые дополнительные категориальные или числовые параметры

Пример содержимого файла

	well_id	X_coord	Y_coord	Z_well	Z_map	horizon_id	tectonic_zone
0	Well_001	125,000	745,000	3,120.5	3,108.7	H1	Zone_A
1	Well_002	126,500	746,200	3,188.2	3,201.5	H1	Zone_A
2	Well_003	128,200	748,100	3,256.4	3,242.1	H1	Zone_B

Загрузка данных

Первичный обзор данных

✅ QC входных данных

Полные дубликаты строк

Полные дубликаты не обнаружены.

well_id с несколькими записями

Для нескольких горизонтов на одну скважину это ожидаемо. Реальное дублирование — только если совпадают well_id И horizon_id.

well_id с несколькими записями не обнаружено.

Совпадающие координаты (с учётом горизонта)

Совпадающих координат (в пределах одного горизонта) не обнаружено.

Пропуски по колонкам

	column	missing values
0	Z_well	0
1	Z_map	0
2	horizon_id	0
3	tectonic_zone	0
4	well_category	0
5	reservoir_flag	0
6	fluid_type	0
7	T_well	0
8	T_map	0
9	well_id	0

Скачать в Excel

Строки, удалённые при очистке

Строки не удалялись.

Количество наблюдений (строк): 100

Уникальных скважин: 100

Колонки: Z_well · Z_map · horizon_id · tectonic_zone · well_category · reservoir_flag · fluid_type · T_well · T_map · well_id · X_coord · Y_coord

Типы данных по колонкам

	Column	Data Types	Pandas dtype	Not NaN	NaN	Unique Values
2	horizon_id	String	object	100	0	1
3	tectonic_zone	String	object	100	0	3
4	well_category	String	object	100	0	3
5	reservoir_flag	String	object	100	0	2
6	fluid_type	String	object	100	0	4
7	T_well	Numeric	float64	100	0	100
8	T_map	Numeric	float64	100	0	100
9	well_id	String	object	100	0	100
10	X_coord	Numeric	float64	100	0	100
11	Y_coord	Numeric	float64	100	0	100

Скачать в Excel

Первые 5 строк

	well_id	X_coord	Y_coord	Z_well	Z_map	horizon_id	tectonic_zone	well_category	reservoir_flag	fluid_type	T_well	T_map
0	W-001	7,501.1	9,671.5	2,319.03	2,304.07	Top_Reservoir	Central_Graben	production	non_reservoir	non_reservoir	1,713.24	1,791.03
1	W-002	10,766.6	6,577.6	2,485.68	2,463.86	Top_Reservoir	South_Block	production	reservoir	water	1,768.15	1,781.45
2	W-003	9,308.2	4,282.2	2,538.94	2,555.91	Top_Reservoir	South_Block	production	reservoir	water	1,866.42	1,821.17
3	W-004	2,702.5	5,237.4	2,325.51	2,283.12	Top_Reservoir	North_Block	production	non_reservoir	non_reservoir	1,772.1	1,707.71
4	W-005	3,602	8,728.1	2,327.43	2,339.09	Top_Reservoir	North_Block	exploration	non_reservoir	non_reservoir	1,730.67	1,704.4

Последние 5 строк

	well_id	X_coord	Y_coord	Z_well	Z_map	horizon_id	tectonic_zone	well_category	reservoir_flag	fluid_type	T_well	T_map
95	W-096	9,015.9	6,778.7	2,468.73	2,495.33	Top_Reservoir	South_Block	production	reservoir	oil	1,817.56	1,832.29
96	W-097	302.4	210.8	2,366.81	2,362.43	Top_Reservoir	North_Block	production	reservoir	oil	1,762.85	1,784.06
97	W-098	4,466.2	3,105.7	2,389.04	2,371.09	Top_Reservoir	Central_Graben	exploration	non_reservoir	non_reservoir	1,765.02	1,783.7
98	W-099	364.2	9,383.4	2,216.75	2,198.68	Top_Reservoir	North_Block	exploration	reservoir	oil	1,707.02	1,660.74
99	W-100	1,474.7	5,384	2,256.62	2,301.07	Top_Reservoir	North_Block	production	reservoir	oil	1,667.11	1,631.74

Скачать в Excel

Статистика параметров Z_well, Z_map

Z_well, m

	Z_well, m
Count	100.00
μ, mean	2,402.19
median	2,405.22
mode	2,216.75
σ, std	92.41
variance	8,539.59
CV %	3.85
min	2,216.75
Q05	2,256.27
Q25	2,325.47

Z_map, m

	Z_map, m
Count	100.00
μ, mean	2,395.26
median	2,390.20
mode	2,198.68
σ, std	98.06
variance	9,616.39
CV %	4.09
min	2,198.68
Q05	2,259.44
Q25	2,308.59

Скачать в Excel

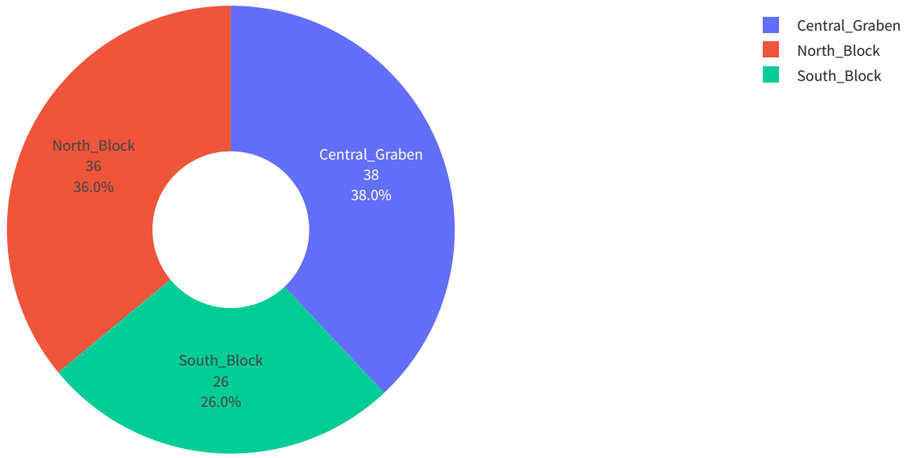
Категориальные признаки

horizon_id (1)

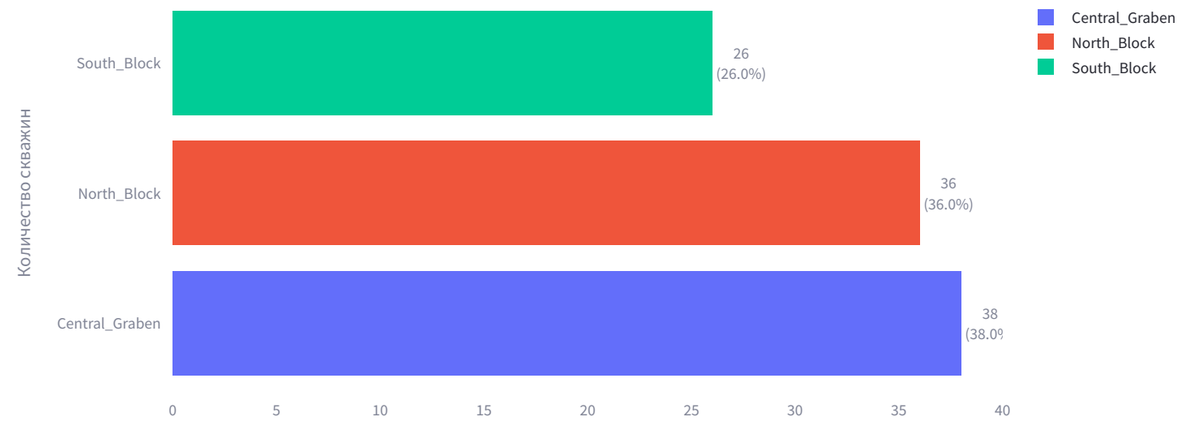
tectonic_zone (3)

Central_Graben, North_Block, South_Block

Количество скважин : tectonic_zone



Количество скважин : tectonic_zone



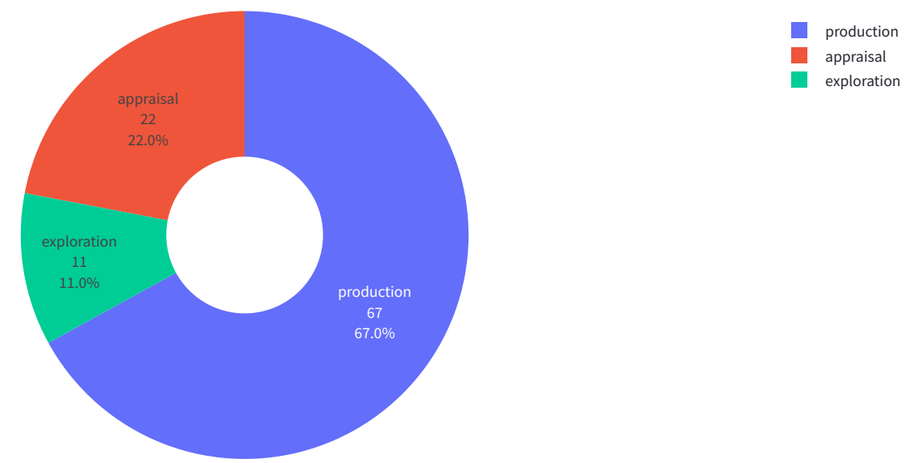
tectonic_zone	Скважин	Записей (скважина-горизонт)	Доля скважин, %
Central_Graben	38	38	38
North_Block	36	36	36
South_Block	26	26	26

Скачать в Excel

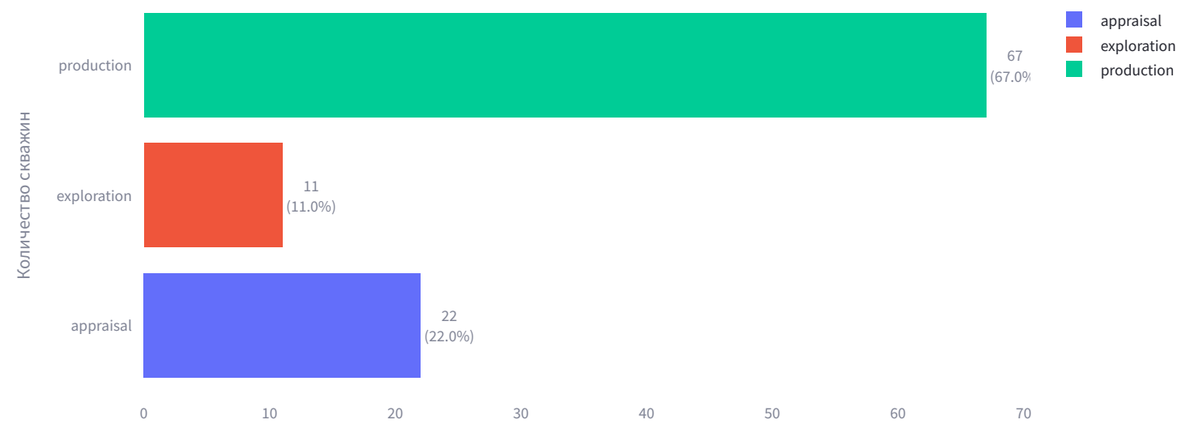
well_category (3)

appraisal, exploration, production

Количество скважин : well_category



Количество скважин : well_category



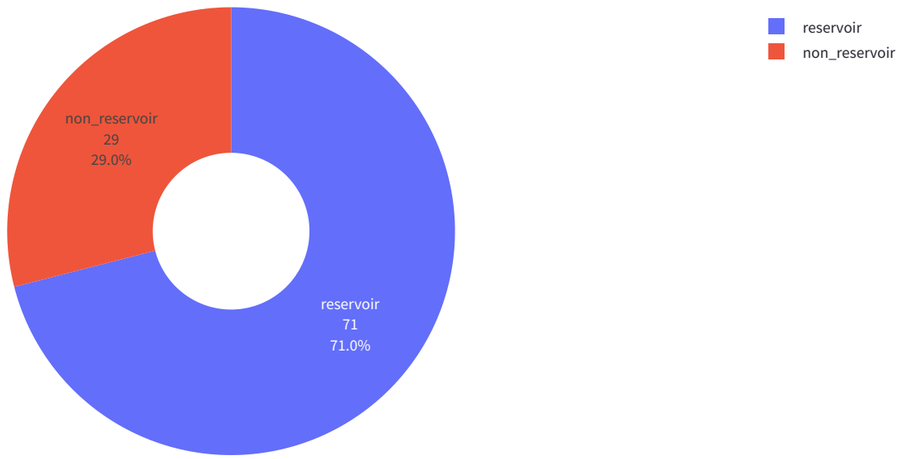
well_category	Скважин	Записей (скважина-горизонт)	Доля скважин, %
appraisal	22	22	22
exploration	11	11	11
production	67	67	67

Скачать в Excel

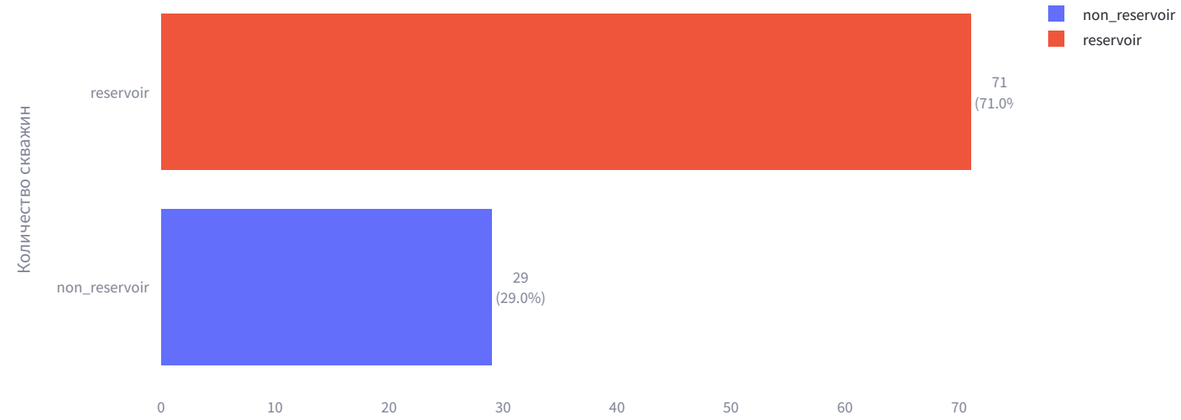
reservoir_flag (2)

non_reservoir, reservoir

Количество скважин : reservoir_flag



Количество скважин : reservoir_flag



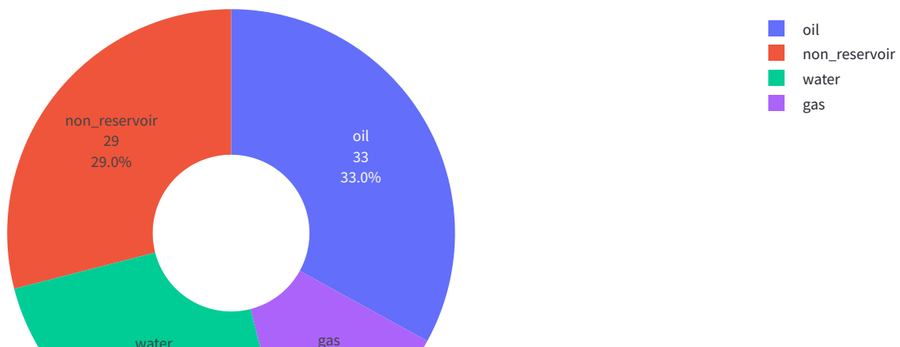
reservoir_flag	Скважин	Записей (скважина-горизонт)	Доля скважин, %
non_reservoir	29	29	29
reservoir	71	71	71

Скачать в Excel

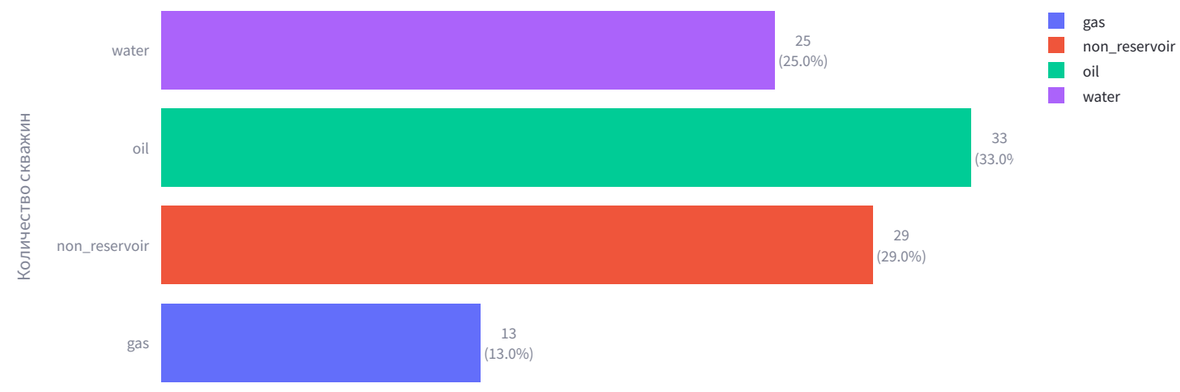
fluid_type (4)

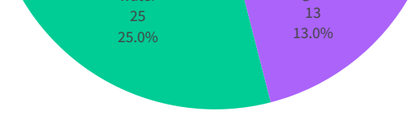
gas, non_reservoir, oil, water

Количество скважин : fluid_type



Количество скважин : fluid_type





fluid_type	Скважин	Записей (скважина-горизонт)	Доля скважин, %
gas	13	13	13
non_reservoir	29	29	29
oil	33	33	33
water	25	25	25

Скачать в Excel

Круговые диаграммы по нескольким категориям

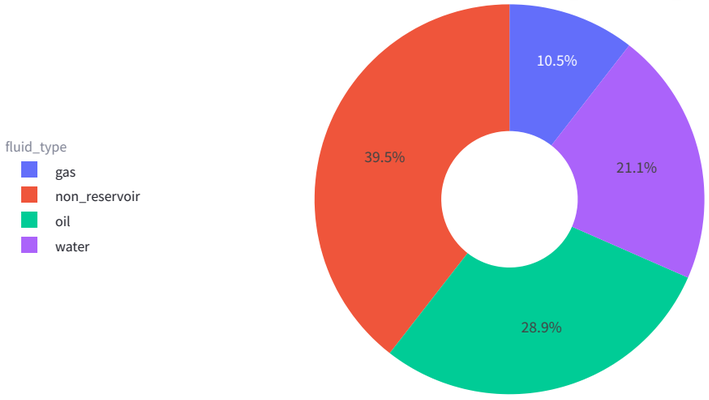
Категория по оси X

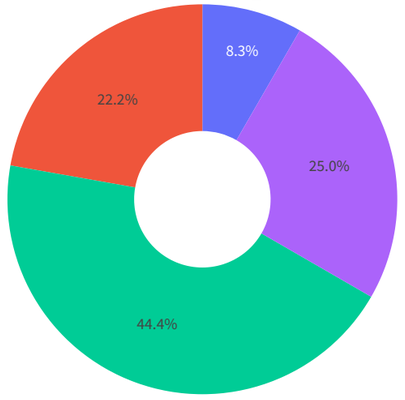
tectonic_zone

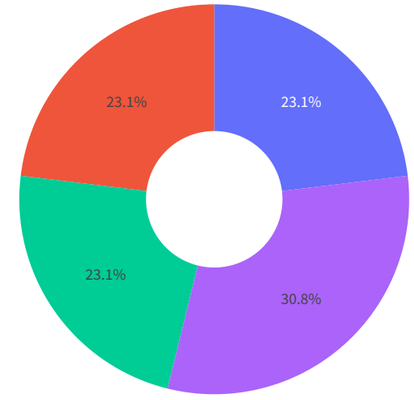
Категория для групп (цвет столбцов)

fluid_type

Круговые диаграммы по нескольким категориям: tectonic_zone × fluid_type







Распределение по двум категориям

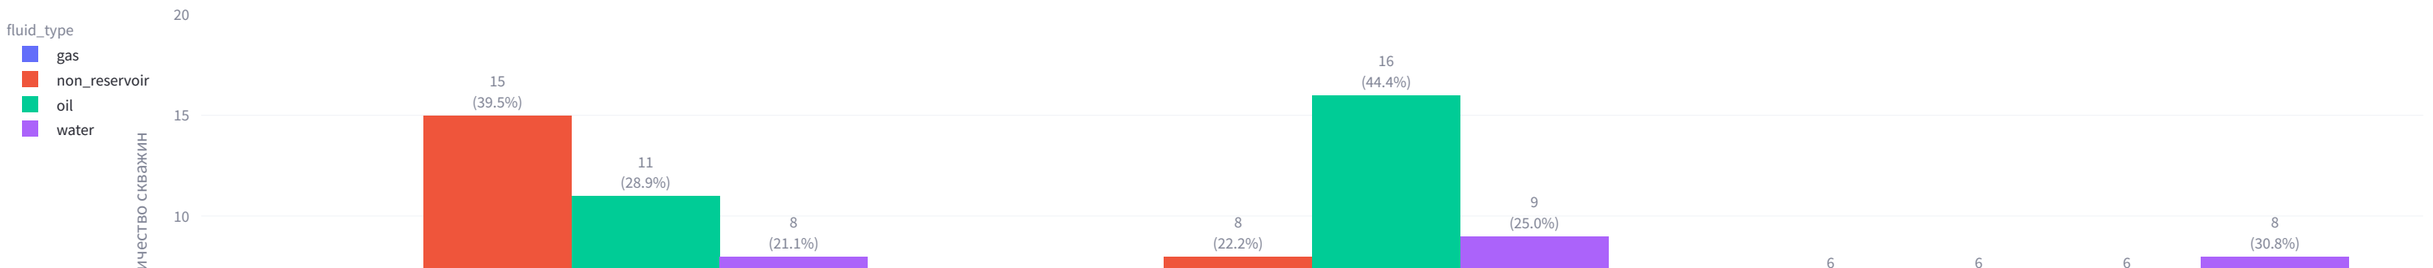
Категория по оси X

tectonic_zone

Категория для групп (цвет столбцов)

fluid_type

Распределение по двум категориям: tectonic_zone × fluid_type



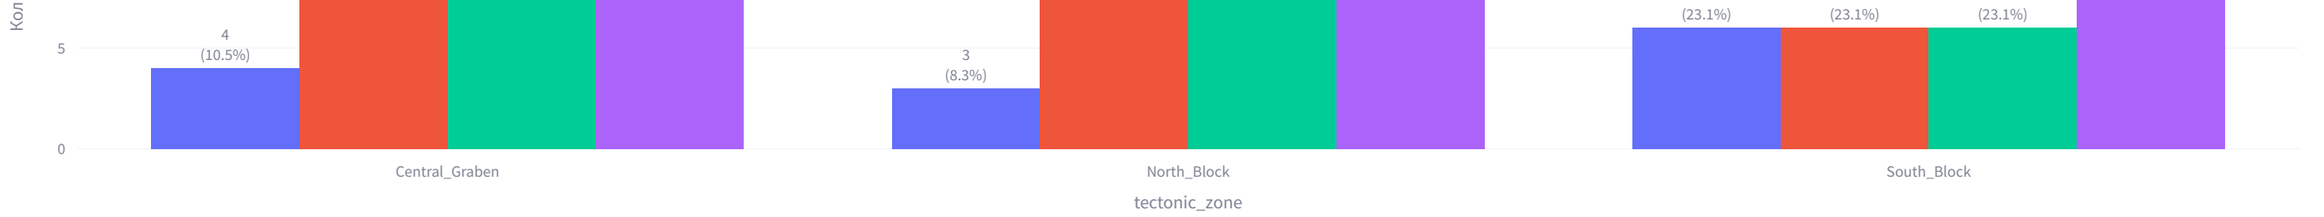


Таблица статистики

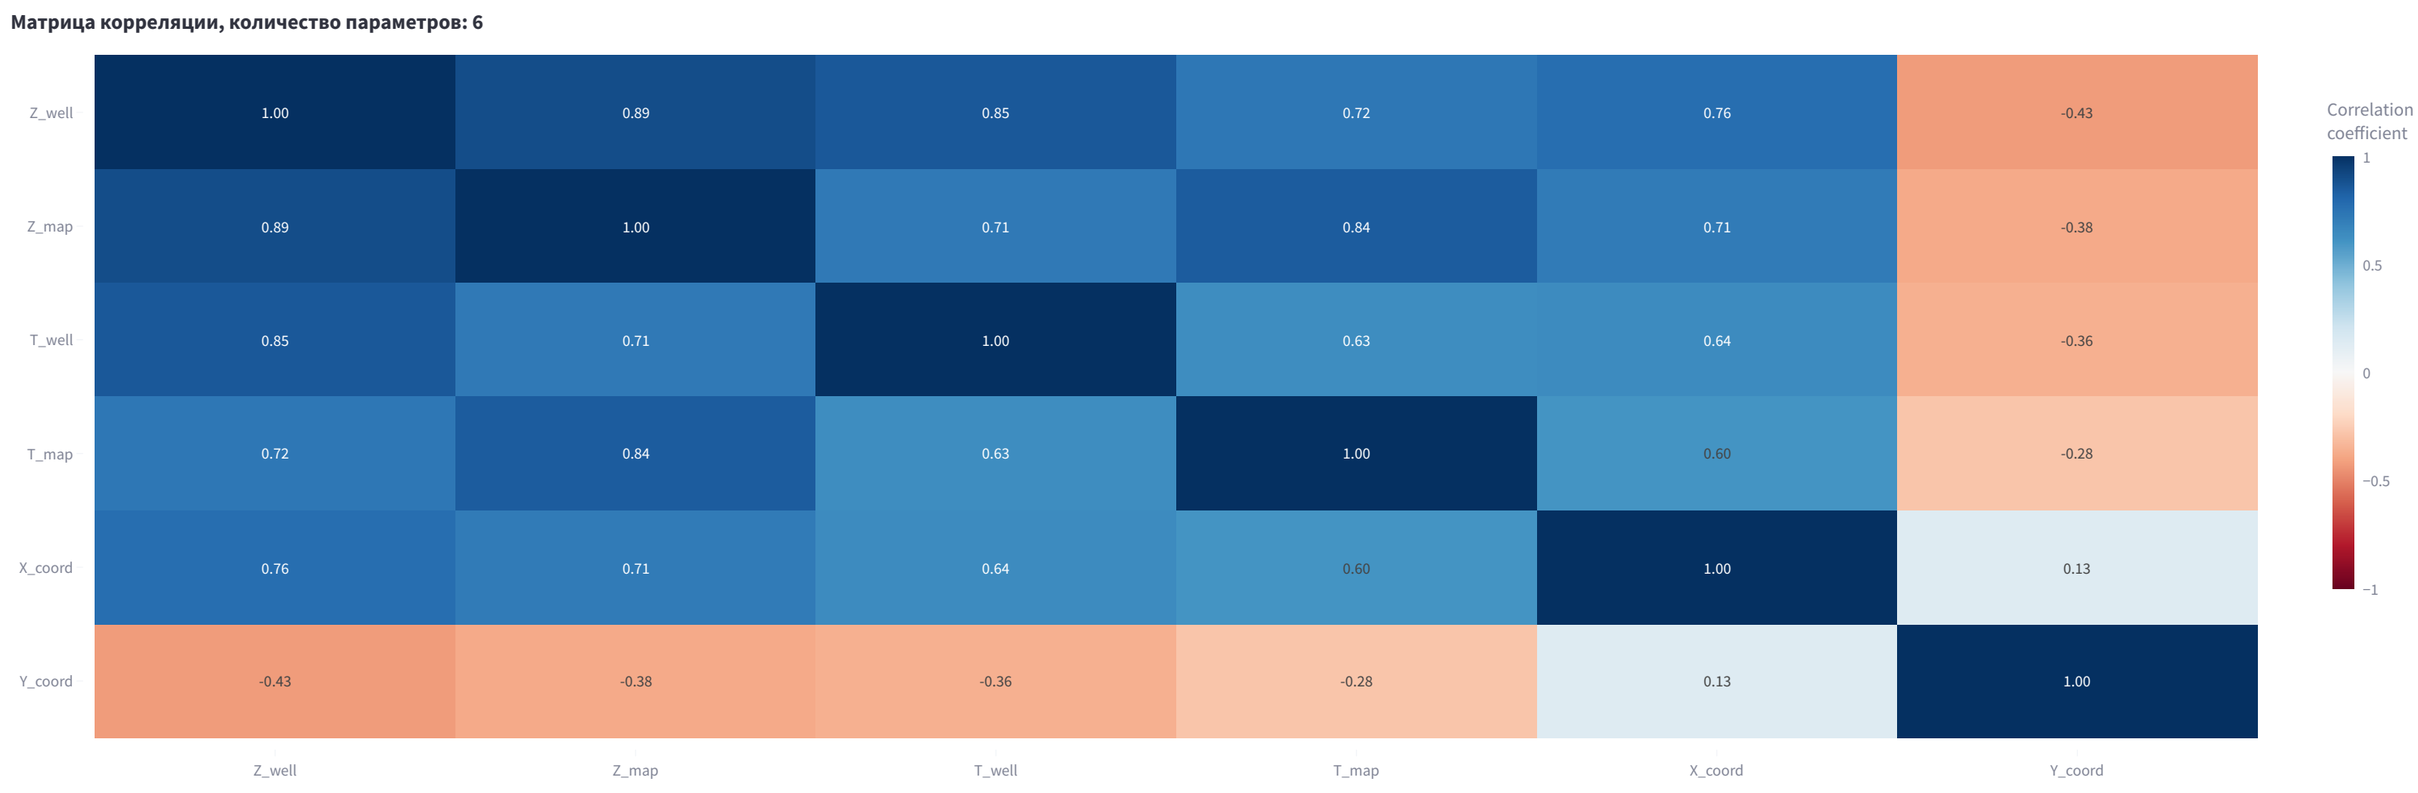
tectonic_zone	gas	non_reservoir	oil	water	Bcero
Central_Graben	4 (10.5%)	15 (39.5%)	11 (28.9%)	8 (21.1%)	38
North_Block	3 (8.3%)	8 (22.2%)	16 (44.4%)	9 (25.0%)	36
South_Block	6 (23.1%)	6 (23.1%)	6 (23.1%)	8 (30.8%)	26
Bcero	13	29	33	25	100

Скачать в Excel

Анализ выбранных параметров

Матрица корреляции

Скачать в Excel



Pearson — только линейная связь. Spearman — любая монотонная (экспонента, логарифм, степенная).

Пары параметров с коэффициентом корреляции больше или равно 0.70

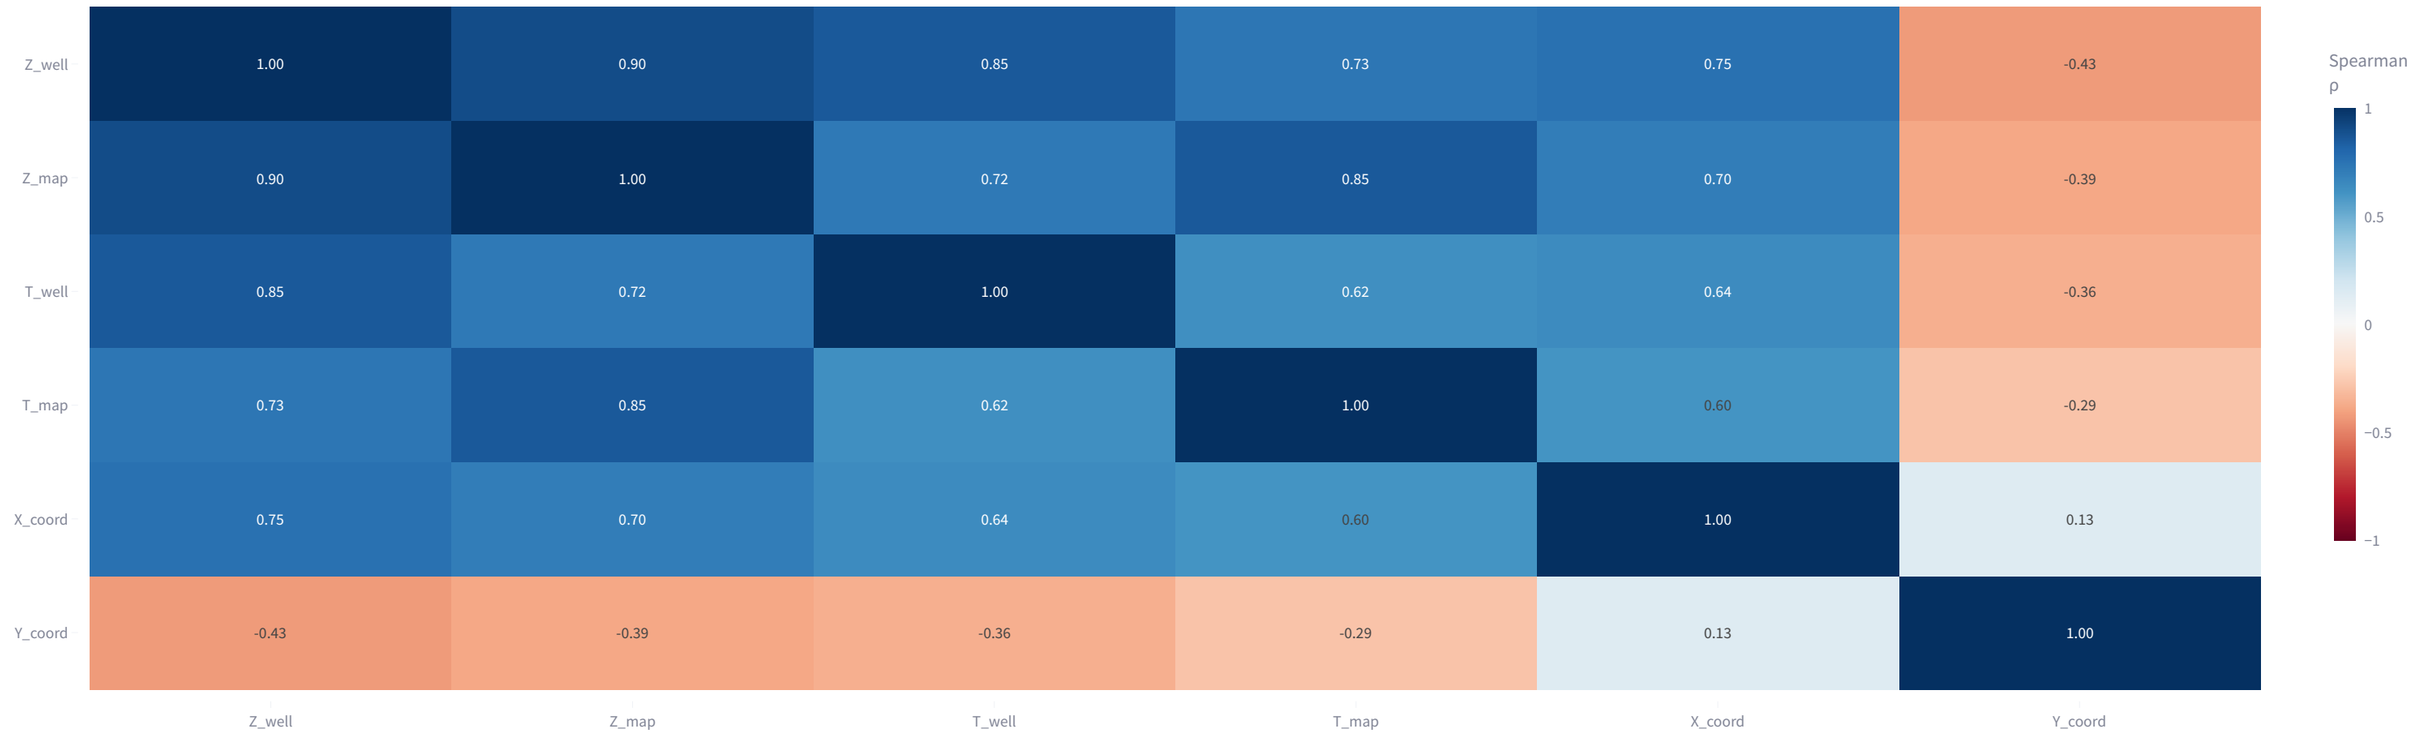
	Параметр 1	Параметр 2	КК
0	Z_well	Z_map	0.894
1	Z_well	T_well	0.851
2	Z_well	T_map	0.724
3	Z_well	X_coord	0.765
4	Z_map	T_well	0.714
5	Z_map	T_map	0.838
6	Z_map	X_coord	0.708

Скачать в Excel

Матрица корреляции (Спирмен)

Скачать в Excel

Матрица корреляции (Спирмен): 6



Пары параметров с коэффициентом корреляции больше или равно 0.70

	Параметр 1	Параметр 2	КК
0	Z_well	Z_map	0.897
1	Z_well	T_well	0.848
2	Z_well	T_map	0.73
3	Z_well	X_coord	0.753
4	Z_map	T_well	0.715
5	Z_map	T_map	0.847

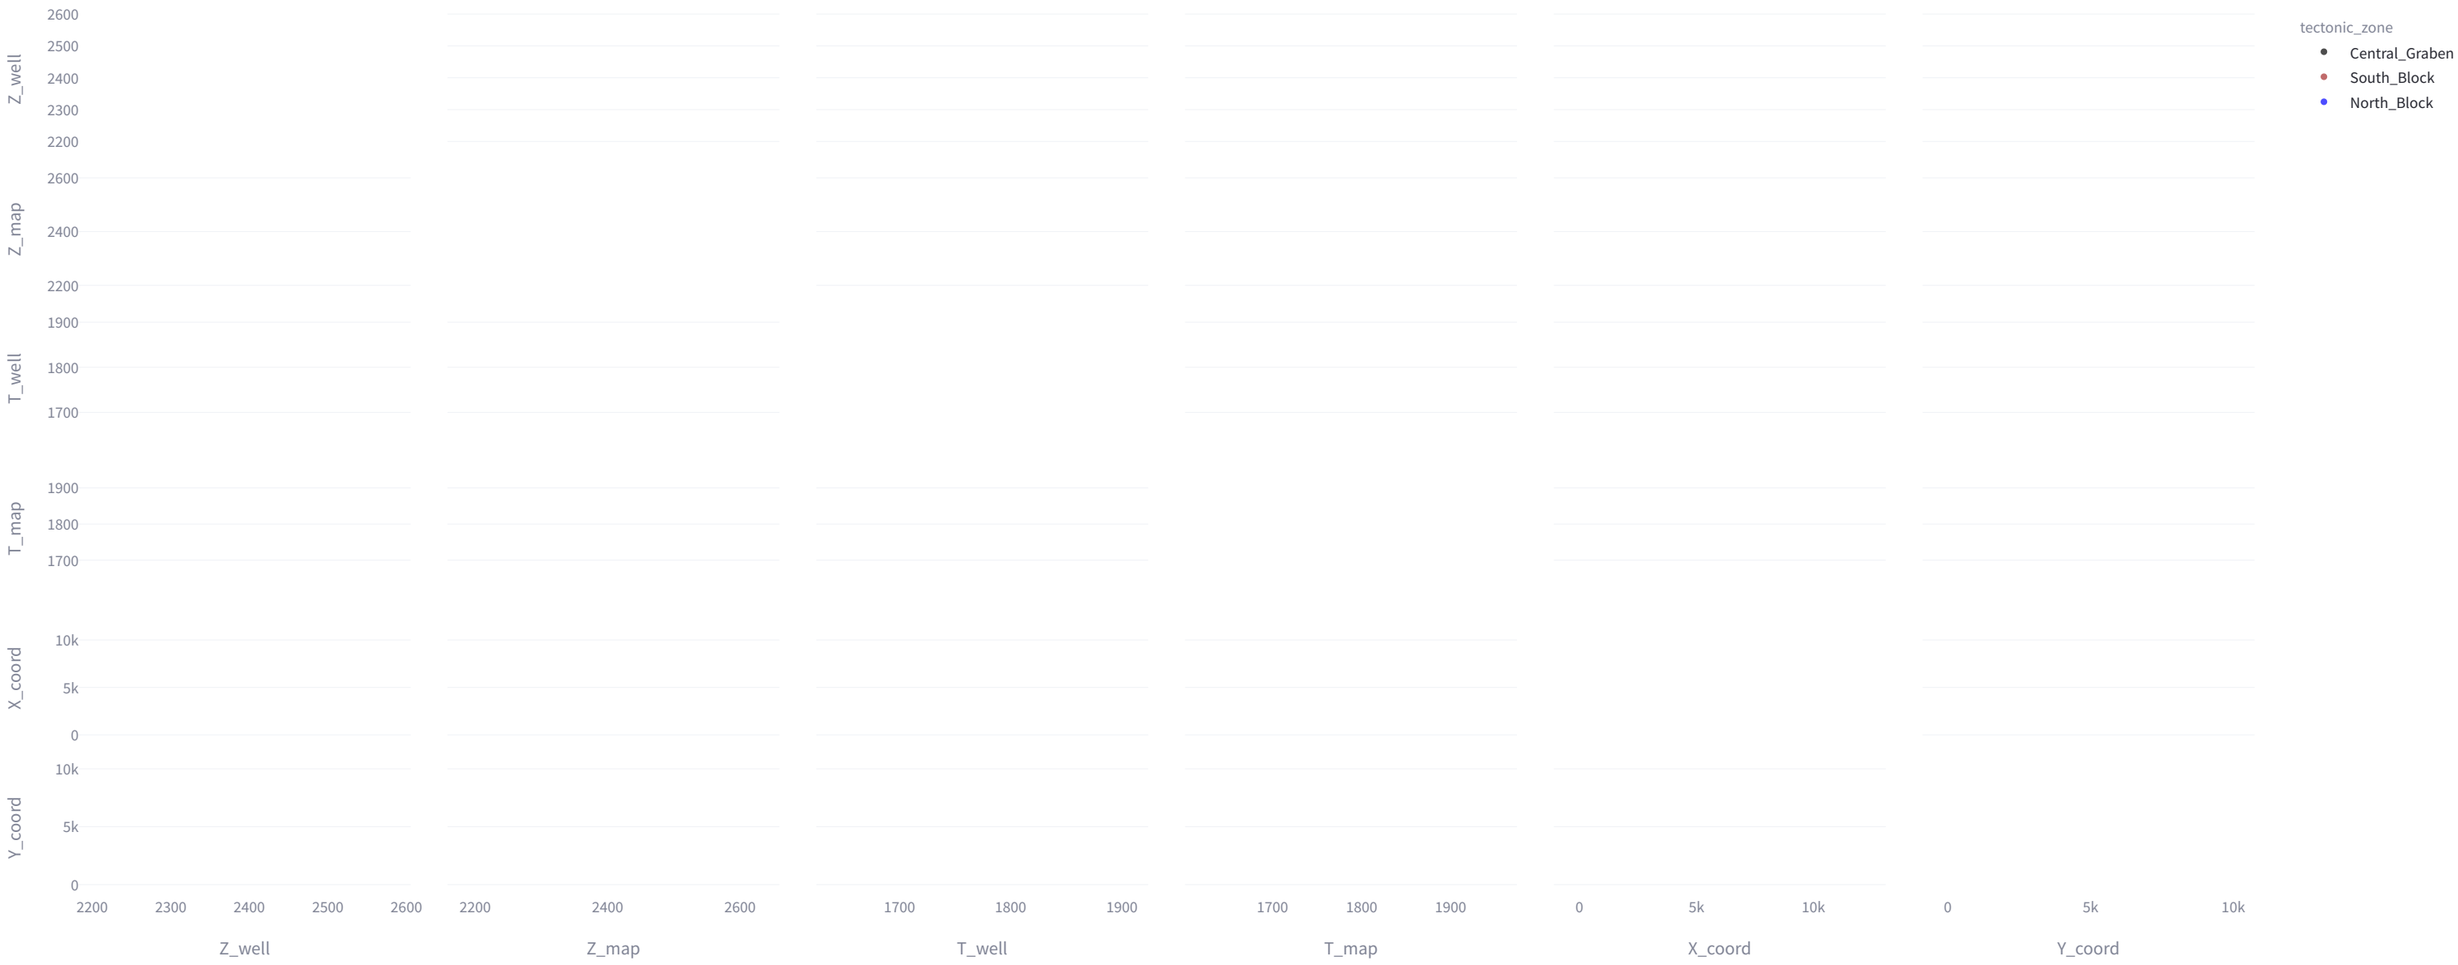
Скачать в Excel

Pairplot

Показать Pairplot

Plotly Pairplot: поддерживаются интерактивность, масштабирование и hover. KDE и гистограммы на диагонали доступны только для Seaborn Pairplot.

Plotly Pairplot, количество параметров: (6)



Статистика числовых параметров

Статистика: T_well

Кол-во бинов гистограммы: T_well

40

10 120

Нормализация гистограммы: T_well

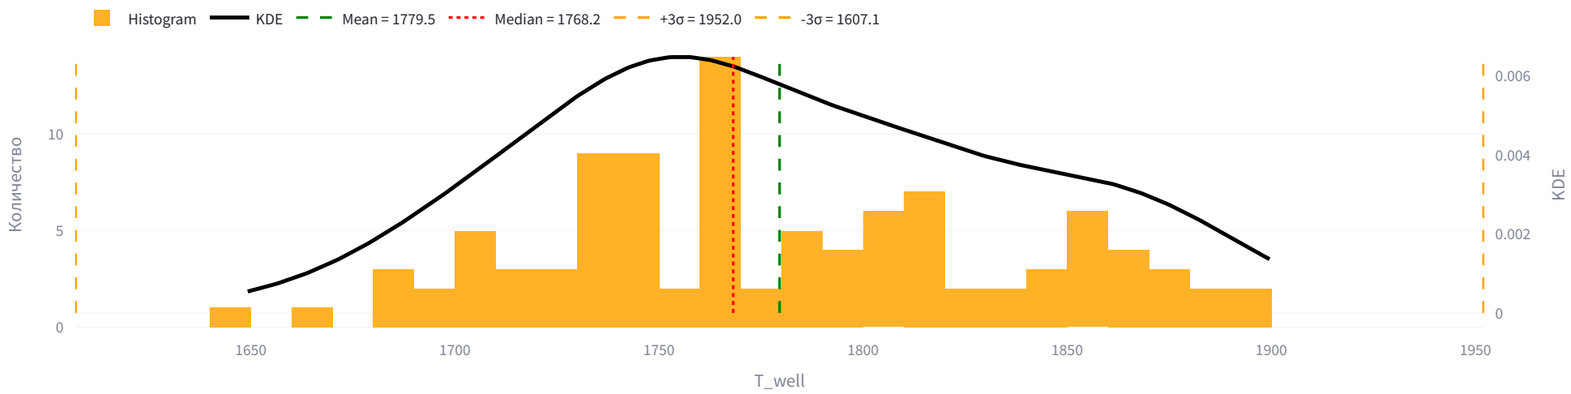
нет

T_well

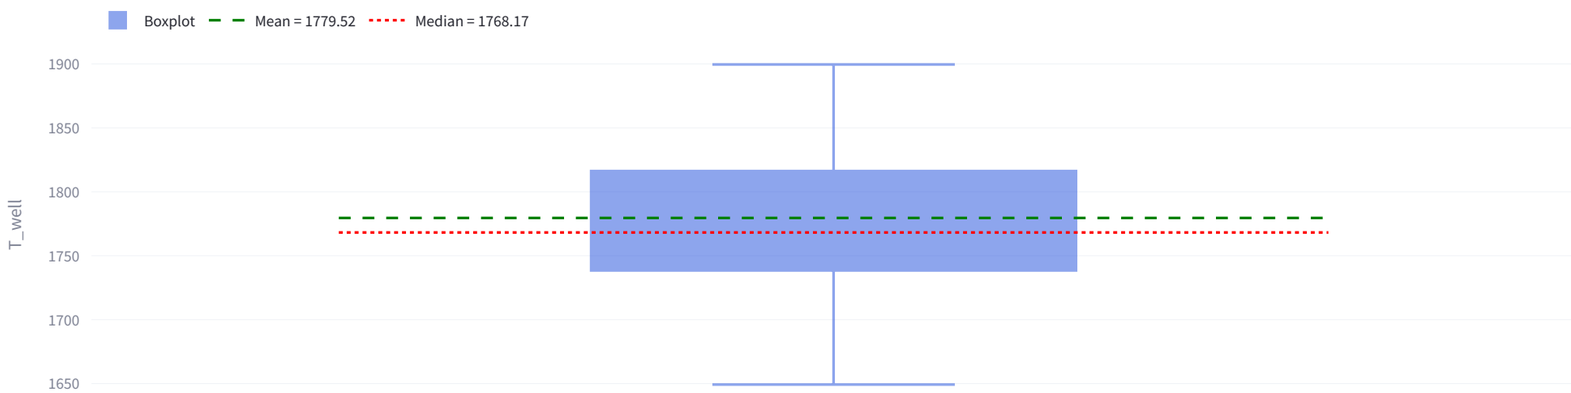
	T_well
Count	100.00
μ, mean	1,779.52
median	1,768.17
mode	1,649.23
σ, std	57.48
variance	3,304.48
CV %	3.23
min	1,649.23
Q05	1,694.36
Q25	1,738.72

Скачать в Excel

Гистограмма: T_well



Boxplot: T_well



Статистика: T_map

Кол-во бинов гистограммы: T_map

40

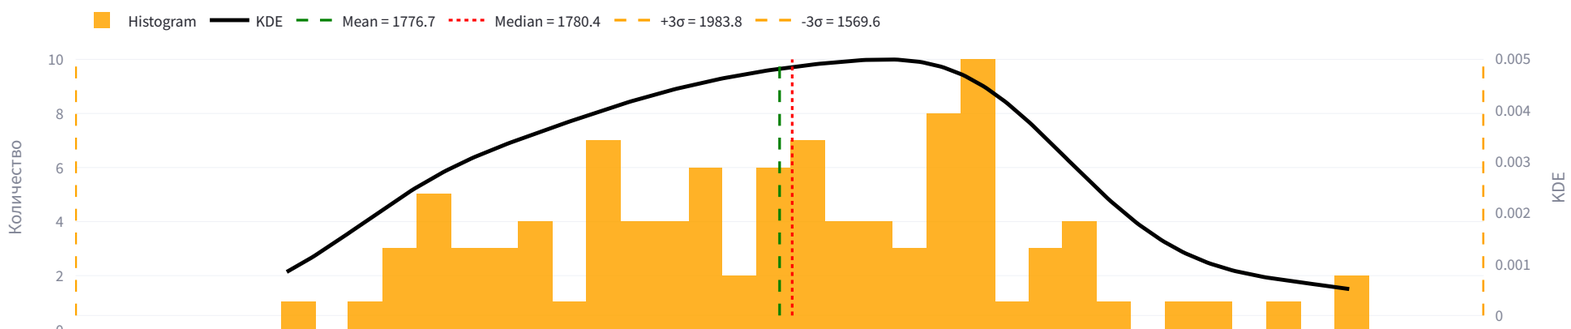
10 120

Нормализация гистограммы: T_map

нет

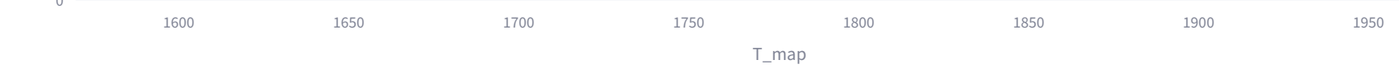
T_map

Гистограмма: T_map



	T_map
Count	100.00
μ, mean	1,776.72
median	1,780.44
mode	1,631.74
σ, std	69.03
variance	4,765.06
CV %	3.89
min	1,631.74
Q05	1,671.88
Q25	1,726.65

Скачать в Excel



Boxplot: T_map



Статистика: X_coord

Кол-во бинов гистограммы: X_coord

40

10

120

Нормализация гистограммы: X_coord

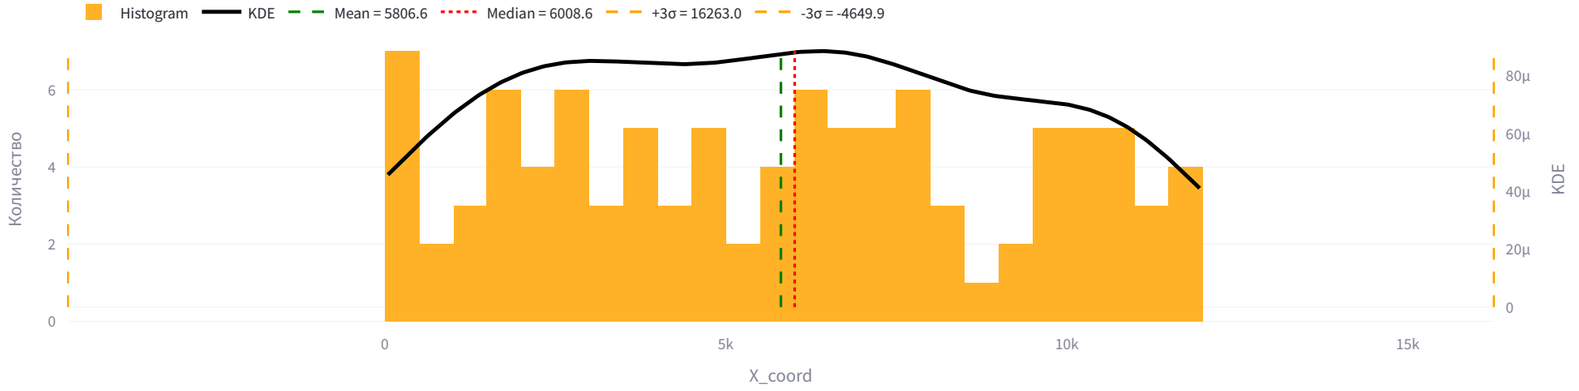
нет

X_coord

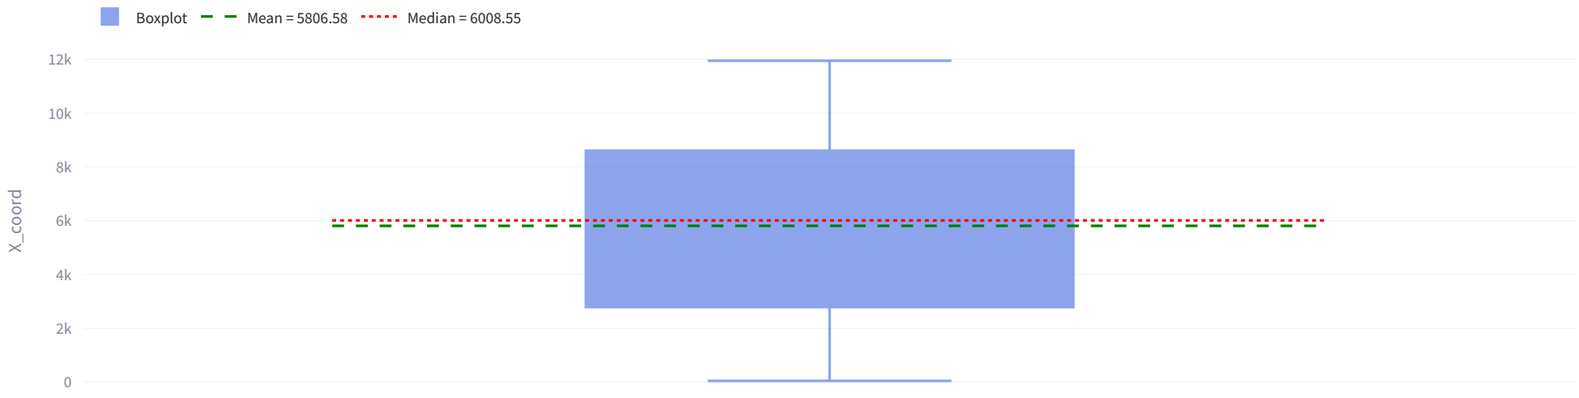
	X_coord
Count	100.00
μ, mean	5,806.58
median	6,008.55
mode	44.80
σ, std	3,485.48
variance	12,148,589.49
CV %	60.03
min	44.80
Q05	425.00
Q25	2,831.05

Скачать в Excel

Гистограмма: X_coord



Boxplot: X_coord



Статистика: Y_coord

Кол-во бинов гистограммы: Y_coord

40

10 120

Нормализация гистограммы: Y_coord

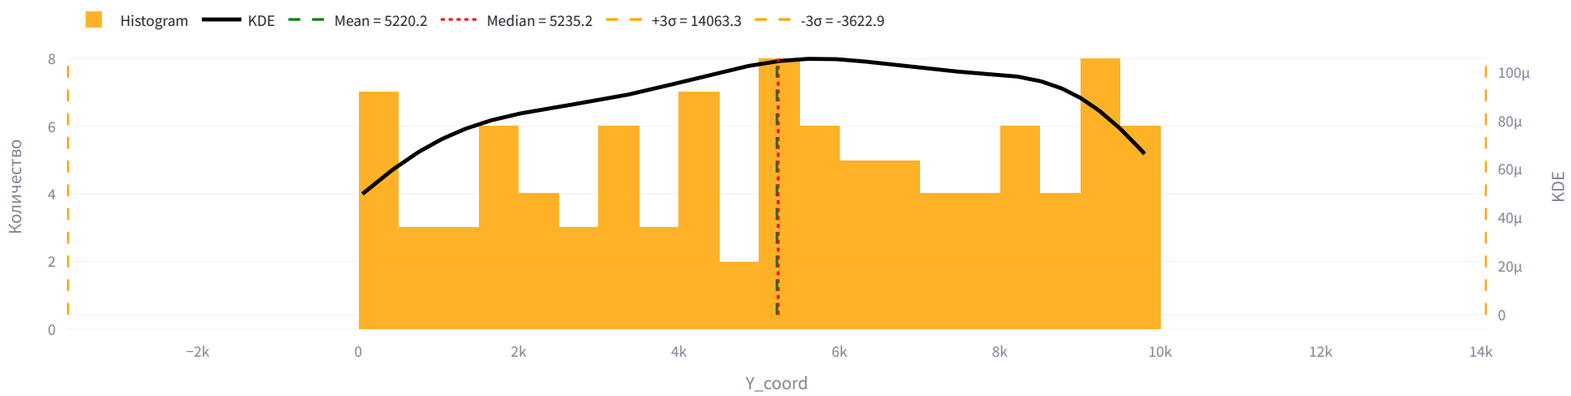
нет

Y_coord

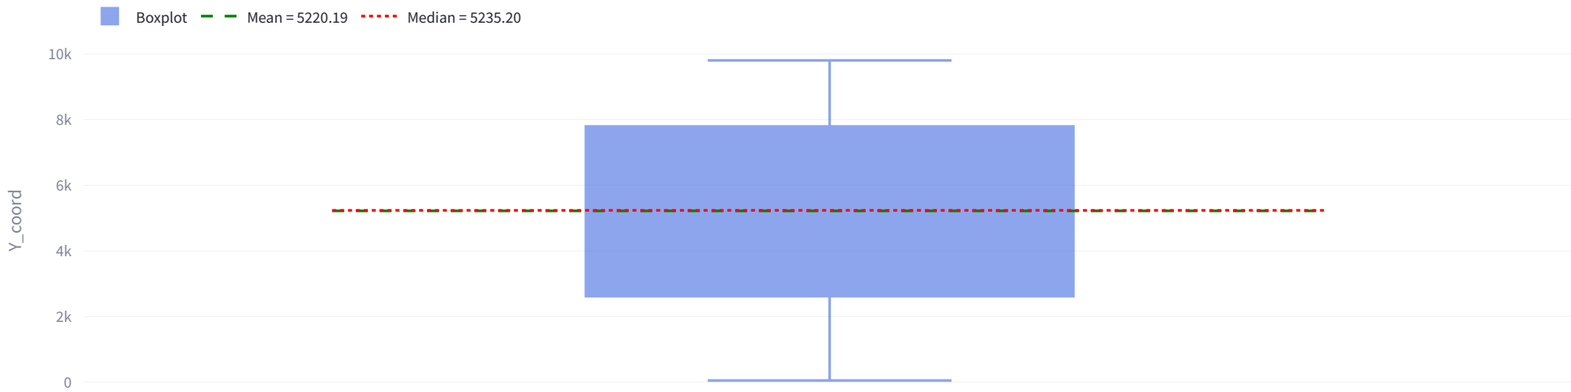
	Y_coord
Count	100.00
μ, mean	5,220.19
median	5,235.20
mode	51.80
σ, std	2,947.69
variance	8,688,860.88
CV %	56.47
min	51.80
Q05	385.55
Q25	2,668.32

Скачать в Excel

Гистограмма: Y_coord



Boxplot: Y_coord



Статистика: Z_well

Кол-во бинов гистограммы: Z_well

40

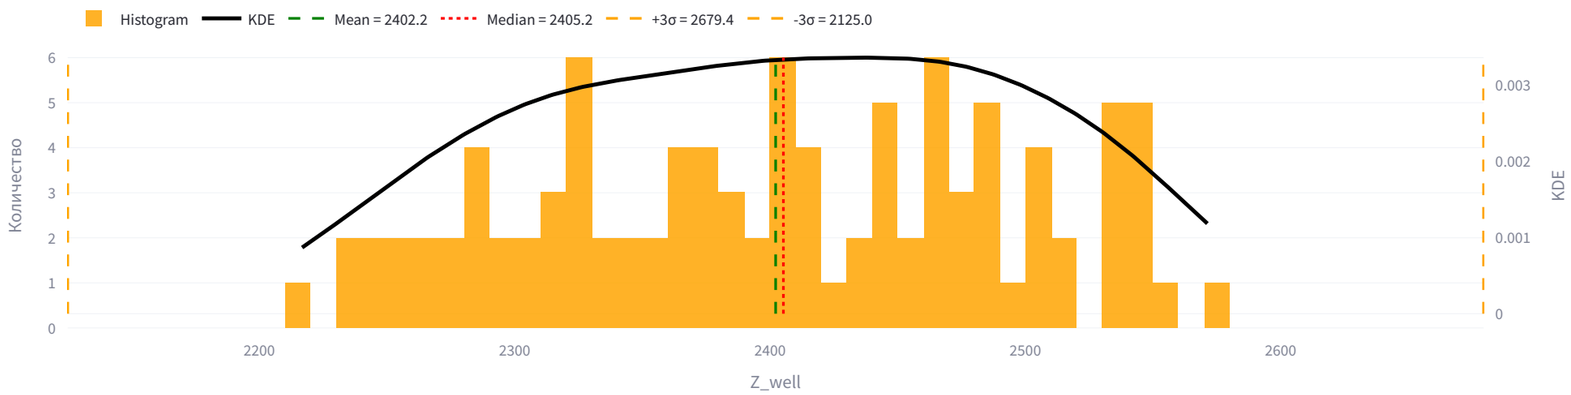
10 120

Нормализация гистограммы: Z_well

нет

Z_well

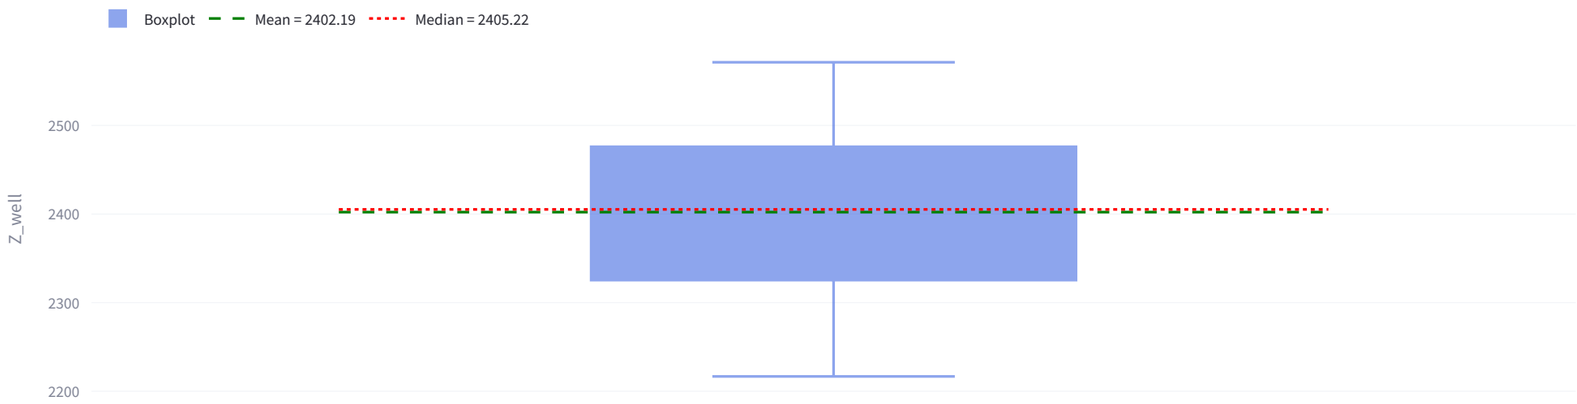
Гистограмма: Z_well



	Z_well
Count	100.00
μ, mean	2,402.19
median	2,405.22
mode	2,216.75
σ, std	92.41
variance	8,539.59
CV %	3.85
min	2,216.75
Q05	2,256.27
Q25	2,325.47

Скачать в Excel

Boxplot: Z_well



Статистика: Z_map

Кол-во бинов гистограммы: Z_map

40

10

Нормализация гистограммы: Z_map

нет

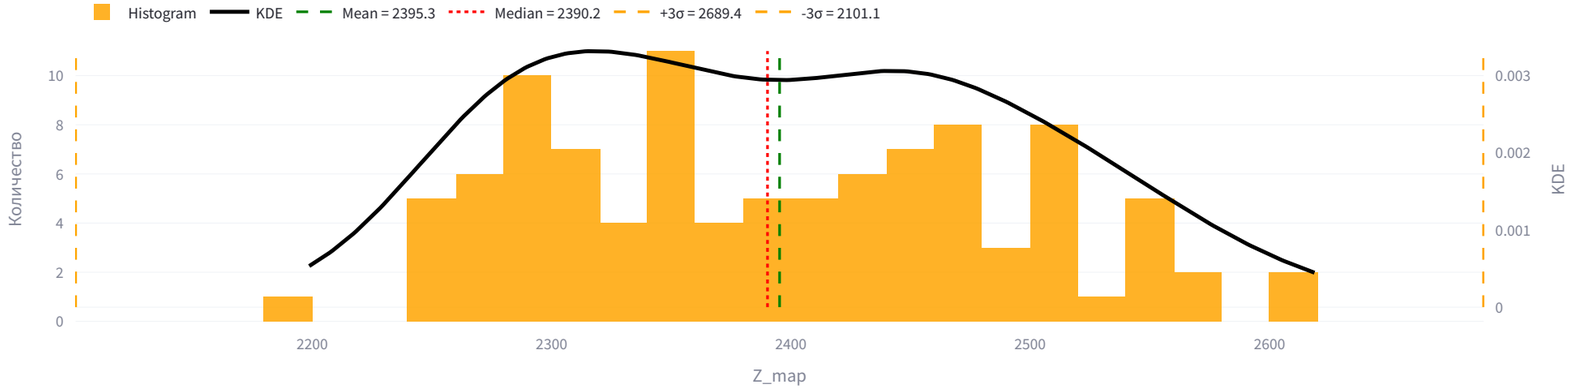
120

Z_map

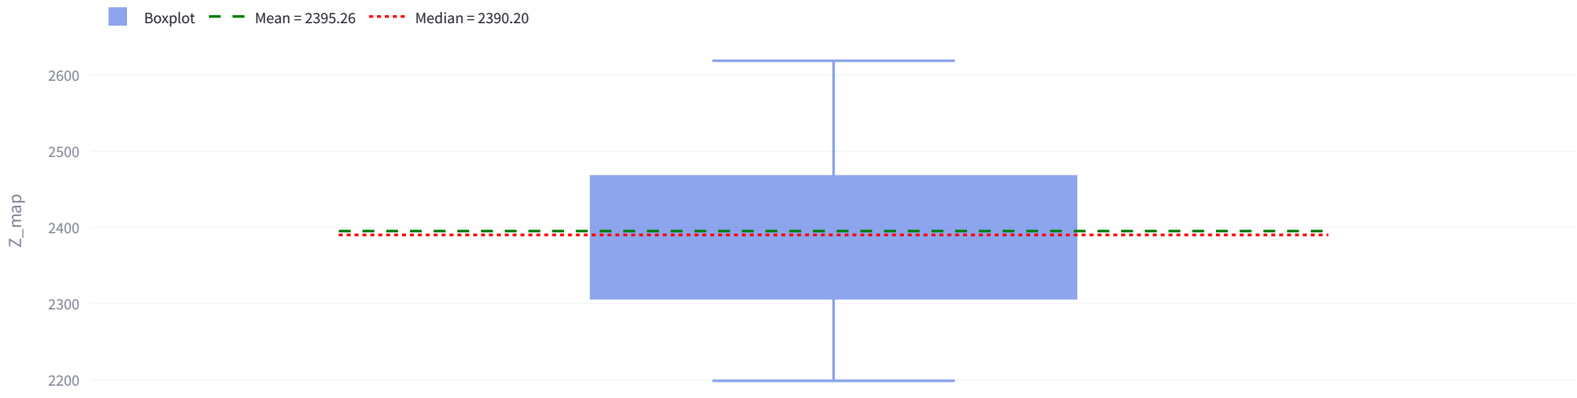
	Z_map
Count	100.00
μ, mean	2,395.26
median	2,390.20
mode	2,198.68
σ, std	98.06
variance	9,616.39
CV %	4.09
min	2,198.68
Q05	2,259.44
Q25	2,308.59

Скачать в Excel

Гистограмма: Z_map



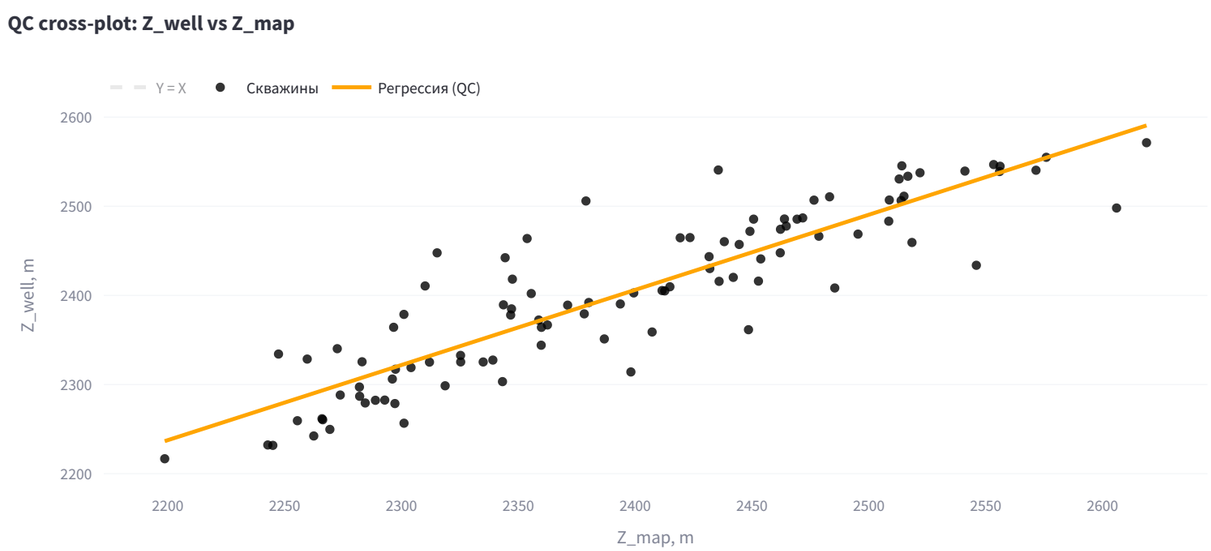
Boxplot: Z_map



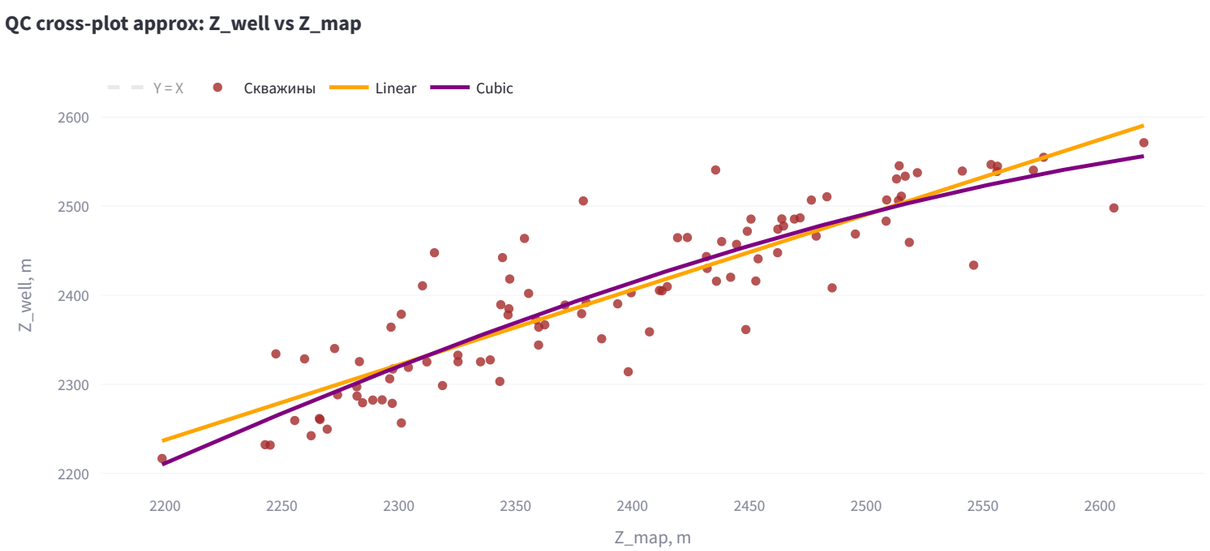
Шаг 1 · QC-анализ зависимости Z_well vs Z_map

QC кросс-плот

Кросс-плот: Z_well vs Z_map



Аппроксимации: Z_well vs Z_map



Метрики QC кросс-плота: Z_well vs Z_map

	R^2_lin	RMSE	MSE	MAE	Bias	Std	Variance	MAPE %	P-value	Equation
0	0.8000	44.4287	1973.9099	31.1295	6.9283	44.1063	1945.3622	1.2898	5.04726e-36	Z_well = 0.84286·Z_map + 383.30964

Скачать в Excel

Сравнение метрик аппроксимаций: Z_well vs Z_map

	Approximation	R^2_fit	RMSE	MSE	MAE	Bias	Std	Variance	MAPE %	Equation
0	Linear	0.8000	41.1198	1690.8376	31.3449	0.0000	41.3270	1707.9168	1.3084	y = 0.84286·x + 383.30964
1	Cubic	0.8089	40.1967	1615.7782	30.9980	-0.0000	40.3992	1632.0992	1.2921	y = -0.00000·x^3 + 0.00293·x^2 - 4.07777·x + 2625.57602

Скачать в Excel

Распределение параметров Z_well , Z_map

Кол-во бинов гистограммы: Z_well, Z_map

40

10 120

Нормализация гистограммы: Z_well, Z_map

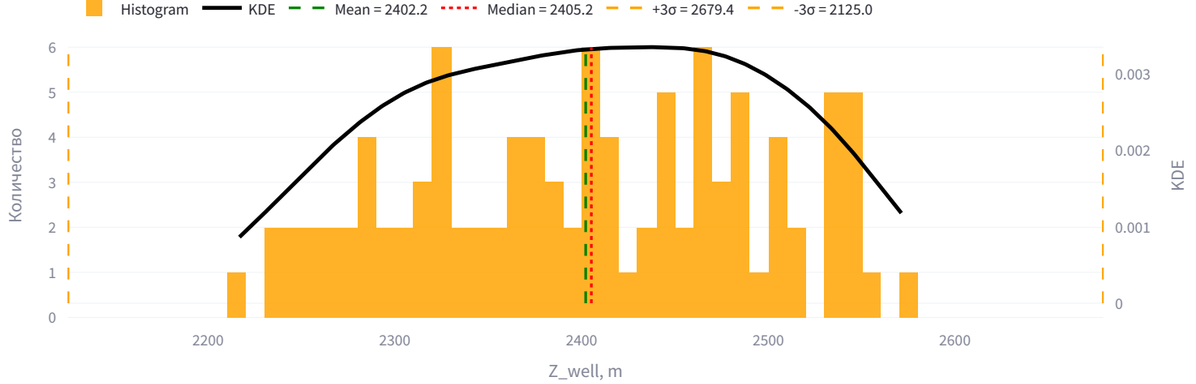
нет

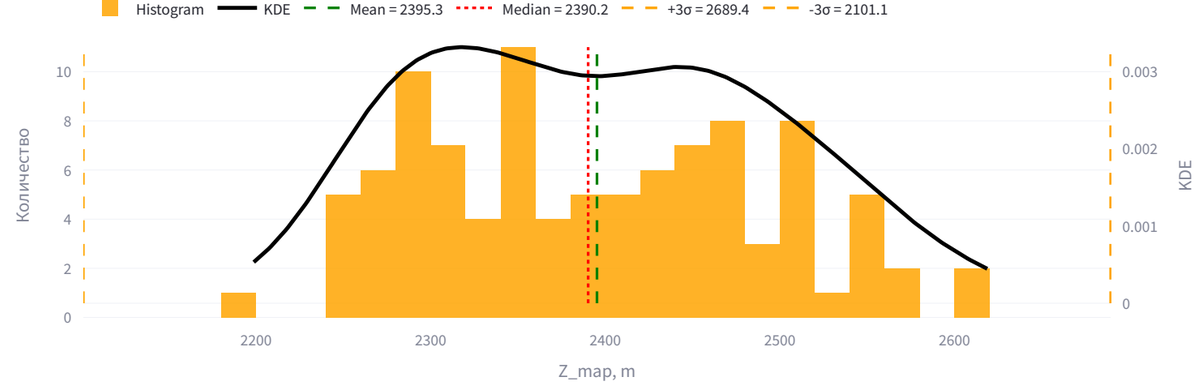
Гистограмма: Z_well

Гистограмма: Z_well

Гистограмма: Z_map

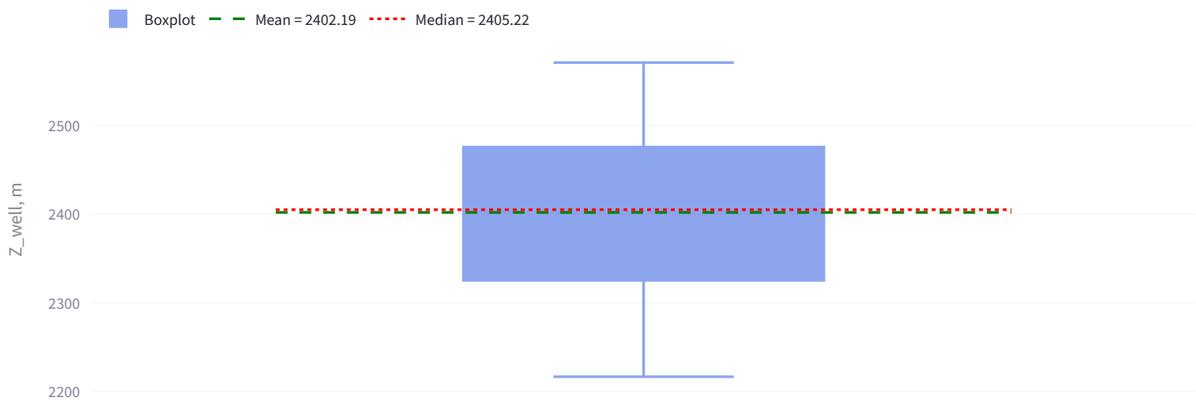
Гистограмма: Z_map





Boxplot: Z_well

Boxplot: Z_well



Boxplot: Z_map

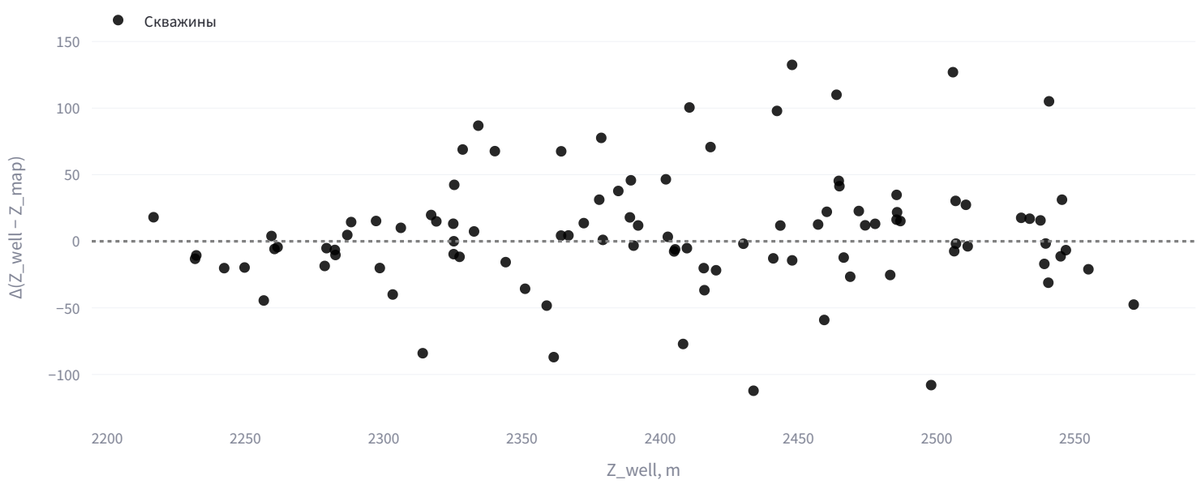
Boxplot: Z_map



Невязки Δ(Z_well − Z_map)

Зависимость невязки Δ(Z_well − Z_map) vs Z_well

Δ(Z_well − Z_map) vs Z_well



Статистика невязок Δ(Z_well − Z_map)

	Metrics	Value
0	Count	100.0000
1	μ, mean	6.9283
2	median	3.6650
3	mode	-112.2200
4	σ, std	44.1063
5	variance	1945.3622
6	CV %	636.6101
7	RMSE	44.4287
8	min	-112.2200
9	Q05	-59.9815

Скачать в Excel

Кол-во бинов гистограммы: Δ(Z_well − Z_map)

40

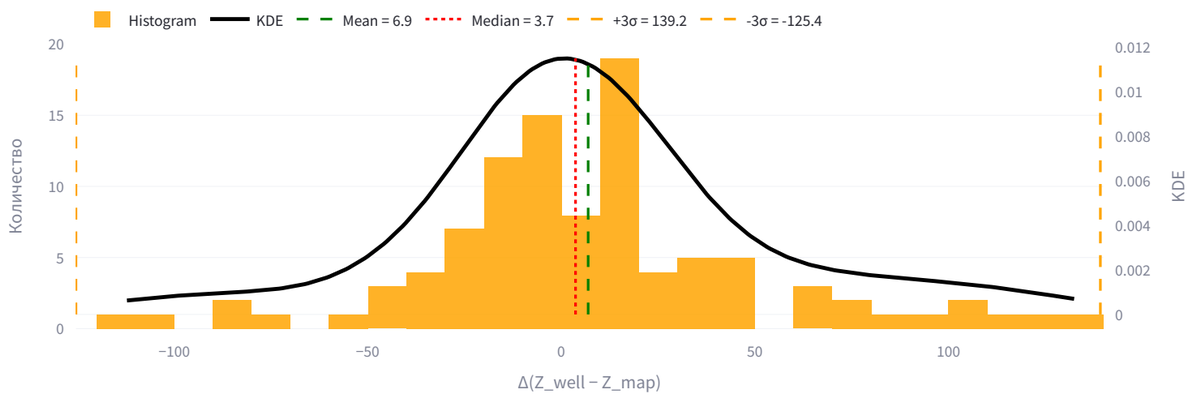
10 120

Нормализация гистограммы: Δ(Z_well − Z_map)

нет

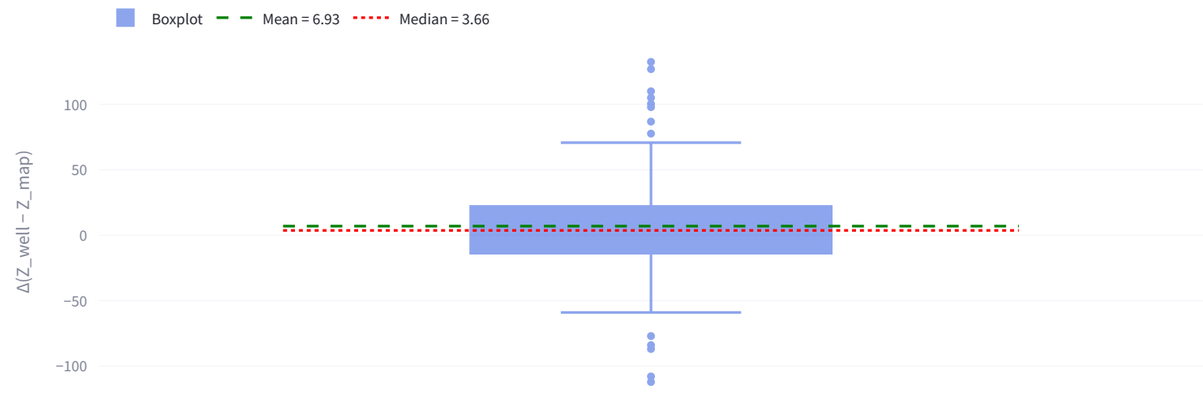
Гистограмма: Δ(Z_well − Z_map)

Гистограмма: Δ(Z_well − Z_map)



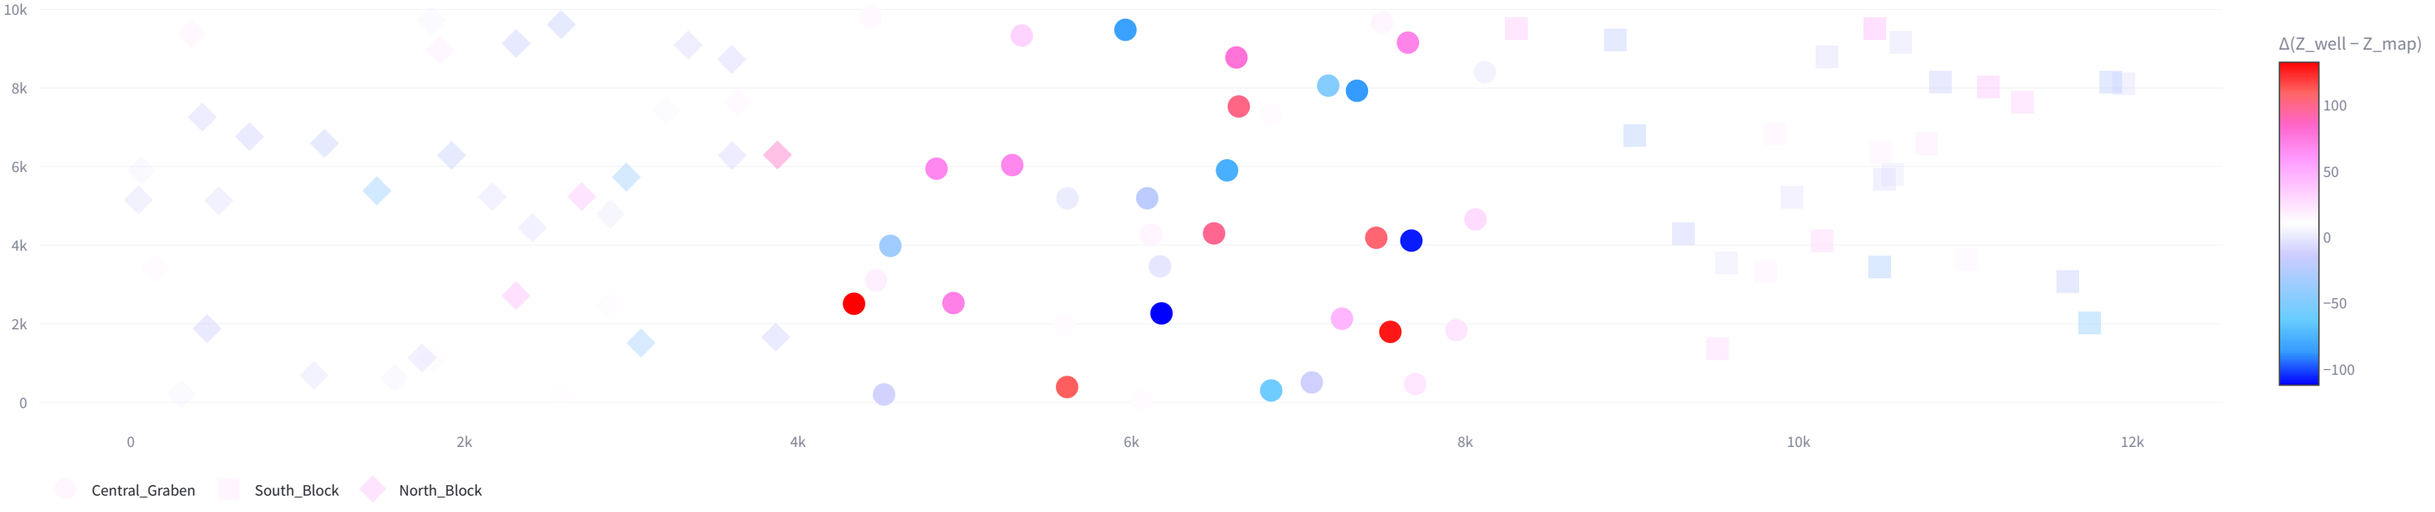
Boxplot: Δ(Z_well − Z_map)

Boxplot: Δ(Z_well − Z_map)



Пространственное распределение невязок Δ(Z_well − Z_map)

Карта невязок Δ(Z_well − Z_map)



Анализ выбросов невязок Δ(Z_well − Z_map)

Sigma rule (|Δ(Z_well − Z_map)| > 2.0σ)

	horizon_id	well_id	X_coord	Y_coord	Z_well	Z_map	Δ(Z_well − Z_map)	category_plot	sigma
15	Top_Reservoir	W-016	6,642	7,529.8	2,410.58	2,310.1	100.48	Central_Graben	2.2781
18	Top_Reservoir	W-019	7,466.2	4,189	2,540.63	2,435.55	105.08	Central_Graben	2.3824
25	Top_Reservoir	W-026	6,178.7	2,264.2	2,433.75	2,545.97	-112.22	Central_Graben	-2.5443
28	Top_Reservoir	W-029	7,550.7	1,794.1	2,505.89	2,378.92	126.97	Central_Graben	2.8787
44	Top_Reservoir	W-045	7,676.6	4,116.5	2,498	2,605.97	-107.97	Central_Graben	-2.448
47	Top_Reservoir	W-048	6,493.7	4,300	2,442.24	2,344.35	97.89	Central_Graben	2.2194
50	Top_Reservoir	W-051	4,335.2	2,510	2,447.7	2,315.23	132.47	Central_Graben	3.0034
92	Top_Reservoir	W-093	5,612.8	389.9	2,463.77	2,353.74	110.03	Central_Graben	2.4947

Скачать в Excel

IQR rule (k = 1.5·IQR)

	horizon_id	well_id	X_coord	Y_coord	Z_well	Z_map	Δ(Z_well − Z_map)	category_plot
15	Top_Reservoir	W-016	6,642	7,529.8	2,410.58	2,310.1	100.48	Central_Graben
18	Top_Reservoir	W-019	7,466.2	4,189	2,540.63	2,435.55	105.08	Central_Graben
22	Top_Reservoir	W-023	7,350.5	7,930.2	2,361.49	2,448.47	-86.98	Central_Graben
25	Top_Reservoir	W-026	6,178.7	2,264.2	2,433.75	2,545.97	-112.22	Central_Graben
28	Top_Reservoir	W-029	7,550.7	1,794.1	2,505.89	2,378.92	126.97	Central_Graben
30	Top_Reservoir	W-031	5,962.5	9,481.2	2,314.11	2,398.15	-84.04	Central_Graben
44	Top_Reservoir	W-045	7,676.6	4,116.5	2,498	2,605.97	-107.97	Central_Graben
47	Top_Reservoir	W-048	6,493.7	4,300	2,442.24	2,344.35	97.89	Central_Graben
50	Top_Reservoir	W-051	4,335.2	2,510	2,447.7	2,315.23	132.47	Central_Graben
54	Top_Reservoir	W-055	3,876.4	6,296.2	2,334.2	2,247.37	86.83	North_Block

Скачать в Excel

Modified Z-score rule (|Modified Z| > 3.5)

	horizon_id	well_id	X_coord	Y_coord	Z_well	Z_map	Δ(Z_well − Z_map)	category_plot
15	Top_Reservoir	W-016	6,642	7,529.8	2,410.58	2,310.1	100.48	Central_Graben
18	Top_Reservoir	W-019	7,466.2	4,189	2,540.63	2,435.55	105.08	Central_Graben
25	Top_Reservoir	W-026	6,178.7	2,264.2	2,433.75	2,545.97	-112.22	Central_Graben
28	Top_Reservoir	W-029	7,550.7	1,794.1	2,505.89	2,378.92	126.97	Central_Graben
44	Top_Reservoir	W-045	7,676.6	4,116.5	2,498	2,605.97	-107.97	Central_Graben
47	Top_Reservoir	W-048	6,493.7	4,300	2,442.24	2,344.35	97.89	Central_Graben
50	Top_Reservoir	W-051	4,335.2	2,510	2,447.7	2,315.23	132.47	Central_Graben
92	Top_Reservoir	W-093	5,612.8	389.9	2,463.77	2,353.74	110.03	Central_Graben

Скачать в Excel

Percentile rule (Q05-Q95)

	horizon_id	well_id	X_coord	Y_coord	Z_well	Z_map	Δ(Z_well − Z_map)	category_plot
15	Top_Reservoir	W-016	6,642	7,529.8	2,410.58	2,310.1	100.48	Central_Graben
18	Top_Reservoir	W-019	7,466.2	4,189	2,540.63	2,435.55	105.08	Central_Graben
22	Top_Reservoir	W-023	7,350.5	7,930.2	2,361.49	2,448.47	-86.98	Central_Graben
25	Top_Reservoir	W-026	6,178.7	2,264.2	2,433.75	2,545.97	-112.22	Central_Graben
28	Top_Reservoir	W-029	7,550.7	1,794.1	2,505.89	2,378.92	126.97	Central_Graben
30	Top_Reservoir	W-031	5,962.5	9,481.2	2,314.11	2,398.15	-84.04	Central_Graben
44	Top_Reservoir	W-045	7,676.6	4,116.5	2,498	2,605.97	-107.97	Central_Graben
50	Top_Reservoir	W-051	4,335.2	2,510	2,447.7	2,315.23	132.47	Central_Graben
92	Top_Reservoir	W-093	5,612.8	389.9	2,463.77	2,353.74	110.03	Central_Graben
93	Top_Reservoir	W-094	6,571.6	5,903.9	2,408.28	2,485.39	-77.11	Central_Graben

Скачать в Excel

Шаг 2 · Кросс-валидация (CV): Z_well vs Z_map

Выбор лучшей CV

Схемы CV покрывают разное число точек: 95–100. Сравнивать их напрямую не совсем корректно.

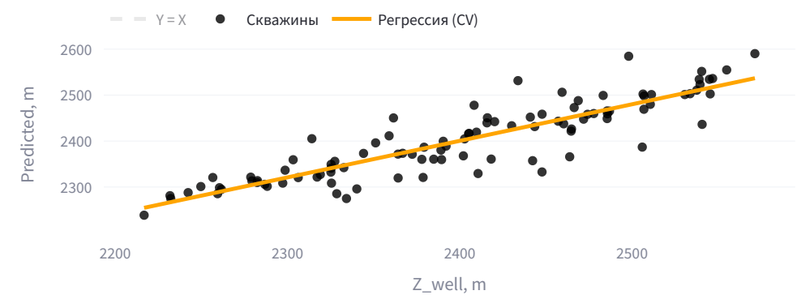
Критерий выбора лучшей схемы CV

RMSE + RMSE_fold_Std (по умолчанию)

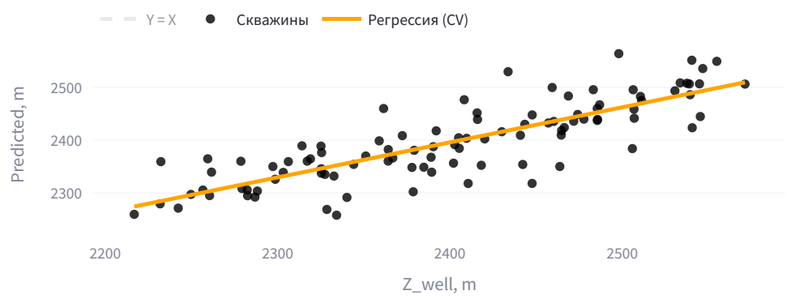
Кросс-плот: Прогноз vs Факт для всех схем кросс-валидации

Схемы упорядочены от самой оптимистичной (Random K-Fold) к самой объективной (Distance-based exclusion CV). Обратите внимание, как меняется форма облака и метрики. Схема со значком ⭐ показана как лучшая.

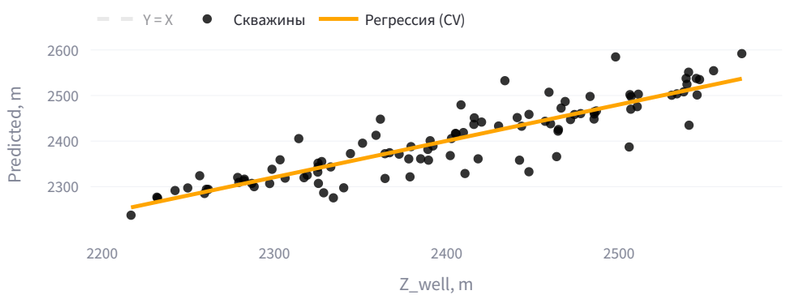
Random K-Fold



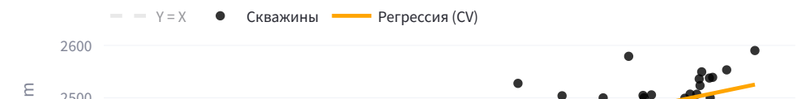
Random K-Fold (buffered)



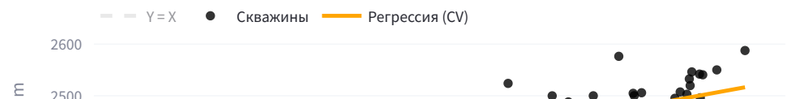
Leave-One-Well-Out



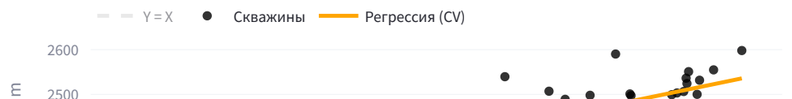
Block CV

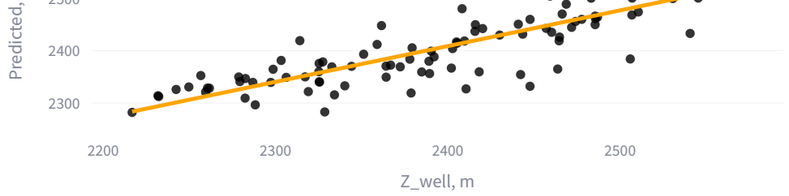


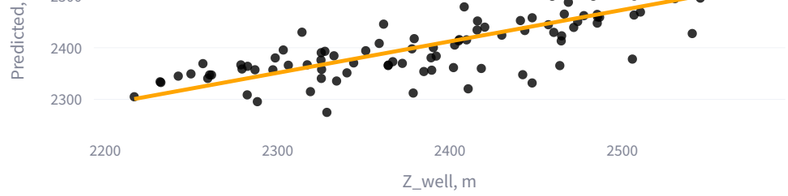
Buffered CV

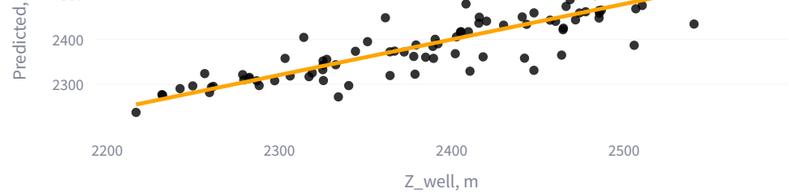


Leave-P-Out

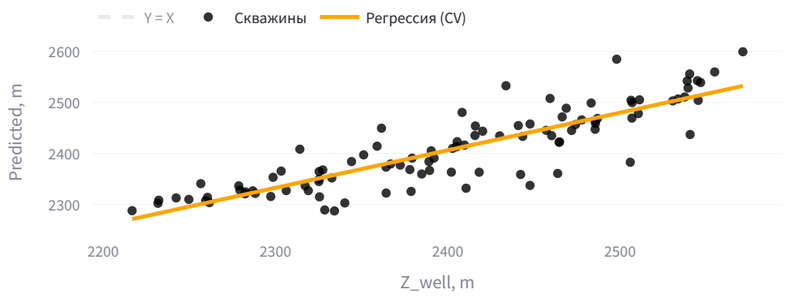








⭐ Spatial Leave-P-Out



Stratified by tectonic_zone



Distance-based exclusion CV



Метрики кросс-плота Прогноз vs Факт для всех схем кросс-валидации

	CV scheme	R^2 (Pearson, Predicted vs Actual)	RMSE	MSE	MAE	Bias	Std	Variance	MAPE %	P-value	Equation
0	Random K-Fold	0.7923	41.9028	1755.8422	32.0699	-0.0578	42.1138	1773.5746	1.3389	3.21000e-35	Predicted = 0.79555·Actual + 491.18448
1	Random K-Fold (buffered)	0.6866	51.7621	2679.3120	41.4743	4.7871	51.7999	2683.2280	1.7300	1.97284e-26	Predicted = 0.66328·Actual + 804.08264
2	Leave-One-Well-Out	0.7921	41.9281	1757.9675	31.9805	-0.0937	42.1392	1775.7159	1.3349	3.39538e-35	Predicted = 0.79666·Actual + 488.55051
3	Block CV	0.7296	48.7388	2375.4740	37.8090	-7.9194	48.3334	2336.1183	1.5923	1.37527e-29	Predicted = 0.68139·Actual + 773.28122
4	Buffered CV	0.6572	55.2978	3057.8503	42.7605	-11.3570	54.3917	2958.4527	1.8068	1.62234e-24	Predicted = 0.60820·Actual + 952.53301
5	Leave-P-Out	0.7826	42.6698	1820.7114	32.2529	0.3209	42.8949	1839.9766	1.3441	1.41453e-32	Predicted = 0.79236·Actual + 498.40077
6	Spatial Leave-P-Out	0.7571	45.7530	2093.3335	35.9987	-5.8915	45.6006	2079.4184	1.5124	7.05080e-32	Predicted = 0.73536·Actual + 641.61648
7	Stratified by tectonic_zone	0.6511	54.7987	3002.8926	43.9498	-7.0422	54.6181	2983.1314	1.8514	3.89181e-24	Predicted = 0.63490·Actual + 884.08675
8	Distance-based exclusion CV	0.6735	53.3669	2848.0222	41.9056	-8.5805	52.9379	2802.4221	1.7669	1.47973e-25	Predicted = 0.64011·Actual + 873.10372

Скачать в Excel

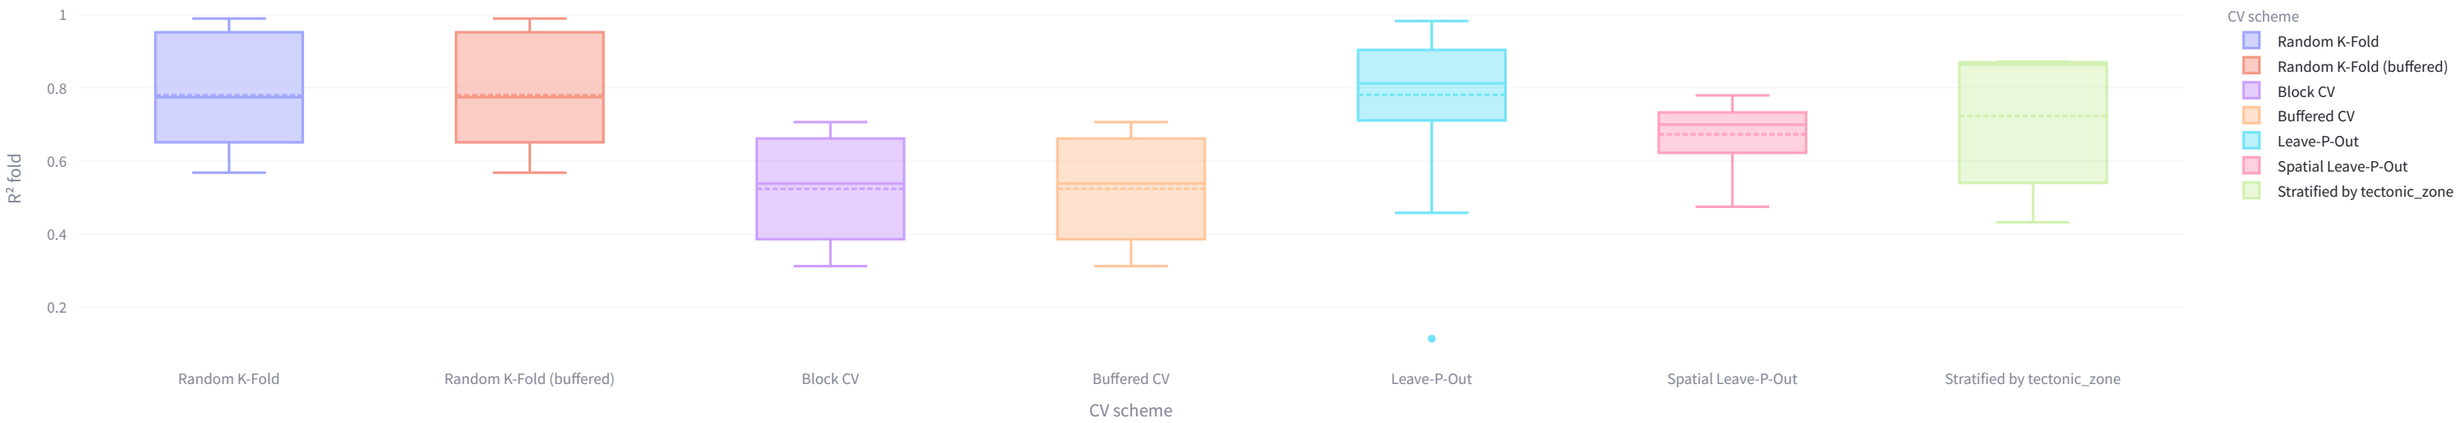
Колонка `score` рассчитана по критерию: **RMSE + RMSE_fold_Std (по умолчанию)**

Таблица R^2 (Pearson) по фолдам по схемам CV

	CV scheme	n_pred	n_test_min	n_test_max	R^2 (Pearson, Predicted vs Actual)	r2_fold_min	r2_fold_max	r2_fold_std	r2_fold_mean	r2_fold_median
0	Random K-Fold	100	10	10	0.7923	0.5679	0.9897	0.1574	0.7794	0.7744
1	Random K-Fold (buffered)	100	10	10	0.6866	0.5679	0.9897	0.1574	0.7794	0.7744
2	Leave-One-Well-Out	100	1	1	0.7921	None	None	None	None	None
3	Block CV	100	21	29	0.7296	0.3121	0.7064	0.1740	0.5237	0.5382
4	Buffered CV	100	21	29	0.6572	0.3121	0.7064	0.1740	0.5237	0.5382
5	Leave-P-Out	95	10	10	0.7826	0.1138	0.9829	0.1808	0.7810	0.8122
6	Spatial Leave-P-Out	100	37	82	0.7571	0.4746	0.7794	0.0784	0.6728	0.6996
7	Stratified by tectonic_zone	100	26	38	0.6511	0.4321	0.8720	0.2516	0.7226	0.8638
8	Distance-based exclusion CV	100	1	1	0.6735	None	None	None	None	None

Скачать в Excel

Boxplot: Разброс R^2 (Pearson) по фолдам по схемам CV



Фолды с R^2 = NaN (меньше 3 точек или постоянные значения у или прогноза, например одноточечные фолды Distance-based CV) не показаны на boxplot и не входят в статистику.

Сравнение схем CV

	CV scheme	n_pred	n_test_min	n_test_max	R^2 (Actual = Predicted)	rmse	mae	bias	rmse_fold_mean	rmse_fold_median	rmse_fold_min	rmse_fold_max	rmse_fold_std	rmse_fold_range	score
0	Random K-Fold	100	10	10	0.7923	41.90	32.07	+0.06	40.50	41.81	23.92	55.25	11.34	31.33	53.24
1	Random K-Fold (buffered)	100	10	10	0.6831	51.76	41.47	-4.79	50.94	51.98	35.94	65.35	9.70	29.42	61.46
2	Leave-One-Well-Out	100	1	1	0.7921	41.93	31.98	+0.09	31.98	25.16	0.46	118.69	27.25	118.24	69.18
3	Block CV	100	21	29	0.7190	48.74	37.81	+7.92	47.28	46.23	36.75	59.92	10.85	23.17	59.59
4	Buffered CV	100	21	29	0.6383	55.30	42.76	+11.36	52.02	47.38	38.17	75.15	17.15	36.98	72.45
5	Leave-P-Out	95	10	10	0.7825	42.67	32.25	-0.32	40.51	38.34	14.44	67.88	12.72	53.44	55.39
6	Spatial Leave-P-Out	100	37	82	0.7524	45.75	36.00	+5.89	49.91	49.75	39.89	66.62	7.01	26.72	52.76
7	Stratified by tectonic_zone	100	26	38	0.6448	54.80	43.95	+7.04	50.46	59.80	28.74	62.84	18.88	34.11	73.67
8	Distance-based exclusion CV	100	1	1	0.6631	53.37	41.91	+8.58	41.91	34.55	1.37	127.90	33.21	126.52	86.58

Скачать в Excel

Boxplot: линия внутри бокса показывает медиану, пунктирная линия показывает среднее значение.

Boxplot: Разброс RMSE по фолдам по схемам CV

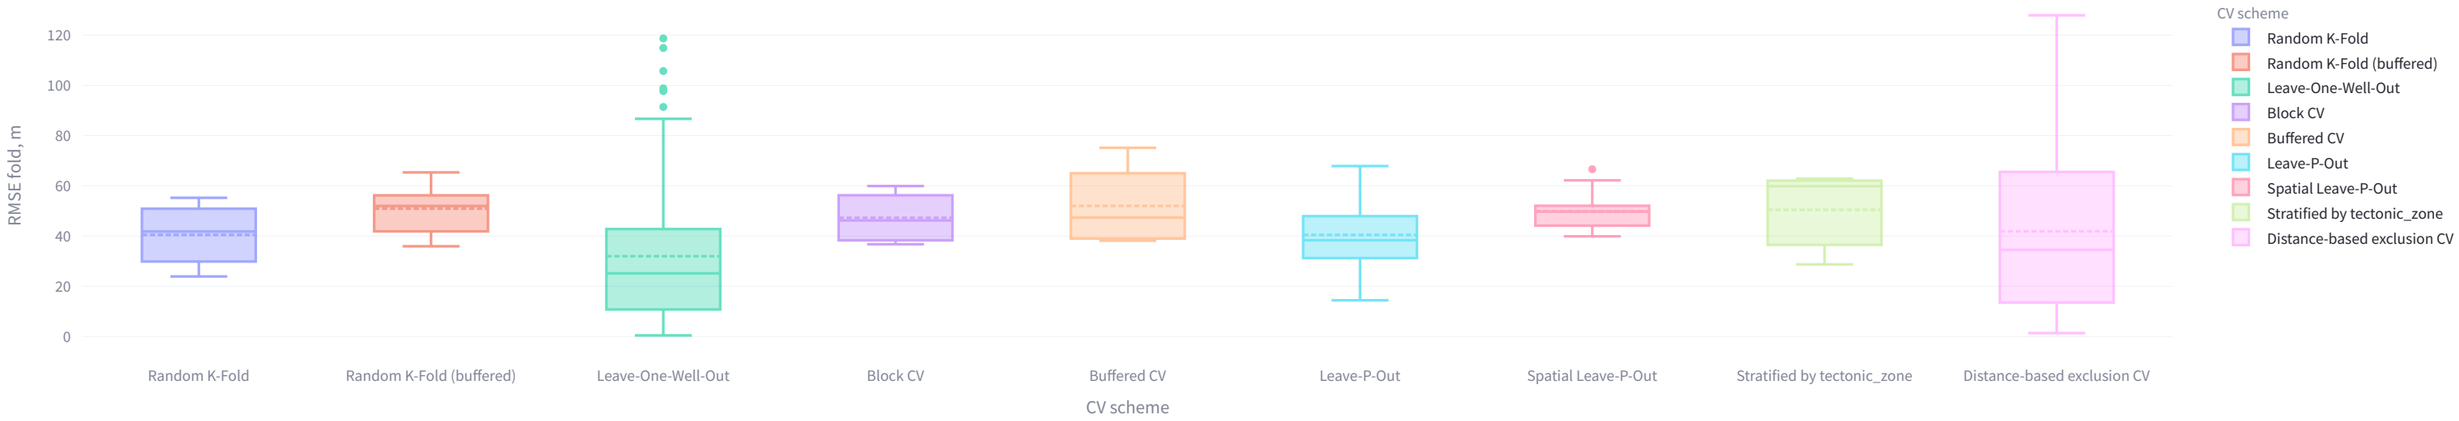


Таблица фолдов по схемам CV

Random K-Fold

	Fold	n_train	n_test	RMSE_fold, m	MAE_fold, m	Bias_fold, m
0	fold_1	90	10	45.0101	34.433	28.3078
1	fold_2	90	10	52.9969	44.4791	5.5207
2	fold_3	90	10	36.6493	28.3234	-12.245
3	fold_4	90	10	55.2529	42.9684	-13.366
4	fold_5	90	10	38.6193	30.1988	-2.1037
5	fold_6	90	10	25.7475	20.5859	-5.3909
6	fold_7	90	10	50.8923	38.493	-12.613
7	fold_8	90	10	23.9224	20.1826	9.8748
8	fold_9	90	10	29.8701	24.508	12.6067
9	fold_10	90	10	46.0311	36.5268	-10.0135

Скачать в Excel

Random K-Fold (buffered)

	Fold	n_train	n_test	RMSE_fold, m	MAE_fold, m	Bias_fold, m
0	buf_fold_1	28	10	61.9582	58.2348	52.6917
1	buf_fold_2	8	10	52.3922	40.336	-9.8727
2	buf_fold_3	12	10	38.5451	25.2055	-18.3179
3	buf_fold_4	19	10	56.227	42.9935	-15.8804
4	buf_fold_5	35	10	41.8795	33.985	-9.3376
5	buf_fold_6	12	10	65.3534	56.4993	28.9313
6	buf_fold_7	9	10	55.909	41.066	-25.4503
7	buf_fold_8	20	10	49.5997	42.0923	-26.6276
8	buf_fold_9	19	10	35.9355	33.3997	-1.5883
9	buf_fold_10	16	10	51.5742	40.9313	-22.4191

Скачать в Excel

Leave-One-Well-Out

	Fold	n_train	n_test	RMSE_fold, m	MAE_fold, m	Bias_fold, m
0	W-001	99	1	6.4174	6.4174	6.4174
1	W-002	99	1	26.0611	26.0611	-26.0611
2	W-003	99	1	1.3979	1.3979	-1.3979
3	W-004	99	1	18.2648	18.2648	-18.2648
4	W-005	99	1	27.7841	27.7841	27.7841
5	W-006	99	1	10.8064	10.8064	10.8064
6	W-007	99	1	25.7224	25.7224	25.7224
7	W-008	99	1	21.2737	21.2737	-21.2737
8	W-009	99	1	14.8044	14.8044	-14.8044
9	W-010	99	1	8.6376	8.6376	8.6376

Скачать в Excel

Block CV

	Fold	n_train	n_test	RMSE_fold, m	MAE_fold, m	Bias_fold, m
0	block_0	79	21	39.893	26.4953	-8.8559
1	block_1	71	29	59.9164	53.7944	50.9766
2	block_2	77	23	52.5654	39.6886	-17.842
3	block_3	73	27	36.7502	27.8378	-3.3349

Скачать в Excel

Buffered CV

	Fold	n_train	n_test	RMSE_fold, m	MAE_fold, m	Bias_fold, m
0	buffered_block_0	51	21	39.8841	26.3192	-7.8039
1	buffered_block_1	46	29	75.1503	68.1775	68.1775
2	buffered_block_2	57	23	54.8794	42.4044	-22.3275
3	buffered_block_3	49	27	38.1661	28.5519	-6.0752

Скачать в Excel

Leave-P-Out

	Fold	n_train	n_test	RMSE_fold, m	MAE_fold, m	Bias_fold, m
0	1	90	10	26.0975	19.6853	-5.3082
1	2	90	10	36.1391	29.0819	-24.7886
2	3	90	10	57.4342	46.3739	15.0394
3	4	90	10	33.3347	26.9062	14.4292
4	5	90	10	44.9008	34.5195	-1.3581
5	6	90	10	36.4071	23.9076	15.7702
6	7	90	10	36.8362	29.8129	-7.353
7	8	90	10	58.9205	44.2631	-34.665
8	9	90	10	26.6288	24.6238	3.3146
9	10	90	10	44.6082	36.6192	-7.8449

Скачать в Excel

Spatial Leave-P-Out

	Fold	n_train	n_test	RMSE_fold, m	MAE_fold, m	Bias_fold, m
0	1	48	52	52.0774	39.2394	-19.7514
1	2	61	39	41.811	31.1279	-4.7476
2	3	34	66	52.0027	43.9136	21.5762
3	4	61	39	42.7793	32.4615	-6.5738
4	5	61	39	42.7793	32.4615	-6.5738
5	6	62	38	52.4249	38.1603	-14.7887
6	7	48	52	52.0774	39.2394	-19.7514
7	8	59	41	66.617	59.4047	56.4078
8	9	63	37	44.1582	31.8907	-1.7009
9	10	18	82	44.7294	33.8224	-3.0445

Скачать в Excel

Stratified by tectonic_zone

	Fold	n_train	n_test	RMSE_fold, m	MAE_fold, m	Bias_fold, m
0	Central_Graben	62	38	62.8429	49.1066	-15.8334
1	North_Block	64	36	59.8027	53.0513	51.4797
2	South_Block	74	26	28.7359	23.8108	-21.0531

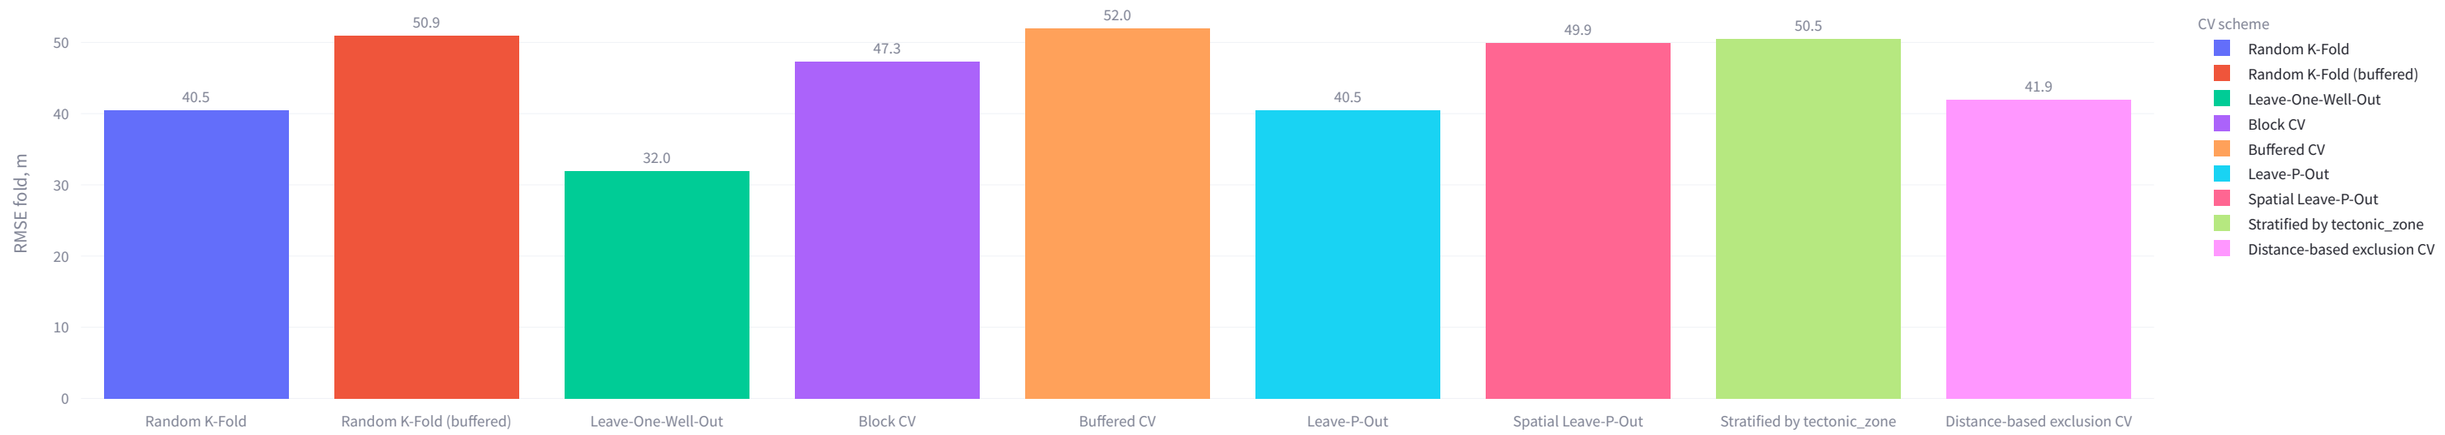
Скачать в Excel

Distance-based exclusion CV

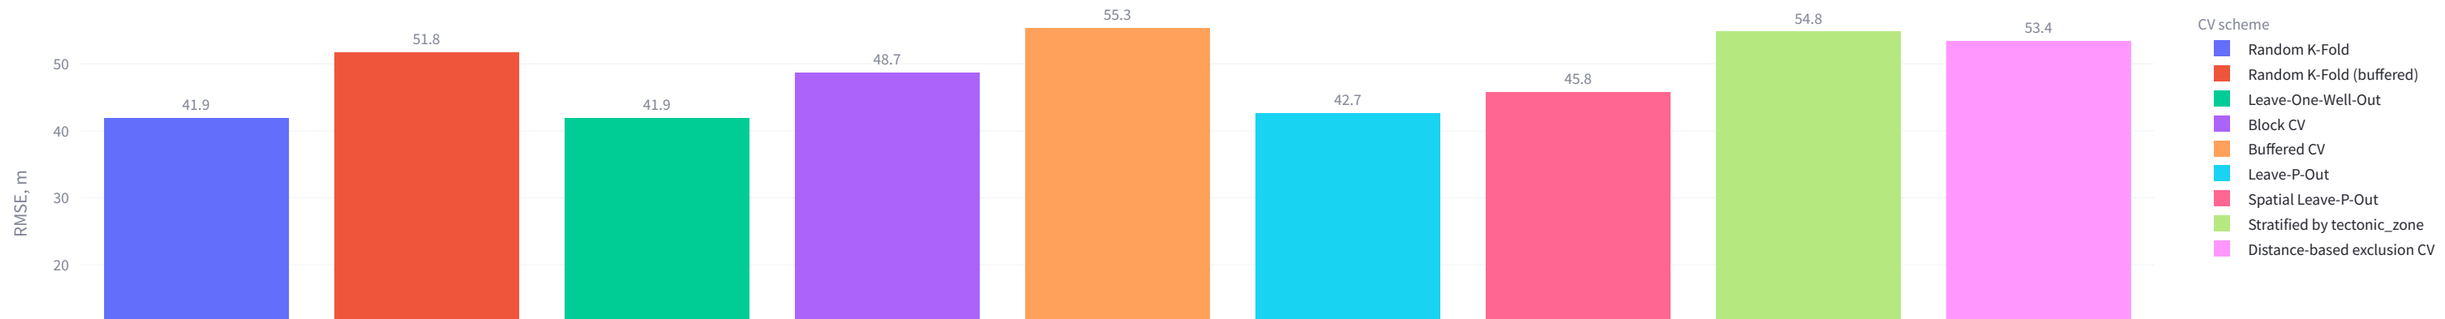
	Fold	n_train	n_test	RMSE_fold, m	MAE_fold, m	Bias_fold, m
0	dist_excl_0	53	1	1.4146	1.4146	-1.4146
1	dist_excl_1	53	1	30.2971	30.2971	-30.2971
2	dist_excl_2	41	1	2.7958	2.7958	-2.7958
3	dist_excl_3	35	1	14.6104	14.6104	14.6104
4	dist_excl_4	54	1	63.0228	63.0228	63.0228
5	dist_excl_5	55	1	5.0217	5.0217	5.0217
6	dist_excl_6	60	1	70.9979	70.9979	70.9979
7	dist_excl_7	49	1	29.4367	29.4367	-29.4367
8	dist_excl_8	48	1	17.379	17.379	-17.379
9	dist_excl_9	18	1	5.4604	5.4604	5.4604

Скачать в Excel

RMSE по фолдам (среднее) по схемам CV



RMSE по схемам CV

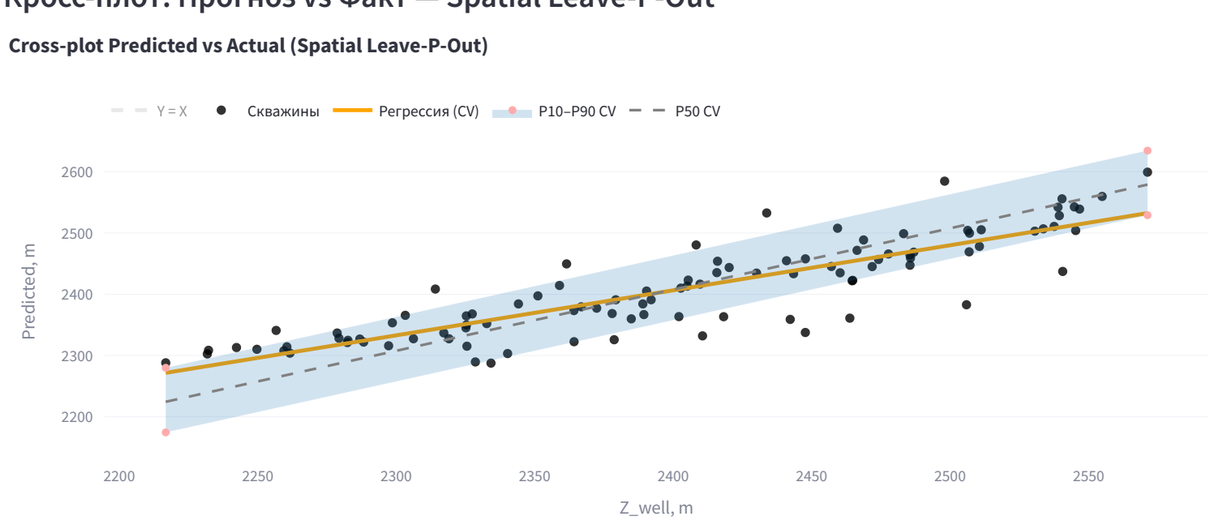




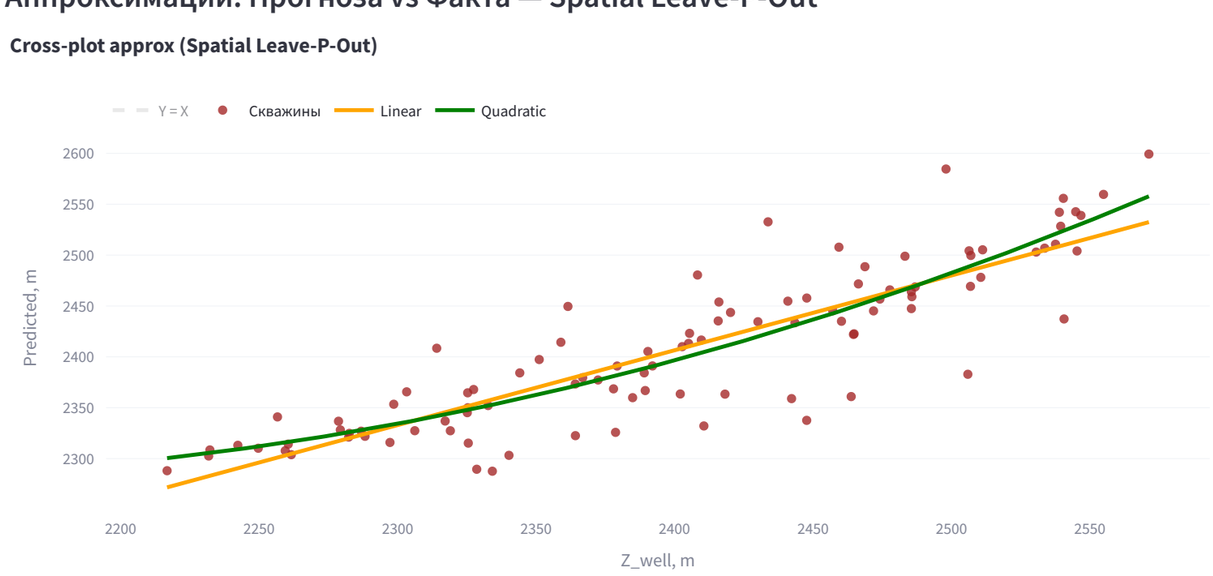
Лучшая схема CV: **Spatial Leave-P-Out** (RMSE=45.75, Std=7.01)

QC кросс-плот лучшей CV

Кросс-плот: Прогноз vs Факт — Spatial Leave-P-Out



Аппроксимации: Прогноза vs Факта — Spatial Leave-P-Out



Метрики кросс-плота Прогноз vs Факт — Spatial Leave-P-Out

	R^2 (Pearson, Predicted vs Actual)	RMSE	MSE	MAE	Bias	Std	Variance	MAPE %	P-value	Equation
0	0.7571	45.7530	2093.3335	35.9987	-5.8915	45.6006	2079.4184	1.5124	7.05080e-32	Predicted = 0.73536·Actual + 641.61648

Скачать в Excel

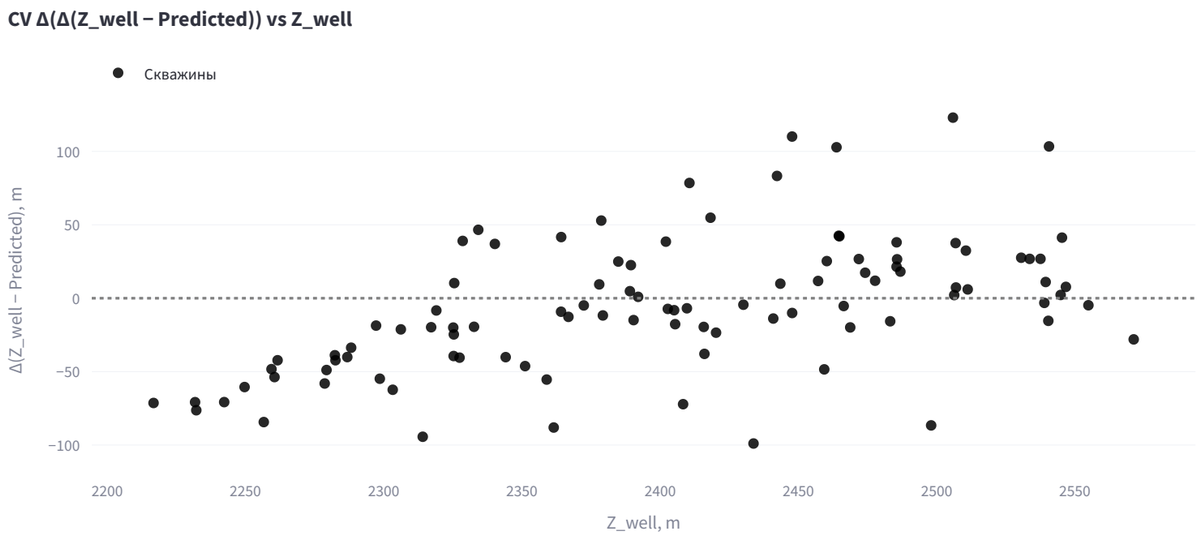
Сравнение метрик выбранных кривых аппроксимации — Spatial Leave-P-Out

	Approximation	R^2_fit	RMSE	MSE	MAE	Bias	Std	Variance	MAPE %	Equation
0	Linear	0.7571	38.2952	1466.5208	27.3023	0.0000	38.4881	1481.3342	1.1329	y = 0.73536·x + 641.61648
1	Quadratic	0.7729	37.0303	1371.2442	25.7375	0.0000	37.2169	1385.0951	1.0664	y = 0.00118·x^2 - 4.91758·x + 7409.52713

Скачать в Excel

Невязки CV (Δ(Z_well − Predicted))

Зависимость CV-невязки Δ (Δ(Z_well − Predicted)) vs Z_well



Статистика CV-невязок Δ (Δ(Z_well – Predicted))

	Metrics	Value
0	Count	100.0000
1	μ, mean	-5.8915
2	median	-7.7156
3	mode	-98.9485
4	σ, std	45.6006
5	variance	2079.4184
6	CV %	774.0124
7	RMSE	45.7530
8	min	-98.9485
9	Q05	-76.6988

Скачать в Excel

Кол-во бинов гистограммы: CV

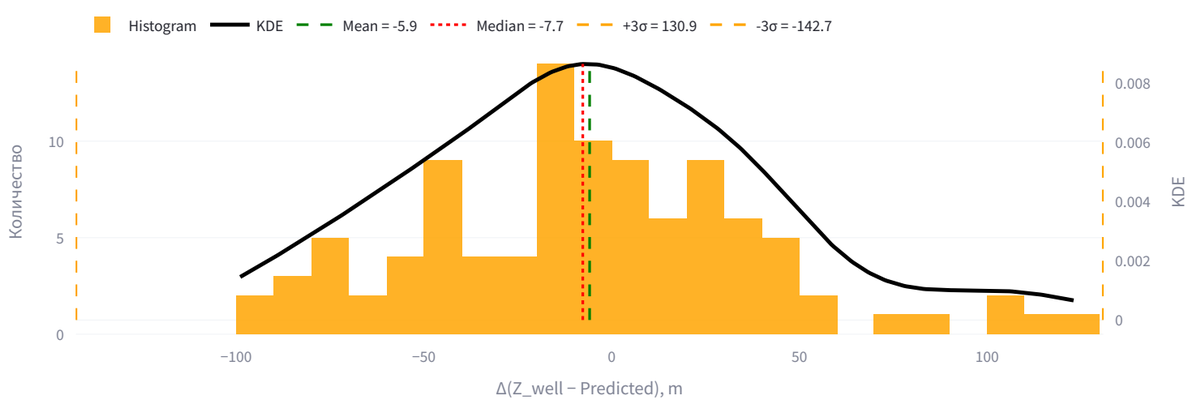
40

10 120

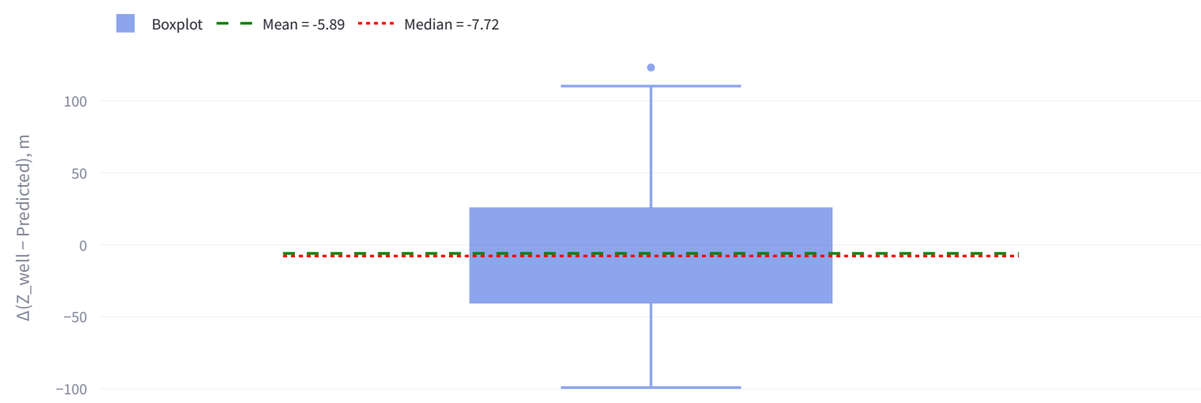
Нормализация гистограммы: CV

нет

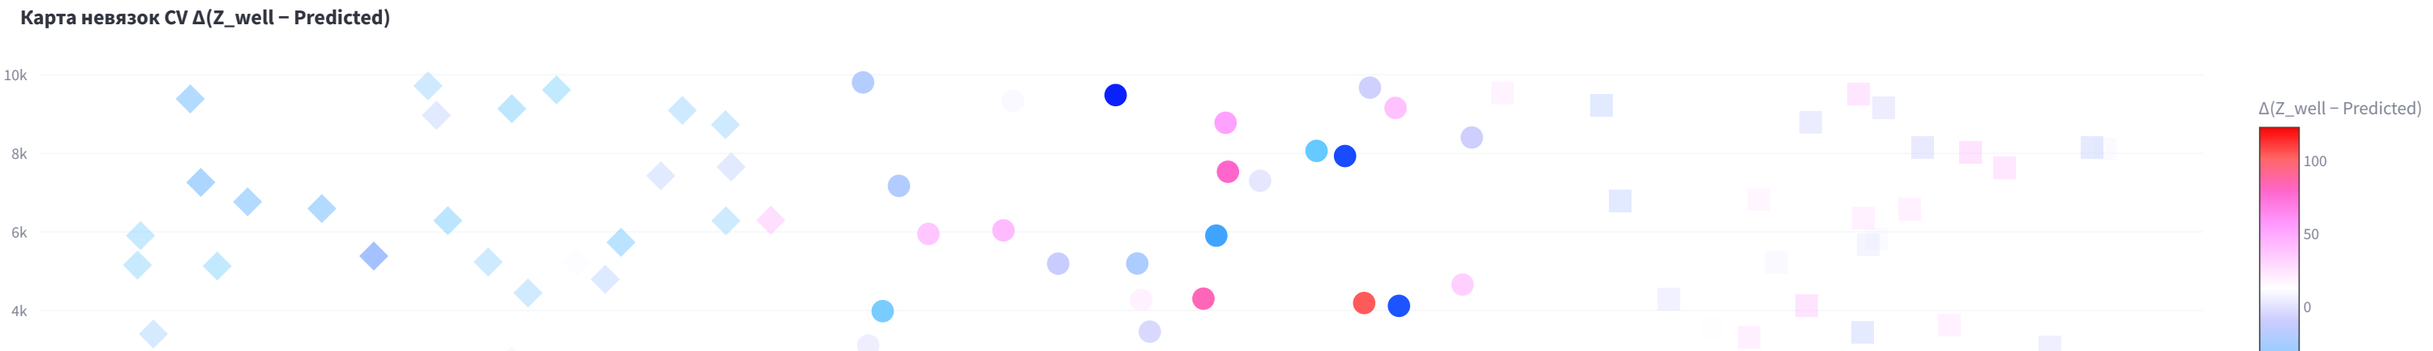
Гистограмма: CV (Δ(Z_well – Predicted))



Boxplot: CV (Δ(Z_well – Predicted))



Пространственное распределение невязок CV Δ(Z_well – Predicted)





Анализ выбросов невязок CV

Sigma rule (|CV-невязка (Z_well)| > 2.0σ)

	horizon_id	well_id	X_coord	Y_coord	CV-невязка (Z_well)	category_plot	sigma
18	Top_Reservoir	W-019	7,466.2	4,189	103.3986	Central_Graben	2.2675
25	Top_Reservoir	W-026	6,178.7	2,264.2	-98.9485	Central_Graben	-2.1699
28	Top_Reservoir	W-029	7,550.7	1,794.1	123.0059	Central_Graben	2.6975
30	Top_Reservoir	W-031	5,962.5	9,481.2	-94.3583	Central_Graben	-2.0692
50	Top_Reservoir	W-051	4,335.2	2,510	110.112	Central_Graben	2.4147
92	Top_Reservoir	W-093	5,612.8	389.9	102.8187	Central_Graben	2.2548

Скачать в Excel

IQR rule (k = 1.5·IQR)

	horizon_id	well_id	X_coord	Y_coord	CV-невязка (Z_well)	category_plot
28	Top_Reservoir	W-029	7,550.7	1,794.1	123.0059	Central_Graben

Скачать в Excel

Modified Z-score rule (|Modified Z| > 3.5)

Выбросов не обнаружено.

Percentile rule (Q05-Q95)

	horizon_id	well_id	X_coord	Y_coord	CV-невязка (Z_well)	category_plot
18	Top_Reservoir	W-019	7,466.2	4,189	103.3986	Central_Graben
22	Top_Reservoir	W-023	7,350.5	7,930.2	-88.0695	Central_Graben
25	Top_Reservoir	W-026	6,178.7	2,264.2	-98.9485	Central_Graben
28	Top_Reservoir	W-029	7,550.7	1,794.1	123.0059	Central_Graben
30	Top_Reservoir	W-031	5,962.5	9,481.2	-94.3583	Central_Graben
44	Top_Reservoir	W-045	7,676.6	4,116.5	-86.6134	Central_Graben
47	Top_Reservoir	W-048	6,493.7	4,300	83.288	Central_Graben
50	Top_Reservoir	W-051	4,335.2	2,510	110.112	Central_Graben
92	Top_Reservoir	W-093	5,612.8	389.9	102.8187	Central_Graben
99	Top_Reservoir	W-100	1,474.7	5,384	-84.3505	North_Block

Скачать в Excel

Шаг 3 · Анализ параметров по категориям: tectonic_zone (Z_well vs Z_map)

Распределение параметров по категориям: tectonic_zone (Z_well vs Z_map)

Количество скважин по категориям : tectonic_zone



Количество скважин по категориям : tectonic_zone





Таблица статистики по категориям

tectonic_zone	Скважин	Записей (скважина-горизонт)	Доля скважин, %
Central_Graben	38	38	38
North_Block	36	36	36
South_Block	26	26	26

Скачать в Excel

Статистика параметров по категориям: tectonic_zone (Z_well vs Z_map)

tectonic_zone: Central_Graben

Z_well, m (Central_Graben)

	Z_well, m (Central_Graben)
Count	38.00
μ, mean	2,417.15
median	2,419.20
mode	2,306.19
σ, std	64.98
variance	4,222.37
CV %	2.69
min	2,306.19
Q05	2,318.29
Q25	2,364.15

Скачать в Excel

Z_map, m (Central_Graben)

	Z_map, m (Central_Graben)
Count	38.00
μ, mean	2,400.61
median	2,392.47
mode	2,259.65
σ, std	83.41
variance	6,957.06
CV %	3.47
min	2,259.65
Q05	2,292.54
Q25	2,344.94

Скачать в Excel

tectonic_zone: North_Block

Z_well, m (North_Block)

Z_map, m (North_Block)

	Z_well, m (North_Block)
Count	36.00
μ, mean	2,321.07
median	2,310.21
mode	2,216.75
σ, std	67.34
variance	4,535.28
CV %	2.90
min	2,216.75
Q05	2,232.10
Q25	2,274.39

Скачать в Excel

	Z_map, m (North_Block)
Count	36.00
μ, mean	2,321.31
median	2,299.24
mode	2,198.68
σ, std	66.92
variance	4,478.40
CV %	2.88
min	2,198.68
Q05	2,244.40
Q25	2,272.68

Скачать в Excel

tectonic_zone: South_Block

Z_well, m (South_Block)

	Z_well, m (South_Block)
Count	26.00
μ, mean	2,492.64
median	2,506.59
mode	2,384.85
σ, std	53.79
variance	2,893.64
CV %	2.16
min	2,384.85
Q05	2,402.80
Q25	2,465.80

Скачать в Excel

Z_map, m (South_Block)

	Z_map, m (South_Block)
Count	26.00
μ, mean	2,489.82
median	2,508.61
mode	2,347.07
σ, std	65.56
variance	4,297.95
CV %	2.63
min	2,347.07
Q05	2,369.80
Q25	2,453.51

Скачать в Excel

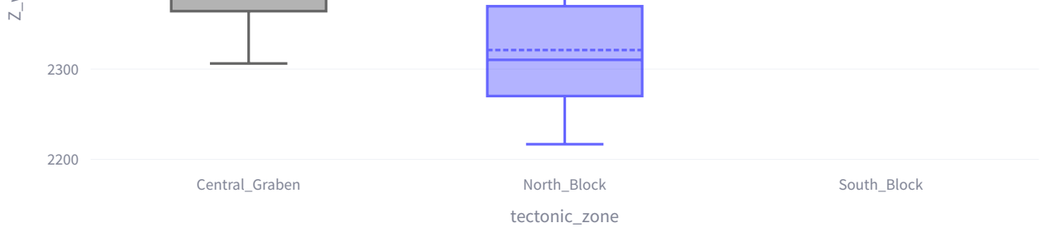
Boxplot: линия внутри бокса показывает медиану, пунктирная линия показывает среднее значение.

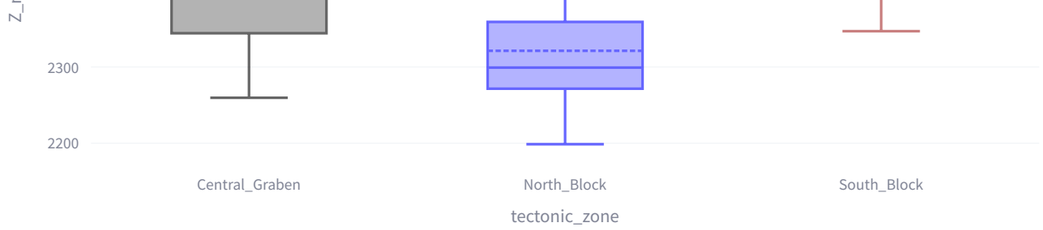
Boxplot Z_well



Boxplot Z_map







Гистограмма: по tectonic_zone

📊 Настройки гистограмм по зонам

Кол-во бинов гистограммы:

40

10 120

Режим отображения

Гистограмма | Только KDE | Гистограмма + KDE

Нормировка гистограмм по зонам

нет

Линия среднего значения (Mean)

Линия медианы (Median)

Прозрачность гистограмм по зонам

0.50

0.10 1.00

Гистограмма: Z_well

Гистограмма: Z_map

QC кросс-плот по категориям

Аппроксимации зависимости параметров: tectonic_zone (Z_well vs Z_map)

Категории для общего графика (tectonic_zone)

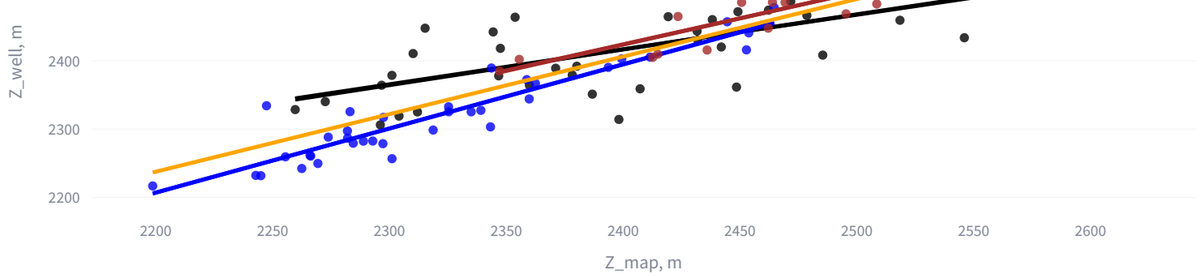
Central_Graben × North_Block × South_Block ×

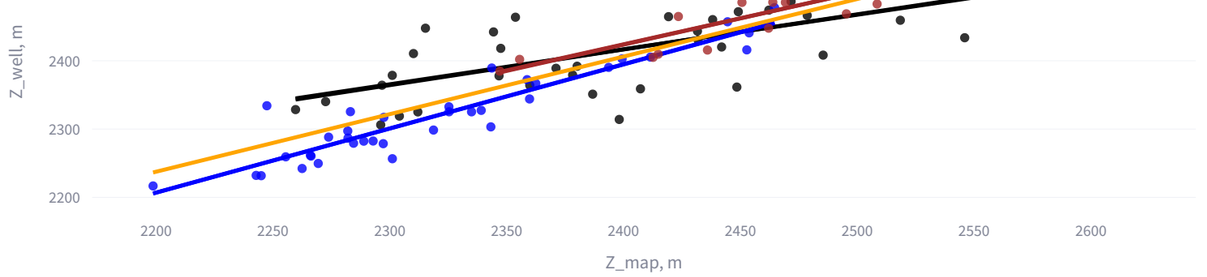
Все категории

Все категории (tectonic_zone)

Только выбранные категории

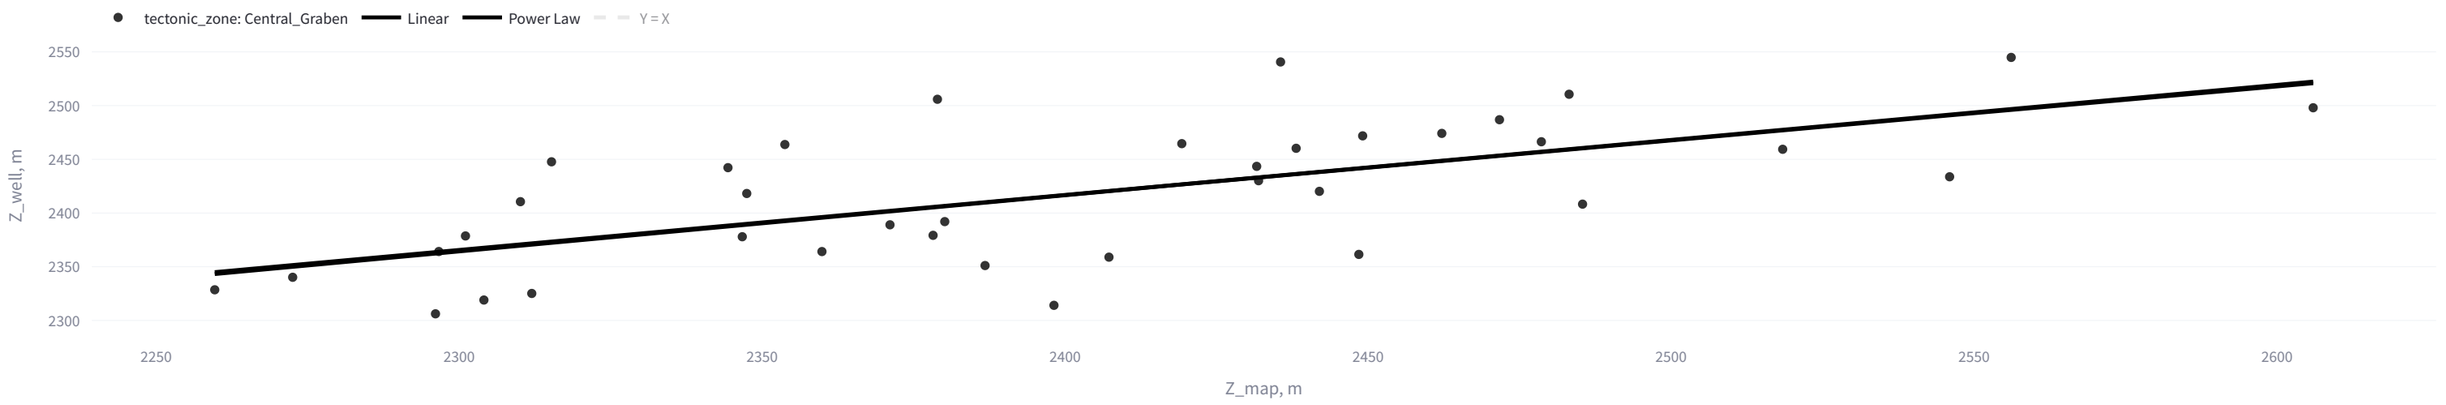
Только выбранные категории (tectonic_zone)



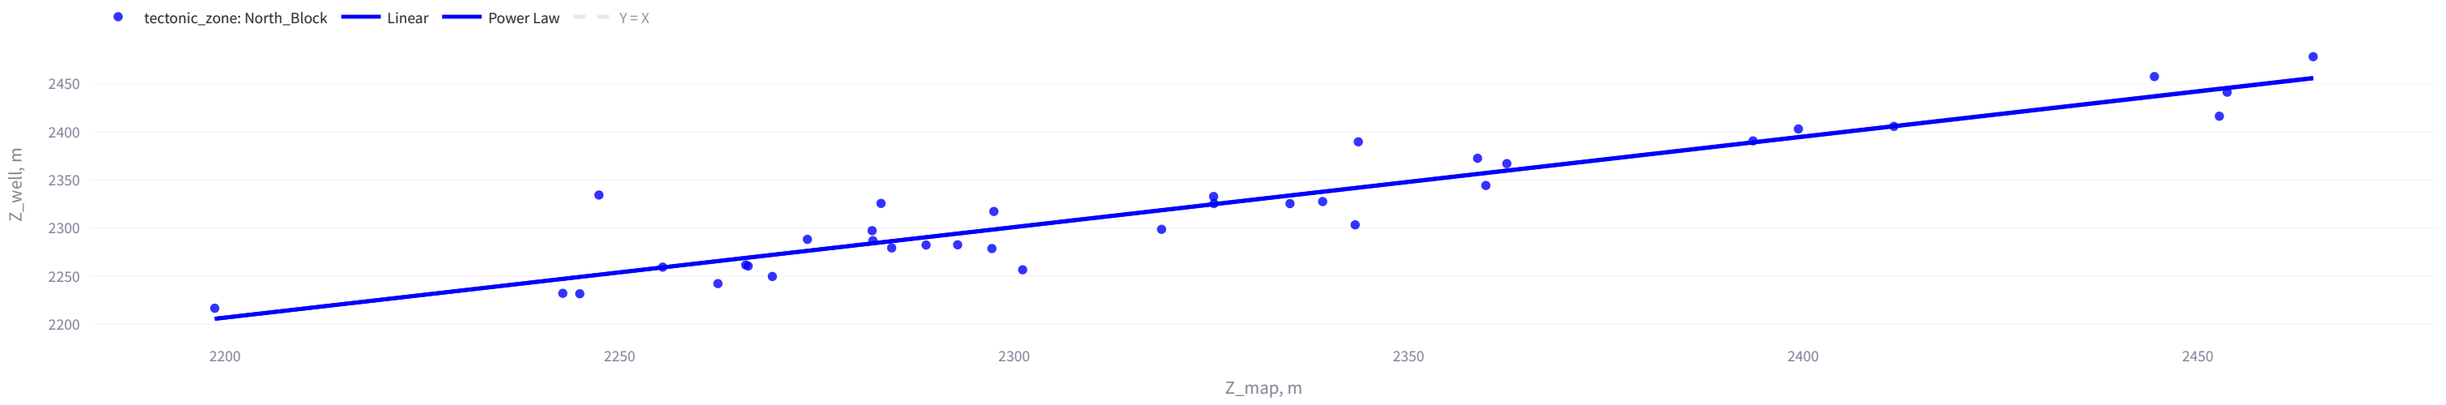


Аппроксимации по отдельным категориям (tectonic_zone)

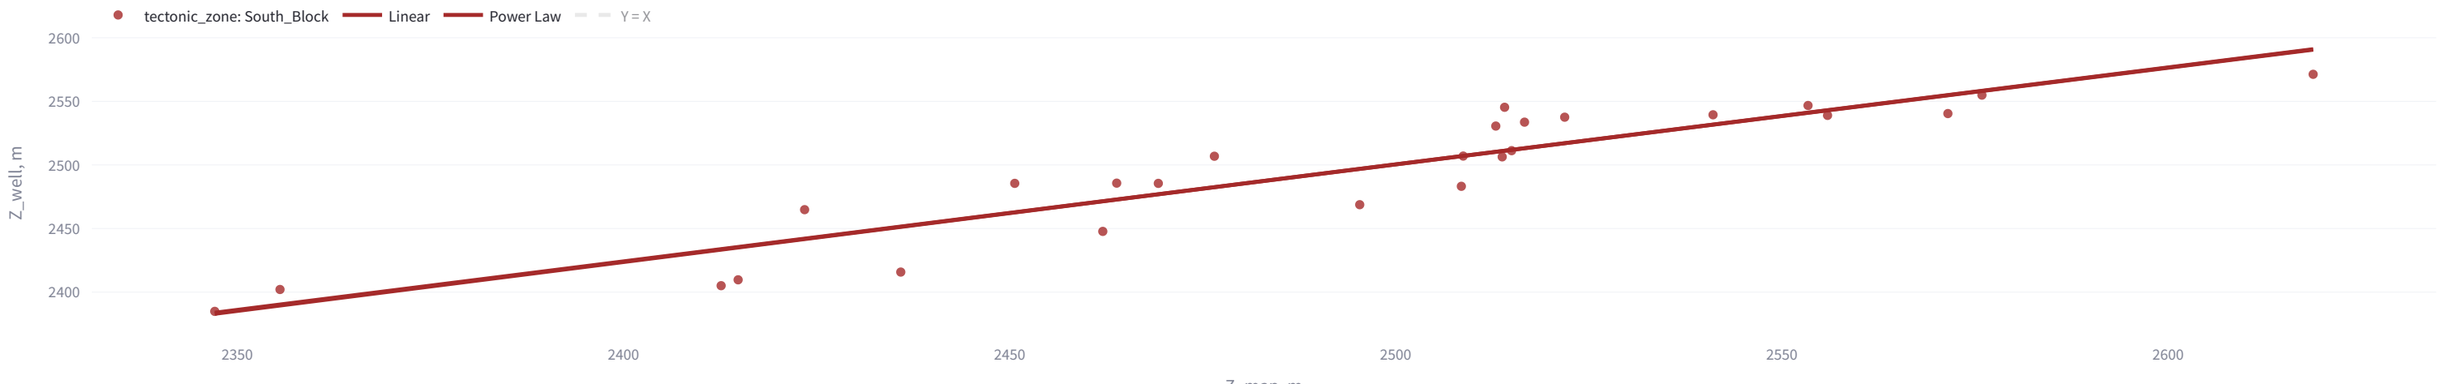
tectonic_zone: Central_Graben



tectonic_zone: North_Block



tectonic_zone: South_Block



Z_map, m

Сравнение метрик выбранных кривых аппроксимации: tectonic_zone

	tectonic_zone	Approximation	R^2_fit	RMSE	MSE	MAE	Bias	Std	Variance	MAPE %	Equation
0	Central_Graben	Linear	0.4321	48.3194	2334.7664	39.7100	0.0000	48.9680	2397.8682	1.6411	y = 0.51211·x + 1187.78175
1	Central_Graben	Power Law	0.4331	48.2775	2330.7177	39.6050	-0.4802	48.9231	2393.4732	1.6365	y = 44.80276·x^0.51237
2	North_Block	Linear	0.8720	23.7568	564.3832	17.2865	-0.0000	24.0937	580.5084	0.7448	y = 0.93972·x + 139.67834
3	North_Block	Power Law	0.8719	23.7653	564.7907	17.2905	-0.1231	24.1021	580.9119	0.7449	y = 1.60764·x^0.93872
4	South_Block	Linear	0.8638	19.4678	378.9960	16.3769	-0.0000	19.8534	394.1558	0.6594	y = 0.76260·x + 593.91226
5	South_Block	Power Law	0.8642	19.4397	377.9019	16.3999	-0.0756	19.8245	393.0120	0.6605	y = 6.40265·x^0.76272

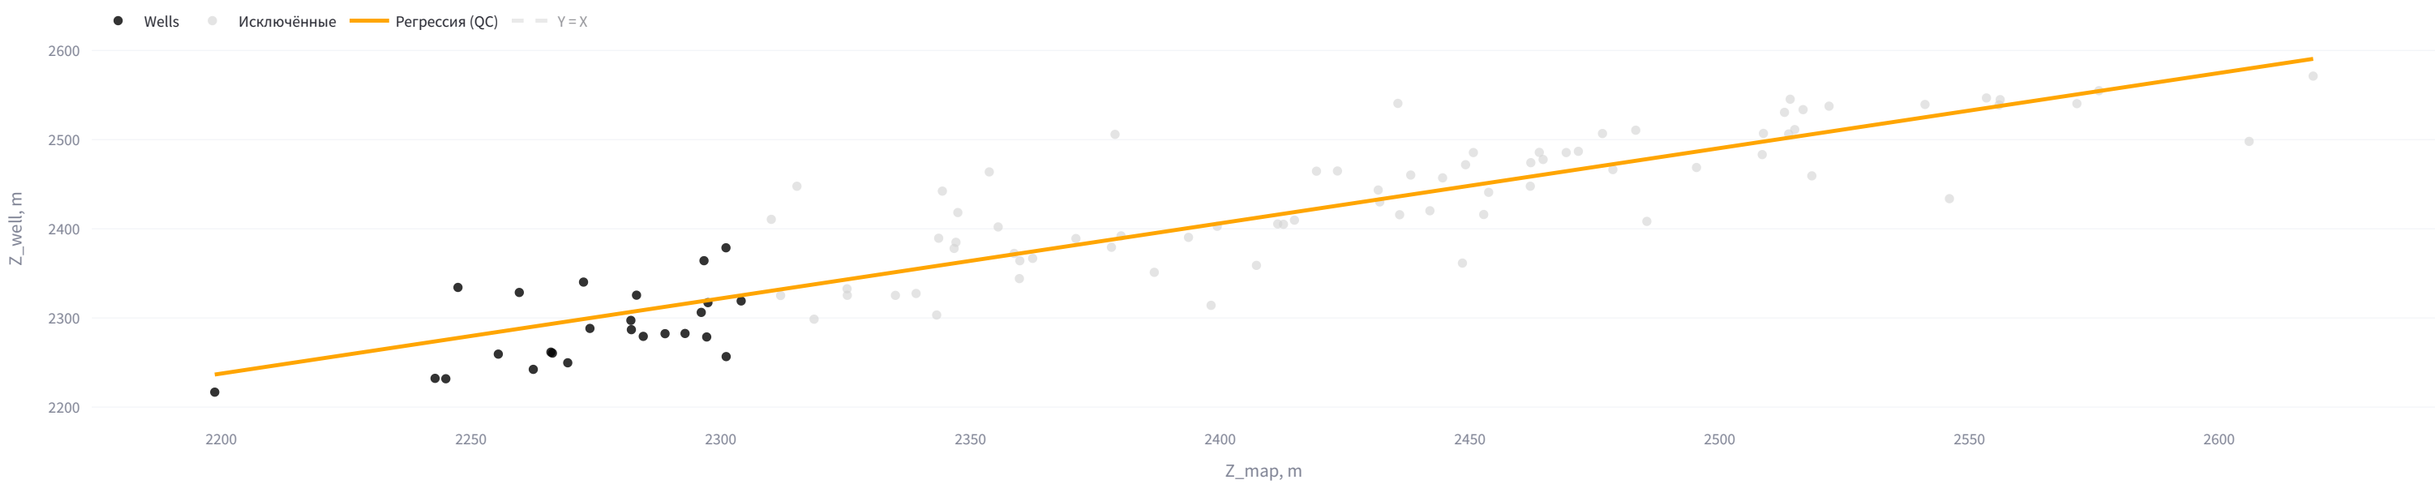
Скачать в Excel

Шаг 4 · Фильтрация скважин

Выделение скважин кликом по точкам

Выделите точки одним из способов: клик по точке (Shift+клик — несколько), рамка (Box) или лассо (Lasso). Переключение режимов — иконки в правом верхнем углу графика. Затем нажмите «Применить исключение».

Выделение скважин кликом по точкам



Применить исключение

Сбросить всё

Выделено точек: 0
Исключено кликом: 75

Исключённые кликом скважины

Исключённые

W-002 × W-003 × W-005 × W-006 × W-008 × W-009 × W-010 × W-012 × W-013 × W-014 × W-015 × W-016 × W-017 × W-018 × W-019 × W-020 × W-021 × W-023 × W-026 × W-027 × W-028 ×
W-029 × W-030 × W-031 × W-032 × W-034 × W-035 × W-037 × W-039 × W-041 × W-042 × W-043 × W-044 × W-045 × W-046 × W-047 × W-048 × W-049 × W-050 × W-051 × W-052 × W-057 ×
W-058 × W-059 × W-060 × W-061 × W-063 × W-064 × W-066 × W-069 × W-070 × W-071 × W-073 × W-074 × W-075 × W-076 × W-077 × W-078 × W-079 × W-080 × W-082 × W-085 × W-086 ×
W-087 × W-088 × W-089 × W-090 × W-091 × W-092 × W-093 × W-094 × W-095 × W-096 × W-097 × W-098 ×

Исходно скважин: 100

Случайно исключено: 0

Исключено вручную: 0

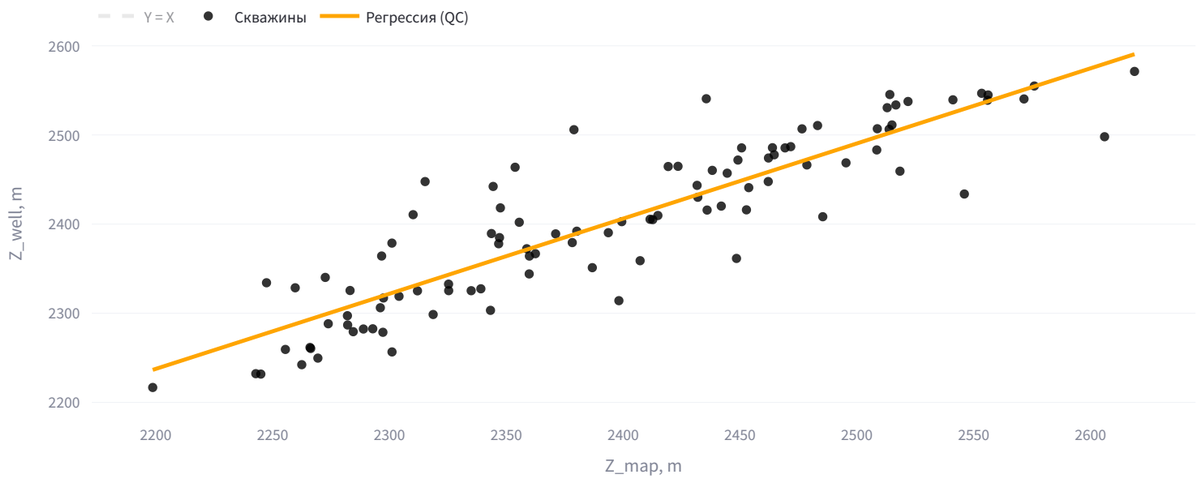
Исключено кликом: 75

Осталось для анализа: 25 (25.0%)

Графики до фильтрации

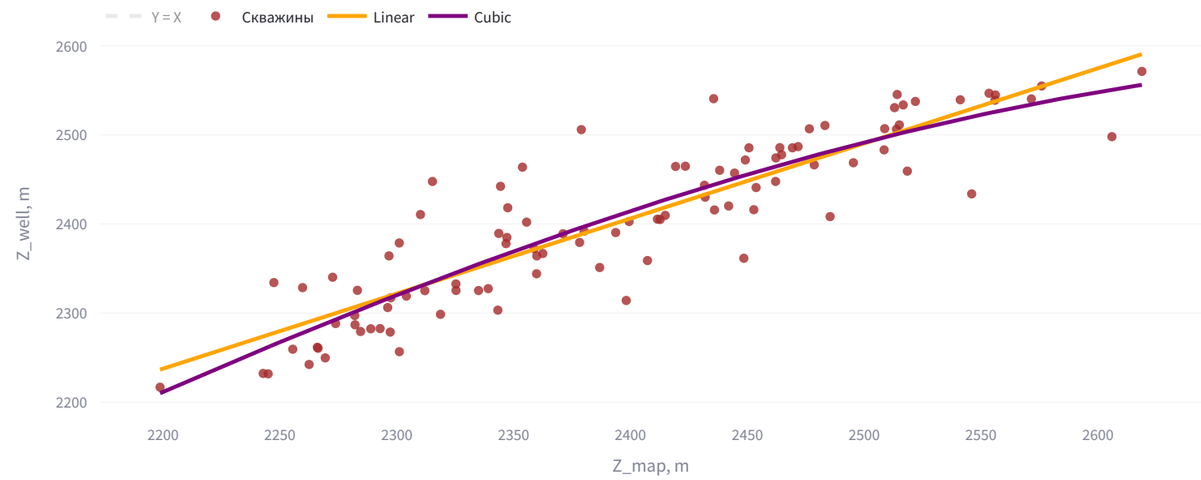
Кросс-плот до фильтрации: Z_well vs Z_map

QC кросс-плот до фильтрации



Аппроксимации до фильтрации: Z_well vs Z_map

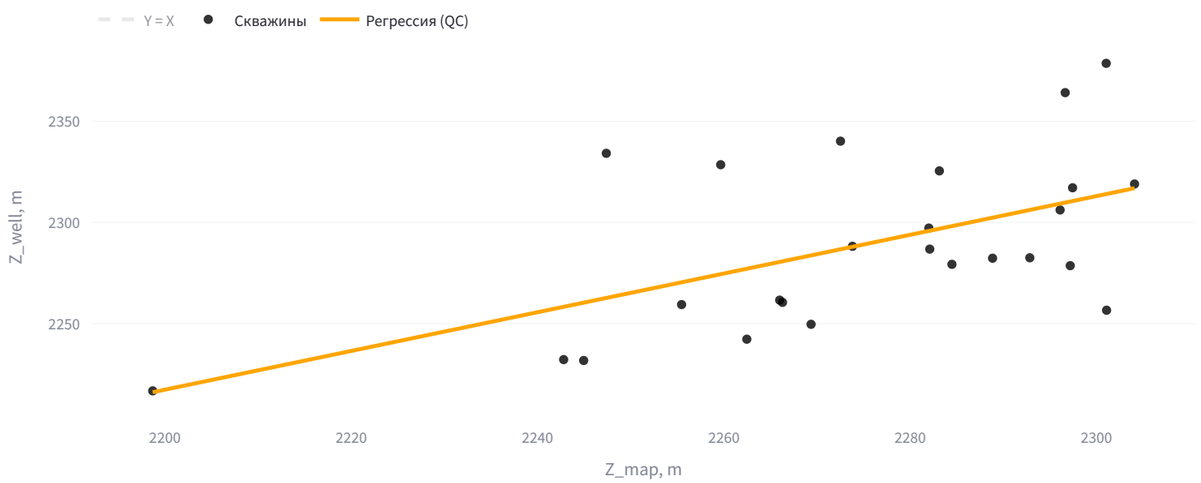
Аппроксимации до фильтрации



Графики после фильтрации

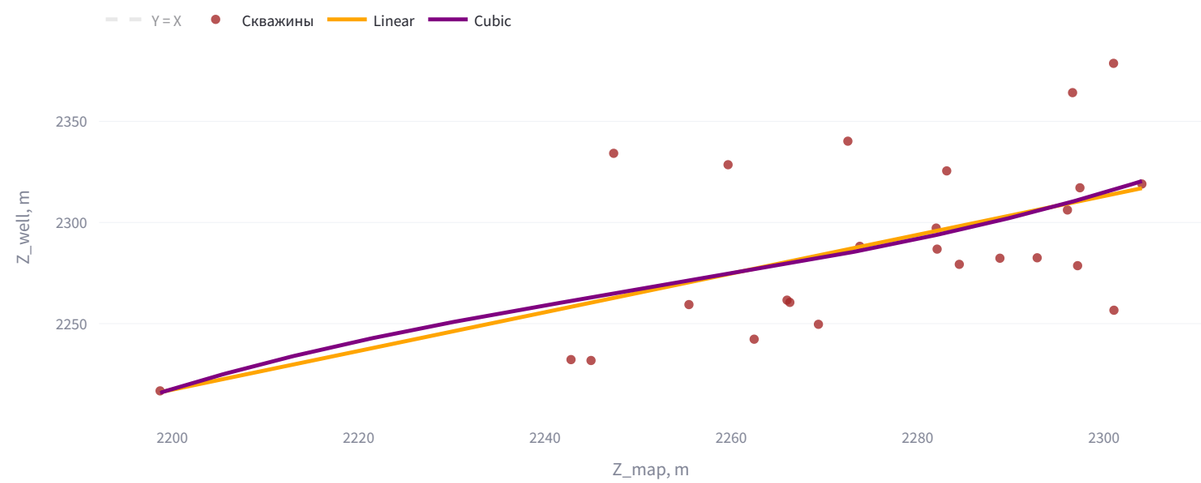
Кросс-плот после фильтрации: Z_well vs Z_map

QC кросс-плот после фильтрации



Аппроксимации после фильтрации: Z_well vs Z_map

Аппроксимации после фильтрации



Метрики QC кросс-плота после фильтрации

	R^2_lin	RMSE	MSE	MAE	Bias	Std	Variance	MAPE %	P-value	Equation
0	0.3095	37.0978	1376.2465	26.8368	14.1456	35.0022	1225.1547	1.1590	3.88015e-03	Z_well = 0.95713·Z_map + 111.65961

Скачать в Excel

Сравнение аппроксимаций после фильтрации

	Approximation	R^2_fit	RMSE	MSE	MAE	Bias	Std	Variance	MAPE %	Equation
0	Linear	0.3095	34.2796	1175.0920	27.0130	-0.0000	34.9865	1224.0542	1.1737	y = 0.95713·x + 111.65961
1	Cubic	0.3112	34.2376	1172.2133	27.0514	-0.0000	34.9436	1221.0556	1.1757	y = 0.00008·x^3 - 0.54237·x^2 + 1221.59236·x - 915452.20988

Скачать в Excel

Сравнение метрик до и после фильтрации

	Metrics	before filt	after filt
0	Well	100	25
1	R^2_lin	0.8000	0.3095
2	RMSE	44.4287	37.0978
3	MSE	1973.9099	1376.2465
4	MAE	31.1295	26.8368
5	Bias	6.9283	14.1456
6	Std	44.1063	35.0022
7	Variance	1945.3622	1225.1547
8	MAPE %	1.2898	1.1590

Скачать в Excel

Распределение R^2 (Pearson) при случайном исключении скважин

Для каждого уровня (5–95 %) выбирается заданное в сайдбаре число случайных наборов скважин; каждая скважина исключается целиком. In-sample: r^2 считается по оставшимся скважинам, на которых обучалась линия. Out-of-sample: линия обучается на оставшихся скважинах, а r^2 считается по исключённым, которых модель не видела. Оба режима используют одни и те же наборы.

Текущий seed: 42

Число наборов: 500

Запустить расчёт

Распределение R^2 (Pearson), in-sample, при случайном исключении скважин

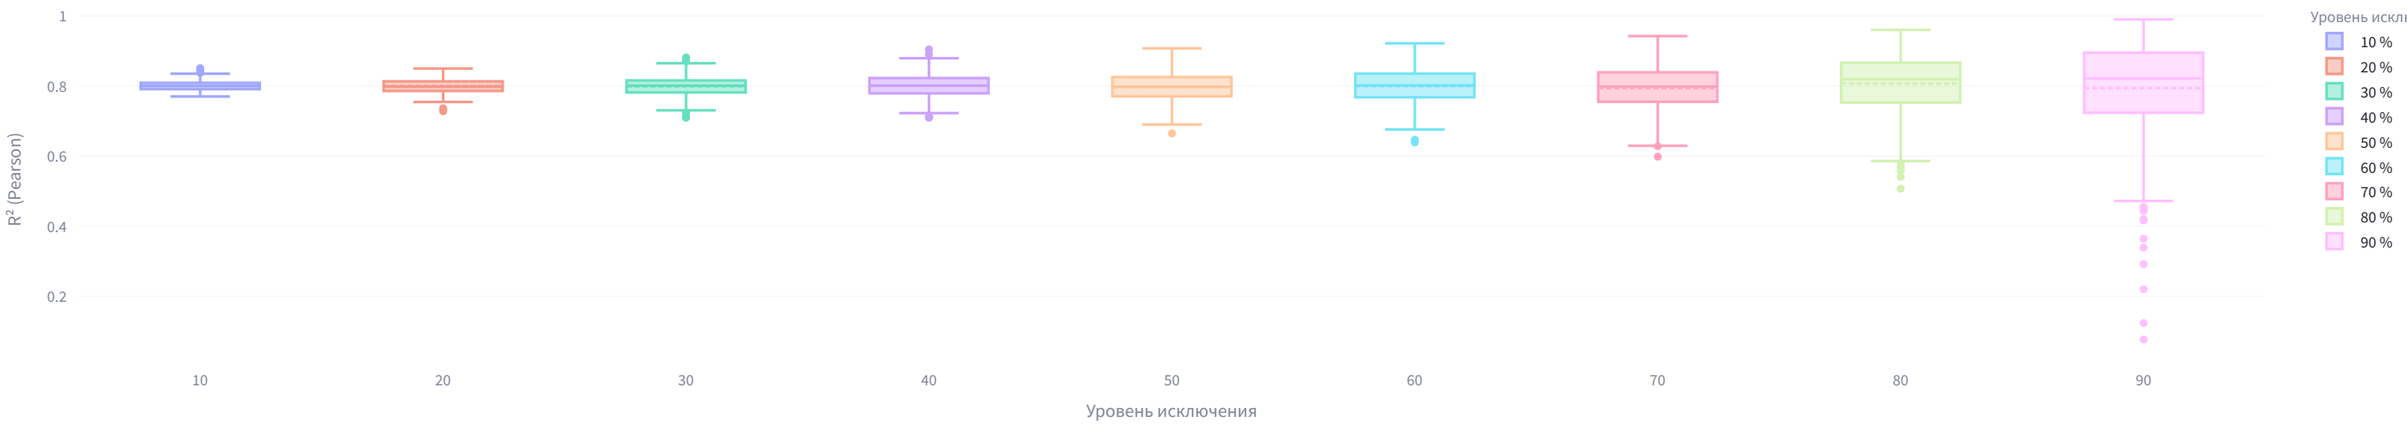
	level_pct	n_excluded	n_remaining	n_train	n_sets	status	min	max	mean	median
0	5 %	5	95	95	500	OK	0.7787	0.8313	0.7998	0.7981
2	10 %	10	90	90	500	OK	0.7704	0.8513	0.8009	0.8006
4	15 %	15	85	85	500	OK	0.7568	0.8531	0.8008	0.8004
6	20 %	20	80	80	500	OK	0.7283	0.8503	0.8000	0.7985
8	25 %	25	75	75	500	OK	0.7338	0.8817	0.7999	0.7996
10	30 %	30	70	70	500	OK	0.7097	0.8817	0.7998	0.8017
12	35 %	35	65	65	500	OK	0.7115	0.8984	0.8026	0.8038
14	40 %	40	60	60	500	OK	0.7098	0.9048	0.8011	0.8015
16	45 %	45	55	55	500	OK	0.6821	0.9058	0.8003	0.8000
18	50 %	50	50	50	500	OK	0.6652	0.9079	0.7977	0.7984

Скачать в Excel

Шаг уровней для boxplot

10 % 5 %

Boxplot: разброс R^2 (Pearson), in-sample, по уровням исключения



Распределение R^2 (Pearson), out-of-sample, при случайном исключении скважин

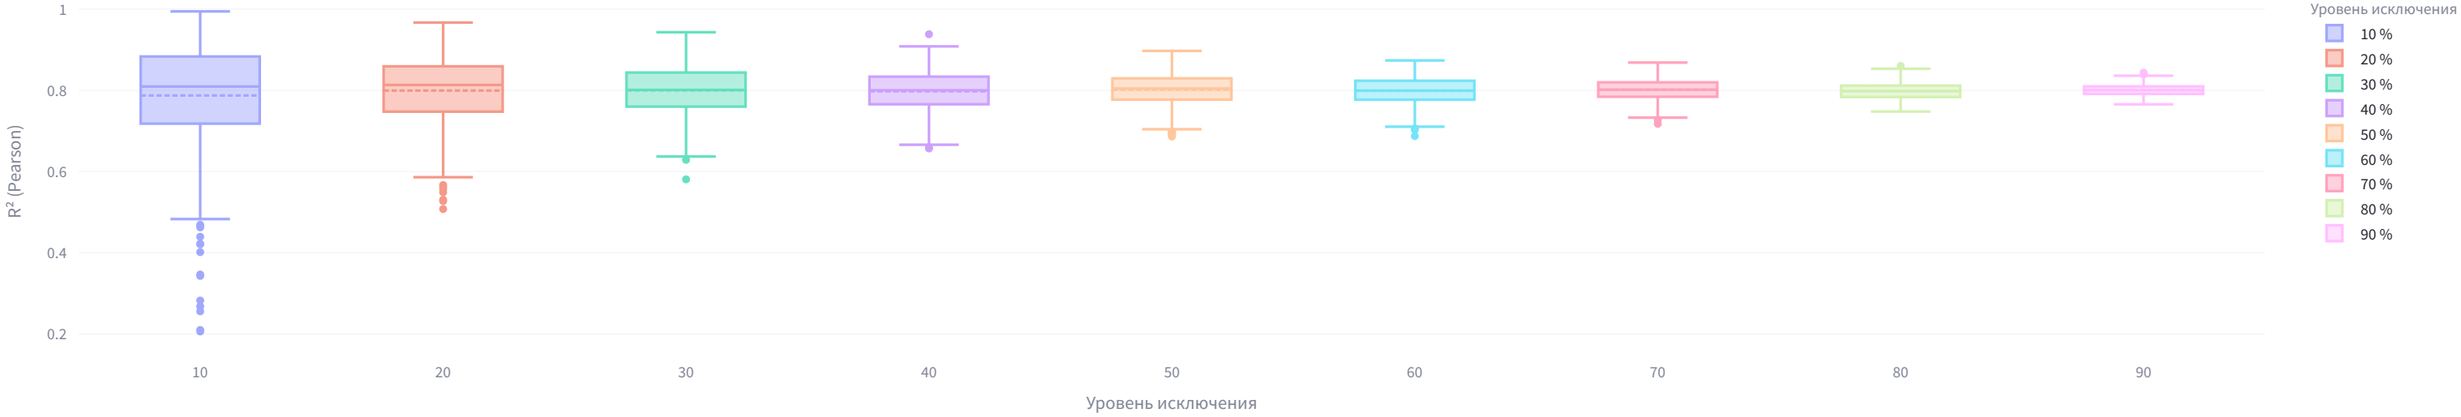
	level_pct	n_excluded	n_remaining	n_train	n_test	n_sets	status	min	max	mean	median
1	5 %	5	95	95	5	500	OK	0.0018	0.9994	0.7811	0.8586
3	10 %	10	90	90	10	500	OK	0.2062	0.9945	0.7875	0.8095
5	15 %	15	85	85	15	500	OK	0.4746	0.9674	0.7922	0.8070
7	20 %	20	80	80	20	500	OK	0.5077	0.9670	0.7994	0.8134
9	25 %	25	75	75	25	500	OK	0.5260	0.9504	0.7995	0.8063
11	30 %	30	70	70	30	500	OK	0.5808	0.9432	0.8000	0.8012
13	35 %	35	65	65	35	500	OK	0.6278	0.9366	0.7949	0.7966
15	40 %	40	60	60	40	500	OK	0.6570	0.9383	0.7975	0.8001
17	45 %	45	55	55	45	500	OK	0.6353	0.9277	0.7989	0.8024
19	50 %	50	50	50	50	500	OK	0.6864	0.8972	0.8019	0.8046

Скачать в Excel

Шаг уровней для boxplot

10 % 5 %

Boxplot: разброс R^2 (Pearson), out-of-sample, по уровням исключения



CROSSPL✳T↔CROSS⊗VALIDATION

Данные обрабатываются в памяти сессии и не записываются на диск приложения.

© А.С.Поздняков 2026