Кросс-плот и кросс-валидация для атрибутного анализа

Название проекта

Attribute QC_CV — кросс-плот и кросс-валидация для оценки качества атрибутного анализа по данным скважин.

Описание проекта

Streamlit-инструмент, который сравнивает эталонный параметр PARAM_1 (H_eff или Phi) и сравниваемый PARAM_2 (Seismic attribute) в одних и тех же точках — скважинах — и проверяет, насколько один параметр предсказывается по другому. Реализованы Шаги 0–4: загрузка и QC данных, базовый QC-кросс-плот с аппроксимациями, кросс-валидация по девяти схемам с автоматическим выбором лучшей, анализ по категориям и фильтрация скважин. Инструмент обобщён на любые пары числовых параметров. Во всех шагах модель — линейная регрессия (полином степени 1).

Описание данных

Входная таблица CSV/XLSX, в которой каждая строка — пара значений PARAM_1 и PARAM_2 в точке скважины (на горизонт). Обязательные колонки: well_id, X, Y, PARAM_1 (H_eff или Phi) и PARAM_2 (Seismic attribute: rms_amplitude, envelope, sweetness и так далее). Имена колонок в файле могут быть любыми — соответствие задаётся при сопоставлении колонок в сайдбаре. Опциональные: horizon_id, tectonic_zone, reservoir_flag (тип коллектора), fluid_type (тип флюида) и любые другие числовые и категориальные колонки. В приложении есть демонстрационные файлы (выбор в сайдбаре) и пример структуры из трёх скважин: well_id, X, Y, H_eff, Phi, rms_amplitude, envelope, sweetness, horizon_id, tectonic_zone.

Цели исследования

Ход исследования

На всех шагах 1–4 строим модель только между выбранным свойством пласта в скважине (Параметр 1, эталонный: H_eff или Phi) и выбранным сейсмическим атрибутом в той же скважине (Параметр 2, сравниваемый). Выбор задаётся в начале Шага 1 и действует на все шаги 1–4. H_eff и Phi анализируются раздельно — не смешивать; у каждого свойства обычно свой оптимальный атрибут и своя чувствительность. На финальном этапе (Шаг 5) предлагается усовершенствовать модель, чтобы на вход шло несколько атрибутов, то есть нужна множественная линейная регрессия

- Шаг 0 — загрузка данных, QC входных данных, статистика и распределения по всем числовым колонкам, корреляционные матрицы Пирсона и Спирмена и pairplot. Корреляции и pairplot сначала строятся для всех выбранных сейсмических атрибутов (без H_eff и Phi), затем отдельно повторяются для пар H_eff – атрибуты и Phi – атрибуты.
- Шаг 1 — выбор Параметра 1 (H_eff или Phi) и Параметра 2 (сейсмический атрибут), базовый QC-кросс-плот, аппроксимации (17 типов), распределения выбранных параметров.
- Шаг 2 — кросс-валидация по девяти схемам, выбор лучшей по выбранному критерию (по умолчанию score = RMSE + RMSE_fold_std), детальный разбор лучшей схемы.
- Шаг 3 — диагностика по выбранной категориальной колонке.
- Шаг 4 — фильтрация скважин: ручная, случайная по проценту или выделением точек кликом.
- Шаг 5 — многоатрибутная регрессия: в шаге 1 при построении QC-кросс-плот считаем модель линейной регрессии для выбранных Параметра 1 (H_eff или Phi) и Параметра 2 (сейсмический атрибут), в шаге 5 нужно построить отдельную модель для H_eff и отдельную для Phi но уже на нескольких выбранных атрибутах.

Ожидаемые результаты

- Сравнительная таблица ошибок (RMSE, MAE, Bias) по схемам CV и по фолдам с выбором лучшей схемы.
- Оценка смещения и тренда: Bias, наклон и intercept регрессии;
- Выбросы CV-невязок по четырём правилам с указанием зон систематических ошибок (Шаг 2).
- Метрики по категориям и оценка устойчивости результата при фильтрации скважин.
- Многоатрибутные модели для H_eff и для Phi отдельно (Шаг 5).
- Вывод о том, на каких участках и горизонтах карте можно доверять, а где её нужно пересмотреть.

Текущая структура кода: app_full.py, app_utils.py, attribute_qc_full.py, translations_full.py, ui_examples_full_ru.py, ui_examples_full_en.py.

Постановка задачи

- Задача: оценивается предиктивная модель (линейная регрессия), связывающая сейсмический атрибут со свойствами пласта — эффективной мощностью коллектора (H_eff) и пористостью (Phi).
- Входные данные — значения атрибутов в точках скважин, извлечённые из сейсмического куба/сейсмических профилей, — на каждой итерации кросс-валидации не пересчитываются, они фиксированы. Пересчитывается (переобучается) только сама модель связи «атрибут → свойство пласта» при исключении скважины или группы скважин из обучающей выборки.
- Главный риск: ложная (случайная) корреляция между атрибутом и свойством пласта. При малом числе скважин и большом числе атрибутов-кандидатов почти всегда найдётся атрибут, статистически «случайно» коррелирующий с целевым параметром (классическая проблема, описанная Kalkomey, 1997).

Инструмент реализован обобщённо и применим не только к паре «скважина ↔ карта», а к любой паре числовых параметров:

Сценарий	**PARAM_1 (Reference) / PARAM_2 (Compared) — примеры**
скважина ↔ атрибут	H_eff / rms_amplitude, Phi / acoustic_impedance
атрибут ↔ атрибут	rms_amplitude / sweetness (проверка мультиколлинеарности)

Далее по тексту плана H_eff / rms_amplitude используются как сквозной иллюстративный пример (атрибутный QC), но все шаги и формулы применимы к любой паре PARAM_1/PARAM_2.

Примеры физически обоснованных связей атрибут — свойство:

Атрибут	**Физическая связь**	**Целевой параметр**
RMS amplitude	Амплитуда отражения растёт при контрасте импеданса на кровле песчаника	H_eff, Phi: связь положительная
Envelope (instantaneous amplitude)	Та же природа, что RMS amplitude: контраст импеданса на кровле коллектора	H_eff, Phi: связь положительная
Sweetness = envelope / √(instantaneous frequency)	Сочетание амплитуды и частоты, высокие значения в песчаных интервалах	H_eff, Phi: связь положительная
Coherence	Падает в каналах и неоднородных интервалах	H_eff, Phi: связь отрицательная
Instantaneous frequency	Поглощение в пористых флюидонасыщенных интервалах снижает частоту	H_eff, Phi: связь отрицательная

Атрибут	Физическая связь	Целевой параметр
AVO intercept (A)	Низкий импеданс пористого песчаника даёт отрицательный интерцепт (класс III)	Phi: связь отрицательная
AVO gradient (B)	Изменение отражения с удалением; сильнее в газонасыщенных песках	Phi: связь отрицательная
Спектральная декомпозиция (20 Hz)	Настройка на толщину: тонкие и средние пласты дают вклад в низкочастотную компоненту	H_eff: связь положительная
Acoustic impedance (инвертированный)	Импеданс падает с ростом пористости и при наличии углеводородов	Phi (прямой индикатор), H_eff: связь отрицательная
Q-factor	Пористые и флюидонасыщенные интервалы сильнее поглощают сейсмику, Q ниже	Phi: связь отрицательная; с частотой положительная

Формат данных

Минимальная структура входной таблицы (CSV/XLSX):

Колонка в коде	Роль	Описание
well_id	обязательная	Идентификатор скважины
X, Y	обязательные	Координаты скважины. Имена колонок в файле любые — выбираются в сайдбаре при сопоставлении
Zprm_well (= PARAM_1)	обязательная · Reference	Эталонный параметр — свойство пласта в скважине: H_eff или Phi. Выбирается на Шаге 1.
Zprm_map (= PARAM_2)	обязательная · Compared	Сравниваемый параметр — сейсмический атрибут в скважине (rms_amplitude, envelope, sweetness и др.). Выбирается на Шаге 1.
horizon_id	опциональная	Идентификатор горизонта — позволяет выбрать один или несколько горизонтов для анализа; для строгой оценки CV рекомендуется один горизонт
tectonic_zone	опциональная	Тектоническая/геологическая зона — пример категориальной колонки для Stratified by {колонка} CV и Шага 3; в этих шагах может использоваться любая категориальная колонка с хотя бы двумя значениями.
любая другая колонка	опциональная	Любая дополнительная числовая колонка — доступна для корреляционного анализа (Шаг 0); любая категориальная — доступна для анализа по категориям (Шаг 3)

- Единицы измерения PARAM_1 и PARAM_2 задаются пользователем при сопоставлении колонок (например, м, км, мс, м/с, доли, % и т.п.) — используются только в подписях графиков и таблиц, не влияют на расчёт. По умолчанию для H_eff — м, для Phi — ед. (доли).
- При загрузке выполняется автоматическая очистка: приведение мусорных значений («NA», «NULL», «—», «?» и т.п.) к NaN, замена запятой на точку в числовых колонках, приведение типов, удаление строк с пропусками в обязательных колонках (с выводом отчёта, сколько строк удалено).

- Опциональные колонки reservoir_flag (тип коллектора) и fluid_type (тип флюида) используются как категориальные признаки для Шага 3 наравне с tectonic_zone.
- В сайдбаре при демо или загрузке данных сопоставляются колонки H_eff и Phi, для каждой задаются единицы измерения. В начале Шага 1 выбираются Параметр 1 (эталонный: H_eff или Phi) и Параметр 2 (сравниваемый: сейсмический атрибут). Выбранная пара используется на Шагах 1–4.

Метрики кросс-плота и обозначения

Обозначение: x = PARAM_2 (сравниваемое значение), y = PARAM_1 (эталонное значение). В CV-аппроксимациях (Шаг 2) роли заданы осознанно иначе: x = Actual (PARAM_1), y = Predicted — кривая описывает прогноз модели как функцию фактического значения.

Невязка Δ — определяется по-разному в двух местах кода, это важно:

- Базовый QC-кросс-плот (Шаг 1, BasicStats): Δ = y − x = PARAM_1 − PARAM_2.
- Аппроксимации и кросс-валидация (Шаги 1–3, FitStats / fold_metrics): Δ = Predicted − Actual, то есть предсказание модели минус фактическое PARAM_1 — обратный знак по сравнению с базовым QC-кросс-плотом. Графики CV-невязок Шага 2 строятся как Actual − Predicted (PARAM_1 − Predicted), см. раздел «Шаг 2». Bias на кросс-плоте Шага 2 (Predicted vs Actual) и в таблицах схем CV считается с одним знаком: Δ = Predicted − Actual.

Таблица ниже — метрики через Δ. Δ — невязка, её определение зависит от раздела: Шаг 1 (BasicStats): Δ = y − x; аппроксимации, CV и Шаг 4 (FitStats, fold_metrics): Δ = Predicted − Actual; для R^2_lin и R^2 (Pearson) используется Δ_OLS — остаток линейной регрессии, для которого $r^2 = 1 - \Sigma(\Delta_OLS)^2 / \Sigma(y - \bar{y})^2$. Коэффициенты корреляции r и ρ — не R^2 и через Δ не выражаются. $\bar{\Delta}$ — среднее невязки (= Bias).

Метрика	**Формула**
Коэффициенты корреляции	
Коэффициент корреляции Пирсона r: - Шаг 0: матрицы корреляции и таблицы пар	r = cov(a, b) / ($\sigma_a \cdot \sigma_b$) для любого выбранного набора числовых колонок
Коэффициент корреляции Спирмена ρ: - Шаг 0: матрицы корреляции и таблицы пар	Пирсон на рангах. Любая монотонная связь
R^2_lin (коэффициент детерминации / квадрат корреляции): — in-sample - Шаг 1: «Метрики кросс-плота» - Шаг 4: до/после фильтрации	$R^2_lin = 1 - \Sigma(\Delta_OLS)^2 / \Sigma(y - \bar{y})^2 = r^2$ (Пирсон, linregress) Δ_OLS = y − (a + b·x), x = PARAM_2, y = PARAM_1; a, b — из linregress
R^2_fit (коэффициент детерминации) : — in-sample - Шаг 1: таблица аппроксимаций (17 типов, для квантильной — τ = 0.1/0.5/0.9) - Шаг 3: таблица аппроксимаций по категориям - Шаг 4: аппроксимации до/после фильтрации	$R^2_fit = 1 - \Sigma(\Delta)^2 / \Sigma(y - \bar{y})^2$ Δ = Predicted − Actual = model(PARAM_2) − PARAM_1, y = PARAM_1
R^2_fit (CV-аппроксимации): — out-of-sample Шаг 2: «Аппроксимации» для лучшей схемы Роли x и y намеренно отличаются от Шага 1: x = Actual (PARAM_1), y = Predicted	$R^2_fit = 1 - \Sigma(\Delta)^2 / \Sigma(y - \bar{y})^2$ Δ = model(Actual) − Predicted, x = Actual (PARAM_1), y = Predicted

R^2 (Pearson, Predicted vs Actual): — out-of-sample - Шаг 2: «Метрики кросс-плота» по всем схемам CV и карточка лучшей схемы; - столбец pooled в «Таблице R^2 (Pearson) по фолдам»	R^2 (Pearson) = 1 − Σ(Δ_OLS)² / Σ(Actual − Ȳ)² Δ_OLS = Actual − (a + b·Predicted), a, b — OLS по out-of-fold прогнозам; равно corrcoef(Actual, Predicted)²
R^2 (Pearson) по фолдам: — out-of-sample - Шаг 2: «Таблица R^2 (Pearson) по фолдам» (r2_fold_*) и boxplot	R^2 (Pearson) = 1 − Σ(Δ_OLS)² / Σ(Actual − Ȳ)² внутри фолда Δ_OLS = Actual − (a + b·Predicted), a, b — OLS внутри фолда; равно corrcoef² фолда. Нужно не меньше 3 точек и ненулевая дисперсия
R^2 (Actual = Predicted): — out-of-sample Шаг 2: «Сравнение схем CV»	R^2 (Actual = Predicted) = 1 − Σ(Δ)² / Σ(Actual − Ȳ)² Δ = Predicted − Actual, Ȳ — среднее Actual; по out-of-fold прогнозам
R^2 (Pearson), in-sample и R^2 (Pearson), out-of-sample: - Шаг 4.5	• In-sample: R^2 (Pearson) = 1 − Σ(Δ_OLS)² / Σ(PARAM_1 − Ȳ)², Δ_OLS = PARAM_1 − (a + b·PARAM_2), a, b — OLS по оставшимся скважинам; равно corrcoef(PARAM_2, PARAM_1)² • Out-of-sample: r² = corrcoef(PARAM_1, pred)² на исключённых скважинах, pred = a + b·PARAM_2 по оставшимся; через Δ не выражается, так как линия обучена на другой выборке
Ошибки и смещение	
RMSE (среднеквадратичная ошибка)	RMSE = √[(1/N)·Σ(Δ)²]
MSE (среднеквадратичная ошибка)	MSE = (1/N)·Σ(Δ)²
MAE (абсолютная погрешность)	MAE = (1/N)·Σ|Δ|
Bias (систематическое смещение)	Bias = (1/N)·Σ(Δ)
Std (стандартное отклонение невязок)	Std = √[(1/(N−1))·Σ(Δᵢ − Δ̄)²]
Variance (дисперсия невязок)	Var = (1/(N−1))·Σ(Δᵢ − Δ̄)²
WAPE, % (взвешенная абсолютная ошибка в процентах)	WAPE = 100 · Σ|Δ| / Σ|y|
P-value (значимость линейной корреляции) Шаг 0 (H_eff vs Phi), Шаг 1, Шаг 2, Шаг 4 — in-sample (Шаги 0, 1, 4); out-of-sample (Шаг 2)	t = r·√[(N−2)/(1−r²)], p = 2·(1 − F_t,N−2(|t|))
Уравнение линейной регрессии	y = a + b·x; наклон b и intercept a — из linregress

P-value отвечает на вопрос: насколько вероятно получить настолько же сильную (или сильнее) линейную связь между PARAM_1 и PARAM_2 случайно, если на самом деле никакой связи нет (нулевая гипотеза H_0: истинный наклон регрессии b = 0). Чем меньше p-value, тем менее правдоподобно, что найденная зависимость — случайность; порогом значимости обычно считают $p < 0.05$. Считается через scipy.stats.linregress на кросс-плотах: H_eff vs Phi в загрузке данных (Шаг 0), базовом QC-кросс-плоте (Шаг 1), по схемам CV и лучшей схеме (Шаг 2), до/после фильтрации (Шаг 4).

В проекте два разных R^2 — разведены по названию, чтобы не путать. R^2_lin (BasicStats.r2, Шаг 1, базовый QC-кросс-плот) = квадрат коэффициента корреляции Пирсона (scipy.stats.linregress) — корректен только как мера силы *линейной* связи. R^2_fit (FitStats.r2, все 17 типов аппроксимации, Шаги 1–3) = sklearn.metrics.r2_score = 1 − Σ(Δ)² / Σ(y − ȳ)², Δ = Predicted − Actual — честная доля объяснённой дисперсии, корректна для кривой любой формы. Для линейной OLS оба совпадают численно, для

остальных 16 типов — нет. **Сравнивать R^2_lin и R^2_fit напрямую нельзя — это разные метрики, а не одна и та же величина, посчитанная дважды.**

В Шаге 2 к ним добавляются ещё два варианта: R^2 (Actual = Predicted) — формула R^2_fit (sklearn r2_score), применённая к out-of-fold прогнозам кросс-валидации, и R^2 (Pearson, Predicted vs Actual) — квадрат корреляции Пирсона между прогнозом и фактом (linregress). Оба считаются по прогнозам кросс-валидации и не равны R^2_lin базового кросс-плота.

Коэффициенты линейной регрессии (наклон / intercept) показывают систематический тренд — например, «карта занижает глубину с ростом глубины» ($b < 1$) — типичный признак ошибки скоростной модели.

In-sample и out-of-sample: что это значит в проекте

In-sample — модель подбирается и проверяется на одних и тех же скважинах. Метрики показывают, насколько хорошо модель описывает данные, которые она уже видела, поэтому обычно они оптимистичны. Уравнение in-sample — обычная линейная регрессия по всем скважинам выбранной выборки.

Out-of-sample — модель подбирается без части скважин, а проверяется на тех, которых при подборе не было (кросс-валидация по схемам LOWO, K-fold и др.). Метрики показывают качество на новых скважинах. Разрыв между in-sample и out-of-sample — признак переобучения. В таблицах Out-of-sample метрики и уравнение Predicted = a + b·Actual получены по одним и тем же out-of-fold предсказаниям.

Шаг	Что считается	Режим
0	корреляции Пирсона и Спирмена, описательная статистика	без модели
1	базовый QC-кросс-плот, аппроксимации, R^2_lin, R^2_fit, P-value, уравнение регрессии	in-sample
2	девять схем CV, фолды, выбор лучшей схемы, выбросы CV-невязок, R^2 (Pearson), R^2 (Actual = Predicted), уравнение Predicted = a + b·Actual, аппроксимации лучшей схемы	out-of-sample
3	аппроксимации и метрики внутри каждой категории	in-sample (внутри категории)
4	метрики до и после фильтрации, аппроксимации после фильтрации	in-sample (на отфильтрованной выборке)
4.5	R^2 (Pearson) по сериям случайного исключения	in-sample (оставшиеся скважины) и out-of-sample (исключённые)
5	одноатрибутные модели и топ-5 многоатрибутных моделей	In-sample: RMSE_in, R^2_in, r_in, уравнение регрессии по всем скважинам; Out-of-sample: RMSE_cv, R^2_cv, r_cv, уравнение Predicted = a + b·Actual

Статистика параметров (Шаг 0)

Для выбранных параметров (PARAM_1 — H_eff или Phi; PARAM_2 — сейсмический атрибут) отдельно считается расширенная описательная статистика:

Статистика	**Формула / определение**
Count	N — число непустых значений
μ (mean)	$\mu = (1/N)\cdot\Sigma x_i$ — среднее арифметическое
median	медиана — значение, делящее выборку пополам (50-й перцентиль)

Статистика	Формула / определение
mode	мода — наиболее часто встречающееся значение
σ (std)	$\sigma = \sqrt{[\ (1/(N-1))\cdot\Sigma(x_i-\mu)^2\ ]}$
variance	$\sigma^2 = (1/(N-1))\cdot\Sigma(x_i-\mu)^2$
CV, %	$(\sigma/\mu)\cdot 100\%$ — коэффициент вариации (разброс относительно среднего)
min	минимальное значение
Q05	5-й перцентиль
Q25	25-й перцентиль (первый квартиль)
Q75	75-й перцентиль (третий квартиль)
Q95	95-й перцентиль
max	максимальное значение
range	max − min
IQR	Q75 − Q25 — межквартильный размах

Типы линий аппроксимации

На кросс-плоте, помимо базовой линейной регрессии, доступен выбор из 17 вариантов аппроксимации (10 полиномов 1–10 степени + 7 прочих методов) и квантильной регрессии (τ = 0.1 / 0.5 / 0.9), которая выводится отдельными строками:

Метод	Общий вид уравнения	Пример
Линейная	$y = a + b\cdot x$	$y = 12.4 + 0.85\cdot x$
Квадратичная	$y = a + b\cdot x + c\cdot x^2$	$y = 5.1 + 0.62\cdot x + 0.014\cdot x^2$
Кубическая	$y = a + b\cdot x + c\cdot x^2 + d\cdot x^3$	$y = 3.7 + 0.41\cdot x + 0.021\cdot x^2 - 0.0006\cdot x^3$
Полином n-й степени (4–10)	$y = a_0 + a_1\cdot x + a_2\cdot x^2 + \ldots + a_n\cdot x^n$	n=4: $y = 2.0 + 0.30\cdot x + 0.05\cdot x^2 - 0.002\cdot x^3 + 0.00004\cdot x^4$
Степенная	$y = a\cdot x^b$ (x, y > 0)	$y = 1.8\cdot x^{0.63}$
Экспонента	$y = a\cdot e^{(b\cdot x)}$ (y > 0)	$y = 4.2\cdot e^{(0.015\cdot x)}$
Логарифмическая	$y = a + b\cdot\ln(x)$ (x > 0)	$y = -3.5 + 6.2\cdot\ln(x)$
Robust (Huber)	y = a + b·x; a, b минимизируют Σ $L\delta(y_i - \hat{y}_i)$	$L\delta(r) = \frac{1}{2}r^2$ при $\lvert r\rvert\le\delta$; $\delta(\lvert r\rvert - \frac{1}{2}\delta)$ при $\lvert r\rvert>\delta$
Theil–Sen	y = a + b·x; b = median{$(y_j-y_i)/(x_j-x_i)$}, i<j	b = медиана всех попарных наклонов между точками
RANSAC	y = a + b·x; коэффициенты — по максимальному числу inlier-точек	точка — inlier, если |остаток| < ε (порог задаётся)
LOWESS	$\hat{y}(x_0)$ — локальная регрессия в окне вокруг x_0	вес $w_i = (1 - \lvert x_i-x_0\rvert^3/h^3)^3$ (tricube kernel)
Квантильная регрессия	y = a_q + b_q·x; минимизирует Σ $\rho_q(y_i - \hat{y}_i)$	$\rho_q(u) = u\cdot(q - \mathbb{1}[u<0])$; τ = 0.1 / 0.5 / 0.9

Пояснения

- Huber, Theil-Sen, RANSAC — не новые формы кривой, а альтернативные способы оценки коэффициентов той же линейной модели, устойчивые к выбросам. Уравнение по-прежнему y = a + b·x, но a и b посчитаны иначе, чем в обычном МНК (OLS).
- LOWESS — не даёт единого уравнения: локальная модель, результат — кривая (набор предсказаний в каждой точке), а не формула с фиксированными коэффициентами. В реализации используется statsmodels lowess с frac = 0.3; значения в точках x получаются линейной интерполяцией кривой.
- Квантильная регрессия — даёт разные a_q, b_q для τ = 0.1 / 0.5 / 0.9; на графике — веер из трёх линий. Метрики считаются отдельно для каждой τ (compute_quantile_stats, оценка через statsmodels QuantReg): на графике аппроксимаций и в таблице метрик выводятся строки для τ = 0.1, 0.5 и 0.9. Для τ = 0.1 и 0.9 R^2_fit может быть отрицательным — такие кривые оцениваются по Equation и Bias, а не по R^2. В общей таблице аппроксимаций (compute_fit_stats) учитывается только τ = 0.5.

Для степенной и логарифмической аппроксимации область определения ограничена (x > 0, и для степенной также y > 0); значения вне домена не участвуют в подгонке коэффициентов, а при отрисовке кривой заменяются на NaN вместо падения графика.

Метрики кривых аппроксимации (R^2_fit, RMSE, MSE, MAE, Bias, Std, Variance, WAPE %, уравнение) считаются по невязке Predicted − Actual = model(x) − y, то есть между предсказанием модели и фактическим эталонным значением PARAM_1 — отдельно от метрик базового QC-кросс-плота (Residual = y − x, см. выше).

Типы кросс-валидации (от худшего к лучшему)

Метод	Суть (как считается в коде)	Когда применять
Random K-Fold	sklearn.KFold(shuffle=True). Скважины случайно перемешиваются и делятся на k равных частей (k = min(заданное k, n)). По очереди каждая часть — тест, обучение — на остальных k−1 частях.	НЕЛЬЗЯ как основной метод — даёт иллюзию точности (игнорирует пространственную корреляцию). Оставлен в сравнении как заведомо оптимистичная база для контраста с остальными схемами.
Random K-Fold (buffered)	Тот же случайный KFold с тем же сидом, то есть те же тестовые фолды, что и у Random K-Fold. Из обучения удаляются скважины, чьё расстояние до ближайшей тестовой скважины ≤ buffer.	Случайные фолды без утечки соседних скважин. Сравнение с обычным Random K-Fold показывает, насколько тот был завышен.
Leave-One-Well-Out (LOWO)	sklearn.LeaveOneGroupOut по well_id. Поочерёдно вся скважина целиком (все её строки/горизонты) исключается и становится тестом; обучение — на всех остальных скважинах.	Стандарт при малом числе скважин (<20–30).
Block CV	Площадь делится регулярной сеткой grid_n×grid_n по координатам X/Y (линейные границы от min до max). Поочерёдно весь блок — тест, обучение — на скважинах вне блока. Блок пропускается, если в обучении остаётся меньше degree + 2 (3 при линейной модели) точек.	Для равномерной сетки скважин. Размер сетки рекомендуется автоматически по медианному расстоянию между скважинами.
Buffered CV	Как Block CV, но из обучения дополнительно убираются скважины, чьё минимальное расстояние до ближайшей тестовой точки блока ≤ buffer.	Снижает остаточную пространственную корреляцию на границе блока по сравнению с обычным Block CV.

Метод	Суть (как считается в коде)	Когда применять
Leave-P-Out	На каждом из repeats повторов случайно (без возврата) выбирается p_percent% скважин — тест, обучение — на остальных. Итоговый прогноз скважины — среднее по всем повторам, где она попадала в тест (preds_sum/preds_count).	Более жёсткая проверка устойчивости, чем k-fold — оценивает разброс качества при разном случайном составе тестовой выборки.
Spatial Leave-P-Out	На каждом из repeats повторов случайно выбирается скважина-центр; все скважины в радиусе ≤ radius от неё — тест, остальные — train. Прогноз усредняется по повторам так же, как в Leave-P-Out.	Максимально приближено к реальному сценарию прогноза новой необуренной области. Требует достаточного пространственного покрытия площади скважинами.
Stratified by {колонка}	sklearn.LeaveOneGroupOut по выбранной категориальной колонке (любая колонка с хотя бы двумя значениями; по умолчанию tectonic_zone, если её нет — horizon_id; выбирается в сайдбаре). Поочерёдно вся зона целиком — тест, обучение — на скважинах из остальных зон.	Лучший вариант для оценки переносимости модели на новую зону. Требует колонку с ≥2 уникальными значениями, иначе схема пропускается.
Distance-based exclusion CV	Для каждой скважины i по очереди: из обучения исключаются все скважины на расстоянии ≤ excl_radius от неё (excl_radius = медиана попарных расстояний между скважинами × variogram_factor), тест — только скважина i. Если в обучении остаётся меньше degree + 2 точек, фолд отмечается как пропущенный (прогноз NaN).	По сути — LOWO с пространственным буфером вокруг тестовой точки. См. пояснение ниже, как оценивается радиус.

Как устроена Distance-based exclusion CV. Схема не выполняет полноценную подгонку модели вариограммы (nugget/sill/range) — радиус пространственной корреляции оценивается упрощённо, как медианное попарное расстояние между скважинами (median_pairwise_distance), масштабируемое множителем variogram_factor. Для тестовой скважины из обучения исключаются все точки ближе этого радиуса. Переименование в Distance-based exclusion CV точнее отражает, что метод делает на самом деле — это практичная эвристика на расстояниях, а не геостатистическая вариограмма. Радиус исключения можно также задать абсолютным значением в метрах (режим absolute, слайдер в сайдбаре); по умолчанию используется медиана попарных расстояний × variogram_factor.

Автоматический подбор рекомендуемых параметров CV

Реализован в сайдбаре на основе числа скважин (n_wells) и медианного расстояния между ними (median_dist):

- **k для Random K-Fold:** 5 при n<20; 7 при n<50; 10 при n<150; иначе 12.
- **Сетка N×N для Block/Buffered CV:** 5×5 при median_dist<300 м; 4×4 при <600 м; 3×3 при <1000 м; иначе 2×2.
- **Buffer (Buffered CV):** 0.5 × median_dist.
- **Число повторов (cv_repeats) для Leave-P-Out / Spatial Leave-P-Out:** 100 при n<30; 50 при n<100; 30 при n<300; иначе 20.
- **Радиус пространственного исключения (Spatial Leave-P-Out):** ≈ median_dist.
- **Множитель радиуса корреляции (Distance-based exclusion CV factor, variogram_factor в коде):** слайдер 0.25–3.00, шаг 0.25, по умолчанию 1.0; значения: 0.5 — мягкая фильтрация; 1.0 — рекомендуемое значение; 1.5 — строгая; 2.0–3.0 — очень строгая, почти независимые скважины.

Все рекомендованные значения доступны для ручной корректировки через слайдеры в сайдбаре.

Выбор лучшей схемы CV

После расчёта всех схем автоматически определяется схема с наилучшим сочетанием точности и устойчивости:

$score = RMSE + RMSE_fold_std \rightarrow min$

Критерий выбора задаётся в сайдбаре: RMSE + RMSE_fold_std (по умолчанию), RMSE, MAE, максимальный R^2 (Actual = Predicted), RMSE + |Bias| или вручную выбранная схема. Все схемы, включая Random K-Fold, участвуют в выборе.

Схема с минимальным score считается лучшей; для неё повторяется часть Шага 1 (кросс-плот Predicted vs Actual, аппроксимации, распределения выбранных параметров).

Шаг 0 · Загрузка данных

QC входных данных

- Полные дубликаты строк
- Дубликаты well_id (для нескольких горизонтов на одну скважину это ожидаемо; реальное дублирование — только при совпадении well_id и horizon_id)
- Совпадающие координаты скважин (X, Y) в пределах одного горизонта
- Пропуски по колонкам
- Строки, удалённые при очистке (с превью первых 20 строк)

Типы данных по колонкам

- Для каждой колонки: тип (Numeric / Date & Time / Boolean / String), pandas dtype, число непустых/пустых значений, число уникальных значений.
- Отдельно — список уникальных значений для каждой категориальной колонки (до 20 значений с указанием общего числа).

Статистика параметров H_eff или Phi (Параметр 1)

- Полный набор статистик и их формулы — см. раздел «Статистика параметров (Шаг 0)» ниже.

Корреляционный анализ выбранных параметров

- Две матрицы корреляции: Пирсона (только линейная связь) и Спирмена (любая монотонная связь — экспонента, логарифм, степенная). Сначала строятся для всех выбранных сейсмических атрибутов (без H_eff и Phi), затем повторяются отдельно для пар H_eff – атрибуты и Phi – атрибуты.
- Pairplot: Seaborn (статический, с KDE/histogram на диагонали) или Plotly (интерактивный scatter-matrix). Строится так же: сначала по всем выбранным атрибутам, затем отдельно H_eff – атрибуты и Phi – атрибуты.
- Для Pairplot и для блока корреляционного анализа рекомендуется не более 10 параметров (предупреждение в интерфейсе). KDE и гистограммы на диагонали доступны только в Seaborn; Plotly даёт интерактивность и hover, но диагональ в ней не выводится.
- Статистика по каждому числовому параметру (кроме well_id; H_eff и Phi показаны выше): таблица статистик, гистограмма с KDE, средним, медианой и ±3σ, boxplot. Число бинов и тип нормировки гистограммы задаются отдельно для каждого параметра.

Шаг 1 · Базовый QC-кросс-плот (обязательный шаг)

Выбор параметров (начало Шага 1): Параметр 1 (эталонный) — H_eff или Phi; Параметр 2 (сравниваемый) — один из выбранных сейсмических атрибутов. Выбранная пара используется на Шагах 1–4.

Классический QC cross-plot

- Ось X: PARAM_2 (сравниваемое значение).
- Ось Y: PARAM_1 (эталонное значение).
- Диагональ: линия идеального совпадения Y = X.
- Линия линейной регрессии (OLS, степень 1).

Метрики раздела «Метрики кросс-плота и обозначения» выше (R^2_lin, RMSE, MSE, MAE, Bias, Std, Variance, WAPE %, P-value, уравнение регрессии).

Ограничение базовых ошибок Шага 1: Bias, RMSE, MSE, MAE, Std, Variance, WAPE % и невязка Δ = PARAM_1 − PARAM_2 зависят от масштаба и единиц параметров (H_eff в метрах, атрибут — в своих единицах), поэтому их значения сравнимы только внутри одной пары PARAM_1–PARAM_2. Качество связи оценивается по R^2 и коэффициентам корреляции (Пирсона и Спирмена); сравнивать абсолютные значения ошибок между разными атрибутами или разными эталонными параметрами нельзя.

Кросс-плот с кривыми аппроксимации

- На тот же кросс-плот накладываются выбранные пользователем типы аппроксимации (из 17, см. раздел выше).
- Для каждой выбранной кривой — отдельная строка в сравнительной таблице метрик (R^2_fit = sklearn r2_score, см. предупреждение про два R^2 выше).

Распределения H_eff / Phi (PARAM_1) и выбранного атрибута (PARAM_2)

- Гистограммы с KDE, линиями Mean/Median/±3σ (опционально).
- Boxplot с линиями Mean/Median.
- Настраиваемое число бинов и тип нормализации гистограммы (none/density/probability/percent).

Шаг 2 · Кросс-валидация

Запускаются все девять схем CV из раздела «Типы кросс-валидации». Stratified by {колонка} (девятая) использует любую категориальную колонку с хотя бы двумя значениями, которую пользователь выбирает в сайдбаре (по умолчанию tectonic_zone, если её нет — horizon_id). Если подходящей колонки нет, схема пропускается и остаётся восемь схем.

Для каждой схемы CV

- Cross-plot Predicted vs Actual.
- Метрики кросс-плота: R^2 (Pearson, Predicted vs Actual), RMSE, MSE, MAE, Bias, Std, Variance, WAPE %, P-value, уравнение регрессии. R^2 (Actual = Predicted) выводится в сравнительной таблице схем.
- Статистика по фолдам: rmse_fold_mean, median, min, max, std, range.

Сравнение схем

- Сводная таблица всех схем с метриками по фолдам.
- Bar chart RMSE по схемам CV.
- Bar chart среднего RMSE по фолдам (rmse_fold_mean) по схемам CV.
- Boxplot разброса RMSE по фолдам для каждой схемы: медиана — сплошная линия, среднее — пунктир, выбросы — точки. Порядок схем совпадает с таблицей.
- Автоматический выбор лучшей схемы по выбранному критерию (см. раздел «Выбор лучшей схемы CV»).
- Таблицы фолдов для каждой схемы: номер фолда, n_train, n_test, RMSE, MAE, Bias. Пропущенные фолды (n_train < degree + 2) показаны строками с n = 0 и пустыми метриками и не попадают на боксплот.
- Сравнительная таблица схем содержит n_pred (число точек с прогнозом); если схемы покрывают разное число точек, выводится предупреждение.
- При одном горизонте фолды Leave-One-Well-Out и Distance-based exclusion CV содержат по одной точке: R^2 (Pearson) по фолдам для них не определён и на boxplot не выводится.
- Сид случайных схем по умолчанию 42 и меняется кнопками в сайдбаре; влияет на Random K-Fold, Random K-Fold (buffered), Leave-P-Out и Spatial Leave-P-Out.

Детальный разбор лучшей схемы (повтор части Шага 1)

- Cross-plot Predicted vs Actual для лучшей модели + кривые аппроксимации.
- Метрики cross-plot и сравнение аппроксимаций.
- Распределение CV-невязок (Residual = PARAM_1 − Predicted): график от PARAM_1, таблица статистик, гистограмма, boxplot.

- Анализ выбросов CV-невязок четырьмя методами: sigma rule (|Residual| > σ_thr·σ, σ_thr по умолчанию 2.0); IQR rule (за пределами [Q1 − k·IQR, Q3 + k·IQR], k по умолчанию 1.5); modified Z-score rule (|0.6745·(x − median)/MAD| > 3.5); percentile rule (за пределами [P_low, P_high], по умолчанию 5% и 95%).
- Карта невязок CV по координатам скважин (X, Y): цвет точки — CV-невязка Actual − Predicted, категории задаются маркерами, выбранная категория подсвечивается. Карта показывает участки, где модель систематически занижает или завышает значение.

Важно: при исключении скважины из фолда пересчитываются коэффициенты модели; значения PARAM_2 остаются неизменными — фиксированные входные данные, извлечённые один раз (например, извлечённые из сейсмического куба или профилей).

Шаг 3 · Диагностика по категориям

Работает для любой категориальной колонки датасета (не только tectonic_zone) — пользователь выбирает, по какой колонке анализировать.

- Круговая и столбчатая диаграммы количества скважин по категориям.
- Статистика PARAM_1 и PARAM_2 по каждой категории (в раскрывающихся блоках).
- Boxplot распределения PARAM_1 и PARAM_2 по категориям.
- Наложенные гистограммы по категориям для PARAM_1 и PARAM_2: каждая категория — своим цветом, полупрозрачно.
- Общий кросс-плот по всем категориям сразу (с индивидуальными цветами точек/линий на категорию) + отдельно по выбранному подмножеству категорий.
- Кросс-плот и аппроксимации отдельно для каждой категории.
- Сравнительная таблица метрик аппроксимаций по категориям.

Шаг 4 · Фильтрация скважин

Реализовано (не только запланировано). Четыре режима:

- Без фильтра.
- Ручное исключение: мультиселект конкретных well_id.
- Случайное исключение (%): слайдер 0–95%, кнопка «Новый набор» для пересэмплирования (фиксированный seed сохраняется в session_state до нажатия кнопки).
- Выделение кликом по точкам на cross-plot: клик по точке (Shift+клик — несколько), рамка (Box) или лассо (Lasso); режимы переключаются иконками в правом верхнем углу графика. Выбранные точки фиксируются кнопкой «Применить исключение», «Сбросить всё» очищает выбор. В сводке показывается строка «Исключено кликом».

После фильтрации пересчитываются: QC cross-plot, аппроксимации, полная таблица метрик, сравнение «до / после фильтрации» (n скважин, R^2_lin и R^2_fit для выбранных кривых, RMSE, MSE, MAE, Bias, Std, Variance, WAPE %, P-value).

Шаг 4.5 — серия случайного исключения: уровни от 5% до 95% с шагом 5%, на каждом уровне — заданное в сайдбаре число наборов (50–2000, по умолчанию 500). Для каждого набора считается R^2 (Pearson): in-sample — по оставшимся скважинам и out-of-sample — линия по оставшимся, R^2 по исключённым. Показываются распределения обоих значений по уровням.

Это позволяет оценивать устойчивость модели к сокращению числа скважин и влияние отдельных наблюдений/их групп на качество зависимости.

Шаг 5 · Многоатрибутная регрессия

Финальный этап: модель строится отдельно для H_eff и отдельно для Phi. На вход подаётся набор сейсмических атрибутов, линейная множественная регрессия (Parameter = b0 + Σ bi · attribute_i) подбирает коэффициенты. Цель — прогноз, который по out-of-fold метрике лучше одноатрибутного.

- Перебор комбинаций — полный (exhaustive), а не пошаговый: рассматриваются все комбинации от 1 до k_max атрибутов из кандидатов, после исключения пар с сильной коллинеарностью (см. ниже).

Отбор — по cross-validation, а не по тренировочному R^2: тренировочный R^2 растёт при добавлении любого атрибута.

- Максимум атрибутов в модели вычисляется из данных: k_max = min(3, число атрибутов-кандидатов, max(1, ⌊N / 5⌋)), где N — число скважин выбранного горизонта. Например, при 10 скважинах k_max = 2, при 15 — 3, при 5 — 1 (верхний предел 3).
- Контроль коллинеарности: пары атрибутов с |r| > 0.8 не добавляются в одну модель.

Кросс-валидация — две схемы, обе по скважинам (скважина целиком либо в обучении, либо в тесте):

- Leave-One-Well-Out (LOWO): N фолдов, в каждом тесте одна скважина.
- K-fold по скважинам с фиксированным сидом: K = max(3, round(N / 10)) фолдов, около 10 скважин в фолде.
- Критерий выбора: RMSE_cv (out-of-fold), меньше — лучше. Для каждой схемы CV и каждого параметра выводится топ-5 моделей по RMSE_cv.
- Критерий принятия: многоатрибутная модель принимается, только если её RMSE_cv меньше RMSE_cv лучшей одноатрибутной модели в той же схеме CV; иначе остаётся одноатрибутная модель.
- Ограничение предсказаний: H_eff снизу ограничивается нулём; Phi ограничивается границами 0–1 (при выборе «%» в интерфейсе — 0–100%). Число ограниченных точек фиксируется в отчёте.
- Структура результатов Шага 5: сначала раздел H_eff, затем раздел Phi. Внутри каждого раздела: (1) Одноатрибутные модели — базовый уровень для сравнения In-sample (RMSE_in, R^2_in): регрессия параметра на одном атрибуте по всем скважинам, где есть оба значения; уравнение и метрики относятся к этой регрессии, r совпадает с корреляцией Пирсона из матрицы корреляции (Шаг 0); одна таблица для обеих схем CV. (2) Одноатрибутные модели — базовый уровень для сравнения Out-of-sample (RMSE_cv, R^2_cv): отдельно для LOWO и для K-fold по скважинам; метрики и уравнение Predicted = a + b·Actual получены по одним и тем же out-of-fold предсказаниям. (3) Топ-5 многоатрибутных моделей In-sample (RMSE_in, R^2_in): регрессия на наборе атрибутов по всем скважинам выбранной схемы; коэффициенты — в уравнении. (4) Топ-5 многоатрибутных моделей Out-of-sample (RMSE_cv, R^2_cv): те же модели; метрики и уравнение Predicted = a + b·Actual по out-of-fold предсказаниям. Колонки: Параметр, Ранг, Атрибуты, k, n (число скважин в модели), метрики, Equation. Intercept, коэффициенты и стандартизованные коэффициенты — в раскрывающемся блоке под таблицей (относятся к in-sample регрессии). Графики: сначала вклад атрибутов лучшей многоатрибутной модели Out-of-sample; затем строка из двух графиков для лучшего одноатрибутного (In-sample слева, Out-of-sample справа) и строка для лучшего многоатрибутного набора (In-sample слева, Out-of-sample справа); под каждым графиком — уравнение. Критерий выбора — RMSE_cv; многоатрибутная модель принимается, только если она лучше лучшей одноатрибутной в той же схеме CV. In-sample R^2 для выбора не используется. Модели не сохраняются. Все таблицы и коэффициенты выгружаются в Excel кнопкой под каждой таблицей.

Проблема переобучения — специфика атрибутного анализа:

- чем больше атрибутов перебирается, тем выше шанс найти «хороший» тренировочный R^2 чисто случайно;
- эмпирическое правило: число атрибутов ограничено формулой k_max выше (не более N / 5 и не более 3);
- многоатрибутная регрессия (multi-attribute transform, как в Hampson–Russell Emerge) почти всегда даёт растущий тренировочный R^2 при добавлении атрибутов — это признак переобучения, а не улучшения модели; полезность атрибута оценивается только по CV-метрике (RMSE_cv), не по тренировочной;
- проверка коллинеарности между атрибутами (попарные корреляции, |r| > 0.8 не добавляются вместе): сильно скоррелированные между собой атрибуты искусственно завышают тренировочный R^2, не добавляя реальной информации;
- физическая осмысленность атрибута обязательна: атрибут должен иметь объяснимую физическую связь со свойством пласта (акустический импеданс, AVO-эффект, спектральная декомпозиция для тонких пластов и т.п.), а не только статистическую корреляцию — «слепой» перебор атрибутов без физического обоснования — основной источник ложных трансформов.

Ограничения:

- Данные синтетические. H_eff и Phi смоделированы, атрибуты не снимались с сейсмического куба. Поэтому результаты кросс-плота отражают заложенную структуру, а не реальную геологию.
- Sweetness и envelope рассчитаны по формуле, поэтому их корреляции с другими атрибутами получились следствием формулы, а не заданы отдельно.

Важные нюансы для сейсмики

Пространственная зависимость

- Если скважины кластеризованы (например, куст на одной структуре), обычный LOWO даёт слишком оптимистичную оценку — соседняя скважина «утекает» информацию.
- Лучше — Block/Buffered/Spatial CV: исключать не одну скважину, а группу скважин в радиусе корреляции (аналог GroupKFold по пространственным кластерам).

Размер выборки

- Скважин мало (<15–20): LOWO практически безальтернативен.
- Скважин больше 30–50: можно k-fold (5–10 фолдов), но желательно с равномерным пространственным покрытием в каждом фолде, иначе один фолд может остаться без скважин на краю площади (для этого в проекте есть Block/Buffered CV).

Важно: разбивать по скважинам, а не по отдельным точкам одной скважины — иначе модель «подглядывает» в соседние точки того же профиля/куста.

Известные ограничения и статус реализации

- R^2_lin и R^2_fit — два разных по смыслу R^2 в разных частях таблиц метрик, разведены по названию — см. предупреждение в разделе «Метрики кросс-плота и обозначения».
- Distance-based exclusion CV (ранее Variogram-Aware CV) — упрощённая эвристика на расстояниях, не полноценная geostatistics-вариограмма — см. пояснение в разделе «Типы кросс-валидации».
- Известная проблема (решение: оставить как есть): Random K-Fold участвует в автоматическом выборе лучшей схемы по score = RMSE + RMSE_fold_std. Оптимистичная схема может быть выбрана «лучшей»; в текущей версии этот выбор не исключает её.
- Ранее известная проблема (решено): при режиме «Все горизонты» Random K-Fold, Random K-Fold (buffered), Leave-P-Out и Spatial Leave-P-Out разбивают записи «скважина — горизонт», а не скважины, поэтому одна скважина может попасть одновременно в обучение и в тест. Решение: мультиселект горизонтов в сайдбаре сохранён (задел на будущее). Для строгой оценки рекомендуется один горизонт. При нескольких горизонтах Random K-Fold, Random K-Fold (buffered), LOWO и Leave-P-Out разбивают скважины целиком (по well_id), поэтому одна скважина не попадает одновременно в обучение и тест. Для Stratified by {колонка} зона должна быть постоянной для скважины.
- Ранее известная ошибка (решено): при случайном исключении процент считается от числа строк (скважина × горизонт), а исключаются скважины; при нескольких горизонтах может быть запрошено больше скважин, чем есть, и расчёт завершится ошибкой. Решение: процент считается от числа уникальных скважин, а исключение выполняется по well_id целиком.
- Ограничение по данным (учитывается в расчёте): нулевые значения H_eff (нет коллектора) не входят в степенную и экспоненциальную аппроксимации ($y > 0$); отрицательные значения avo_intercept и avo_gradient не входят в степенную и логарифмическую ($x > 0$). В демо-файле 97 из 200 значений H_eff равны нулю.
- Исправлено: степенная и логарифмическая аппроксимации могли давать NaN/падать при отрисовке кривой на участке $x \leq 0$ — добавлено ограничение домена (x_line_safe) в коде отрисовки (app_utils).
- Добавлено кэширование (@st.cache_data) для attribute_qc_full.run_all_cv — кросс-валидация (включая Leave-P-Out/Spatial Leave-P-Out с десятками повторов) больше не пересчитывается при каждом взаимодействии с сайдбаром (например, смене цвета точек), а только при изменении данных или параметров CV.

- Реализован двуязычный интерфейс RU/EN (переключатель Language в сайдбаре; тексты в translations_full, примеры в ui_examples_full_ru и ui_examples_full_en). Планируется: разбиение app_full.py (~4900 строк) на модули (sidebar / step1–step4 / plotting).

Практическая схема пайплайна

- Сбор данных: well_id, X, Y, PARAM_1, PARAM_2, horizon_id, tectonic_zone (опционально).
- Базовый анализ: глобальные RMSE/MAE/Bias, общий cross-plot (Шаг 0–1).
- K-fold CV по скважинам: разбить на k фолдов, перестроить модель без тестового фолда, посчитать ошибки, свести в таблицу.
- LOWO / Block / Buffered / Spatial Leave-P-Out / Distance-based exclusion / Stratified by {колонка} CV — полный набор схем для оценки устойчивости (Шаг 2).
- Диагностика по категориям — выявление зон систематических ошибок (Шаг 3).
- Фильтрация и стресс-тест выборки — оценка устойчивости к сокращению числа скважин (Шаг 4).
- Интерпретация: сравнить ошибки разных схем CV, выделить зоны и горизонты систематических ошибок; для H_eff и Phi выбрать набор атрибутов из топ-5 по RMSE_cv (LOWO и K-fold) и сравнить его с одноатрибутной моделью (Шаг 5).