Language

RU

Данные

Выбрать демонстрационный файл

attribute_wells_100.csv

Сопоставление колонок DEMO-файла

DEMO: well_id

well_id

DEMO: X

X

DEMO: Y

Y

DEMO: Колонка H_eff

H_eff

DEMO: Колонка Phi

Phi

DEMO: Единицы H_eff

m

DEMO: Единицы Phi

fractions

DEMO: horizon_id

horizon_id

DEMO: tectonic_zone

tectonic_zone

Загрузить CSV/XLSX

Drag and drop file here

Limit 200MB per file • CSV, XLS, XLSX

Browse files

Содержание

- Загрузка данных
  - Первичный обзор данных
  - Параметры пласта: Нэф и Кп
  - Категориальные признаки
  - Анализ выбранных параметров
- Шаг 1 · QC-анализ зависимости между параметрами
  - QC кросс-плот
  - Распределение параметров
- Шаг 2 · Кросс-валидация
  - Выбор лучшей CV
  - QC кросс-плот лучшей CV
  - Невязки CV
  - Анализ выбросов невязок CV
- Шаг 3 · Анализ параметров по категориям
  - Распределение параметров по категориям
  - QC кросс-плот по категориям
- Шаг 4 · Фильтрация скважин на кросс-плоте
- Шаг 5 · Многоатрибутная регрессия
  - H_eff
    - Out-of-sample: Leave-One-Well-Out
    - Out-of-sample: K-fold по скважинам
  - Phi
    - Out-of-sample: Leave-One-Well-Out
    - Out-of-sample: K-fold по скважинам

Выбор горизонта

Все горизонты

Горизонты

Top_Reservoir ×

Выбрано горизонтов: 1 из 2

Круговая диаграмма

Палетка для диаграммы категорий

Plotly

Прозрачность

1.00

0.10 1.00

Граница секторов

Толщина линии

0

0 5

black

Столбчатая диаграмма

Что считать на столбцах

Количество скважин

Загрузка данных: категориальные признаки

Палетка для Bar chart по категориям

Plotly

Направление

Вертикальное Горизонтальное

Граница столбцов

Толщина линии

0

0 5

black

Прозрачность

1.00

0.10 1.00

Шаг 2: RMSE по фолдам

Палетка для Bar chart RMSE для CV

Plotly

Направление

Вертикальное | Горизонтальное

Граница столбцов

Толщина линии

0

0 — 5

black

Прозрачность

1.00

0.10 — 1.00

Шаг 2: RMSE по схемам CV

Палетка для Bar chart RMSE для CV

Plotly

Направление

Вертикальное | Горизонтальное

Граница столбцов

Толщина линии

0

0 — 5

black

Прозрачность

1.00

Что считать на столбцах

Количество скважин

Шаг 3: количество скважин по категориям

Палетка для Bar chart по категориям

Plotly

Направление

Вертикальное | Горизонтальное

Граница столбцов

Толщина линии

0

0 — 5

black

Прозрачность

1.00

0.10 — 1.00

Шаг 5: вклад атрибутов

Палетка для Bar chart по категориям

Plotly

Направление

Вертикальное | Горизонтальное

Граница столбцов

Толщина линии

0

0 — 5

black

Прозрачность

1.00

0.10 — 1.00

Круговые диаграммы по нескольким категориям

Палетка для Bar chart по категориям

Plotly

Прозрачность

1.00

0.10 — 1.00

Граница секторов

Толщина линии

0

0 — 5

black

Столбчатая диаграмма по нескольким категориям

Палетка для Bar chart по категориям

Plotly

Что считать на столбцах

Количество скважин

Направление

Вертикальное | Горизонтальное

Прозрачность

1.00

0.10 — 1.00

Граница столбцов

Толщина линии

0

0 — 5

black

Матрица корреляции и Pairplot

Палитра матрицы корреляции

RdBu

Цвет точек Pairplot

steelblue

Размер точек Pairplot

5

2 — 20

Прозрачность точек Pairplot

0.70

0.10 — 1.00

Категория для цвета точек (опционально)

tectonic_zone

Цвета категорий (Pairplot)

Central_Graben

black

North_Block

blue

South_Block

brown

Тип Pairplot

Plotly Pairplot (interactive)

Гистограмма

Цвет заливки гистограмм

orange

Прозрачность гистограммы

0.85

0.10 1.00

Обводка столбцов

Включить обводку

black

Толщина линии

1

0 5

Кривая KDE

black

solid

Толщина линии

3

1 10

Линия среднего значения (Mean)

green

dash

Толщина линии

2

1 10

Линия медианы (Median)

red

dot

Толщина линии

2

1 10

Линии ±σ

orange

dash

Толщина линии

2

1 10

Множитель σ

3

1 3

Boxplot

Цвет заливки boxplot

royalblue

Прозрачность бокспота

0.60

0.10 1.00

Направление

Вертикальное Горизонтальное

Контур бокспота

Толщина линии

2

0 6

royalblue

Линия среднего значения Mean на boxplot

green

dash

Толщина линии

2

1 10

Линия медианы Median на boxplot

red

dot

Толщина линии

2

1 10

Кросс-плот

Точки на основных cross-plot

black

Размер точек

7

3 — 20

Прозрачность точек

0.80

0.10 — 1.00

Точки на графиках аппроксимаций

brown

Размер точек аппроксимации

7

3 — 20

Прозрачность точек аппроксимации

0.80

0.10 — 1.00

Линия регрессии для кросс-плота

Линия регрессии для QC и CV

orange

Толщина линии регрессии

3

1 — 8

Тип линии регрессии

solid

Линия Y = X для cross-plot

Линия Y = X

lightgray

Толщина линии Y = X

3

1 — 8

Тип линии Y = X

dash

Карта невязок

Палетка для карты невязок Δ

RdBu

Размер точек карты

12

3 — 30

Прозрачность точек карты

0.90

0.10 — 1.00

Категория на карте

tectonic_zone

Подсветить значение

Без подсветки

Яркость подсвеченной категории

1.00

0.10 — 1.00

Яркость остальных точек

0.15

0.05 — 1.00

График невязок

Цвет точек на графике невязок

black

Размер точек

8

3 — 20

Прозрачность точек

0.85

0.10 — 1.00

Корреляционный анализ

Порог КК (|КК| ≥)

0.70

0.00 — 1.00

Порог КК (|КК| ≤)

0.50

0.00 — 1.00

Типы аппроксимации

Выбор типов

Типы аппроксимации (Шаг 1 и Шаг 4)

Все линии аппроксимации (Шаг 1 и Шаг 4)

Типы аппроксимации (Шаг 1 и Шаг 4)

Linear × Cubic ×

Типы аппроксимаций для графиков кросс-валидации (Шаг 2)

Все линии аппроксимации (Шаг 2)

Типы аппроксимаций для графиков кросс-валидации (Шаг 2)

Linear × Quadratic ×

Типы аппроксимаций по категориям (Шаг 3)

Все линии аппроксимации (Шаг 3)

Типы аппроксимаций по категориям (Шаг 3)

Linear × Power Law ×

Цвета линий аппроксимаций

Linear

orange

solid

Толщина линии

3

1 10

Quadratic

green

solid

Толщина линии

3

1 10

Cubic

purple

solid

Толщина линии

3

1 10

Polynomial Degree 4

darkgreen

solid

Толщина линии

3

1 10

Polynomial Degree 5

darkred

solid

Толщина линии

3

1 10

Polynomial Degree 6

black

solid

Толщина линии

3

1 10

Polynomial Degree 7

blue

solid

Толщина линии

3

1 10

Polynomial Degree 8

brown

solid

Толщина линии

3

1 10

Polynomial Degree 9

cadetblue

solid

Толщина линии

3

1 10

Polynomial Degree 10

coral

solid

Толщина линии

3

1 10

Power Law

magenta

solid

Толщина линии

3

Exponential

red

solid

Толщина линии

3

1 10

Logarithmic

brown

solid

Толщина линии

3

1 10

Robust (Huber)

black

solid

Толщина линии

3

1 10

Theil-Sen

darkcyan

solid

Толщина линии

3

1 10

RANSAC

darkmagenta

solid

Толщина линии

3

1 10

LOWESS

cyan

solid

Толщина линии

3

1 10

Quantile Regression (τ = 0.1 / 0.5 / 0.9)

τ=0.1

darkred

solid

Толщина линии

3

1 10

τ=0.5

black

solid

Толщина линии

3

1 10

τ=0.9

darkgreen

solid

Толщина линии

3

1 10

Анализ выбросов по невязкам (Шаг 2)

Порог выбросов по правилу σ

2.00

1.00 6.00

Множитель IQR (правило IQR)

1.50

1.00 3.00

Нижний перцентиль (правило перцентилей), %

5.00

0.00 20.00

Верхний перцентиль (правило перцентилей), %

95.00

80.00 100.00

Параметры валидации (Шаг 2)

Random seed: Random K-Fold, Random K-Fold (buffered), Leave-P-Out, Spatial Leave-P-Out (Шаг 2)

Текущий seed: 42

Новый seed

Сбросить seed

Случайное разбиение заданного seed. Влияет только на Random K-Fold, Leave-P-Out и Spatial Leave-P-Out. Остальные схемы CV детерминированы и от seed не зависят.

Random K-Fold / Random K-Fold (buffered)

Рекомендуемое k: 10 (скважин: 100)

k влияет на стабильность и достоверность оценки модели.

k для Random K-Fold

10

3 20

Block / Buffered Cross Validation

Рекомендуемая сетка: 2×2 (медианное расстояние между скважинами: 5677 м)

Сетка должна соответствовать плотности скважин.

Сетка для Block CV (N×N)

2

2 10

Buffered Cross Validation / Random K-Fold (buffered)

Рекомендуемый buffer: 2838 м (основано на медианном расстоянии между скважинами)

Buffer исключает точки рядом с тестовым блоком, снижая пространственную зависимость между обучением и тестом. Координаты X_coord и Y_coord — в метрах.

Буферная зона Buffer zone (м)

2838

64 11353

Leave-P-Out / Spatial Leave-P-Out

Рекомендуемое количество повторов: 30

Число повторов CV

30

5 200

Используется для Leave-P-Out и Spatial Leave-P-Out. Метрики усредняются по нескольким случайным разбиениям.

Leave-P-Out

Leave-P-Out test size (%)

10

1 50

На каждом повторе случайно исключается P% скважин для проверки модели.

Spatial Leave-P-Out

Рекомендуемый радиус пространственного исключения: 5676 м

Скважины внутри радиуса вокруг тестовой точки исключаются из обучения. Координаты X_coord и Y_coord — в метрах.

Радиус пространственного исключения Spatial exclusion radius (м)

5676

64 14067

Колонка для Stratified by Zone (CV)

Колонка для Stratified by Zone (CV)

tectonic_zone

Distance-based exclusion CV

Способ задания радиуса исключения

- Множитель медианного межскважинного расстояния
- Абсолютный радиус (м)

Множитель медианного межскважинного расстояния (Distance-based exclusion CV)

1.00

0.25 3.00

0.5 — мягкая пространственная фильтрация

1.0 — рекомендуемое значение

1.5 — строгая пространственная фильтрация

2.0–3.0 — очень строгая проверка, почти независимые скважины

Анализ по категориям (Шаг 3)

Категориальный параметр

tectonic_zone

Размер точек

7

3 20

Прозрачность точек

0.80

0.10 1.00

Central_Graben (38 скв.)

Цвет точек

black

Цвет линии

black

North_Block (36 скв.)

Цвет точек

blue

Цвет линии

blue

South_Block (26 скв.)

Цвет точек

brown

Цвет линии

brown

Фильтрация скважин (Шаг 4)

Режим фильтрации

- Без фильтра
- Ручное исключение
- Случайное исключение (%)
- Выделение кликом по точке

Текущий режим: Без фильтра

Новый seed

Сбросить seed

Текущий набор: 42

Число наборов на уровень

500

50 2000

Attribute QC — cross-plot & cross-validation

CROSSPL✳T↔CROSS⊗VALIDATION

Данные обрабатываются в памяти сессии и не записываются на диск приложения.

© А.С.Поздняков 2026

📖 О проекте и логика работы

В геологии и сейсморазведке регулярно возникает задача оценки связи между эталонными свойствами пласта, измеренными в скважинах, и сейсмическими атрибутами, снятыми в тех же точках. От того, насколько атрибут надёжно предсказывает свойство пласта, зависит, можно ли использовать его как прокси на участках без скважин. Проект построен на методологии кросс-плота, набора аппроксимаций и кросс-валидации. Этот аппарат не привязан к конкретной паре параметров и одинаково применим к оценке связи между любыми двумя количественными величинами.

▶️ **С чего начать:** загрузите свой CSV/XLSX в сайдбаре слева или выберите готовый пример из выпадающего списка «Выбрать демонстрационный файл». Ничего готовить заранее не нужно. Дальше всё устроено по шагам, они описаны ниже.

Attribute QC_CV — cross-plot & cross-validation сравнивает два числовых ряда в одних и тех же точках (скважинах): эталонный параметр `PARAM_1` (H_eff или Phi) и сравниваемый `PARAM_2` (сейсмический атрибут, который вы выбираете сами из колонок файла) — и проверяет, насколько один можно предсказать по другому.

Примеры сочетаний, которые можно анализировать:

Сценарий	Пример PARAM_1 / PARAM_2
скважина ↔ атрибут	H_eff / rms_amplitude, Phi / acoustic_impedance
атрибут ↔ атрибут	rms_amplitude / sweetness (проверка мультиколлинеарности)

Все шаги и формулы одинаково применимы к любой паре PARAM_1 / PARAM_2. Ниже для наглядности используются H_eff и rms_amplitude.

Как это устроено, по шагам

Шаг 0 · Загрузка данных. Импорт CSV/XLSX, сопоставление колонок (координаты X и Y, H_eff, Phi, горизонт, зона и другие опциональные колонки), единицы измерения (по умолчанию для H_eff — метры, для Phi — доли), автоматическая очистка (пропуски, дубли, мусорные значения, типы данных). Далее — статистика H_eff и Phi и корреляционный анализ трёх групп параметров: все сейсмические атрибуты; атрибуты и H_eff; атрибуты и Phi. В каждой группе — матрицы Пирсона и Спирмена, таблица пар с коэффициентом корреляции не ниже порога (по умолчанию 0.7), pairplot. Состав атрибутов в каждом блоке выбирается мультиселектом. Для Pairplot рекомендуется не более 10 параметров. Ниже — описательная статистика, гистограммы и боксплоты по каждой числовой колонке. Большинство таблиц можно скачать в Excel.

Шаг 1 · Выбор параметров и базовый QC-кросс-плот. В начале шага выбираются PARAM_1 (H_eff или Phi), PARAM_2 (сейсмический атрибут) и единица измерения PARAM_2. Выбранная пара используется на шагах 1–4. Далее — кросс-плот PARAM_1 (ось Y) против PARAM_2 (ось X): диагональ Y = X, линейная регрессия, набор кривых аппроксимации на выбор, полный набор метрик качества и распределения обоих параметров. Во всех шагах моделью является линейная регрессия (полином степени 1). Базовые ошибки этого шага (Bias, RMSE, MAE и др.) зависят от масштаба и единиц параметров, поэтому сравнивать их можно только внутри одной пары PARAM_1–PARAM_2. Качество связи оценивайте по R^2 и коэффициентам корреляции. Метрики этого шага — in-sample: модель подбирается и проверяется на всех скважинах выбранной пары.

Шаг 2 · Кросс-валидация. Та же линейная модель (степень 1), но честно проверенная: обучаем на части скважин, предсказываем на оставшихся, повторяем по разным схемам разбиения, чтобы увидеть реальную, а не «подогнанную» точность. Всего девять схем. Девятая — Stratified by {колонка}: она использует любую категориальную колонку с хотя бы двумя значениями (по умолчанию tectonic_zone, если её нет — horizon_id), колонка выбирается в сайдбаре. Если подходящей колонки нет, схема пропускается и остаётся восемь. Лучшая схема выбирается автоматически по критерию, который задаётся в сайдбаре: RMSE + RMSE_fold_std (по умолчанию), RMSE, MAE, максимальный R^2 (Actual = Predicted), RMSE + |Bias| или ручной выбор. В выборе участвуют все схемы, включая Random K-Fold и Random K-Fold (buffered). Разброс RMSE по фолдам показан столбчатыми диаграммами и боксплотом для каждой схемы, полные данные по фолдам — отдельными таблицами: номер фолда, n_train, n_test, RMSE, MAE и Bias. На этом шаге же анализируются выбросы CV-невязок (Actual − Predicted) четырьмя правилами. Карта невязок CV показывает невязки по координатам скважин: цвет точки — значение Actual − Predicted, категории задаются маркерами, выбранная категория подсвечивается. По карте видно, на каких участках модель систематически занижает или завышает значение. Результаты воспроизводимы: сид случайных операций по умолчанию 42 и меняется кнопками в сайдбаре; он влияет на Random K-Fold, Random K-Fold (buffered), Leave-P-Out и Spatial Leave-P-Out. Если для фолда в обучении остаётся меньше degree + 2 точек, он отмечается в таблице фолдов как пропущенный: в колонке Fold указаны причина и число обучающих точек, n = 0, метрики пусты, на боксплоте

такой фолд не отображается. В таблице сравнения схем указано число точек с прогнозом (n_pred); если схемы покрывают разное число точек, приложение выводит предупреждение. При одном горизонте фолды Leave-One-Well-Out и Distance-based exclusion CV содержат по одной точке, поэтому R^2 (Pearson) по фолдам для них не определён и на boxplot R^2 не выводится. Метрики этого шага — out-of-sample: каждая скважина предсказана моделью, которая её при подборе не видела.

Шаг 3 · Анализ по категориям. Та же пара параметров, но отдельно по горизонтам, тектоническим зонам, типу коллектора, типу флюида, категории скважины или любой другой категориальной колонке. Позволяет увидеть, не «едет» ли точность в конкретной зоне или горизонте. Для каждой категории есть таблица статистики. Общий боксплот и наложенные гистограммы показывают все категории вместе: на одной сетке бинов и с общими настройками нормировки и прозрачности. Метрики по категориям — in-sample внутри каждой категории.

Шаг 4 · Фильтрация скважин. Ручное исключение конкретных скважин, случайное исключение заданного процента скважин (0–95%, с пересэмплированием) или выделение скважин кликом на кросс-плоте. Цель — проверить, насколько результат устойчив к сокращению числа скважин и к отдельным наблюдениям. При заданном сиде случайный набор воспроизводим, а кнопка формирует следующий. Блок 4.5 повторяет случайное исключение на уровнях от 5% до 95% с шагом 5%, по 50–2000 наборов на уровень (по умолчанию 500, задаётся в сайдбаре). Для каждого набора считается R^2 (Pearson) in-sample — по оставшимся скважинам и out-of-sample — линия по оставшимся, R^2 по исключённым, показываются распределения обоих значений. Метрики до и после фильтрации — in-sample на отфильтрованной выборке; блок 4.5 показывает и in-sample, и out-of-sample значения.

Выделение кликом: одна точка за клик, несколько через Shift+клик, либо рамка (Box) или лассо (Lasso). Переключение режимов — иконками в правом верхнем углу графика.

Шаг 5 · Многоатрибутная регрессия. Финальный этап: отдельно для H_eff и отдельно для Phi, на нескольких сейсмических атрибутах. Сначала раздел H_eff, затем раздел Phi. Внутри каждого раздела:

- **Одноатрибутные модели — базовый уровень для сравнения In-sample (RMSE_in, R^2_in).** Регрессия параметра на одном атрибуте по всем скважинам, где есть оба значения. Уравнение и метрики относятся к этой регрессии; r совпадает с корреляцией Пирсона из матрицы (Шаг 0). Одна таблица для обеих схем CV.
- **Одноатрибутные модели — базовый уровень для сравнения Out-of-sample (RMSE_cv, R^2_cv).** Отдельно для LOWO и для K-fold по скважинам. Метрики и уравнение Predicted = a + b·Actual получены по одним и тем же out-of-fold предсказаниям.
- **Топ-5 многоатрибутных моделей In-sample (RMSE_in, R^2_in).** Регрессия на наборе атрибутов по всем скважинам; коэффициенты — в уравнении.
- **Топ-5 многоатрибутных моделей Out-of-sample (RMSE_cv, R^2_cv).** Те же модели; метрики и уравнение Predicted = a + b·Actual по out-of-fold предсказаниям.

Критерий выбора — RMSE_cv; многоатрибутная модель принимается, только если она лучше лучшей одноатрибутной в той же схеме. Коэффициенты (intercept, коэффициенты, стандартизованные) — в раскрывающемся блоке под таблицей. Графики: вклад атрибутов лучшей многоатрибутной модели; затем строка из двух графиков для лучшего одноатрибутного (In-sample | Out-of-sample) и строка для лучшего многоатрибутного набора (In-sample | Out-of-sample). Все таблицы выгружаются в Excel кнопкой под каждой таблицей.

Дальше — подробный справочник (зачем нужна кросс-валидация, все схемы CV, все кривые аппроксимации, все метрики с формулами). Для первого знакомства достаточно прочитать до этого места.

Зачем вообще кросс-валидация, а не просто регрессия

Если построить регрессию по всем скважинам и посчитать R^2 и RMSE на них же, результат будет обманчиво хорошим: модель «видела» все точки при обучении. Кросс-валидация исключает часть скважин из обучения и проверяет предсказание именно на них. Схемы ниже отличаются тем, **как именно** выбираются исключаемые скважины. Это особенно важно для пространственных данных: соседние скважины похожи друг на друга, и случайное разбиение это игнорирует.

Типы кросс-валидации (от самой оптимистичной к самой честной)

Метод	Суть	Когда применять	Пример (100 скважин)
Random K-Fold	`sklearn.KFold(shuffle=True)`: скважины случайно перемешиваются и делятся на k равных частей (если заданное k превышает число скважин n, оно автоматически уменьшается до n); каждая часть по очереди становится тестом, обучение — на остальных	⚠️ Не для пространственных данных: даёт завышенную точность	5 фолдов по ~20 скважин: в каждом обучение на ~80 скважинах, n_test ≈ 20, n_train ≈ 80. Соседние скважины регулярно оказываются одновременно в обучении и тесте
Random K-Fold (buffered)	Тот же случайный KFold с тем же сидом, то есть те же тестовые фолды. Перед обучением из обучающей выборки удаляются скважины, чьё расстояние до ближайшей тестовой скважины ≤ buffer	Случайные фолды без утечки соседних скважин; сравнение с обычным Random K-Fold показывает, насколько тот был завышен	То же разбиение 20/80: n_test совпадает с Random K-Fold, n_train ≈ 80, если соседи дальше buffer. При плотной сети n_train может упасть до 40–60, это видно в колонке n_train
Leave-One-Well-Out (LOWO)	`LeaveOneGroupOut` по `well_id`: поочерёдно вся скважина целиком (все её строки по горизонтам) исключается из обучения и становится единственным тестом	Стандарт при малом числе скважин (<20–30)	100 фолдов по одной скважине: n_test = 1, n_train = 99
Block CV	Площадь делится регулярной сеткой grid_n×grid_n по координатам X и Y; весь блок по очереди становится тестом, обучение — на скважинах вне блока (блок пропускается, если для обучения остаётся меньше degree + 2 точек, то есть меньше 3 при линейной модели)	Равномерная сетка скважин	Сетка 3×3 даёт до 9 блоков, примерно по 11 скважин в каждом: n_test ≈ 11, n_train ≈ 89

Метод	Суть	Когда применять	Пример (100 скважин)
Buffered CV	Как Block CV, но из обучения дополнительно убираются скважины, чьё минимальное расстояние до ближайшей тестовой точки блока ≤ buffer	Снижает утечку через границу блока	Та же сетка 3×3: n_test ≈ 11, n_train меньше 89 на число скважин, попавших в буфер вокруг блока
Leave-P-Out	На каждом из repeats повторов случайно (без возврата) выбирается p_percent% скважин — тест, обучение — на остальных. Итоговый прогноз скважины — среднее по всем повторам, где она попадала в тест; скважины, которые ни разу не попали в тест, остаются без прогноза (NaN)	Оценка разброса устойчивости при разном случайном составе теста	50 повторов по 10 случайным скважинам в тесте: n_test = 10, n_train = 90. Скважины, которые ни разу не попали в тест, без прогноза, поэтому n_pred < 100
Spatial Leave-P-Out	На каждом из repeats повторов случайно выбирается скважина-центр; все скважины в радиусе ≤ radius от неё — тест, остальные — обучение. Прогноз усредняется по повторам так же, как в Leave-P-Out	Ближе всего к реальному прогнозу новой, необуренной площади	Центр — случайная скважина, радиус 1000 м: в тест попадают все скважины внутри круга, их число меняется от повтора к повтору
Stratified by {колонка}	`LeaveOneGroupOut` по выбранной категориальной колонке (любая колонка с хотя бы двумя значениями; по умолчанию tectonic_zone, если её нет — horizon_id). Поочерёдно вся категория целиком становится тестом, обучение — на остальных	Проверка, переносится ли модель на новую зону или горизонт	4 тектонические зоны дают 4 фолда: n_test — число скважин в зоне, n_train — все остальные
Distance-based exclusion CV	Для каждой скважины i по очереди: из обучения исключаются все скважины на расстоянии ≤ excl_radius от неё (excl_radius = медиана попарных расстояний между скважинами × variogram_factor), тест — только скважина i. Фолды одиночные, поэтому std RMSE по фолдам — это разброс абсолютных остатков по точкам. Если в обучении остаётся меньше degree + 2 точек, фолд пропускается и помечается в таблице, прогноз — NaN	Самая строгая проверка на пространственную утечку, по сути LOWO с буфером	100 фолдов по одной скважине: n_train — скважины дальше excl_radius от неё. У скважин в плотном центре облака n_train мал, такие фолды помечаются как пропущенные

Параметры k, grid_n, buffer, p_percent, radius, variogram_factor и repeats — это слайдеры в сайдбаре; для каждого там же показано рекомендуемое значение. Рекомендуемый buffer равен 0.5 × медианное расстояние между скважинами и общий для Buffered CV и Random K-Fold (buffered). excl_radius для Distance-based задаётся либо как медиана × variogram_factor, либо абсолютным значением в метрах (режим absolute). Координаты X и Y предполагаются заданными в метрах; buffer, radius и excl_radius задаются в тех же единицах. При выборе нескольких горизонтов все схемы разбивают скважины целиком: одна и та же скважина не может одновременно попасть в обучение и в тест, а её записи по горизонтам всегда попадают в одну группу.

Кривые аппроксимации

Помимо прямой линии, на кросс-плот можно наложить одну из 17 кривых — от простых полиномов до устойчивых к выбросам методов, а также квантильную регрессию (τ = 0.1 / 0.5 / 0.9):

Метод	Общий вид уравнения	Когда полезен
Linear	$y = a + bx$	Базовая линейная связь
Quadratic	$y = a + bx + cx^2$	Связь с одним изгибом
Cubic	$y = a + bx + cx^2 + dx^3$	Связь с точкой перегиба
Polynomial Degree 4–10	$y = a_0 + a_1 x + \cdots + a_n x^n$	Более сложная, но реже оправданная форма связи
Power Law	$y = ax^b$ $(x, y > 0)$	Степенная зависимость
Exponential	$y = ae^{bx}$ $(y > 0)$	Экспоненциальный рост или спад
Logarithmic	$y = a + b \ln x$ $(x > 0)$	Насыщение или замедление роста
Robust (Huber)	$y = a + bx$; коэффициенты минимизируют функцию потерь Хьюбера	Линейная связь, устойчивая к выбросам
Theil-Sen	$y = a + bx; b = \mathrm{median}\left(\frac{y_j - y_i}{x_j - x_i}\right)$	Линейная связь, устойчивая к выбросам
RANSAC	$y = a + bx$; подбор по максимальному числу inlier-точек	Линейная связь при сильных выбросах или аномалиях
LOWESS	без единой формулы — локальная регрессия в скользящем окне	Повторяет форму облака точек без предположений о форме связи
Quantile Regression (τ=0.1/0.5/0.9)	$y = a_\tau + b_\tau x$	Три линии для нижней, средней и верхней границы разброса

Область определения: степенная и экспоненциальная аппроксимации не используют точки с y ≤ 0 (например, H_eff = 0 у интервалов без коллектора); степенная и логарифмическая не используют точки с x ≤ 0 (например, отрицательные значения avo_intercept). Такие точки в подгонку этих аппроксимаций не входят; остальные аппроксимации используют все точки, включая эти.

Для кривых τ = 0.1 и τ = 0.9 метрика R^2 может быть отрицательной — это нормально. Квантильная регрессия оптимизирует не квадрат ошибки, как линейная регрессия, а функцию «pinball loss», поэтому её кривые описывают границы разброса, а не центр облака точек. Для оценки таких кривых ориентируйтесь на Equation и Bias, а не на R^2.

In-sample и out-of-sample в проекте

In-sample — модель подбирается и проверяется на одних и тех же скважинах. Метрики показывают, насколько хорошо модель описывает данные, которые она уже видела, поэтому обычно они оптимистичны. Уравнение in-sample — обычная линейная регрессия по всем скважинам выбранной выборки.

Out-of-sample — модель подбирается без части скважин, а проверяется на тех, которых при подборе не было (кросс-валидация по схемам LOWO, K-fold и др.). Метрики показывают качество на новых скважинах. Разрыв между in-sample и out-of-sample — признак переобучения. В таблицах Out-of-sample метрики и уравнение Predicted = a + b·Actual получены по одним и тем же out-of-fold предсказаниям.

Шаг	Что считается	Режим
0	корреляции Пирсона и Спирмена, описательная статистика	без модели
1	базовый QC-кросс-плот, аппроксимации, R^2_lin, R^2_fit, P-value, уравнение регрессии	in-sample
2	девять схем CV, фолды, выбор лучшей схемы, выбросы CV-невязок, R^2 (Pearson), R^2 (Actual = Predicted), уравнение Predicted = a + b·Actual, аппроксимации лучшей схемы	out-of-sample
3	аппроксимации и метрики внутри каждой категории	in-sample (внутри категории)
4	метрики до и после фильтрации, аппроксимации после фильтрации	in-sample (на отфильтрованной выборке)
4.5	R^2 (Pearson) по сериям случайного исключения	in-sample (оставшиеся скважины) и out-of-sample (исключённые)
5	одноатрибутные модели и топ-5 многоатрибутных моделей	In-sample: RMSE_in, R^2_in, r_in, уравнение по всем скважинам; Out-of-sample: RMSE_cv, R^2_cv, r_cv, уравнение Predicted = a + b·Actual

Метрики кросс-плота и обозначения

Обозначим Δ — невязку. На базовом QC-кросс-плоте (Шаг 1, BasicStats) Δ = y − x = PARAM_1 − PARAM_2. В аппроксимациях и метриках кросс-валидации (Шаги 1–4, FitStats и fold_metrics) Δ = Predicted − Actual. Графики CV-невязок Шага 2 строятся как Actual − Predicted. Bias на кросс-плоте Шага 2 (Predicted vs Actual) считается с тем же знаком, что и в таблицах CV: Δ = Predicted − Actual. Квадратичные и абсолютные метрики (RMSE, MSE, MAE, R^2) от знака не зависят, а знаковый Bias меняет знак при смене соглашения.

Ограничение базовых ошибок Шага 1. Bias, RMSE, MSE, MAE, Std, Variance, WAPE % и невязка Δ = PARAM_1 − PARAM_2 зависят от масштаба и единиц параметров: H_eff измеряется в метрах, атрибут — в своих единицах. Поэтому значения этих метрик сравнимы только внутри одной пары PARAM_1–PARAM_2. Качество связи оценивается по R^2 и коэффициентам корреляции Пирсона и Спирмена. Сравнивать абсолютные значения ошибок между разными атрибутами или разными эталонными параметрами нельзя.

Метрика	Формула
Pearson r (коэффициент корреляции, Шаг 0)	$r = \frac{\mathrm{cov}(a,b)}{\sigma_a \sigma_b}$; не R^2, через Δ не выражается
Spearman ρ (коэффициент корреляции, Шаг 0)	коэффициент Пирсона на рангах; не R^2, через Δ не выражается
R^2_lin (коэффициент детерминации, Шаги 1 и 4) — **in-sample**	$R^2_{lin} = 1 - \frac{\sum(\Delta_{OLS})^2}{\sum(y-\bar{y})^2} = r^2$, где $\Delta_{OLS} = y - (a+bx)$ — остаток линейной регрессии (`linregress`); только линейная связь
R^2_fit (кривые аппроксимации, Шаги 1, 3, 4) — **in-sample**	$R^2_{fit} = 1 - \frac{\sum(\Delta)^2}{\sum(y-\bar{y})^2}, \Delta = Predicted - Actual$; любая форма кривой
R^2_fit (CV-аппроксимации, Шаг 2) — **out-of-sample**	$R^2_{fit} = 1 - \frac{\sum(\Delta)^2}{\sum(y-\bar{y})^2}, \Delta = model(Actual) - Predicted$; здесь $x = Actual$ (PARAM_1), $y = Predicted$, роли намеренно отличаются от Шага 1
R^2 (Actual = Predicted), Шаг 2 — **out-of-sample**	$1 - \frac{\sum(\Delta)^2}{\sum(Actual - \overline{Actual})^2}, \Delta = Predicted - Actual$, по out-of-fold прогнозам (`r2_score`)
R^2 (Pearson, Predicted vs Actual), Шаг 2, pooled — **out-of-sample**	$1 - \frac{\sum(\Delta_{OLS})^2}{\sum(Actual - \overline{Actual})^2} = r^2, \Delta_{OLS} = Actual - (a + b \cdot Predicted)$ по out-of-fold прогнозам (`linregress`)

Метрика	Формула
R^2 (Pearson) по фолдам, Шаг 2 — **out-of-sample**	то же, что выше, внутри каждого фолда; нужно не меньше 3 точек и ненулевая дисперсия
R^2 (Pearson), in-sample, Шаг 4.5	$1 - \frac{\sum(\Delta_{OLS})^2}{\sum(PARAM_1 - \overline{PARAM_1})^2} = r^2, \Delta_{OLS} = PARAM_1 - (a + b \cdot PARAM_2)$ по оставшимся скважинам
R^2 (Pearson), out-of-sample, Шаг 4.5	$r^2 = corrcoef(PARAM_1, pred)^2$ на исключённых скважинах, $pred = a + b \cdot PARAM_2$ по оставшимся; через Δ не выражается, так как линия обучена на другой выборке
RMSE (среднеквадратичная ошибка)	$\sqrt{\frac{1}{N}\sum(\Delta)^2}$
MSE (среднеквадратичная ошибка)	$\frac{1}{N}\sum(\Delta)^2$
MAE (абсолютная погрешность)	$\frac{1}{N}\sum\lvert\Delta\rvert$
Bias (систематическое смещение)	$\frac{1}{N}\sum(\Delta)$
Std (стандартное отклонение невязок)	$\sqrt{\frac{1}{N-1}\sum(\Delta_i - \bar{\Delta})^2}$
Variance (дисперсия невязок)	$\frac{1}{N-1}\sum(\Delta_i - \bar{\Delta})^2$
WAPE, % (взвешенная абсолютная ошибка в процентах)	$100 \cdot \frac{\sum\lvert\Delta\rvert}{\sum\lvert y\rvert}$
P-value (значимость линейной корреляции) — **in-sample** (Шаги 0, 1, 4); **out-of-sample** (Шаг 2)	$t = r\sqrt{\frac{N-2}{1-r^2}},\ p = 2\,(1 - F_{t,\,N-2}(\lvert t\rvert))$
Уравнение линейной регрессии	$y = a + bx$; наклон b и intercept a — из `linregress`

P-value отвечает на вопрос: насколько вероятно получить наблюдаемую линейную связь между PARAM_1 и PARAM_2 (или более сильную) случайно, если на самом деле линейной зависимости нет (нулевая гипотеза H_0: истинный наклон b = 0). Чем меньше p-value, тем меньше оснований считать зависимость случайной. Обычно связь считают статистически значимой при p < 0.05. Показатель рассчитывается для базового QC-кросс-плота (Шаг 1) и для кросс-плота Шага 2 по out-of-fold прогнозам, через `scipy.stats.linregress`.

Выбросы CV-невязок

Выбросы ищутся на Шаге 2 в CV-невязках (Actual − Predicted) четырьмя независимыми правилами. Каждая точка проверяется по каждому правилу отдельно, поэтому результаты можно сравнивать между собой:

Правило	Условие выброса	Параметр в сайдбаре
Сигма	$\lvert\Delta\rvert > k\sigma$, где σ — выборочное стандартное отклонение невязок (ddof = 1)	k = 1.0–6.0, по умолчанию 2.0
IQR	$\Delta < Q25 - k \cdot IQR$ или $\Delta > Q75 + k \cdot IQR$	k = 1.0–3.0, по умолчанию 1.5
Modified z-score	$\lvert 0.6745\,(\Delta - \tilde{\Delta})/MAD\rvert > 3.5$, где $\tilde{\Delta}$ — медиана невязок, MAD — медианное абсолютное отклонение; устойчиво к экстремальным значениям	фиксированный порог 3.5
Квантильное	$\Delta < P_{low}$ или $\Delta > P_{high}$ — хвосты за пределами выбранных перцентилей	P_low 0–20%, по умолчанию 5%; P_high 80–100%, по умолчанию 95%

Если σ или MAD равны нулю, соответствующее правило не помечает ни одной точки.

Статистика параметров

Для H_eff и Phi (Шаг 0) и для каждого числового параметра выводится расширенная описательная статистика. Вот что означает каждая величина:

Статистика	Формула / определение
Count	N — число непустых значений
μ (mean)	$\mu = \frac{1}{N}\sum x_i$ — среднее арифметическое
median	медиана — значение, делящее выборку пополам (50-й перцентиль)
mode	мода — наиболее часто встречающееся значение
σ (std)	$\sigma = \sqrt{\frac{1}{N-1}\sum (x_i - \mu)^2}$
variance	$\sigma^2 = \frac{1}{N-1}\sum (x_i - \mu)^2$
CV, %	$\frac{\sigma}{\mu} \times 100\%$ — коэффициент вариации (разброс относительно среднего)
min	минимальное значение
Q05	5-й перцентиль
Q25	25-й перцентиль (первый квартиль)
Q75	75-й перцентиль (третий квартиль)
Q95	95-й перцентиль
max	максимальное значение
range	$\max - \min$
IQR	$Q75 - Q25$ — межквартильный размах

Границы IQR, RMSE и μ±3σ выводятся в статистике CV-невязок Шага 2, а не в описательной статистике параметров. Коэффициент k для IQR задаётся слайдером в сайдбаре.

📂 Формат входного файла

Имена колонок в файле могут быть любыми: соответствие задаётся при сопоставлении колонок в сайдбаре. Ниже описаны роли колонок.

- **well_id** — идентификатор скважины
- **X, Y** — координаты скважины в метрах
- **H_eff** — эффективная мощность коллектора (по умолчанию единица — метры)
- **Phi** — пористость (по умолчанию единица — доли, fractions)
- **Сейсмические атрибуты** — любые числовые колонки: rms_amplitude, envelope, sweetness, coherence и другие. Параметр 2 выбирается из них в начале Шага 1.

Дополнительные колонки:

- **horizon_id** — горизонт; при выборе нескольких горизонтов скважины разбиваются целиком
- **tectonic_zone** — тектоническая зона
- **well_category** — категория скважины (используется в Шаге 3)
- **reservoir_flag** — тип коллектора
- **fluid_type** — тип флюида; значение `non_reservoir` означает отсутствие флюида там, где нет коллектора
- любые другие числовые и категориальные колонки

Пример: три скважины из демонстрационного файла.

Пример содержимого файла

	well_id	X	Y	horizon_id	tectonic_zone	H_eff	Phi	rms_amplitude	envelope	sweetness
0	W-001	7,501.1	9,671.5	Top_Reservoir	Central_Graben	5.47	0.223	0.1047	0.1312	0.0342
1	W-002	10,766.6	6,577.6	Top_Reservoir	South_Block	4.19	0.193	0.0734	0.0901	0.0235
2	W-004	2,702.5	5,237.4	Top_Seal	North_Block	0	0.062	0.046	0.0575	0.015

Загрузка данных

Первичный обзор данных

✅ QC входных данных

Полные дубликаты строк

Полные дубликаты не обнаружены.

well_id с несколькими записями

Для нескольких горизонтов на одну скважину это ожидаемо. Реальное дублирование — только если совпадают well_id И horizon_id.

well_id с несколькими записями не обнаружено.

Совпадающие координаты (с учётом горизонта)

Совпадающих координат (в пределах одного горизонта) не обнаружено.

Пропуски по колонкам

	column	missing values
0	horizon_id	0
1	tectonic_zone	0
2	well_category	0
3	reservoir_flag	0
4	fluid_type	0
5	H_eff	0
6	Phi	0
7	rms_amplitude	0
8	envelope	0
9	sweetness	0

Скачать в Excel

Строки, удалённые при очистке

Строки не удалялись.

Количество наблюдений (строк): 100

Уникальных скважин: 100

Колонки: horizon_id · tectonic_zone · well_category · reservoir_flag · fluid_type · H_eff · Phi · rms_amplitude · envelope · sweetness · coherence · inst_frequency · avo_intercept · avo_gradient · spectral_decomp_20Hz · acoustic_impedance · q_factor · well_id · X_coord · Y_coord

Типы данных по колонкам

	Column	Data Types	Pandas dtype	Not NaN	NaN	Unique Values
0	horizon_id	String	object	100	0	1
1	tectonic_zone	String	object	100	0	3
2	well_category	String	object	100	0	3
3	reservoir_flag	String	object	100	0	2
4	fluid_type	String	object	100	0	4
5	H_eff	Numeric	float64	100	0	71
6	Phi	Numeric	float64	100	0	83
7	rms_amplitude	Numeric	float64	100	0	95
8	envelope	Numeric	float64	100	0	94
9	sweetness	Numeric	float64	100	0	96

Скачать в Excel

Первые 5 строк

	well_id	X_coord	Y_coord	horizon_id	tectonic_zone	well_category	reservoir_flag	fluid_type	H_eff	Phi	rms_amplitude	envelope	sweetness	coherence	inst_frequency	avo_intercept	avo_gradient	spectral_decomp_20Hz	acoustic_impedance	q_factor
0	W-001	7,501.1	9,671.5	Top_Reservoir	Central_Graben	production	reservoir	oil	5.47	0.223	0.1047	0.109	0.164	0.443	44.19	-0.0968	-0.1178	0.3292	8.081	54.5
1	W-002	10,766.6	6,577.6	Top_Reservoir	South_Block	appraisal	reservoir	oil	4.19	0.193	0.0734	0.0922	0.148	0.671	38.86	-0.0905	-0.0222	0.4752	8.191	75.8
2	W-003	9,308.2	4,282.2	Top_Reservoir	South_Block	appraisal	reservoir	oil	9.38	0.16	0.0594	0.0727	0.1983	0.38	13.45	-0.036	-0.1041	0.756	9.659	54.9
3	W-005	3,602	8,728.1	Top_Reservoir	North_Block	production	reservoir	oil	9.27	0.225	0.083	0.1079	0.199	0.777	29.41	-0.13	-0.0886	0.6171	9.032	57.4
4	W-006	10,482.6	3,442.1	Top_Reservoir	South_Block	exploration	non_reservoir	non_reservoir	0	0.057	0.0437	0.0762	0.1755	0.722	18.88	0.1965	0.2599	0.4855	10.135	39.8

Последние 5 строк

	well_id	X_coord	Y_coord	horizon_id	tectonic_zone	well_category	reservoir_flag	fluid_type	H_eff	Phi	rms_amplitude	envelope	sweetness	coherence	inst_frequency	avo_intercept	avo_gradient	spectral_decomp_20Hz	acoustic_impedance	q_factor
95	W-064	1,809.5	1,124.1	Top_Reservoir	North_Block	production	reservoir	gas	3.26	0.183	0.0761	0.1026	0.1612	0.336	40.49	-0.069	-0.2207	0.4714	8.294	82.4
96	W-066	2,874.8	4,792	Top_Reservoir	North_Block	production	reservoir	oil	3.6	0.153	0.0817	0.1006	0.1954	0.424	26.48	0.137	-0.1158	0.3952	9.576	37.2
97	W-073	10,488.9	6,352.3	Top_Reservoir	South_Block	appraisal	reservoir	gas	11.24	0.237	0.131	0.1292	0.2027	0.975	40.64	-0.0615	-0.1623	0.5525	9.094	48.4
98	W-083	6,627.9	8,776.9	Top_Reservoir	Central_Graben	exploration	non_reservoir	non_reservoir	0	0.058	0.0795	0.1095	0.1372	0.96	63.7	0.1093	0.1254	0.5175	9.659	79
99	W-088	4,515.5	202.2	Top_Reservoir	Central_Graben	appraisal	reservoir	water	5.21	0.16	0.0777	0.0913	0.1498	0.929	37.12	0.049	0.0586	0.5459	8.355	68.8

Скачать в Excel

Параметры пласта: Нэф и Кп

Статистика параметров H_eff, Phi

H_eff

	H_eff
Count	100.00
μ, mean	6.32
median	4.03
mode	0.00
σ, std	6.34
variance	40.15
CV %	100.31
min	0.00
Q05	0.00
Q25	0.00

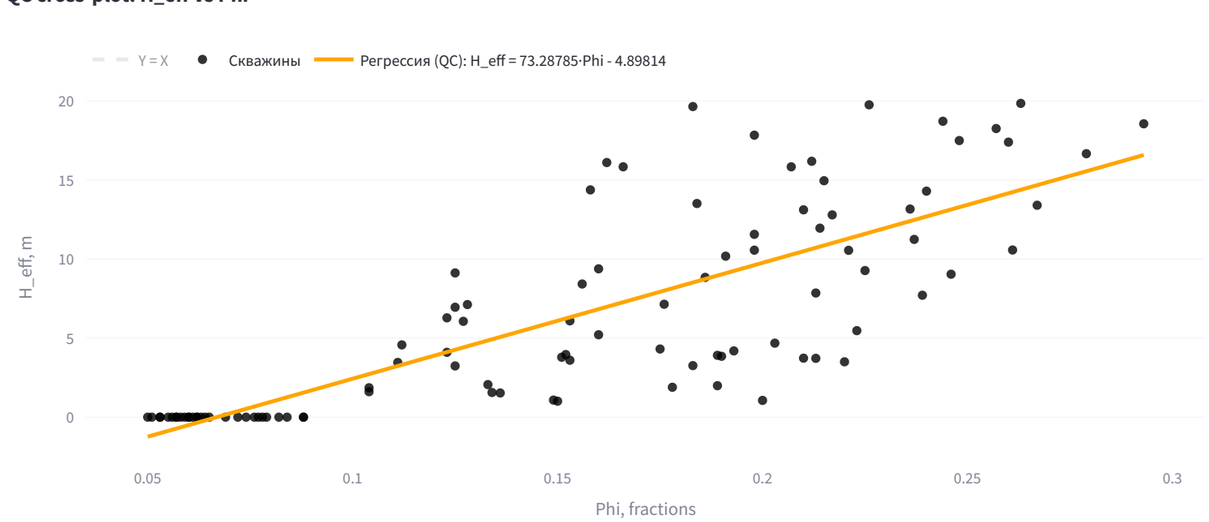
Phi

	Phi
Count	100.00
μ, mean	0.15
median	0.16
mode	0.12
σ, std	0.07
variance	0.00
CV %	44.90
min	0.05
Q05	0.06
Q25	0.08

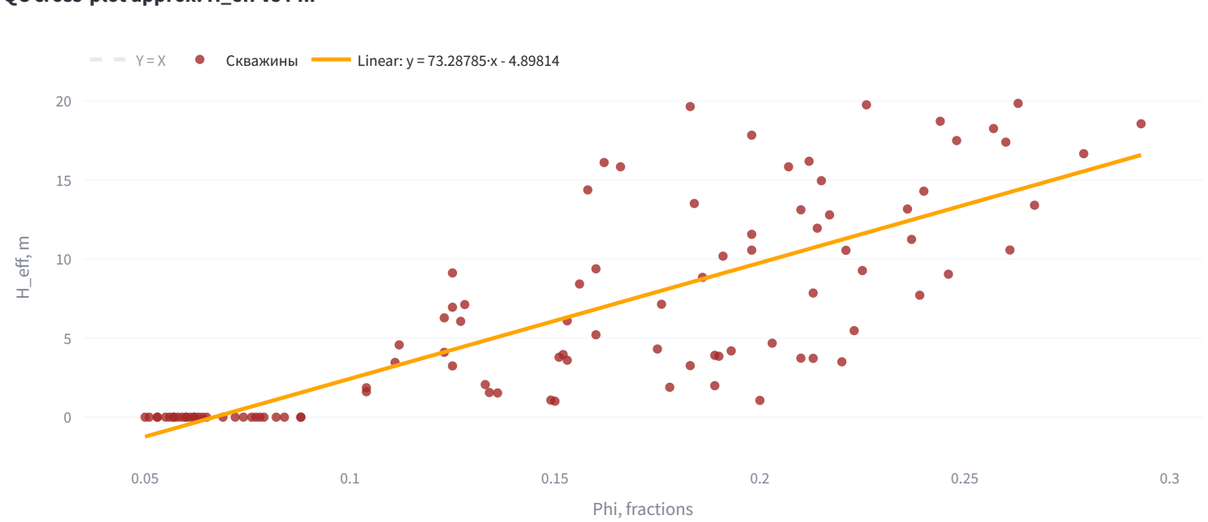
Скачать в Excel

Кросс-плот: H_eff и Phi

Кросс-плот: H_eff vs Phi



Аппроксимации: H_eff vs Phi



Метрики QC кросс-плота: H_eff vs Phi

	R^2_lin	r	RMSE	MSE	MAE	Bias	Std	Variance	WAPE %	P-value	Equation
0	0.6316	0.7947	8.7787	77.0650	6.2023	6.1641	6.2820	39.4639	98.1832	5.66608e-23	H_eff = 73.28785·Phi + -4.89814

Δ на Шаге 1 = PARAM_1 − PARAM_2 (эталон минус атрибут): положительная Δ означает, что PARAM_1 выше PARAM_2.

Скачать в Excel

Сравнение метрик аппроксимаций: H_eff vs Phi

	Approximation	R^2_fit	r	RMSE	MSE	MAE	Bias	Std	Variance	WAPE %	Equation	n_fit
0	Linear	0.6316	0.7947	3.8268	14.6446	2.8477	0.0000	3.8461	14.7925	45.0794	y = 73.28785·x - 4.89814	100

Скачать в Excel

Корреляция и pairplot: H_eff и Phi

Матрица корреляции

Скачать в Excel

Матрица корреляции, количество параметров: 2



Pearson — только линейная связь. Spearman — любая монотонная (экспонента, логарифм, степенная).

Пары параметров с коэффициентом корреляции больше или равно 0.70

	Параметр 1	Параметр 2	КК
0	H_eff	Phi	0.795

Скачать в Excel

Матрица корреляции (Спирмен)

Скачать в Excel

Матрица корреляции (Спирмен): 2



Пары параметров с коэффициентом корреляции больше или равно 0.70

	Параметр 1	Параметр 2	КК
0	H_eff	Phi	0.848

Скачать в Excel

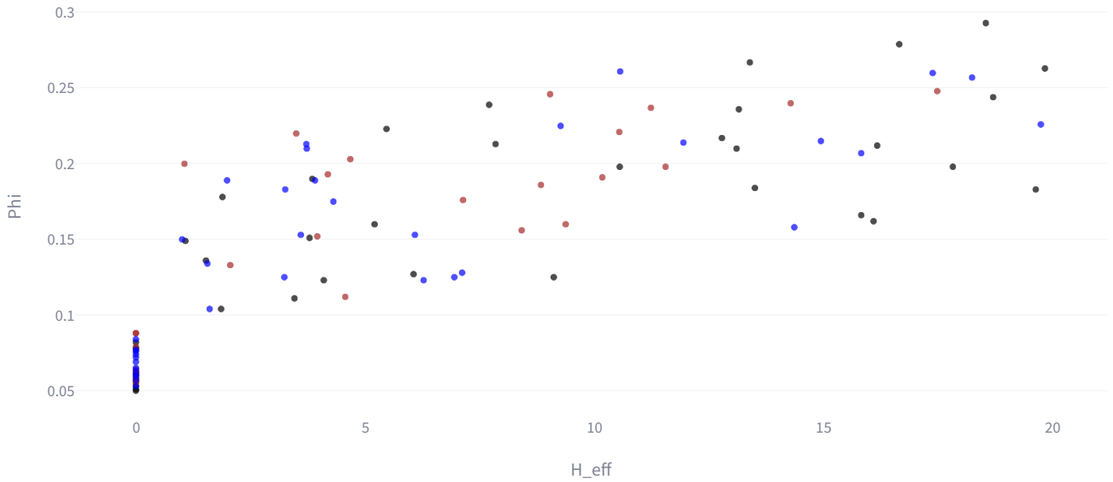
Pairplot

Показать Pairplot

Plotly Pairplot: поддерживаются интерактивность, масштабирование и hover. KDE и гистограммы на диагонали доступны только для Seaborn Pairplot.

Plotly Pairplot, количество параметров: (2)







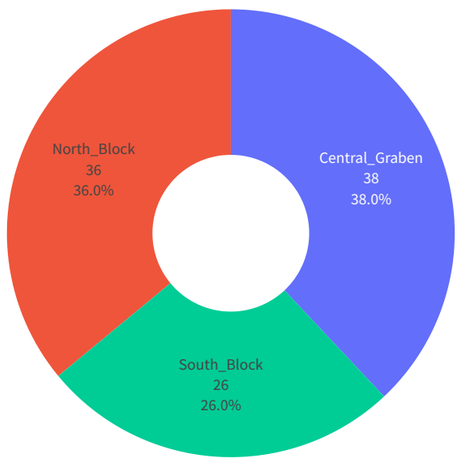
Категориальные признаки

horizon_id (1)

tectonic_zone (3)

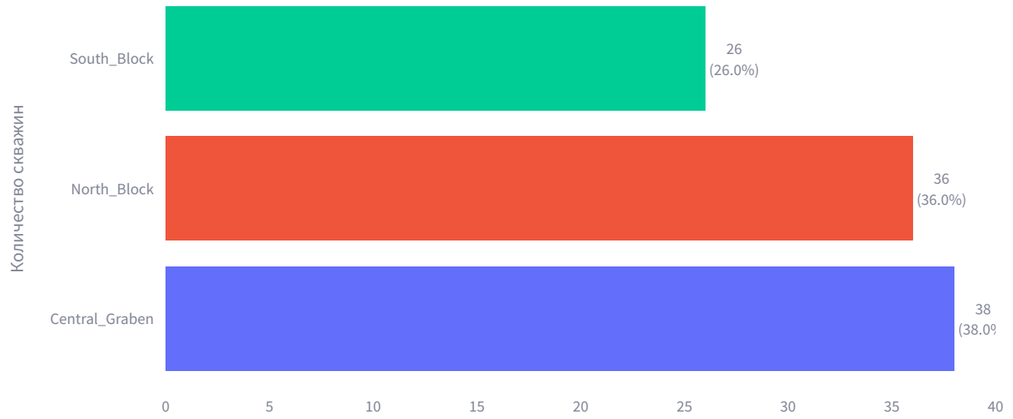
Central_Graben, North_Block, South_Block

Количество скважин : tectonic_zone





Количество скважин : tectonic_zone



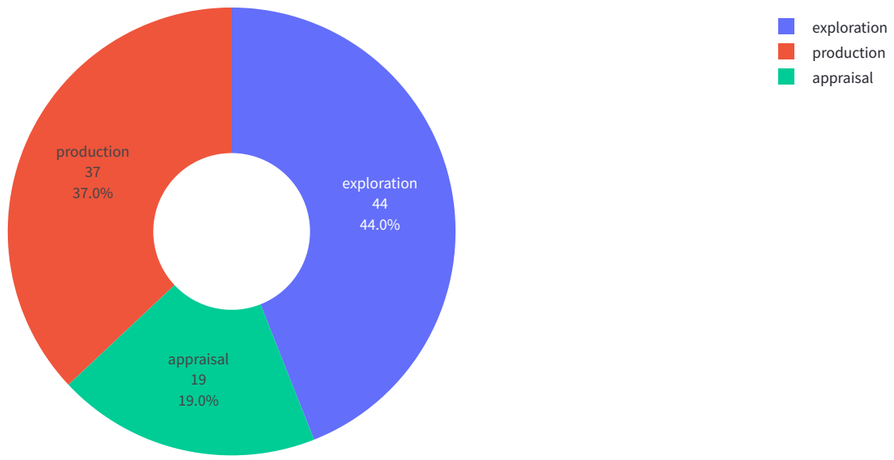
tectonic_zone	Скважин	Записей (скважина-горизонт)	Доля скважин, %
Central_Graben	38	38	38
North_Block	36	36	36
South_Block	26	26	26

Скачать в Excel

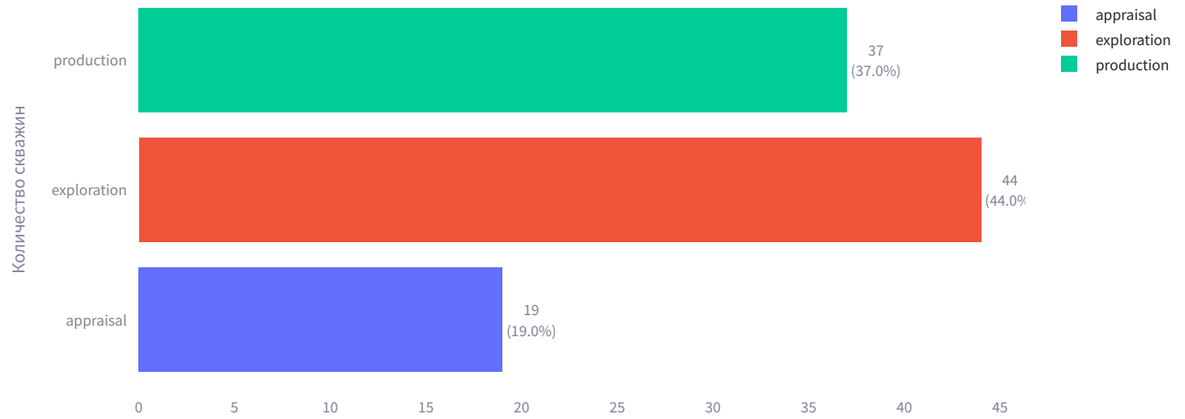
well_category (3)

appraisal, exploration, production

Количество скважин : well_category



Количество скважин : well_category



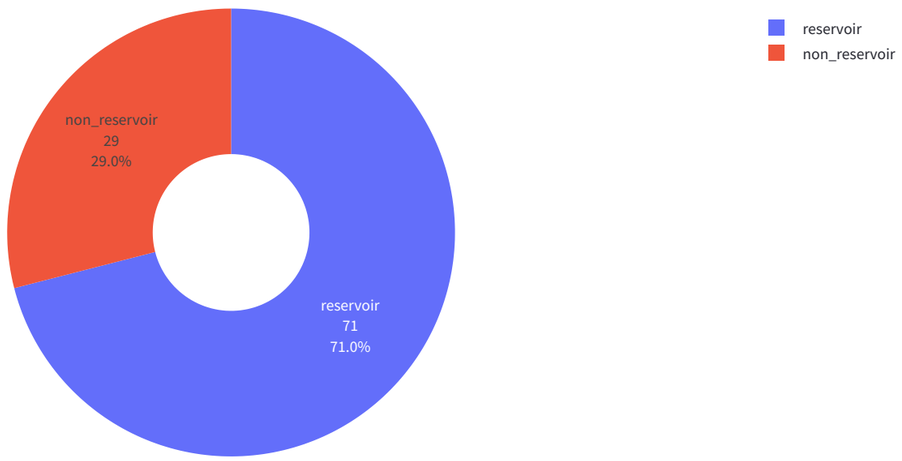
well_category	Скважин	Записей (скважина-горизонт)	Доля скважин, %
appraisal	19	19	19
exploration	44	44	44
production	37	37	37

Скачать в Excel

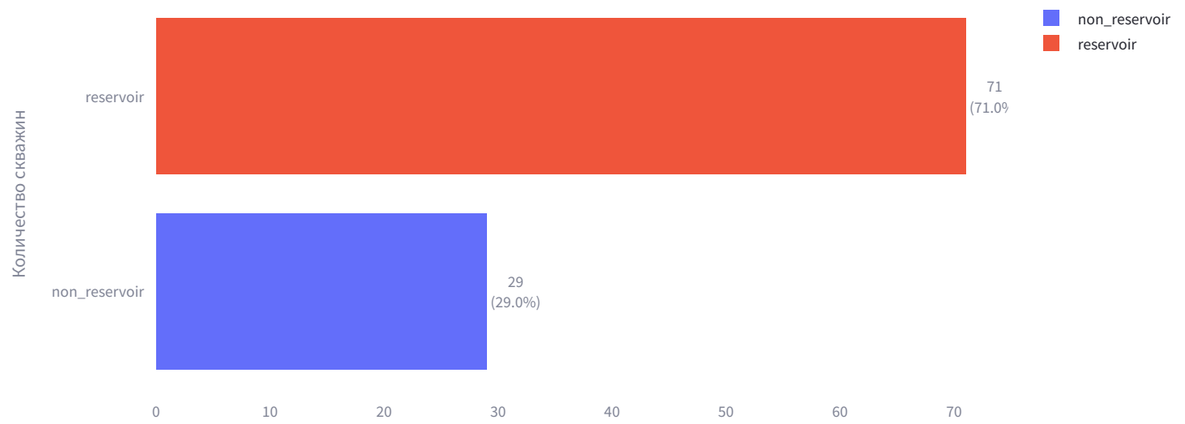
reservoir_flag (2)

non_reservoir, reservoir

Количество скважин : reservoir_flag



Количество скважин : reservoir_flag



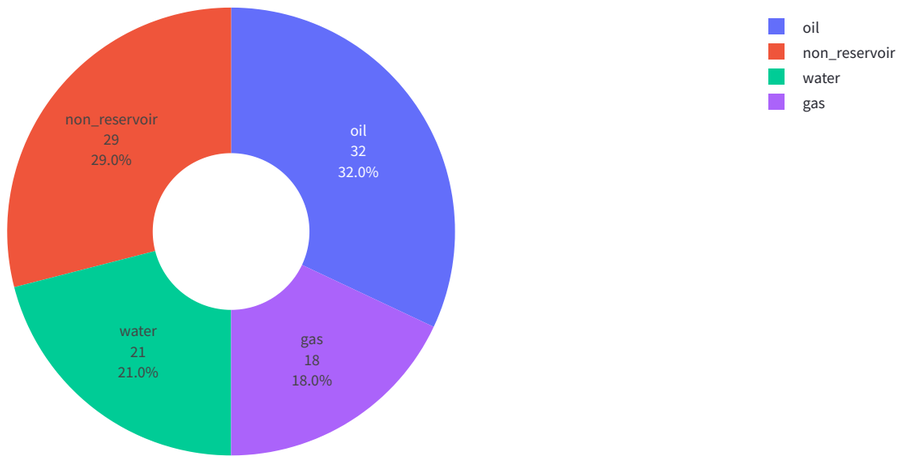
reservoir_flag	Скважин	Записей (скважина-горизонт)	Доля скважин, %
non_reservoir	29	29	29
reservoir	71	71	71

Скачать в Excel

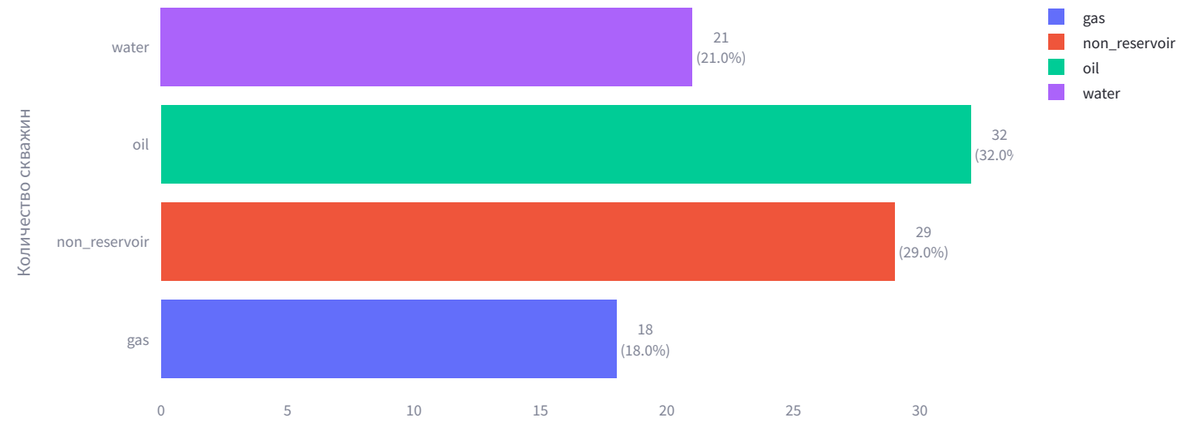
fluid_type (4)

gas, non_reservoir, oil, water

Количество скважин : fluid_type



Количество скважин : fluid_type



fluid_type	Скважин	Записей (скважина-горизонт)	Доля скважин, %
gas	18	18	18
non_reservoir	29	29	29
oil	32	32	32
water	21	21	21

Скачать в Excel

Круговые диаграммы по нескольким категориям

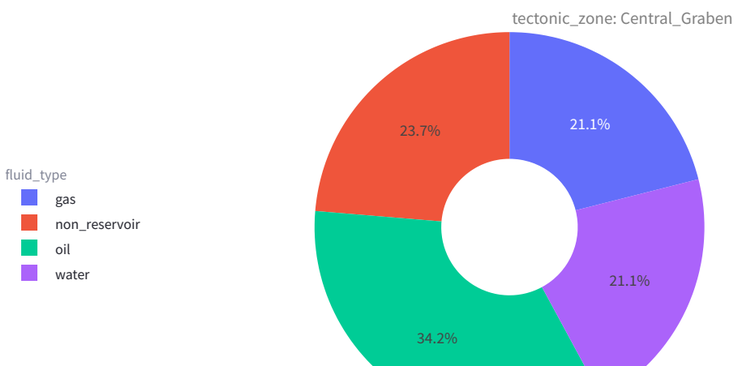
Категория по оси X

tectonic_zone

Категория для групп (цвет столбцов)

fluid_type

Круговые диаграммы по нескольким категориям: tectonic_zone × fluid_type



Распределение по двум категориям

Категория по оси X

tectonic_zone

Категория для групп (цвет столбцов)

fluid_type

Распределение по двум категориям: tectonic_zone × fluid_type

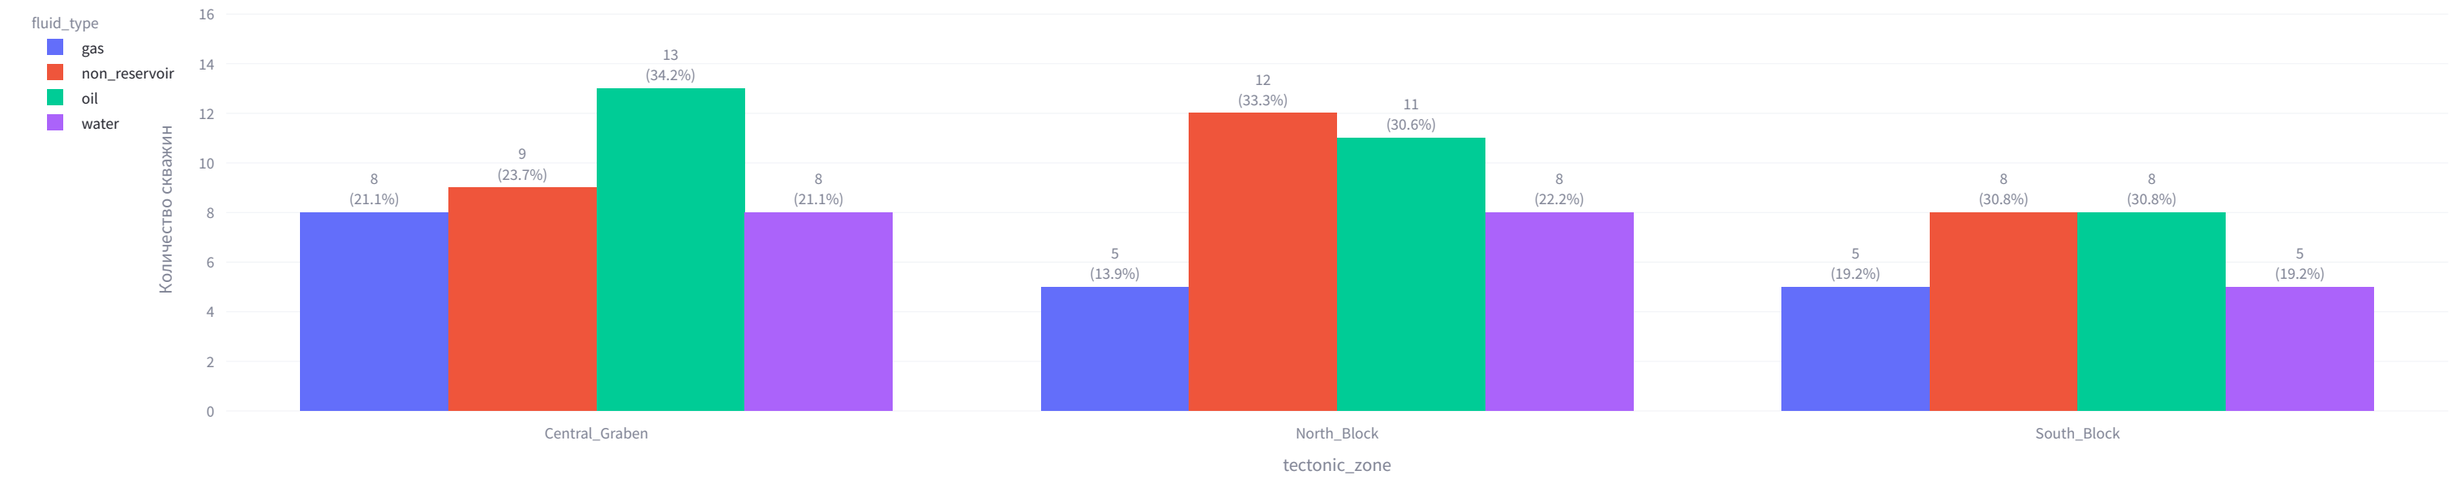


Таблица статистики

tectonic_zone	gas	non_reservoir	oil	water	Всего
Central_Graben	8 (21.1%)	9 (23.7%)	13 (34.2%)	8 (21.1%)	38
North_Block	5 (13.9%)	12 (33.3%)	11 (30.6%)	8 (22.2%)	36
South_Block	5 (19.2%)	8 (30.8%)	8 (30.8%)	5 (19.2%)	26
Всего	18	29	32	21	100

Скачать в Excel

Анализ выбранных параметров

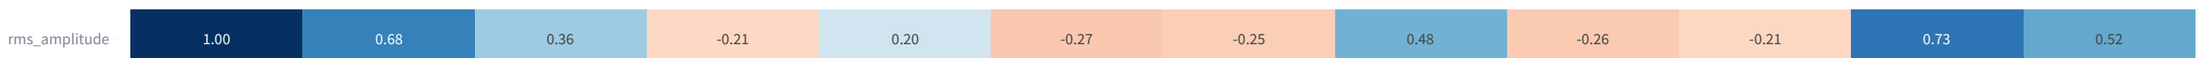
Матрица корреляции: атрибуты, H_eff, Phi

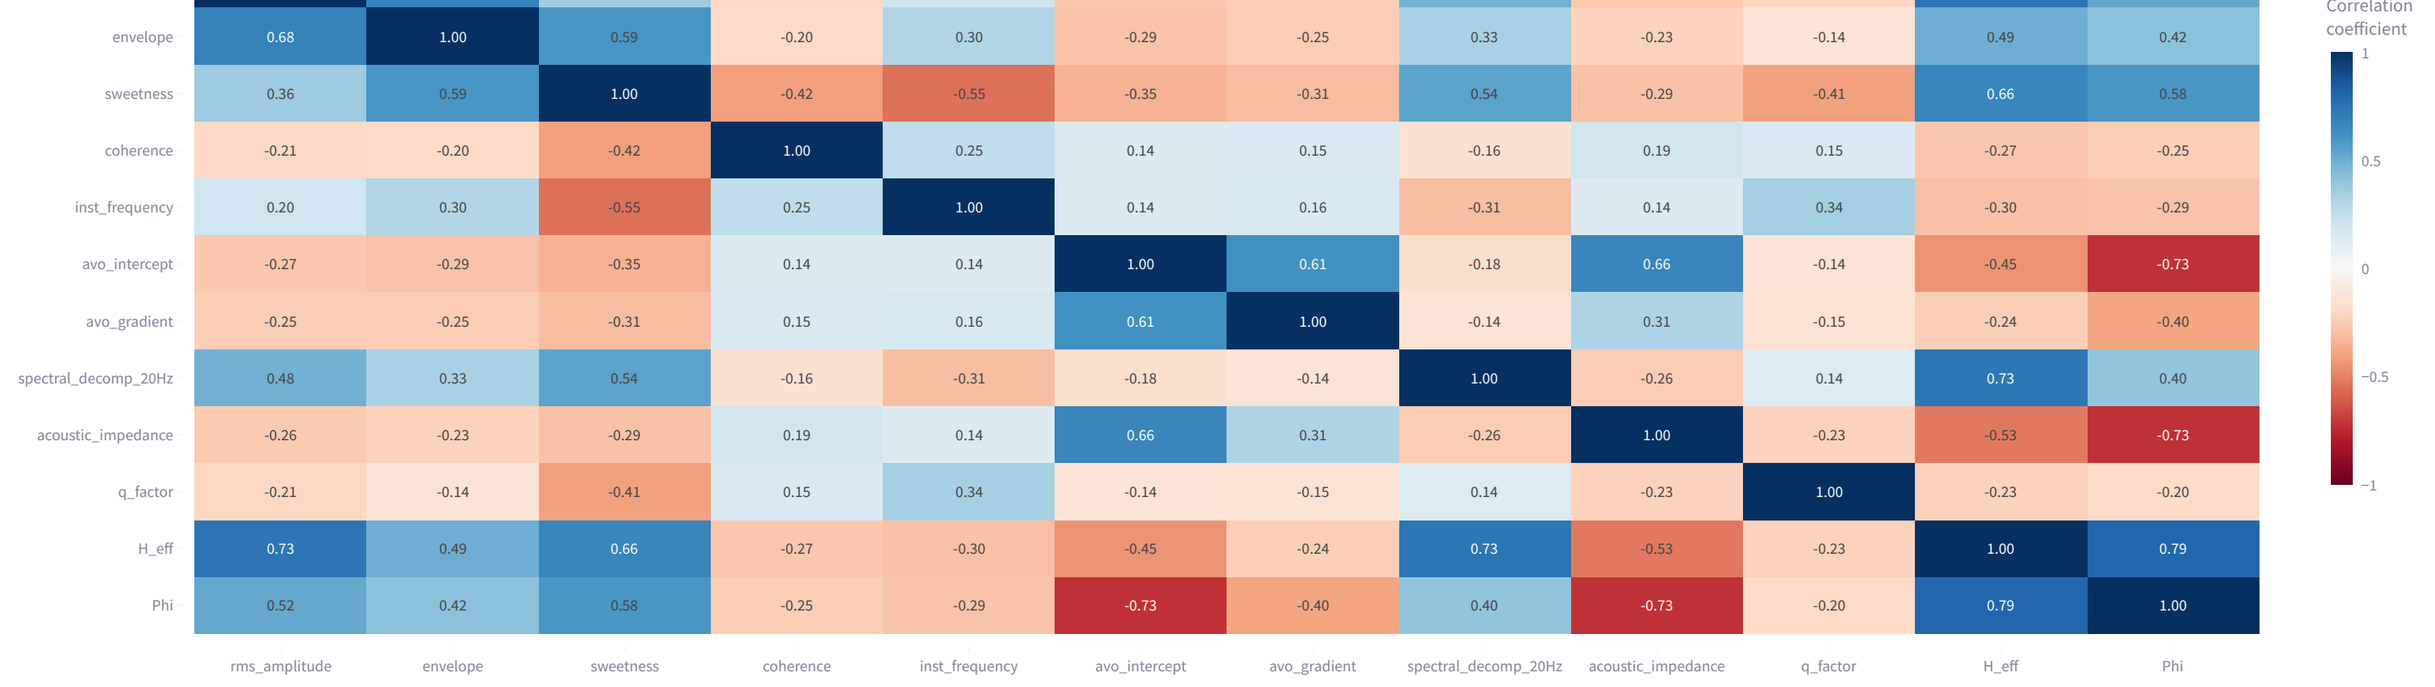
Атрибуты для корреляции

rms_amplitude × envelope × sweetness × coherence × inst_frequency × avo_intercept × avo_gradient × spectral_decom… × acoustic_imped… × q_factor ×

Матрица корреляции

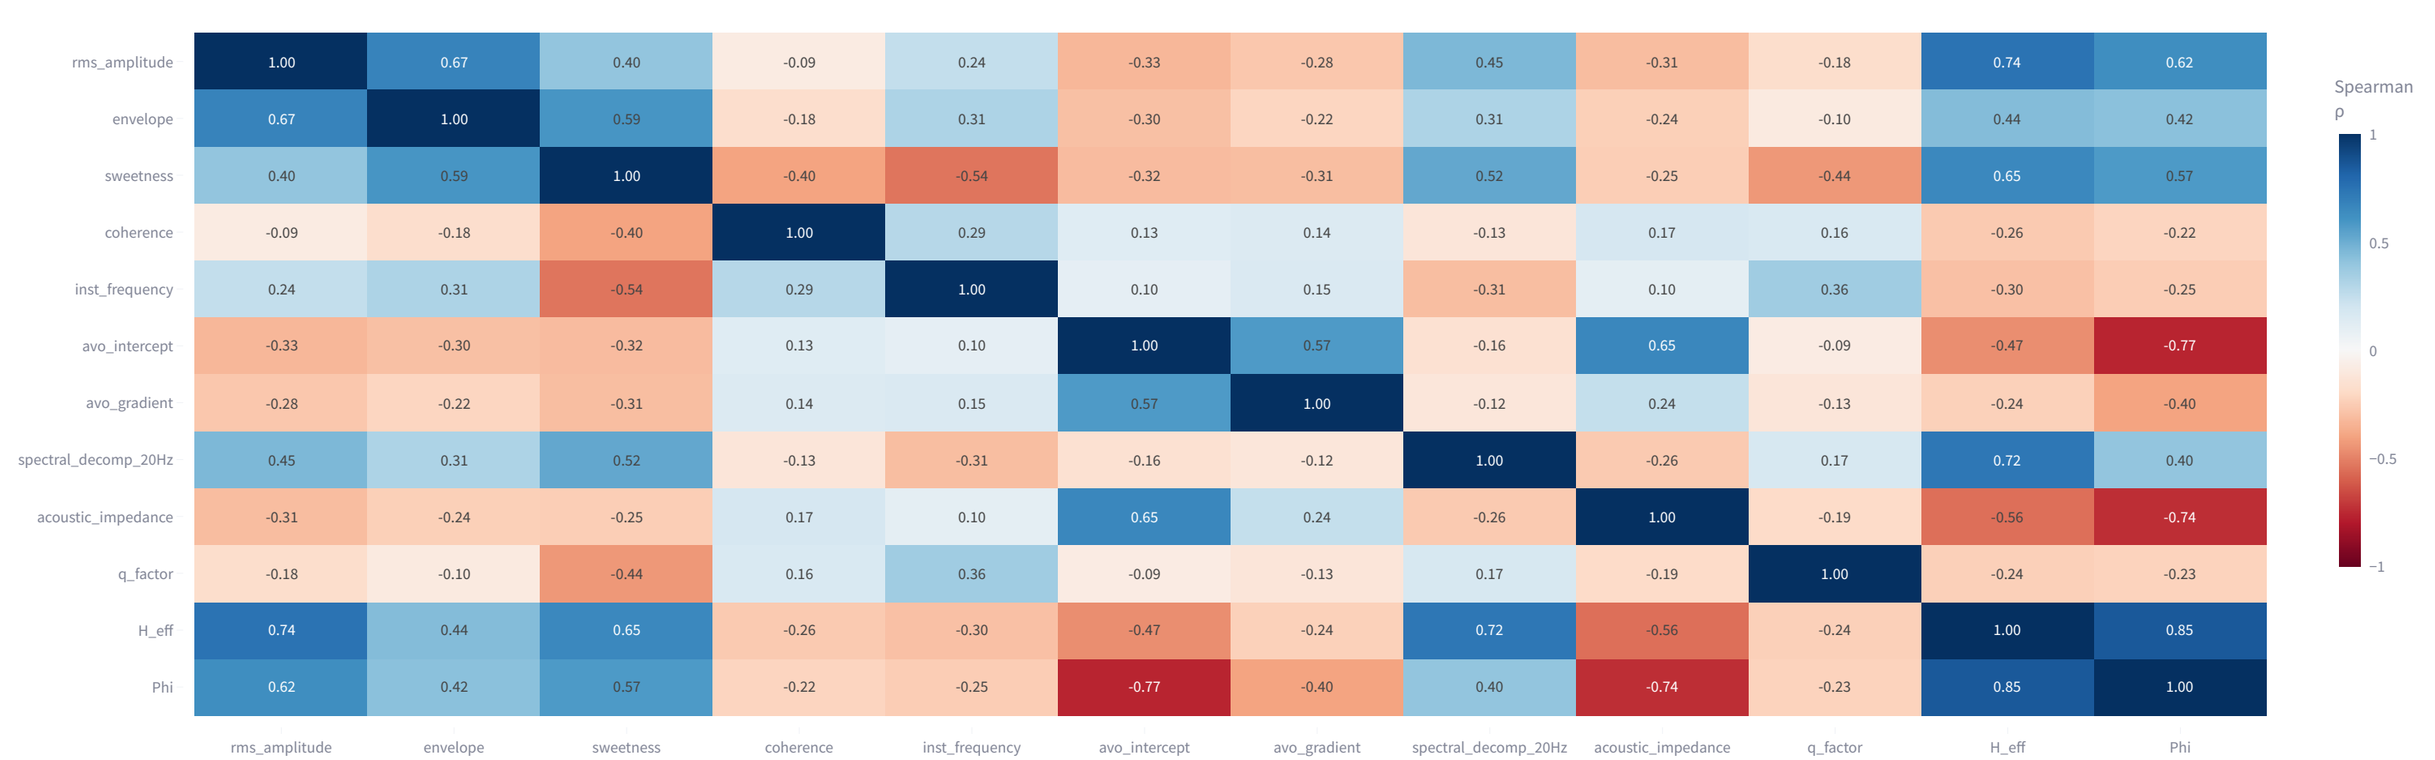
Скачать в Excel





Матрица корреляции (Спирмен)

Скачать в Excel



Pearson — только линейная связь. Spearman — любая монотонная (экспонента, логарифм, степенная).

Пары параметров с коэффициентом корреляции больше или равно 0.70

	Группа	Параметр 1	Параметр 2	КК	ρ (Спирмен)
0	H_eff – атрибут	rms_amplitude	H_eff	0.732	0.743
1	Phi – атрибут	avo_intercept	Phi	-0.73	-0.768
2	H_eff – атрибут	spectral_decomp_20Hz	H_eff	0.728	0.723
3	Phi – атрибут	acoustic_impedance	Phi	-0.731	-0.74
4	H_eff – Phi	H_eff	Phi	0.795	0.848

Скачать в Excel

Пары параметров с коэффициентом корреляции меньше или равно 0.50

	Группа	Параметр 1	Параметр 2	КК	ρ (Спирмен)
0	атрибут – атрибут	rms_amplitude	sweetness	0.363	0.397
1	атрибут – атрибут	rms_amplitude	coherence	-0.206	-0.086
2	атрибут – атрибут	rms_amplitude	inst_frequency	0.202	0.245
3	атрибут – атрибут	rms_amplitude	avo_intercept	-0.272	-0.333
4	атрибут – атрибут	rms_amplitude	avo_gradient	-0.248	-0.276
5	атрибут – атрибут	rms_amplitude	spectral_decomp_20Hz	0.481	0.454
6	атрибут – атрибут	rms_amplitude	acoustic_impedance	-0.263	-0.313
7	атрибут – атрибут	rms_amplitude	q_factor	-0.212	-0.18
8	атрибут – атрибут	envelope	coherence	-0.199	-0.177
9	атрибут – атрибут	envelope	inst_frequency	0.302	0.314

Скачать в Excel

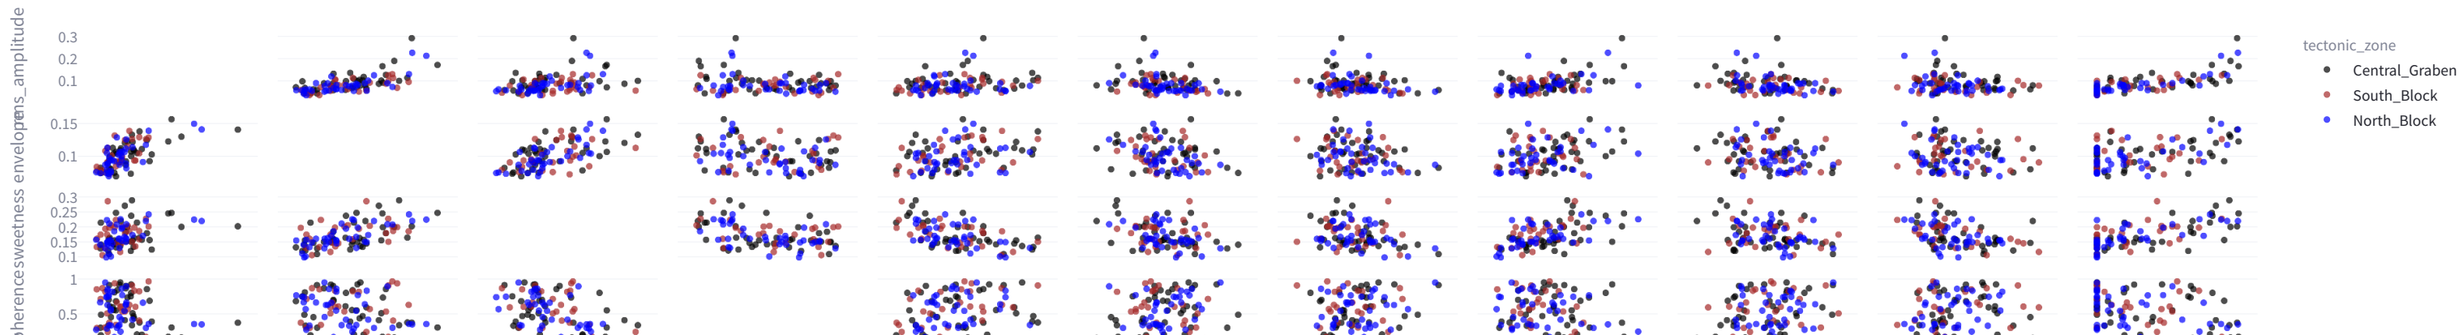
Pairplot: атрибуты и H_eff

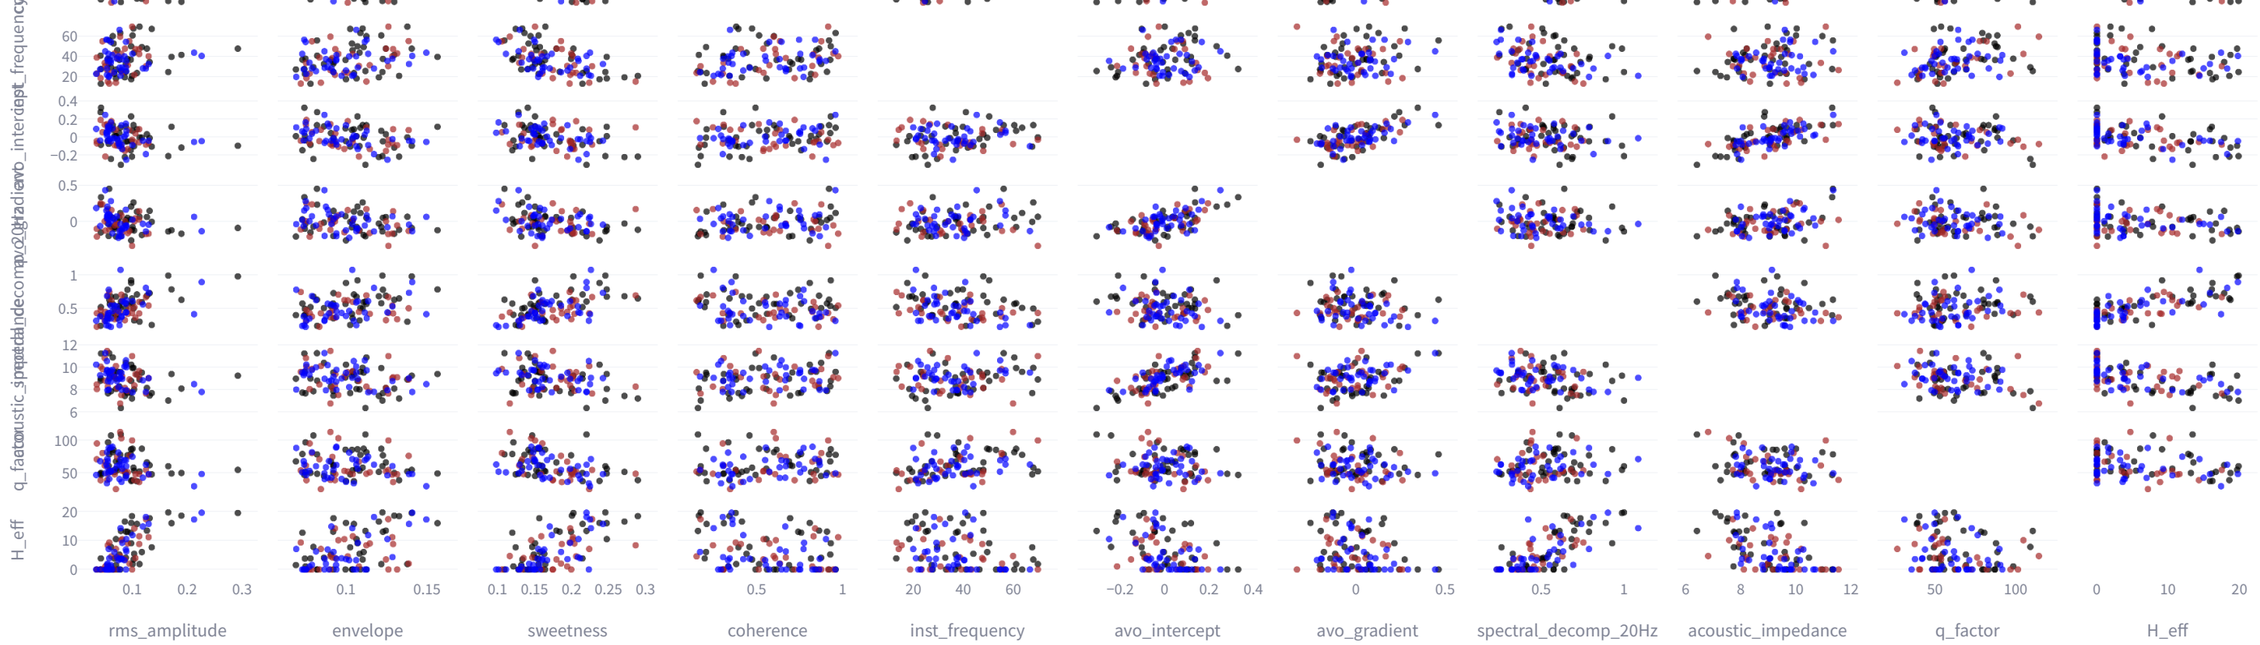
Для Pairplot рекомендуется выбирать не более 10 параметров.

Показать Pairplot

Plotly Pairplot: поддерживаются интерактивность, масштабирование и hover. KDE и гистограммы на диагонали доступны только для Seaborn Pairplot.

Plotly Pairplot, количество параметров: (11)





Pairplot: атрибуты и Phi

Для Pairplot рекомендуется выбирать не более 10 параметров.

Показать Pairplot

Статистика числовых параметров

Статистика: H_eff

Кол-во бинов гистограммы: H_eff

40

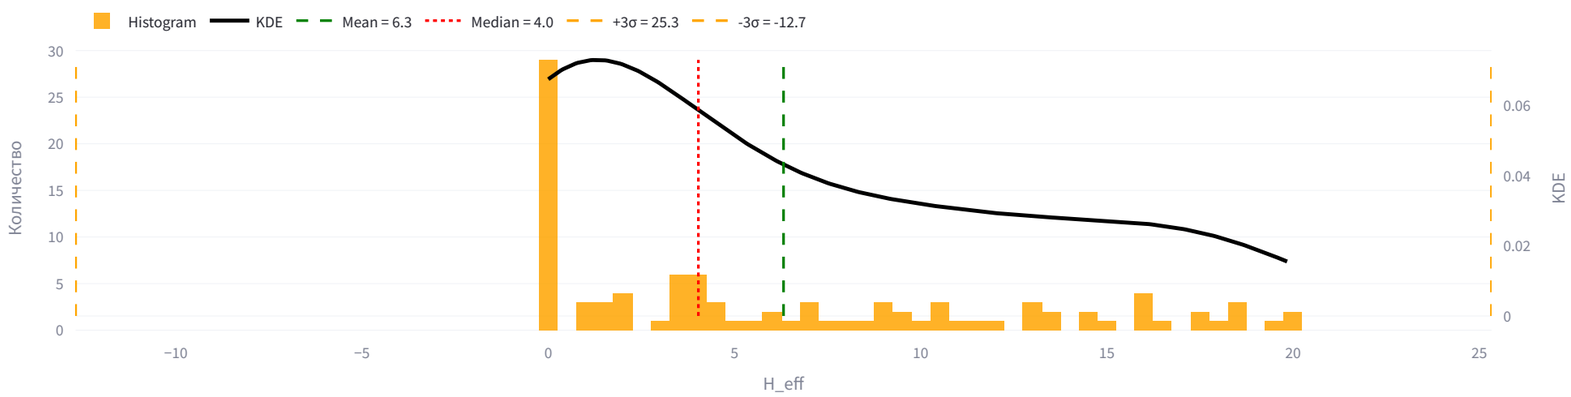
10 120

Нормализация гистограммы: H_eff

нет

H_eff

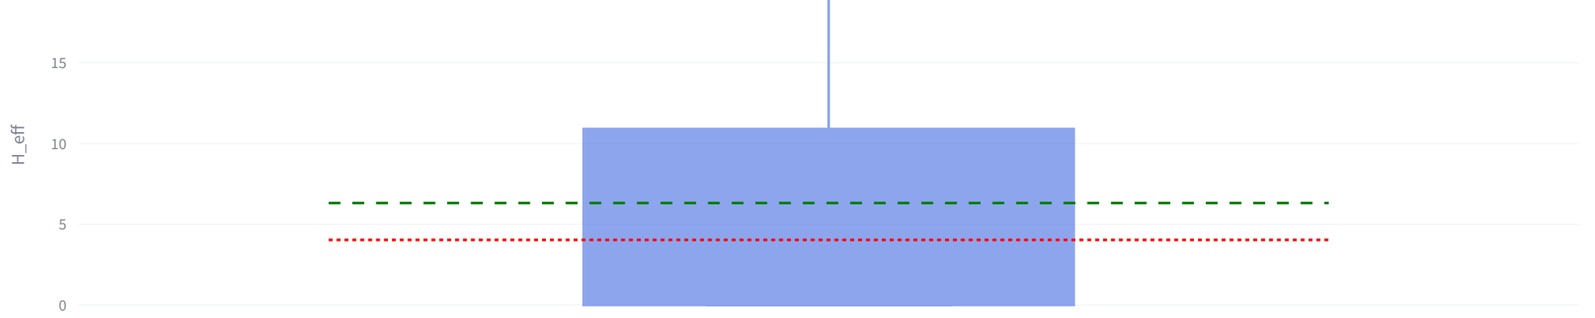
Гистограмма: H_eff



Boxplot: H_eff



	H_eff
Count	100.00
μ, mean	6.32
median	4.03
mode	0.00
σ, std	6.34
variance	40.15
CV %	100.31
min	0.00
Q05	0.00
Q25	0.00



Скачать в Excel

Статистика: Phi

Статистика: rms_amplitude

Статистика: envelope

Статистика: sweetness

Статистика: coherence

Статистика: inst_frequency

Статистика: avo_intercept

Статистика: avo_gradient

Статистика: spectral_decomp_20Hz

Кол-во бинов гистограммы: spectral_decomp_20Hz

40

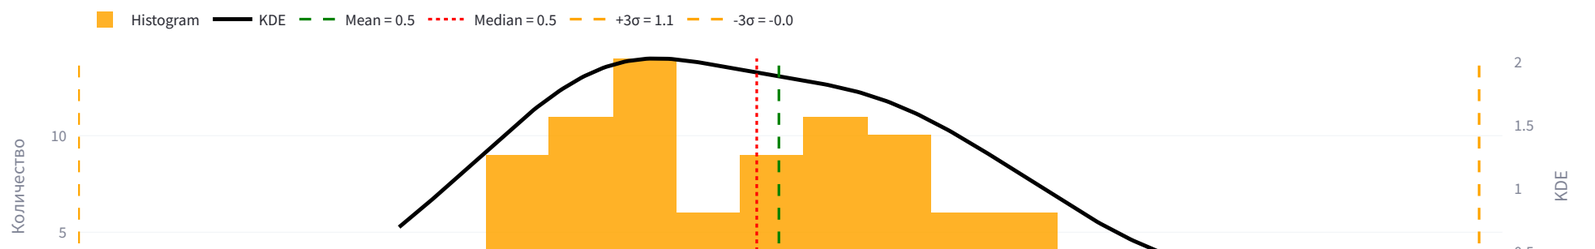
10 120

Нормализация гистограммы: spectral_decomp_20Hz

нет

spectral_decomp_20Hz

Гистограмма: spectral_decomp_20Hz

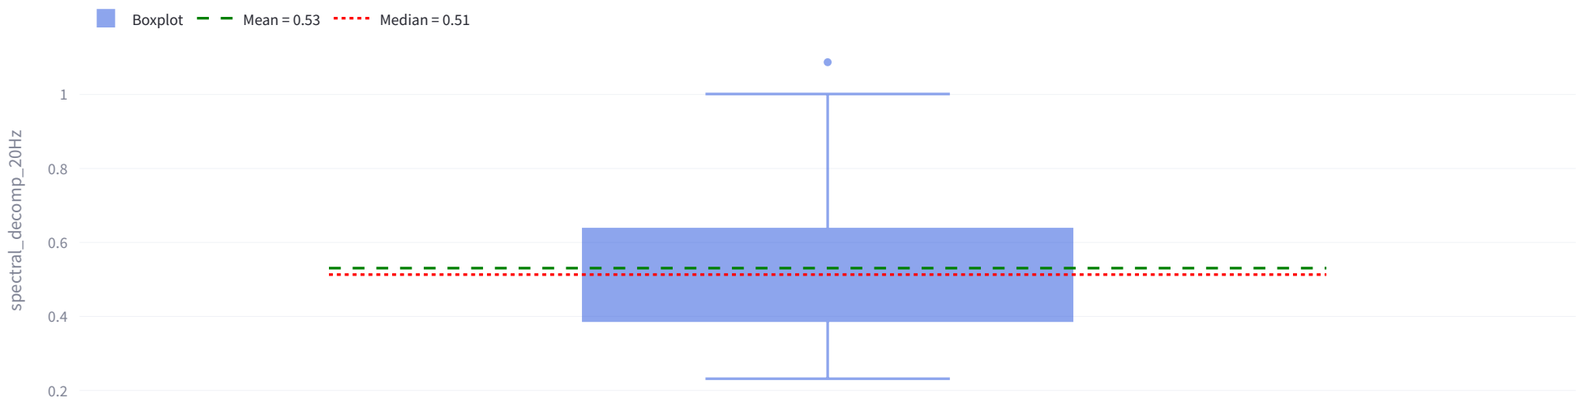


	spectral_decomp_20Hz
Count	100.00
μ, mean	0.53
median	0.51
mode	0.39
σ, std	0.18
variance	0.03
CV %	34.62
min	0.23
Q05	0.26
Q25	0.39

Скачать в Excel



Boxplot: spectral_decomp_20Hz



Статистика: acoustic_impedance

Статистика: q_factor

Статистика: X_coord

Статистика: Y_coord

Выбор параметров

Параметр 1 (эталонный): H_eff

Параметр 2 (сравниваемый): rms_amplitude

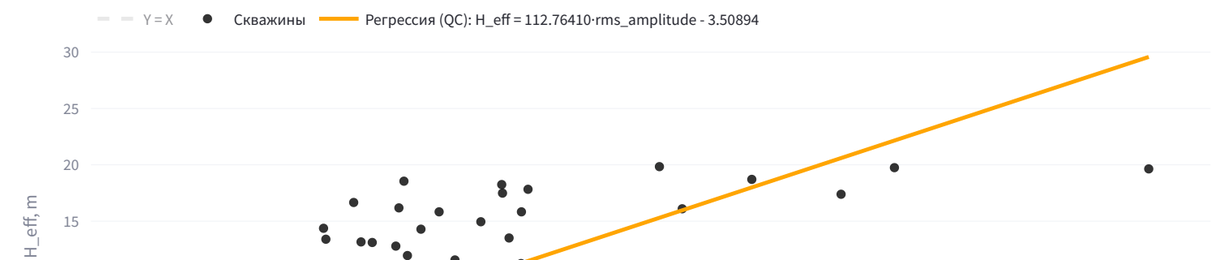
Единицы параметра 2: units

Шаг 1 · QC-анализ зависимости H_eff vs rms_amplitude

QC кросс-плот

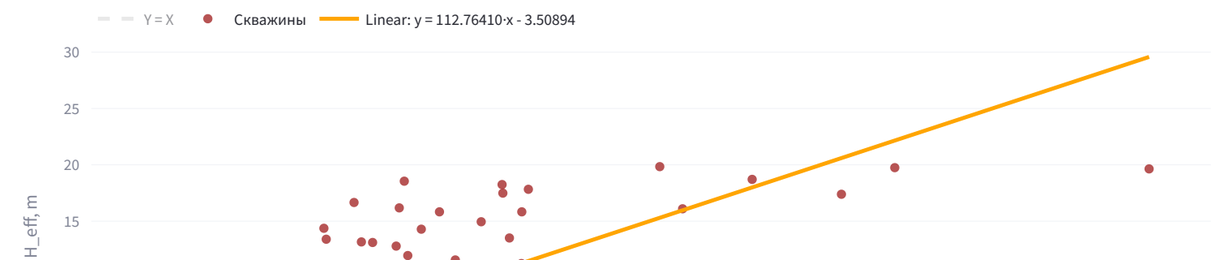
Кросс-плот: H_eff vs rms_amplitude

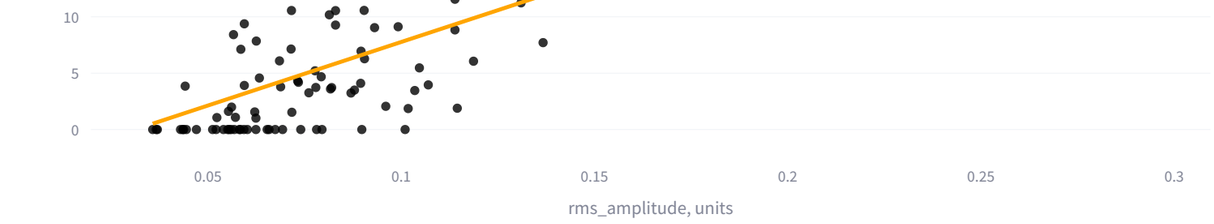
QC cross-plot: H_eff vs rms_amplitude

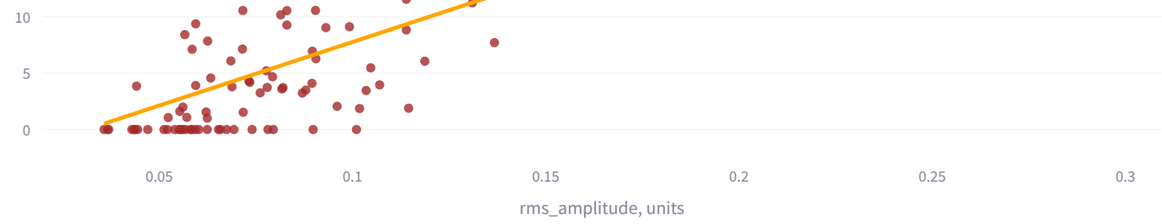


Аппроксимации: H_eff vs rms_amplitude

QC cross-plot approx: H_eff vs rms_amplitude







Метрики QC кросс-плота: H_eff vs rms_amplitude

	R^2_lin	r	RMSE	MSE	MAE	Bias	Std	Variance	WAPE %	P-value	Equation
0	0.5359	0.7321	8.8423	78.1860	6.2640	6.2300	6.3064	39.7713	99.1588	5.02265e-18	H_eff = 112.76410·rms_amplitude + -3.50894

Δ на Шаге 1 = PARAM_1 − PARAM_2 (эталон минус атрибут): положительная Δ означает, что PARAM_1 выше PARAM_2.

Скачать в Excel

Сравнение метрик аппроксимаций: H_eff vs rms_amplitude

	Approximation	R^2_fit	r	RMSE	MSE	MAE	Bias	Std	Variance	WAPE %	Equation	n_fit
0	Linear	0.5359	0.7321	4.2951	18.4478	3.5252	-0.0000	4.3167	18.6342	55.8042	y = 112.76410·x - 3.50894	100

Скачать в Excel

Распределение параметров H_eff , rms_amplitude

Кол-во бинов гистограммы: H_eff, rms_amplitude

40

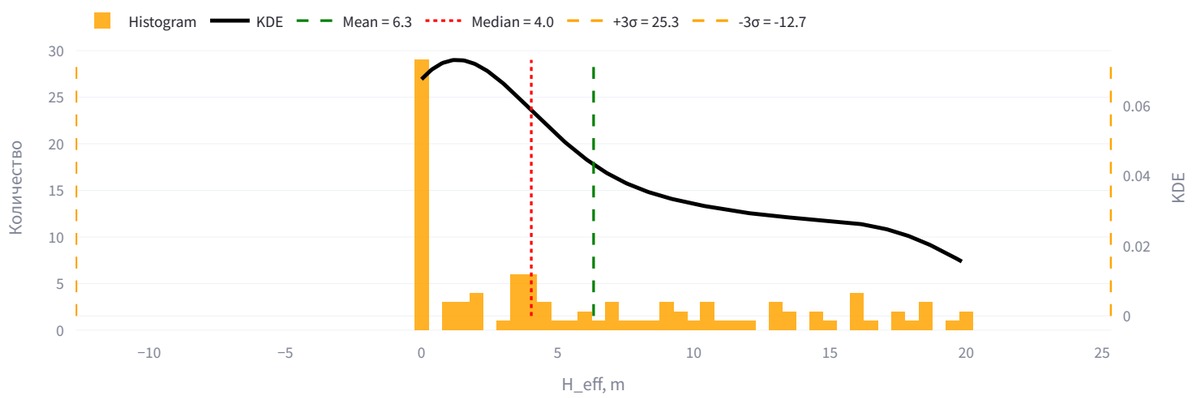
10 120

Нормализация гистограммы: H_eff, rms_amplitude

нет

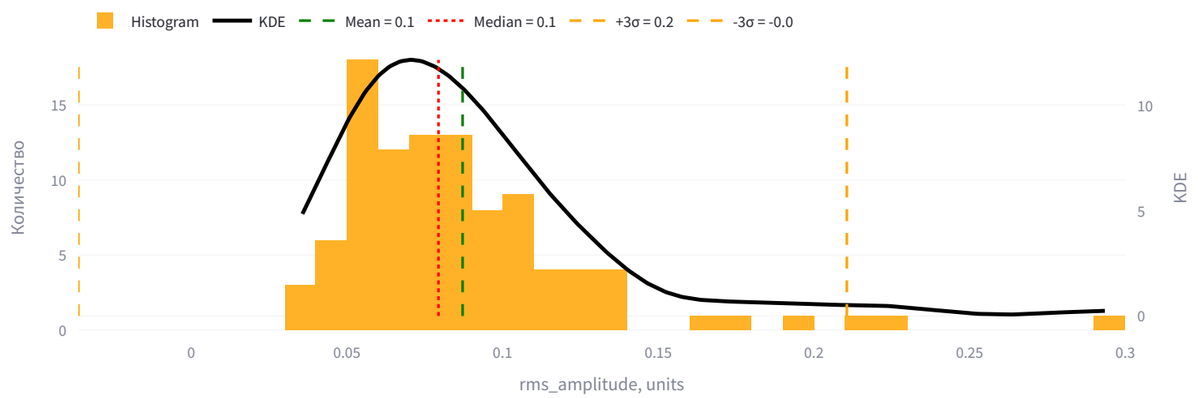
Гистограмма: H_eff

Гистограмма: H_eff



Гистограмма: rms_amplitude

Гистограмма: rms_amplitude



Boxplot: H_eff

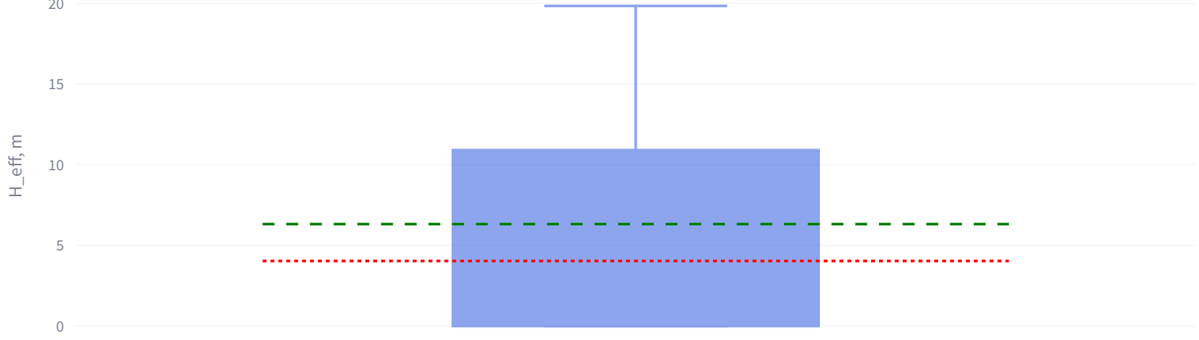
Boxplot: H_eff



Boxplot: rms_amplitude

Boxplot: rms_amplitude







Шаг 2 · Кросс-валидация (CV): H_eff vs rms_amplitude

Выбор лучшей CV

Схемы CV покрывают разное число точек: 95–100. Сравнивать их напрямую не совсем корректно.

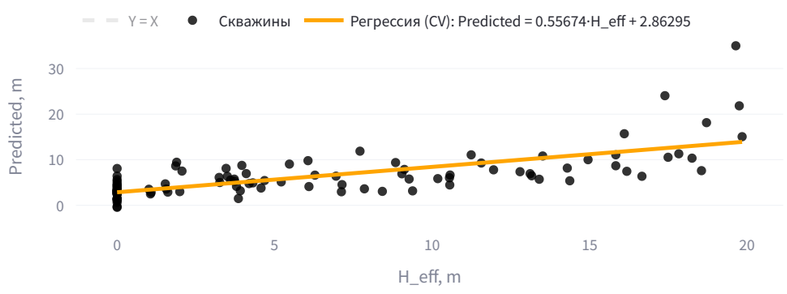
Критерий выбора лучшей схемы CV

RMSE + RMSE_fold_Std (по умолчанию)

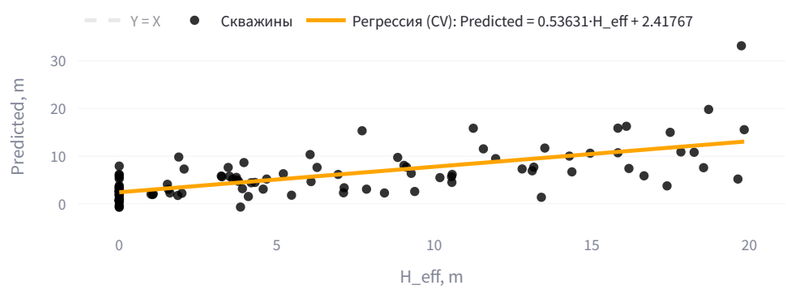
Кросс-плот: Прогноз vs Факт для всех схем кросс-валидации

Схемы упорядочены от самой оптимистичной (Random K-Fold) к самой объективной (Distance-based exclusion CV). Обратите внимание, как меняется форма облака и метрики. Схема со значком ⭐ показана как лучшая.

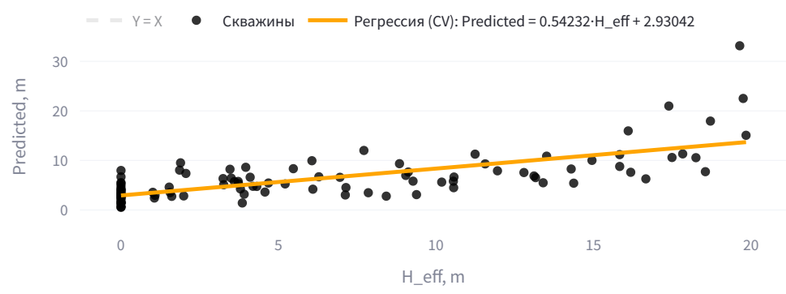
Random K-Fold



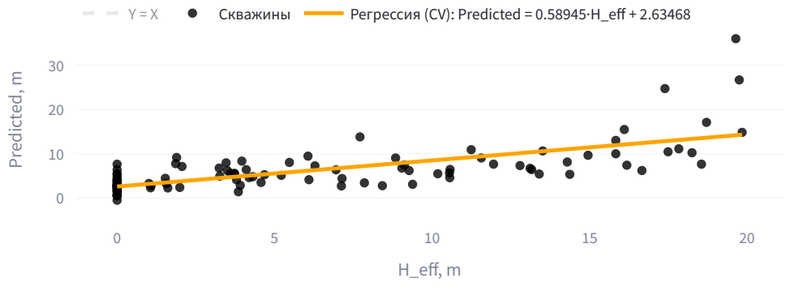
Random K-Fold (buffered)



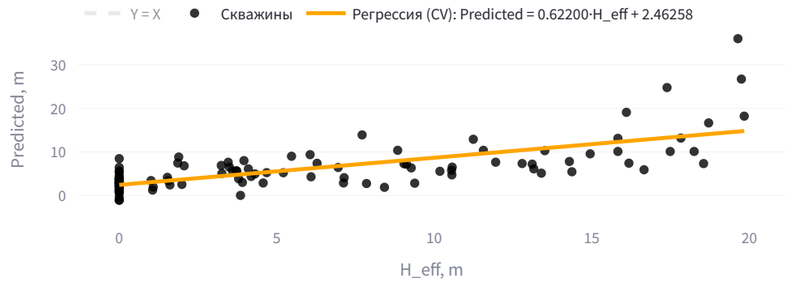
Leave-One-Well-Out



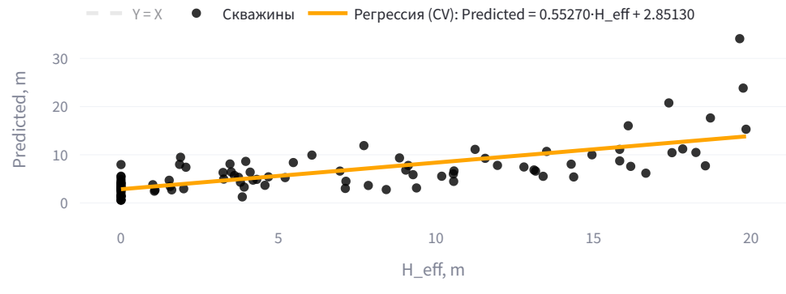
⭐ Block CV



Buffered CV



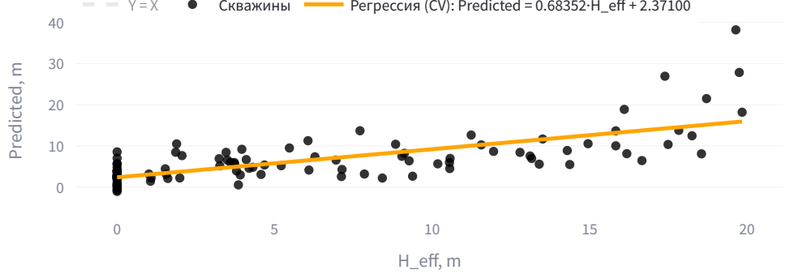
Leave-P-Out

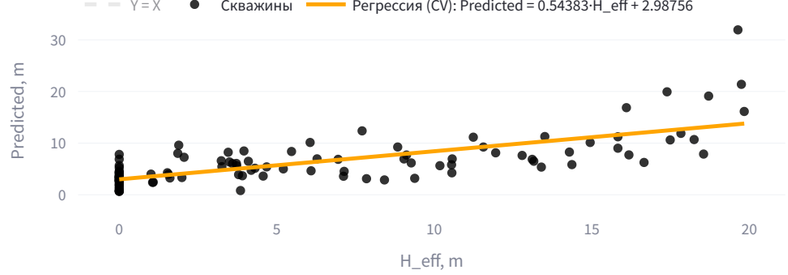


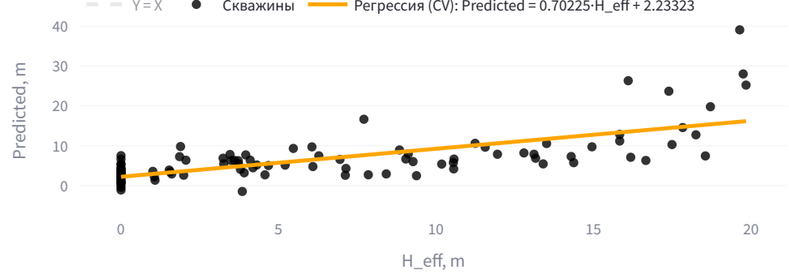
Spatial Leave-P-Out

Stratified by tectonic_zone

Distance-based exclusion CV







Метрики кросс-плота Прогноз vs Факт для всех схем кросс-валидации

	CV scheme	R^2 (Pearson, Predicted vs Actual)	r (Pearson, Predicted vs Actual)	RMSE	MSE	MAE	Bias	Std	Variance	WAPE %	P-value	Equation
0	Random K-Fold	0.4892	0.6995	4.5471	20.6765	3.6563	0.0628	4.5696	20.8814	57.8787	5.73500e-16	Predicted = 0.55674·Actual + 2.86295
1	Random K-Fold (buffered)	0.4509	0.6715	4.7677	22.7311	3.5520	-0.5115	4.7641	22.6965	56.2288	2.06933e-14	Predicted = 0.53631·Actual + 2.41767
2	Leave-One-Well-Out	0.5048	0.7105	4.4494	19.7975	3.6160	0.0392	4.4717	19.9959	57.2415	1.24375e-16	Predicted = 0.54232·Actual + 2.93042
3	Block CV	0.4887	0.6991	4.5988	21.1494	3.6656	0.0412	4.6218	21.3613	58.0274	6.02504e-16	Predicted = 0.58945·Actual + 2.63468
4	Buffered CV	0.4951	0.7037	4.6223	21.3652	3.6956	0.0747	4.6449	21.5754	58.5019	3.22554e-16	Predicted = 0.62200·Actual + 2.46258
5	Leave-P-Out	0.5000	0.7071	4.5477	20.6812	3.6953	-0.0473	4.5715	20.8989	57.0238	1.16058e-15	Predicted = 0.55270·Actual + 2.85130
6	Spatial Leave-P-Out	0.5109	0.7148	4.6795	21.8981	3.6462	0.3718	4.6883	21.9797	57.7198	6.72193e-17	Predicted = 0.68352·Actual + 2.37100
7	Stratified by tectonic_zone	0.5199	0.7211	4.3747	19.1377	3.5754	0.1059	4.3954	19.3196	56.5995	2.67534e-17	Predicted = 0.54383·Actual + 2.98756
8	Distance-based exclusion CV	0.5008	0.7076	4.8158	23.1916	3.7659	0.3523	4.8271	23.3004	59.6147	1.85500e-16	Predicted = 0.70225·Actual + 2.23323

Скачать в Excel

Колонка `score` рассчитана по критерию: **RMSE + RMSE_fold_Std (по умолчанию)**

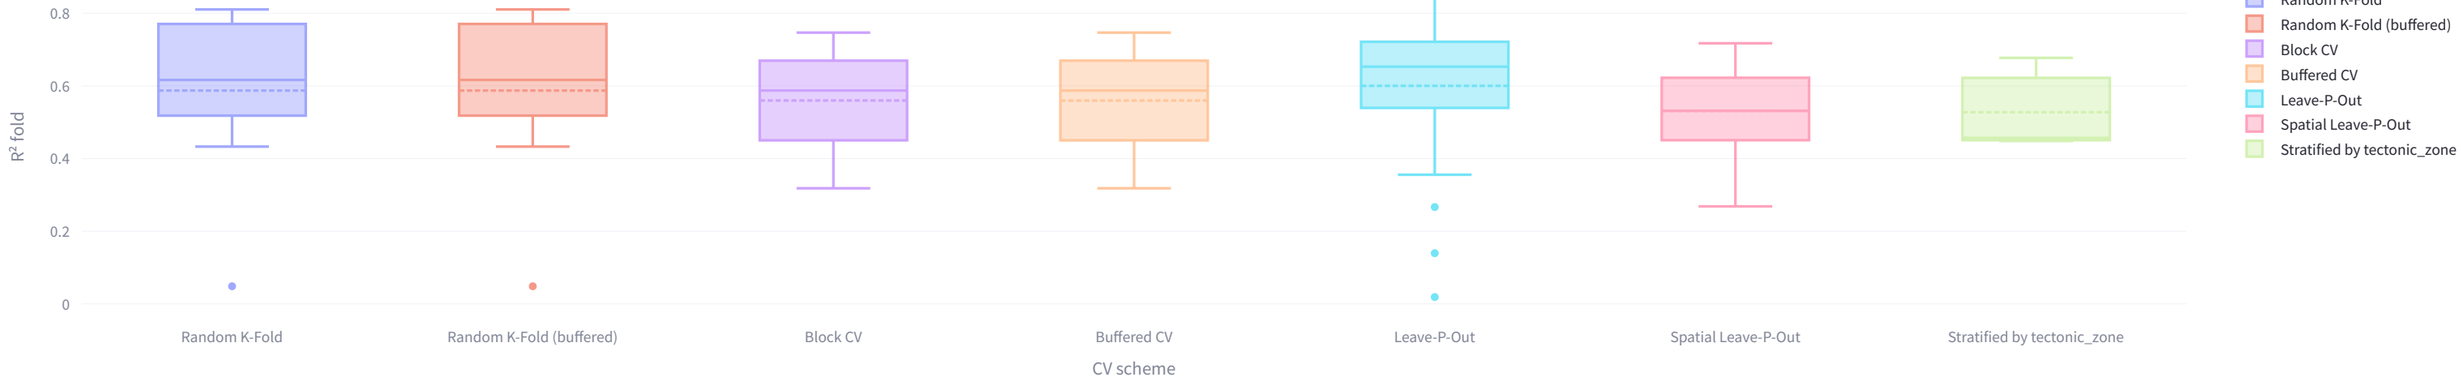
Таблица R^2 (Pearson) по фолдам по схемам CV

	CV scheme	n_pred	n_test_min	n_test_max	R^2 (Pearson, Predicted vs Actual)	r2_fold_min	r2_fold_max	r2_fold_std	r2_fold_mean	r2_fold_median
0	Random K-Fold	100	10	10	0.4892	0.0484	0.8103	0.2256	0.5871	0.6163
1	Random K-Fold (buffered)	100	10	10	0.4509	0.0484	0.8103	0.2256	0.5871	0.6163
2	Leave-One-Well-Out	100	1	1	0.5048	None	None	None	None	None
3	Block CV	100	21	29	0.4887	0.3181	0.7466	0.1778	0.5598	0.5872
4	Buffered CV	100	21	29	0.4951	0.3181	0.7466	0.1778	0.5598	0.5872
5	Leave-P-Out	95	10	10	0.5000	0.0188	0.8998	0.2056	0.6001	0.6528
6	Spatial Leave-P-Out	100	25	82	0.5109	0.2683	0.7173	0.1253	0.5312	0.5314
7	Stratified by tectonic_zone	100	26	38	0.5199	0.4485	0.6772	0.1297	0.5275	0.4568
8	Distance-based exclusion CV	100	1	1	0.5008	None	None	None	None	None

Скачать в Excel

Boxplot: Разброс R^2 (Pearson) по фолдам по схемам CV





Фолды с R^2 = NaN (меньше 3 точек или постоянные значения у или прогноза, например одноточечные фолды Leave-One-Well-Out и Distance-based CV) не показаны на boxplot и не входят в статистику.

Сравнение схем CV

	CV scheme	n_pred	n_test_min	n_test_max	R^2 (Actual = Predicted)	rmse	mae	bias	rmse_fold_mean	rmse_fold_median	rmse_fold_min	rmse_fold_max	rmse_fold_std	rmse_fold_range	score
0	Random K-Fold	100	10	10	0.4798	4.55	3.66	+0.06	4.42	4.44	3.11	6.49	1.12	3.38	5.67
1	Random K-Fold (buffered)	100	10	10	0.4281	4.77	3.55	-0.51	4.59	4.18	3.15	7.49	1.38	4.35	6.15
2	Leave-One-Well-Out	100	1	1	0.5019	4.45	3.62	+0.04	3.62	3.09	0.02	13.50	2.61	13.48	7.06
3	Block CV	100	21	29	0.4679	4.60	3.67	+0.04	4.59	4.60	3.75	5.42	0.68	1.67	5.28
4	Buffered CV	100	21	29	0.4625	4.62	3.70	+0.07	4.62	4.63	3.73	5.47	0.71	1.74	5.33
5	Leave-P-Out	95	10	10	0.4944	4.55	3.70	-0.05	4.43	4.31	2.87	6.11	0.83	3.24	5.38
6	Spatial Leave-P-Out	100	25	82	0.4491	4.68	3.65	+0.37	4.84	4.66	4.09	7.07	0.70	2.99	5.38
7	Stratified by tectonic_zone	100	26	38	0.5185	4.37	3.58	+0.11	4.23	3.77	3.61	5.32	0.94	1.70	5.32
8	Distance-based exclusion CV	100	1	1	0.4166	4.82	3.77	+0.35	3.77	3.04	0.05	19.41	3.02	19.36	7.83

Скачать в Excel

Boxplot: линия внутри бокса показывает медиану, пунктирная линия показывает среднее значение.

Boxplot: Разброс RMSE по фолдам по схемам CV



Таблица фолдов по схемам CV

Random K-Fold

	Fold	n_train	n_test	RMSE_fold, m	MAE_fold, m	Bias_fold, m
0	fold_1	90	10	6.4864	4.8372	3.1585
1	fold_2	90	10	3.1096	2.9673	-0.3341
2	fold_3	90	10	5.946	4.889	-1.8159
3	fold_4	90	10	4.8457	4.1746	-0.0332
4	fold_5	90	10	4.4861	3.9207	-1.045
5	fold_6	90	10	3.2471	2.8281	-0.7996
6	fold_7	90	10	4.3872	3.3247	-1.2532
7	fold_8	90	10	4.5061	3.9208	1.9049
8	fold_9	90	10	3.7936	2.7428	0.1526
9	fold_10	90	10	3.402	2.9574	0.6933

Скачать в Excel

Random K-Fold (buffered)

	Fold	n_train	n_test	RMSE_fold, m	MAE_fold, m	Bias_fold, m
0	buf_fold_1	4	10	7.4949	4.9452	-4.3483
1	buf_fold_2	4	10	3.1942	2.7959	-1.124
2	buf_fold_3	17	10	5.814	4.7061	-2.1017
3	buf_fold_4	18	10	4.8556	3.9393	-0.5619
4	buf_fold_5	19	10	3.7394	3.2996	-0.3134
5	buf_fold_6	28	10	3.6582	2.6912	-0.3173
6	buf_fold_7	8	10	5.5934	4.0533	1.7365
7	buf_fold_8	26	10	4.4147	3.7571	1.5632
8	buf_fold_9	13	10	3.9367	2.7369	0.1399
9	buf_fold_10	15	10	3.149	2.5956	0.2122

Скачать в Excel

Leave-One-Well-Out

	Fold	n_train	n_test	RMSE_fold, m	MAE_fold, m	Bias_fold, m
0	W-001	99	1	2.8613	2.8613	2.8613
1	W-002	99	1	0.5844	0.5844	0.5844
2	W-003	99	1	6.2824	6.2824	-6.2824
3	W-004	99	1	0.5304	0.5304	0.5304
4	W-005	99	1	3.4544	3.4544	-3.4544
5	W-006	99	1	1.4497	1.4497	1.4497
6	W-007	99	1	3.0891	3.0891	3.0891
7	W-008	99	1	2.2573	2.2573	-2.2573
8	W-009	99	1	6.0192	6.0192	-6.0192
9	W-010	99	1	4.302	4.302	4.302

Скачать в Excel

Block CV

	Fold	n_train	n_test	RMSE_fold, m	MAE_fold, m	Bias_fold, m
0	block_0	79	21	4.5749	3.8563	-0.793
1	block_1	71	29	4.6258	3.3476	1.7338
2	block_2	77	23	5.4202	4.6229	-0.574
3	block_3	73	27	3.7474	3.0435	-0.6039

Скачать в Excel

Buffered CV

	Fold	n_train	n_test	RMSE_fold, m	MAE_fold, m	Bias_fold, m
0	buffered_block_0	51	21	4.6276	3.9294	-0.7588
1	buffered_block_1	46	29	4.6396	3.4034	1.8494
2	buffered_block_2	57	23	5.4671	4.5676	-0.8865
3	buffered_block_3	49	27	3.7273	3.0848	-0.3642

Скачать в Excel

Leave-P-Out

	Fold	n_train	n_test	RMSE_fold, m	MAE_fold, m	Bias_fold, m
0	1	90	10	3.5287	3.0177	0.8927
1	2	90	10	6.1107	4.8833	2.7003
2	3	90	10	5.2242	4.4038	-3.6941
3	4	90	10	3.3036	2.9978	1.931
4	5	90	10	4.0432	3.6741	2.9194
5	6	90	10	3.8873	2.8203	1.2093
6	7	90	10	4.2892	3.7807	0.8392
7	8	90	10	4.7421	4.0253	-2.9951
8	9	90	10	5.2421	4.483	0.0907
9	10	90	10	3.9955	3.2566	0.42

Скачать в Excel

Spatial Leave-P-Out

	Fold	n_train	n_test	RMSE_fold, m	MAE_fold, m	Bias_fold, m
0	1	18	82	5.6554	4.0552	1.2662
1	2	37	63	4.6618	3.6859	-0.5305
2	3	68	32	4.0917	3.3431	-0.8226
3	4	73	27	4.9308	3.9304	-1.2855
4	5	73	27	4.9308	3.9304	-1.2855
5	6	52	48	4.7043	3.8995	-0.5326
6	7	18	82	5.6554	4.0552	1.2662
7	8	44	56	4.6585	3.6456	0.0048
8	9	41	59	4.9325	3.8161	-0.6118
9	10	43	57	4.5156	3.6384	1.0312

Скачать в Excel

Stratified by tectonic_zone

	Fold	n_train	n_test	RMSE_fold, m	MAE_fold, m	Bias_fold, m
0	Central_Graben	62	38	5.3165	4.3989	-0.3428
1	North_Block	64	36	3.6119	3.0866	0.7875
2	South_Block	74	26	3.7725	3.0489	-0.182

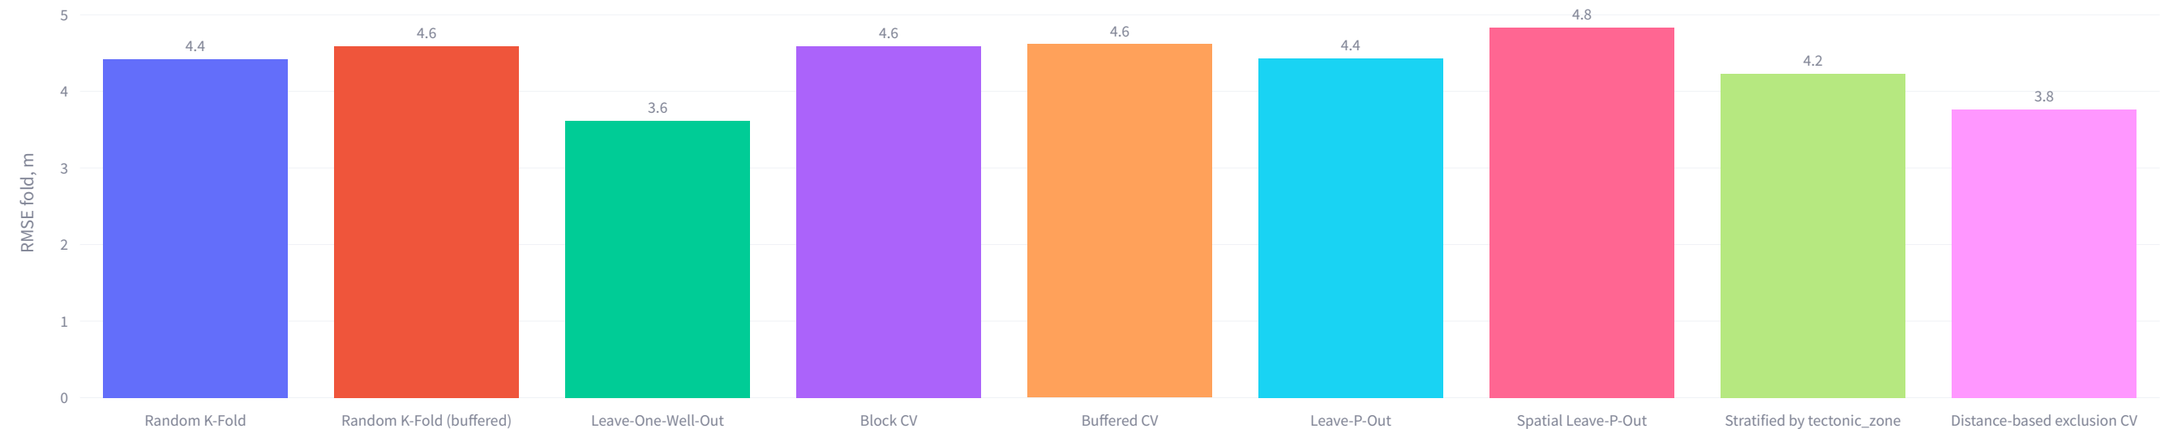
Скачать в Excel

Distance-based exclusion CV

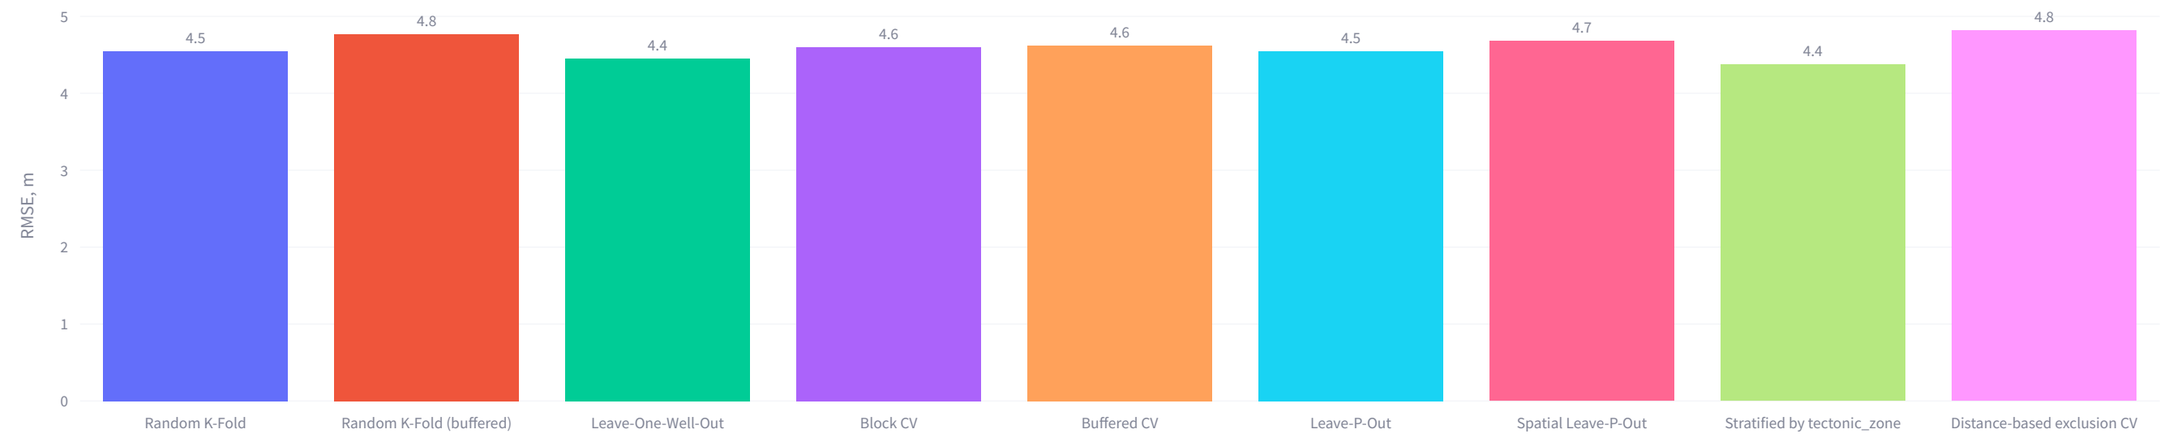
	Fold	n_train	n_test	RMSE_fold, m	MAE_fold, m	Bias_fold, m
0	dist_excl_0	53	1	3.8691	3.8691	3.8691
1	dist_excl_1	53	1	0.2957	0.2957	0.2957
2	dist_excl_2	41	1	6.8759	6.8759	-6.8759
3	dist_excl_3	54	1	3.2355	3.2355	-3.2355
4	dist_excl_4	55	1	1.3028	1.3028	1.3028
5	dist_excl_5	60	1	2.9637	2.9637	2.9637
6	dist_excl_6	49	1	1.9008	1.9008	-1.9008
7	dist_excl_7	48	1	6.9737	6.9737	-6.9737
8	dist_excl_8	18	1	8.9398	8.9398	8.9398
9	dist_excl_9	43	1	3.6457	3.6457	3.6457

Скачать в Excel

RMSE по фолдам (среднее) по схемам CV



RMSE по схемам CV

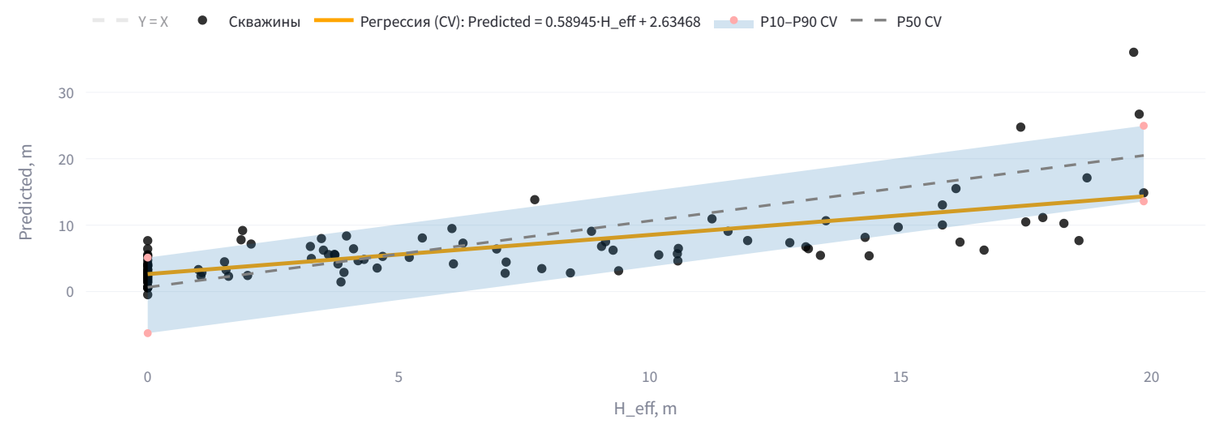


Лучшая схема CV: **Block CV** (RMSE=4.60, Std=0.68)

QC кросс-плот лучшей CV

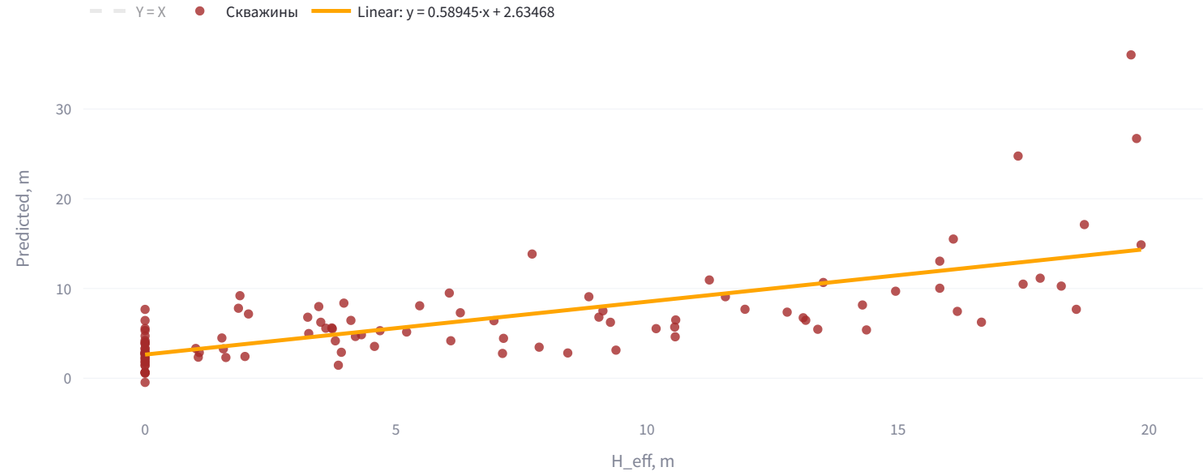
Кросс-плот: Прогноз vs Факт — Block CV

Cross-plot Predicted vs Actual (Block CV)



Аппроксимации: Прогноза vs Факта — Block CV

Cross-plot approx (Block CV)



Метрики кросс-плота Прогноз vs Факт — Block CV

	R^2 (Pearson, Predicted vs Actual)	r (Pearson, Predicted vs Actual)	RMSE	MSE	MAE	Bias	Std	Variance	WAPE %	P-value	Equation
0	0.4887	0.6991	4.5988	21.1494	3.6656	0.0412	4.6218	21.3613	58.0274	6.02504e-16	Predicted = 0.58945·Actual + 2.63468

Δ в аппроксимациях и метриках CV = Predicted − Actual (предсказание минус факт). Положительный Bias означает, что модель завышает значение.

Скачать в Excel

Сравнение метрик выбранных кривых аппроксимации — Block CV

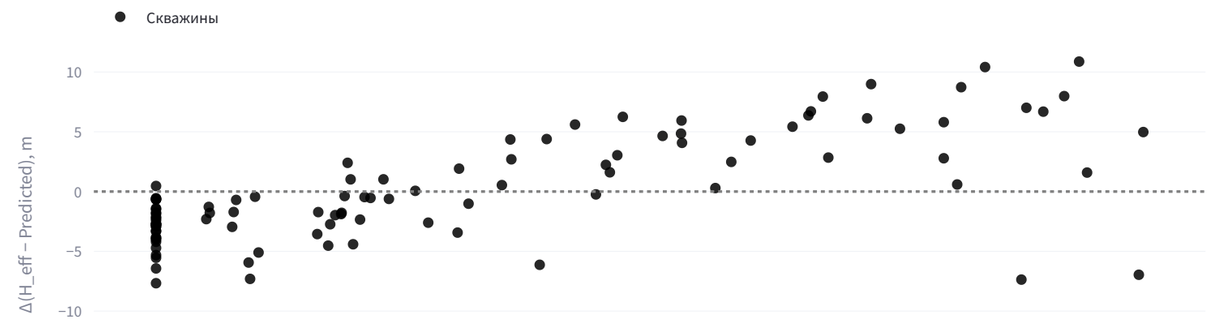
	Approximation	R^2_fit	r	RMSE	MSE	MAE	Bias	Std	Variance	WAPE %	Equation	n_fit
0	Linear	0.4887	0.6991	3.8010	14.4478	2.4669	-0.0000	3.8202	14.5938	38.7414	y = 0.58945·x + 2.63468	100

Скачать в Excel

Невязки CV (Δ(H_eff − Predicted))

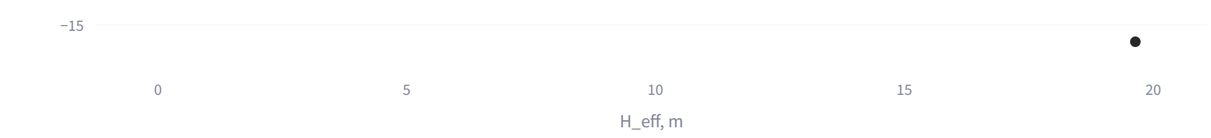
Зависимость CV-невязки Δ (Δ(H_eff − Predicted)) vs H_eff

CV Δ(Δ(H_eff − Predicted)) vs H_eff



Статистика CV-невязок Δ (Δ(H_eff − Predicted))

Графики CV-невязок и карта невязок: Actual − Predicted (факт минус предсказание). Положительная невязка означает, что модель занижает значение.



	Metrics	Value
0	Count	100.0000
1	μ, mean	-0.0412
2	median	-0.6507
3	mode	-16.3901
4	σ, std	4.6218
5	variance	21.3613
6	RMSE	4.5988
7	min	-16.3901
8	Q05	-6.4591
9	Q25	-2.7865

Скачать в Excel

Кол-во бинов гистограммы: CV

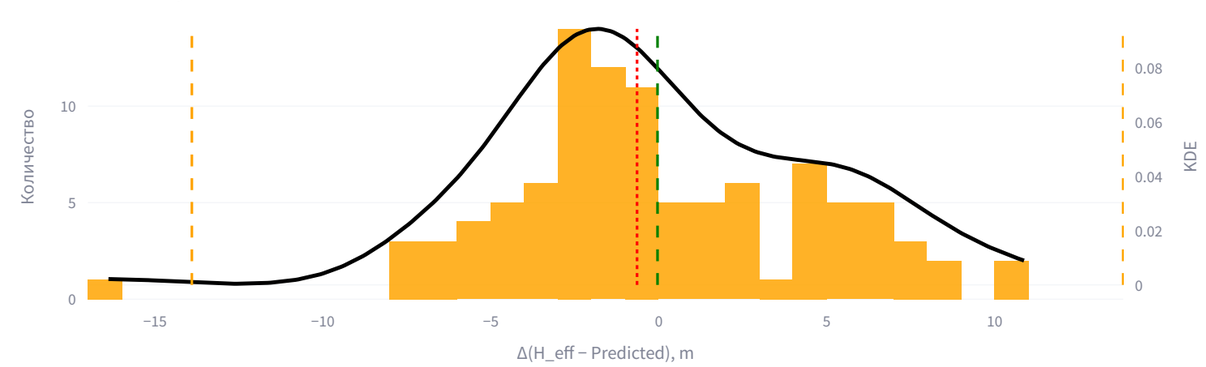
40

10 120

Нормализация гистограммы: CV

нет

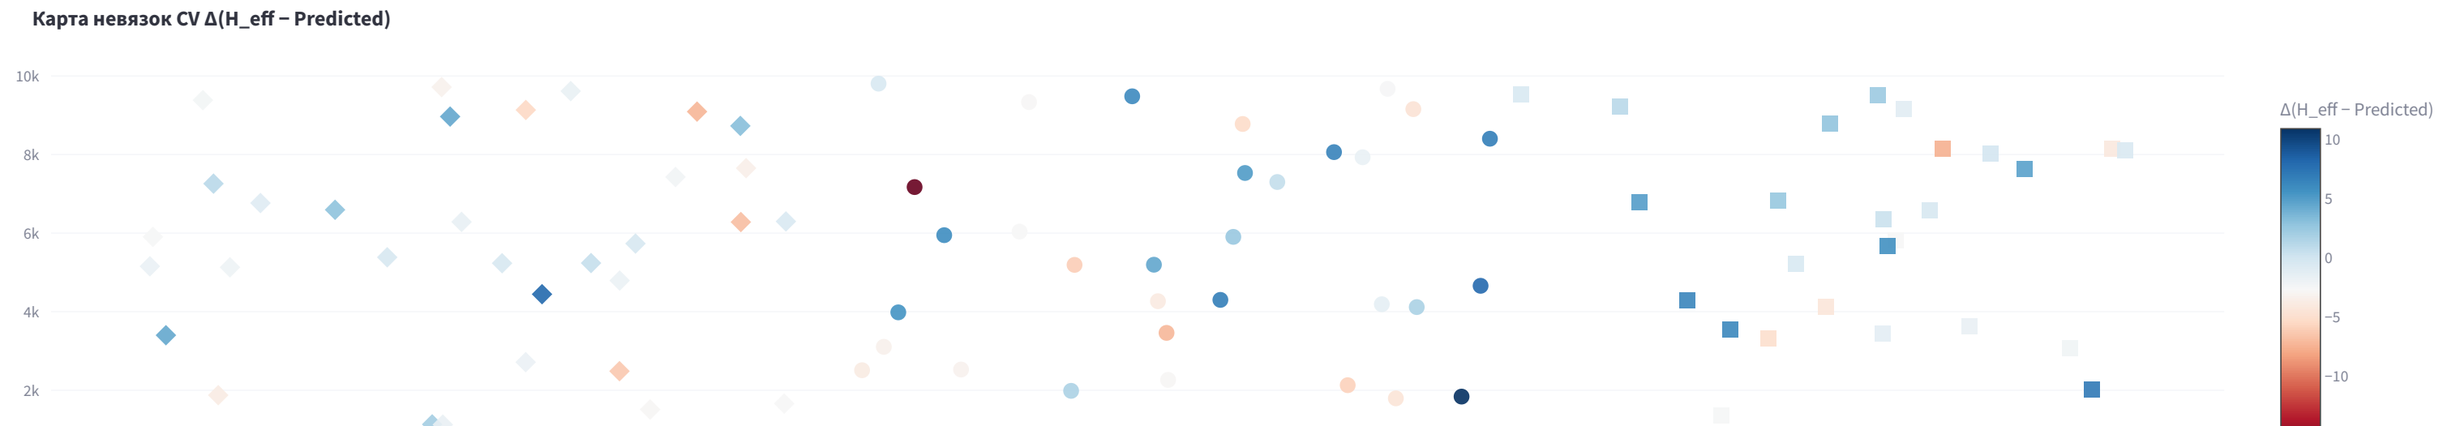
Гистограмма: CV (Δ(H_eff − Predicted))

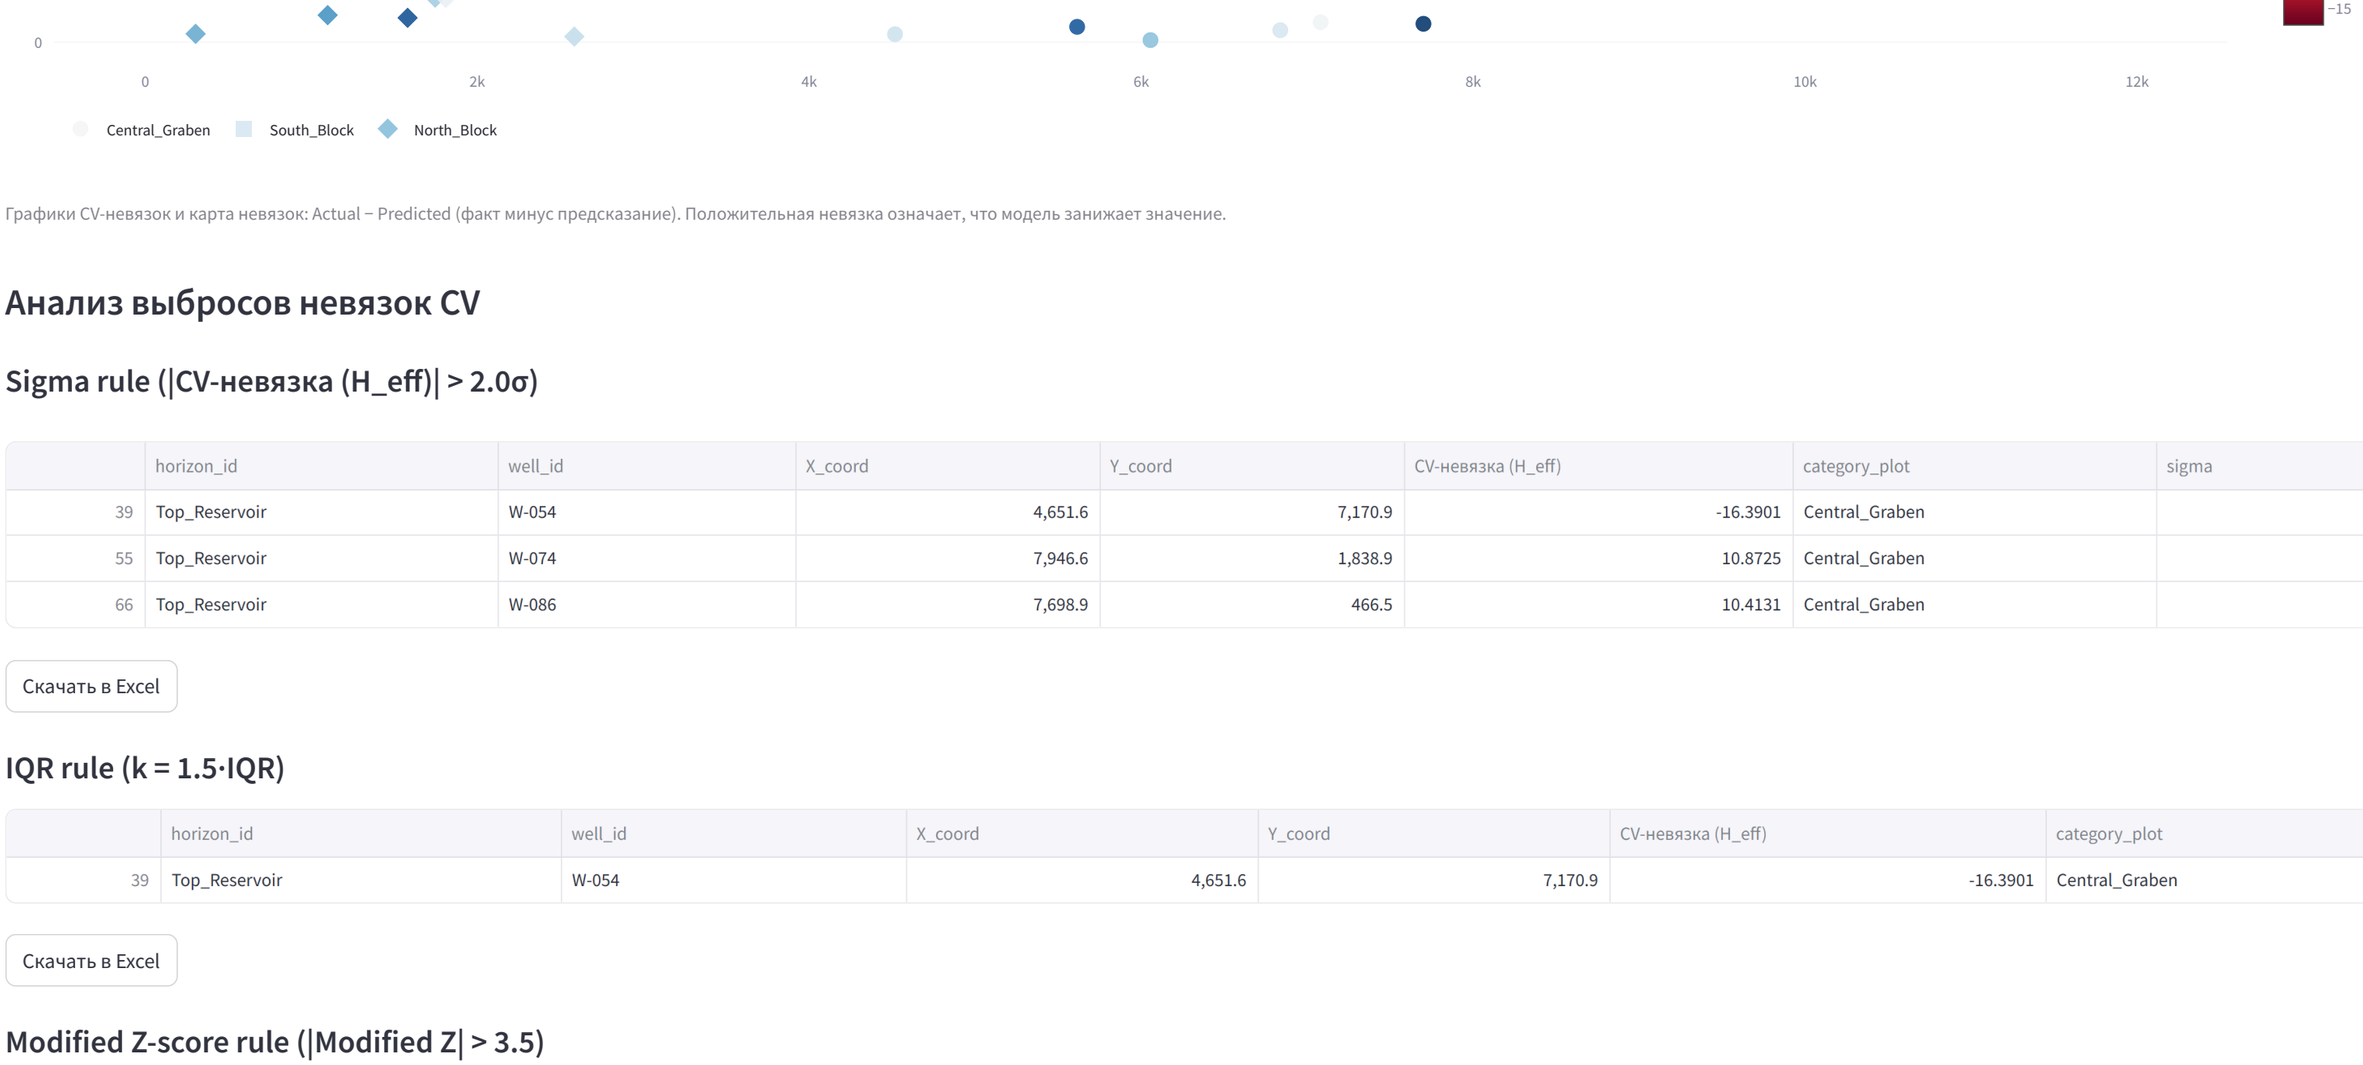


Boxplot: CV (Δ(H_eff − Predicted))



Пространственное распределение невязок CV Δ(H_eff − Predicted)





Графики CV-невязок и карта невязок: Actual – Predicted (факт минус предсказание). Положительная невязка означает, что модель занижает значение.

Анализ выбросов невязок CV

Sigma rule (|CV-невязка (H_eff)| > 2.0σ)

	horizon_id	well_id	X_coord	Y_coord	CV-невязка (H_eff)	category_plot	sigma
39	Top_Reservoir	W-054	4,651.6	7,170.9	-16.3901	Central_Graben	-3.5462
55	Top_Reservoir	W-074	7,946.6	1,838.9	10.8725	Central_Graben	2.3524
66	Top_Reservoir	W-086	7,698.9	466.5	10.4131	Central_Graben	2.253

Скачать в Excel

IQR rule (k = 1.5·IQR)

	horizon_id	well_id	X_coord	Y_coord	CV-невязка (H_eff)	category_plot
39	Top_Reservoir	W-054	4,651.6	7,170.9	-16.3901	Central_Graben

Скачать в Excel

Modified Z-score rule (|Modified Z| > 3.5)

	horizon_id	well_id	X_coord	Y_coord	CV-невязка (H_eff)	category_plot
39	Top_Reservoir	W-054	4,651.6	7,170.9	-16.3901	Central_Graben

Скачать в Excel

Percentile rule (Q05-Q95)

	horizon_id	well_id	X_coord	Y_coord	CV-невязка (H_eff)	category_plot
10	Top_Reservoir	W-012	3,341.1	9,091.8	-7.3674	North_Block
23	Top_Reservoir	W-030	6,169.4	3,460.6	-7.306	Central_Graben
26	Top_Reservoir	W-036	2,407.3	4,444.8	7.982	North_Block
39	Top_Reservoir	W-054	4,651.6	7,170.9	-16.3901	Central_Graben
54	Top_Reservoir	W-072	3,605	6,281	-6.9617	North_Block
55	Top_Reservoir	W-074	7,946.6	1,838.9	10.8725	Central_Graben
56	Top_Reservoir	W-075	1,579.4	618.7	8.9863	North_Block
59	Top_Reservoir	W-078	10,847	8,152.2	-7.6696	South_Block
66	Top_Reservoir	W-086	7,698.9	466.5	10.4131	Central_Graben
72	Top_Reservoir	W-093	5,612.8	389.9	8.7303	Central_Graben

Скачать в Excel

Шаг 3 · Анализ параметров по категориям: tectonic_zone (H_eff vs rms_amplitude)

Распределение параметров по категориям: tectonic_zone (H_eff vs rms_amplitude)

Количество скважин по категориям : tectonic_zone



Количество скважин по категориям : tectonic_zone





Таблица статистики по категориям

tectonic_zone	Скважин	Записей (скважина-горизонт)	Доля скважин, %
Central_Graben	38	38	38
North_Block	36	36	36
South_Block	26	26	26

Скачать в Excel

Статистика параметров по категориям: tectonic_zone (H_eff vs rms_amplitude)

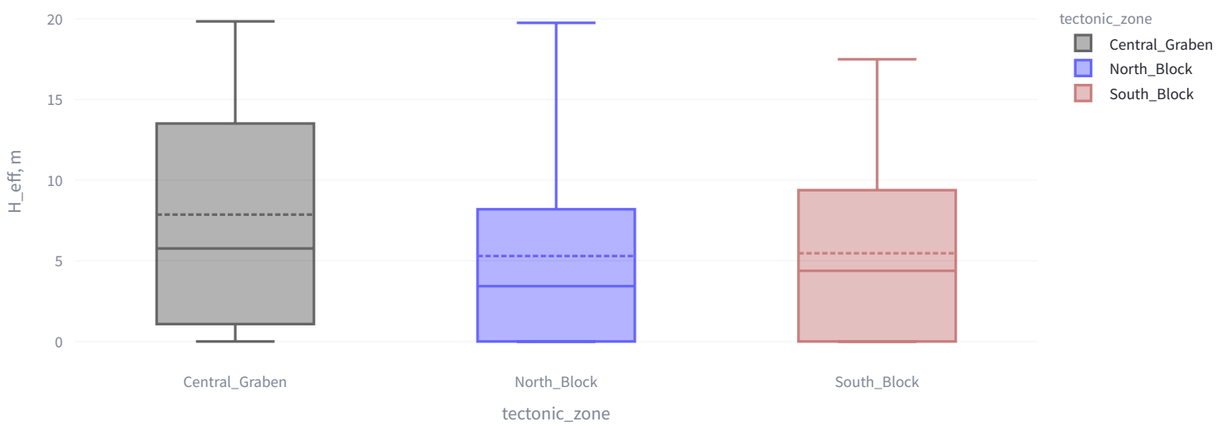
tectonic_zone: Central_Graben

tectonic_zone: North_Block

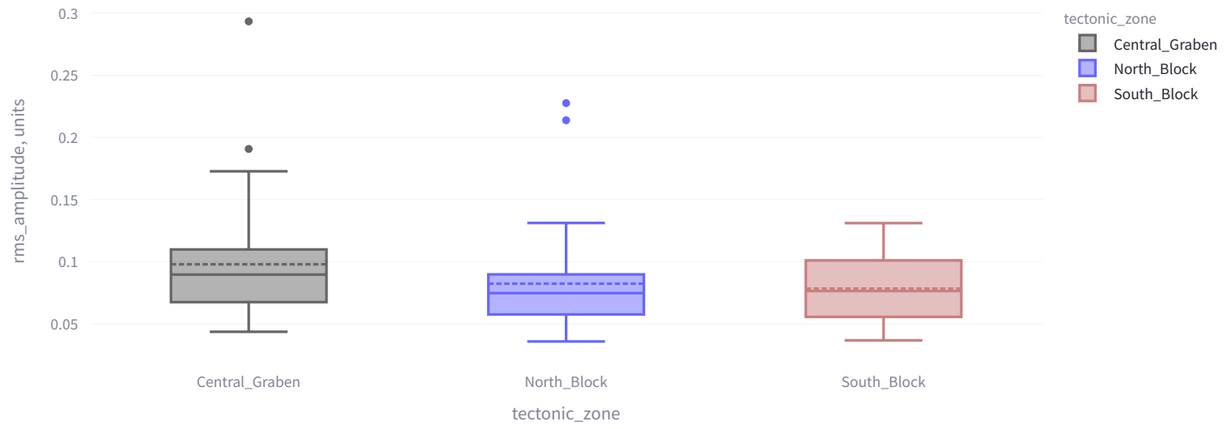
tectonic_zone: South_Block

Boxplot: линия внутри бокса показывает медиану, пунктирная линия показывает среднее значение.

Boxplot H_eff



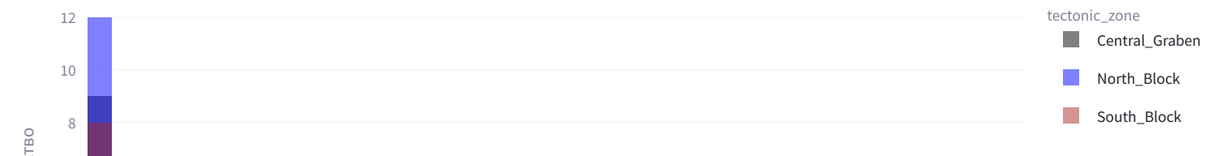
Boxplot rms_amplitude



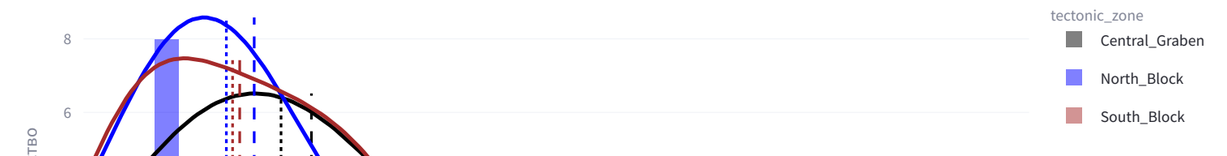
Гистограмма: по tectonic_zone

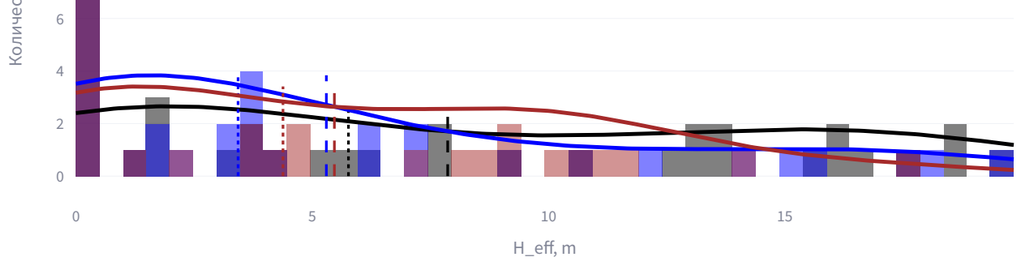
📊 Настройки гистограмм по зонам

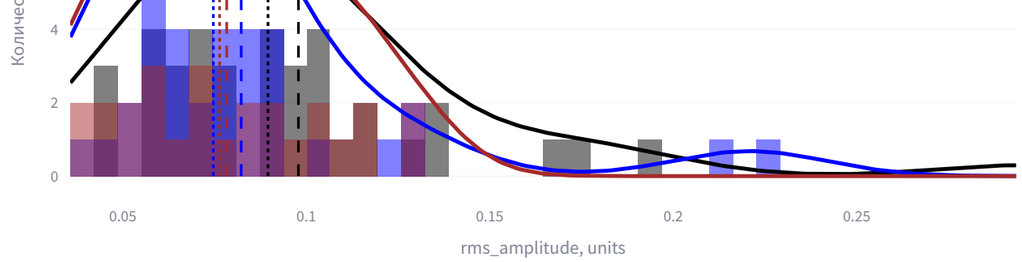
Гистограмма: H_eff



Гистограмма: rms_amplitude







QC кросс-плот по категориям

Аппроксимации зависимости параметров: tectonic_zone (H_eff vs rms_amplitude)

Категории для общего графика (tectonic_zone)

Central_Graben × North_Block × South_Block ×

Все категории

Только выбранные категории

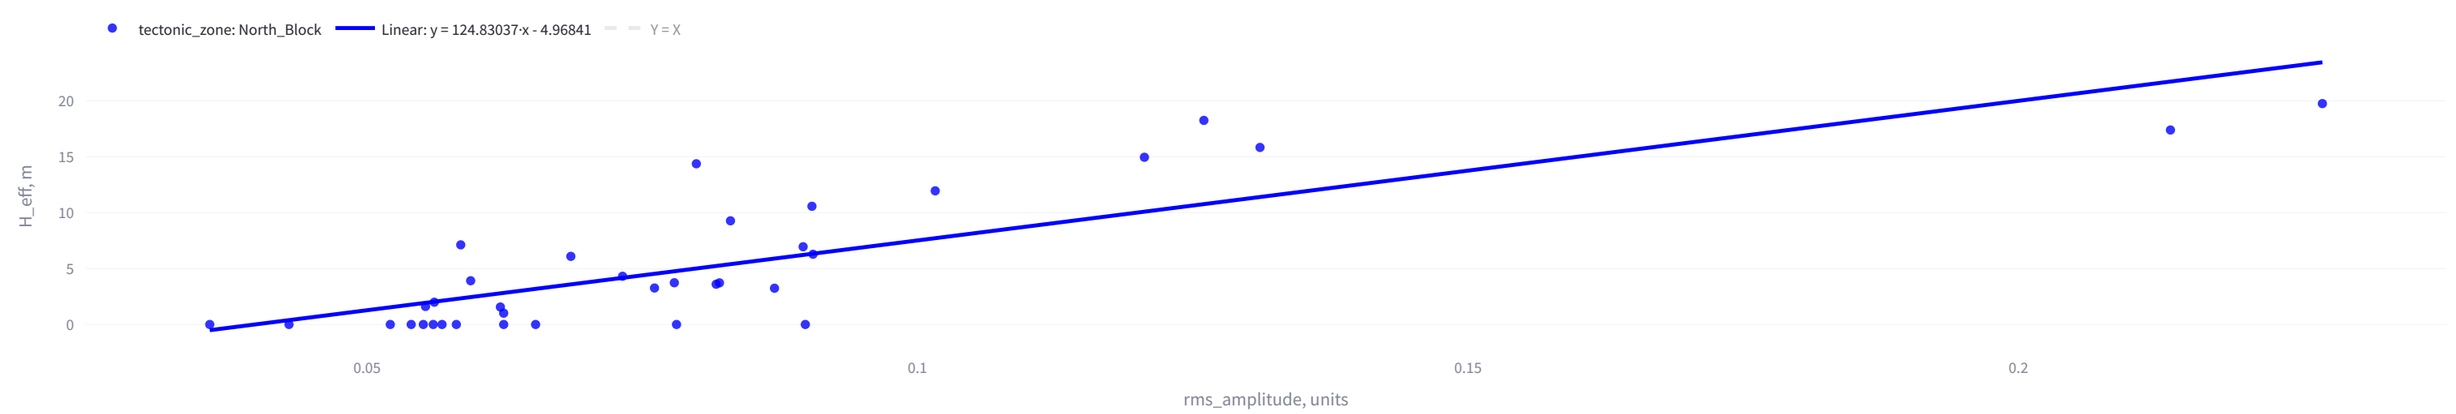
Все категории (tectonic_zone)

Только выбранные категории (tectonic_zone)

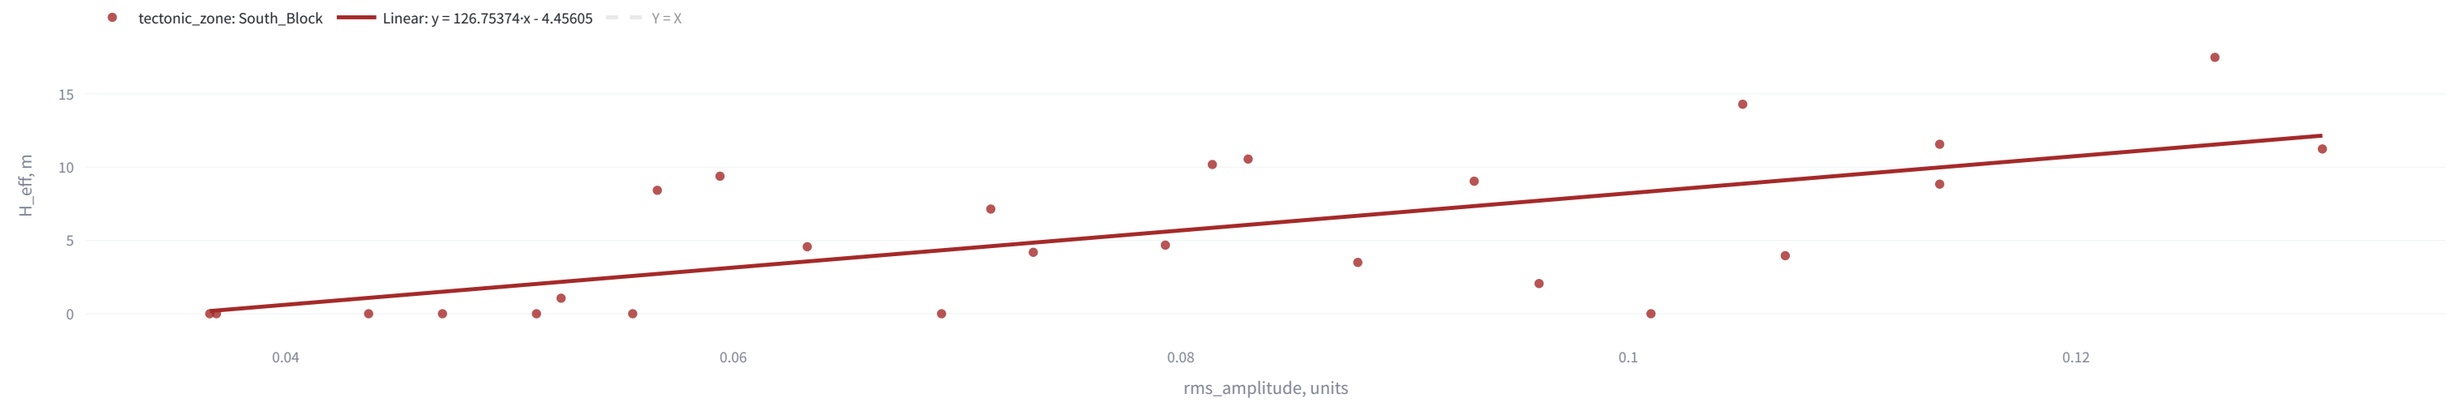
Аппроксимации по отдельным категориям (tectonic_zone)

tectonic_zone: Central_Graben

tectonic_zone: North_Block



tectonic_zone: South_Block



Сравнение метрик выбранных кривых аппроксимации: tectonic_zone

	tectonic_zone	Approximation	R^2_fit	r	RMSE	MSE	MAE	Bias	Std	Variance	WAPE %	Equation	n_fit
0	Central_Graben	Linear	0.4485	0.6697	5.1665	26.6925	4.5845	0.0000	5.2358	27.4139	58.2938	y = 99.12473·x - 1.83332	38
1	North_Block	Linear	0.6772	0.8229	3.4374	11.8155	2.7034	0.0000	3.4861	12.1531	51.0318	y = 124.83037·x - 4.96841	36
2	South_Block	Linear	0.4568	0.6759	3.7446	14.0220	2.9997	0.0000	3.8187	14.5828	54.8662	y = 126.75374·x - 4.45605	26

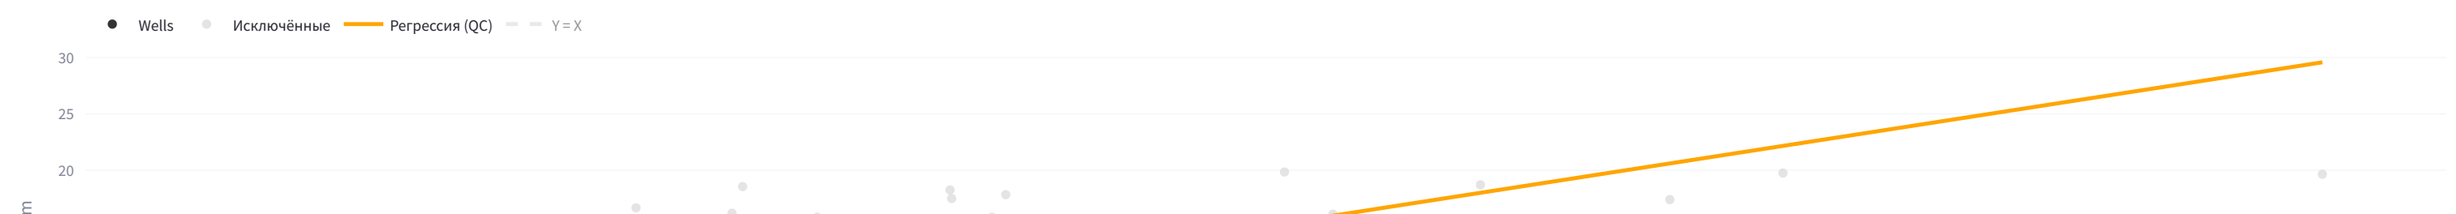
Скачать в Excel

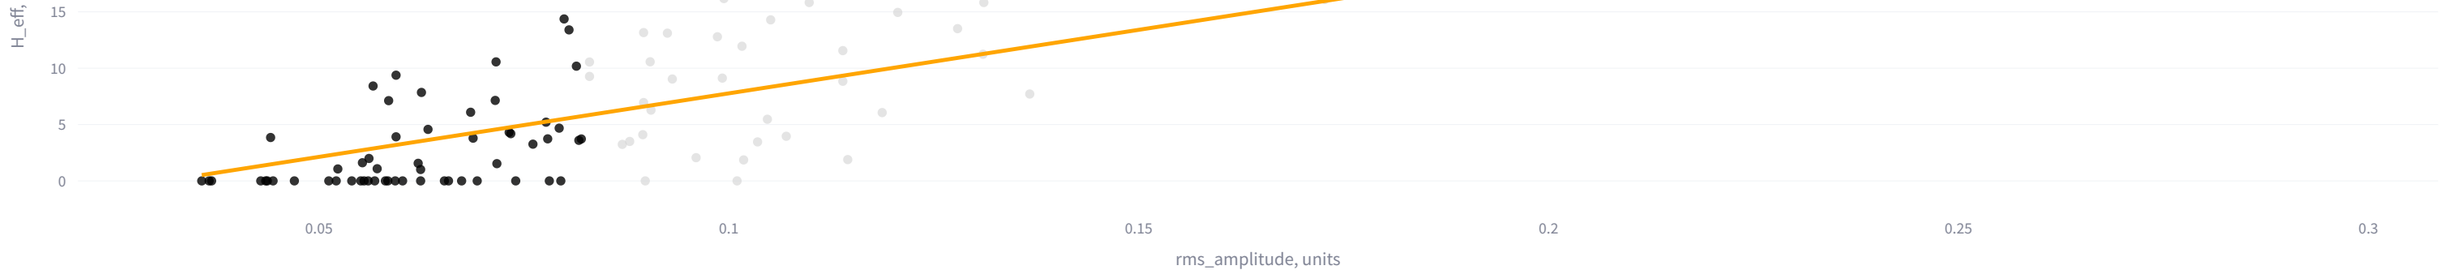
Шаг 4 · Фильтрация скважин

Выделение скважин кликом по точкам

Выделите точки одним из способов: клик по точке (Shift+клик — несколько), рамка (Box) или лассо (Lasso). Переключение режимов — иконки в правом верхнем углу графика. Затем нажмите «Применить исключение».

Выделение скважин кликом по точкам





Применить исключение

Сбросить всё

Выделено точек: 0

Исключено кликом: 44

Исключённые кликом скважины

Исходно скважин: 100

Случайно исключено: 0

Исключено вручную: 0

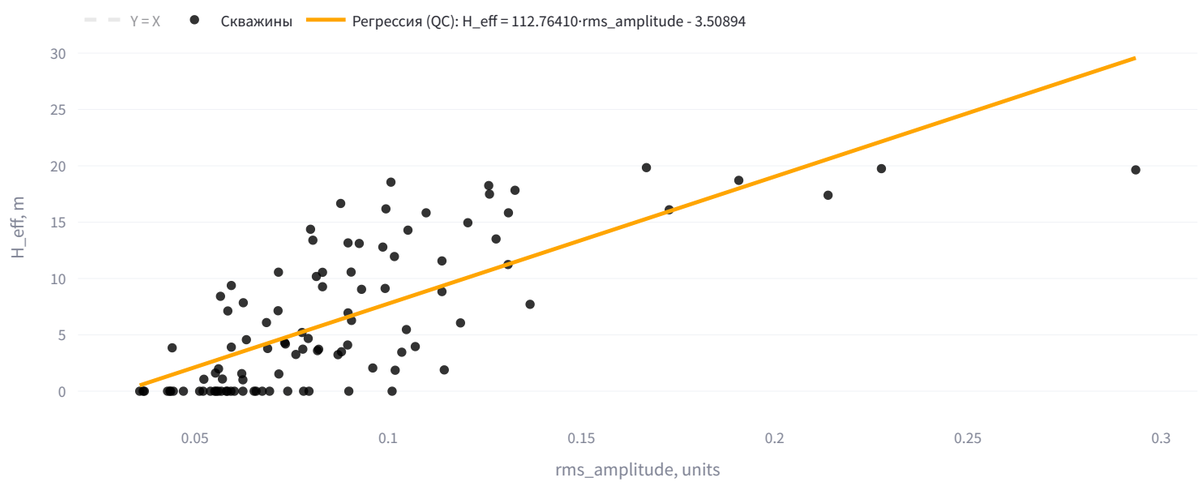
Исключено кликом: 44

Осталось для анализа: 56 (56.0%)

Графики до фильтрации

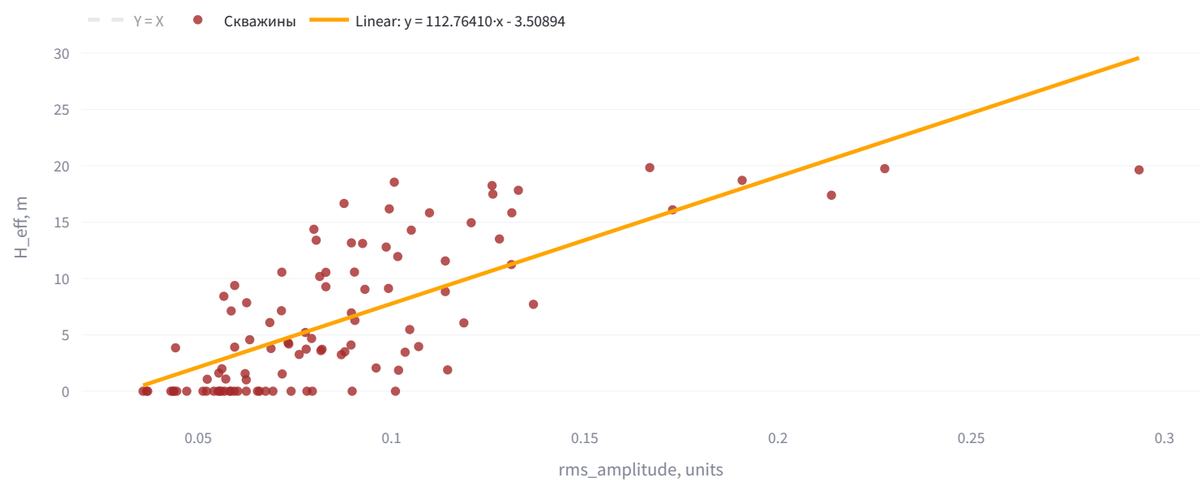
Кросс-плот до фильтрации: H_eff vs rms_amplitude

QC кросс-плот до фильтрации



Аппроксимации до фильтрации: H_eff vs rms_amplitude

Аппроксимации до фильтрации



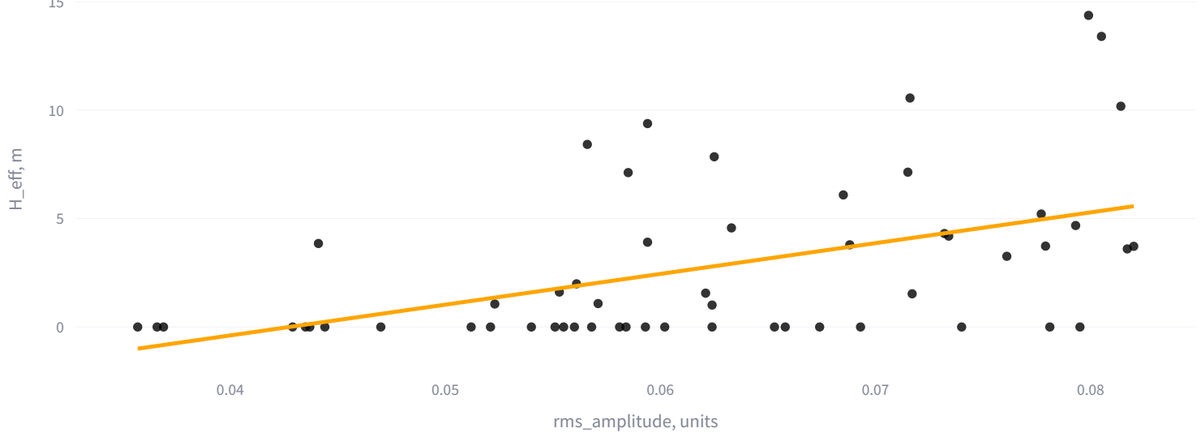
Графики после фильтрации

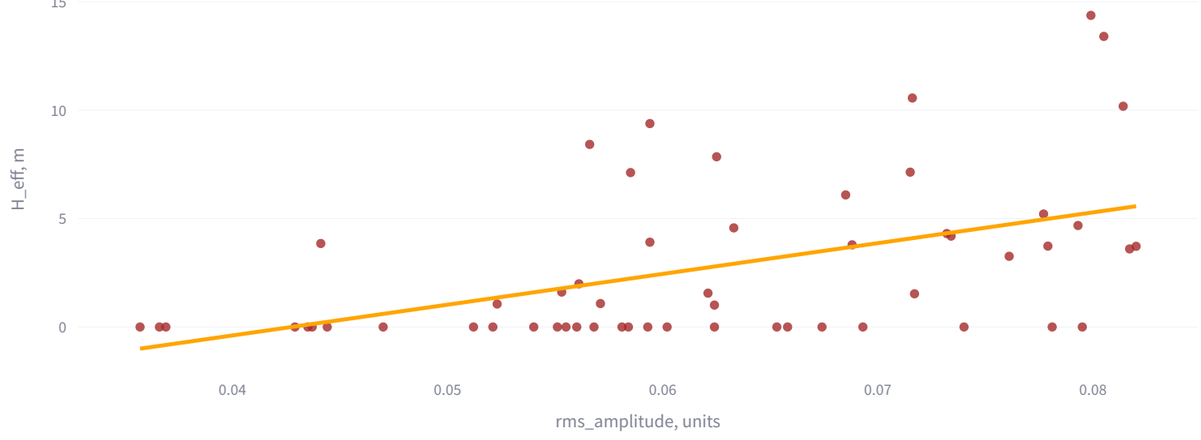
Кросс-плот после фильтрации: H_eff vs rms_amplitude

QC кросс-плот после фильтрации

Аппроксимации после фильтрации: H_eff vs rms_amplitude

Аппроксимации после фильтрации





Метрики QC кросс-плота

	Стадия	R^2_lin	r	RMSE	MSE	MAE	Bias	Std	Variance	WAPE %	P-value	Equation
0	До фильтрации	0.5359	0.7321	8.8423	78.1860	6.2640	6.2300	6.3064	39.7713	99.1588	5.02265e-18	H_eff = 112.76410·rms_amplitude + -3.50894
1	После фильтрации	0.2350	0.4848	4.5428	20.6374	2.7271	2.6732	3.7063	13.7370	99.7029	1.52802e-04	H_eff = 141.87419·rms_amplitude + -6.06482

Δ на Шаге 1 = PARAM_1 − PARAM_2 (эталон минус атрибут): положительная Δ означает, что PARAM_1 выше PARAM_2.

Скачать в Excel

Сравнение аппроксимаций

	Стадия	Approximation	R^2_fit	r	RMSE	MSE	MAE	Bias	Std	Variance	WAPE %	Equation	n_fit
0	До фильтрации	Linear	0.5359	0.7321	4.2951	18.4478	3.5252	-0.0000	4.3167	18.6342	55.8042	y = 112.76410·x - 3.50894	100
1	После фильтрации	Linear	0.2350	0.4848	3.2179	10.3549	2.4004	-0.0000	3.2470	10.5431	87.7596	y = 141.87419·x - 6.06482	56

Скачать в Excel

Сравнение метрик до и после фильтрации

	Metrics	before filt	after filt
0	Well	100	56
1	R^2_lin	0.5359	0.2350
2	r	0.7321	0.4848
3	RMSE	8.8423	4.5428
4	MSE	78.1860	20.6374
5	MAE	6.2640	2.7271
6	Bias	6.2300	2.6732
7	Std	6.3064	3.7063
8	Variance	39.7713	13.7370
9	WAPE %	99.1588	99.7029

Скачать в Excel

Распределение R^2 (Pearson) при случайном исключении скважин

Для каждого уровня (5–95 %) выбирается заданное в сайдбаре число случайных наборов скважин; каждая скважина исключается целиком. In-sample: r^2 считается по оставшимся скважинам, на которых обучалась линия. Out-of-sample: линия обучается на оставшихся скважинах, а r^2 считается по исключённым, которых модель не видела. Оба режима используют одни и те же наборы.

Текущий seed: 42

Число наборов: 500

Запустить расчёт

Распределение R^2 (Pearson), in-sample, при случайном исключении скважин

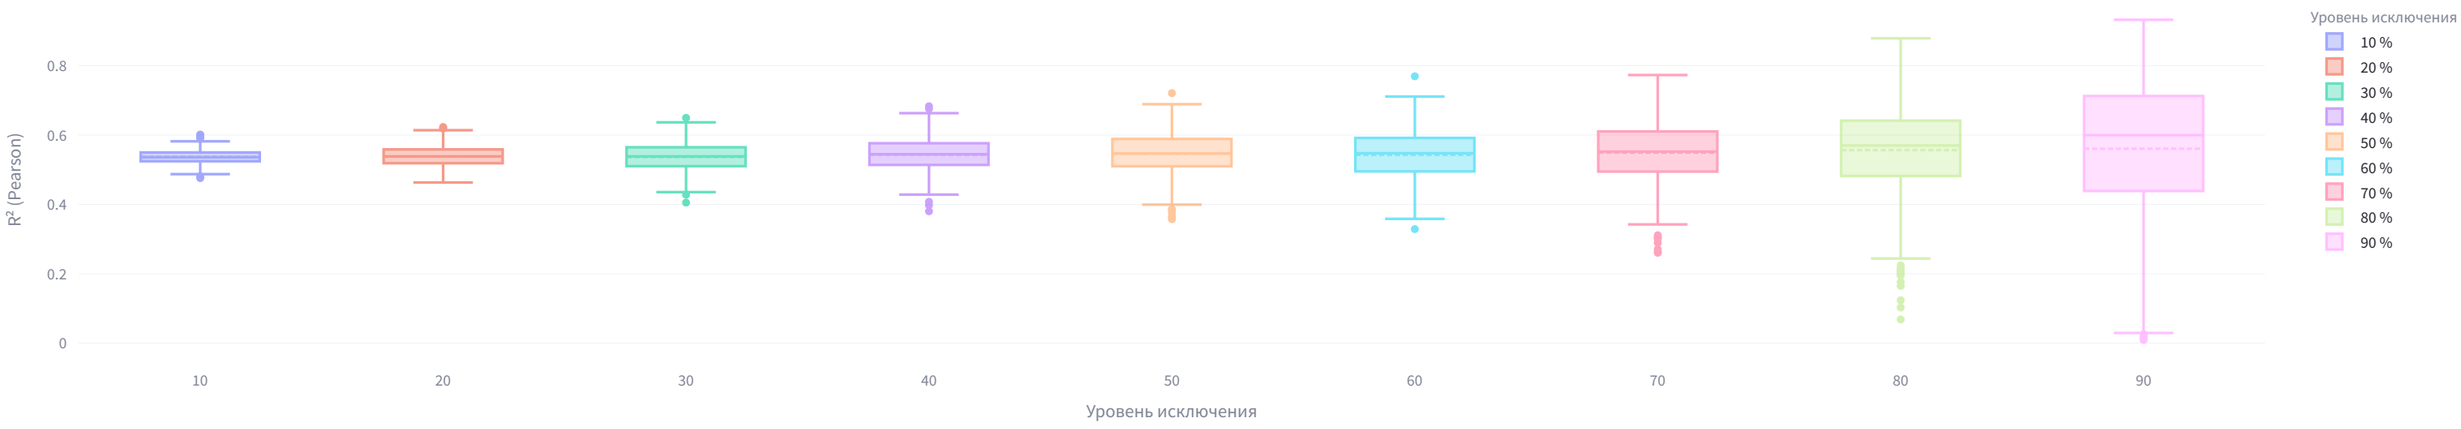
	level_pct	n_excluded	n_remaining	n_train	n_sets	status	min	max	mean	median
0	5 %	5	95	95	500	OK	0.4893	0.5766	0.5361	0.5366
2	10 %	10	90	90	500	OK	0.4759	0.6012	0.5365	0.5359
4	15 %	15	85	85	500	OK	0.4657	0.6151	0.5382	0.5396
6	20 %	20	80	80	500	OK	0.4632	0.6231	0.5379	0.5382
8	25 %	25	75	75	500	OK	0.4522	0.6195	0.5391	0.5376
10	30 %	30	70	70	500	OK	0.4052	0.6495	0.5373	0.5385
12	35 %	35	65	65	500	OK	0.4172	0.6690	0.5419	0.5419
14	40 %	40	60	60	500	OK	0.3801	0.6830	0.5436	0.5446
16	45 %	45	55	55	500	OK	0.3823	0.6802	0.5442	0.5476
18	50 %	50	50	50	500	OK	0.3576	0.7207	0.5467	0.5469

Скачать в Excel

Шаг уровней для boxplot

10 % 5 %

Boxplot: разброс R^2 (Pearson), in-sample, по уровням исключения



Распределение R^2 (Pearson), out-of-sample, при случайном исключении скважин

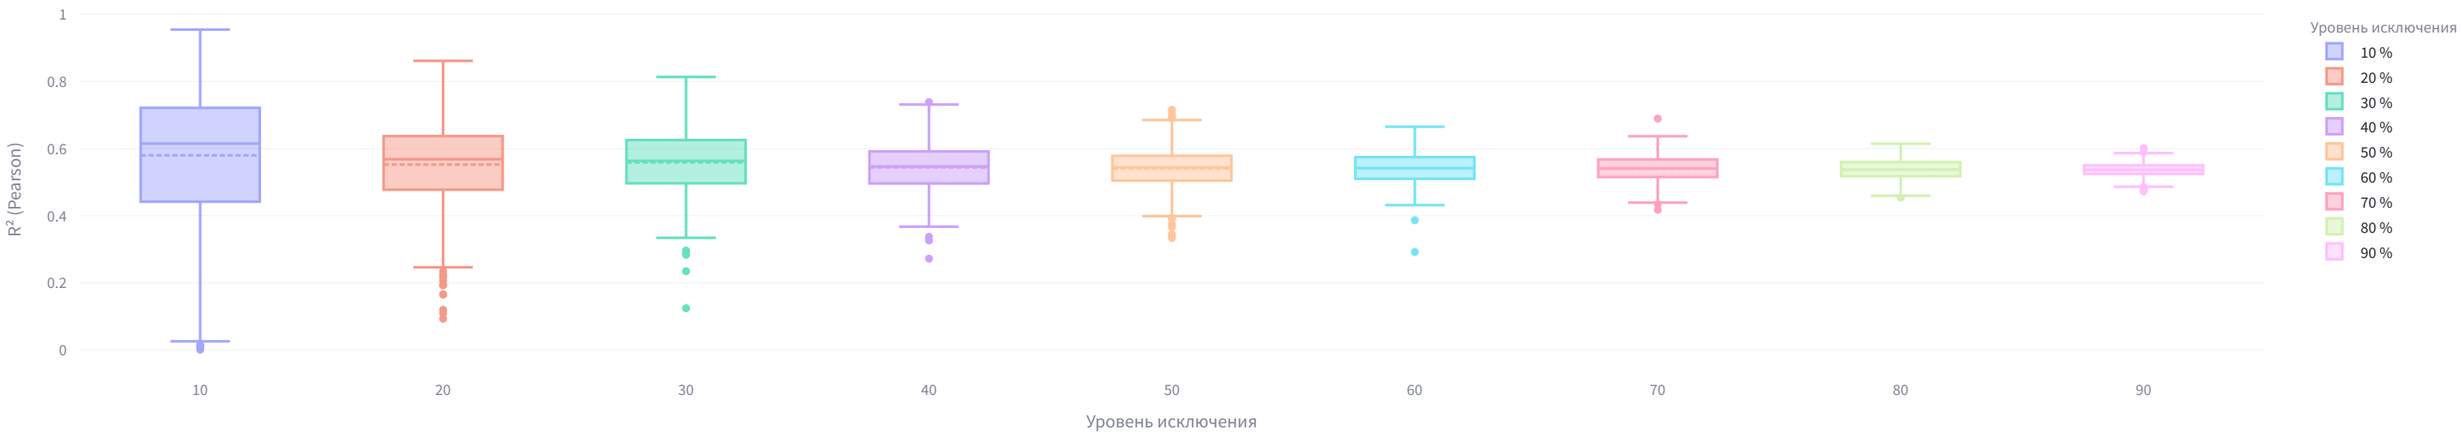
	level_pct	n_excluded	n_remaining	n_train	n_test	n_sets	status	min	max	mean	median
1	5 %	5	95	95	5	499	OK	0.0004	0.9981	0.5898	0.6455
3	10 %	10	90	90	10	500	OK	0.0008	0.9547	0.5799	0.6150
5	15 %	15	85	85	15	500	OK	0.0113	0.9042	0.5623	0.5695
7	20 %	20	80	80	20	500	OK	0.0929	0.8614	0.5523	0.5682
9	25 %	25	75	75	25	500	OK	0.2470	0.8080	0.5535	0.5608
11	30 %	30	70	70	30	500	OK	0.1242	0.8134	0.5586	0.5634
13	35 %	35	65	65	35	500	OK	0.2010	0.7507	0.5438	0.5497
15	40 %	40	60	60	40	500	OK	0.2721	0.7384	0.5437	0.5468
17	45 %	45	55	55	45	500	OK	0.3529	0.7196	0.5439	0.5434
19	50 %	50	50	50	50	500	OK	0.3337	0.7156	0.5404	0.5437

Скачать в Excel

Шаг уровней для boxplot

10 % 5 %

Boxplot: разброс R^2 (Pearson), out-of-sample, по уровням исключения



Шаг 5 · Многоатрибутная регрессия

Отдельная линейная модель для H_eff и для Phi на нескольких сейсмических атрибутах. Перебираются все комбинации до k_max атрибутов, оценка по LOWO и K-fold по скважинам, критерий выбора — RMSE_cv.

k_max = 3 (скважин: 100, атрибутов-кандидатов: 10, пар с |r| > 0.8 исключено: 0). K-fold: K = 10 фолдов по скважинам.

H_eff

Одноатрибутные модели — базовый уровень для сравнения In-sample (RMSE_in, R^2_in)

	Параметр	Ранг	Атрибуты	k	n	RMSE_in	R^2_in (Pearson)	r_in (Pearson, Predicted vs Actual)	Bias_in	Equation
0	H_eff	1	rms_amplitude	1	100	4.2951	0.5359	0.7321	0	H_eff = -3.509 + 112.8·rms_amplitude
1	H_eff	2	spectral_decomp_20Hz	1	100	4.3228	0.5299	0.7279	0	H_eff = -7.004 + 25.11·spectral_decomp_20Hz
2	H_eff	3	sweetness	1	100	4.7415	0.4344	0.6591	0	H_eff = -11.38 + 101.7·sweetness
3	H_eff	4	acoustic_impedance	1	100	5.3532	0.2791	-0.5283	0	H_eff = 34.48 - 3.107·acoustic_impedance
4	H_eff	5	envelope	1	100	5.4877	0.2424	0.4923	0	H_eff = -9.135 + 151.5·envelope
5	H_eff	6	avo_intercept	1	100	5.6197	0.2055	-0.4533	0	H_eff = 6.317 - 23.94·avo_intercept
6	H_eff	7	inst_frequency	1	100	6.0156	0.0896	-0.2994	0	H_eff = 11.39 - 0.1355·inst_frequency
7	H_eff	8	coherence	1	100	6.0643	0.0748	-0.2735	0	H_eff = 10.4 - 7.196·coherence
8	H_eff	9	avo_gradient	1	100	6.1127	0.06	-0.2449	0	H_eff = 6.317 - 10.35·avo_gradient
9	H_eff	10	q_factor	1	100	6.1294	0.0549	-0.2342	0	H_eff = 11.21 - 0.078·q_factor

Скачать в Excel

Топ-5 моделей: Leave-One-Well-Out

Одноатрибутные модели — базовый уровень для сравнения Out-of-sample (RMSE_cv, R^2_cv)

	Параметр	Ранг	Атрибуты	k	n	RMSE_cv	R^2_cv (Pearson, Predicted vs Actual)	r_cv (Pearson, Predicted vs Actual)	Bias_cv	ΔRMSE к лучшей одноатрибутной	Equation
0	H_eff	1	spectral_decomp_20Hz	1	100	4.406	0.5119	0.7155	-0.0002	0	Predicted = 3.014 + 0.5229·Actual
1	H_eff	2	rms_amplitude	1	100	4.4494	0.5048	0.7105	0.0392	0.0435	Predicted = 2.93 + 0.5423·Actual
2	H_eff	3	sweetness	1	100	4.8407	0.4109	0.641	-0.0002	0.4348	Predicted = 3.635 + 0.4245·Actual
3	H_eff	4	acoustic_impedance	1	100	5.4494	0.2536	0.5036	-0.0053	1.0435	Predicted = 4.629 + 0.2664·Actual
4	H_eff	5	envelope	1	100	5.604	0.211	0.4593	-0.0055	1.198	Predicted = 4.885 + 0.2258·Actual
5	H_eff	6	avo_intercept	1	100	5.7219	0.1775	0.4213	-0.0068	1.3159	Predicted = 5.099 + 0.1917·Actual
6	H_eff	7	inst_frequency	1	100	6.1151	0.0618	0.2486	0.0052	1.7091	Predicted = 5.852 + 0.07444·Actual
7	H_eff	8	coherence	1	100	6.1938	0.0402	0.2006	-0.0091	1.7879	Predicted = 5.961 + 0.05493·Actual
8	H_eff	9	avo_gradient	1	100	6.2266	0.0298	0.1727	0.0131	1.8206	Predicted = 6.063 + 0.04229·Actual
9	H_eff	10	q_factor	1	100	6.2505	0.0242	0.1556	-0.0111	1.8445	Predicted = 6.07 + 0.0373·Actual

Скачать в Excel

Топ-5 многоатрибутных моделей In-sample (RMSE_in, R^2_in)

	Параметр	Ранг	Атрибуты	k	n	RMSE_in	R^2_in (Pearson)	r_in (Pearson, Predicted vs Actual)	Bias_in	Equation
0	H_eff	1	spectral_decomp_20Hz, acoustic_impedance, q_factor	3	100	2.589	0.8314	0.9118	0	H_eff = 27.51 + 23.13·spectral_decomp_20Hz - 2.694·acoustic_impedance - 0.1442·q_facto
1	H_eff	2	rms_amplitude, inst_frequency, acoustic_impedance	3	100	2.7302	0.8125	0.9014	0	H_eff = 18.01 + 114.4·rms_amplitude - 0.1861·inst_frequency - 1.62·acoustic_impedance
2	H_eff	3	rms_amplitude, spectral_decomp_20Hz, acoustic_impedance	3	100	2.8106	0.8013	0.8951	0	H_eff = 8.353 + 68.08·rms_amplitude + 15.13·spectral_decomp_20Hz - 1.765·acoustic_imp
3	H_eff	4	avo_intercept, spectral_decomp_20Hz, q_factor	3	100	2.9417	0.7823	0.8845	0	H_eff = 1.303 - 20.11·avo_intercept + 24.61·spectral_decomp_20Hz - 0.1282·q_factor
4	H_eff	5	rms_amplitude, inst_frequency, spectral_decomp_20Hz	3	100	2.8007	0.8027	0.8959	0	H_eff = -2.437 + 100.1·rms_amplitude - 0.1514·inst_frequency + 10.75·spectral_decomp_2(

Скачать в Excel

Топ-5 многоатрибутных моделей Out-of-sample (RMSE_cv, R^2_cv)

	Параметр	Ранг	Атрибуты	k	n	RMSE_cv	R^2_cv (Pearson, Predicted vs Actual)	r_cv (Pearson, Predicted vs Actual)	WAPE_cv, %	Bias_cv	ΔRMSE к лучшей одноатрибутной	Принята	Equation
0	H_eff	1	spectral_decomp_20Hz, acoustic_impedance, q_factor	3	100	2.5288	0.8451	0.9193	30.0402	0.2508	-1.8772	да	Predicted = 1.614 + 0.7842·Actual
1	H_eff	2	rms_amplitude, inst_frequency, acoustic_impedance	3	100	2.8224	0.8017	0.8954	34.2252	0.2555	-1.5835	да	Predicted = 1.626 + 0.7831·Actual
2	H_eff	3	rms_amplitude, spectral_decomp_20Hz, acoustic_impedance	3	100	2.9247	0.7863	0.8868	35.2538	0.2261	-1.4812	да	Predicted = 1.663 + 0.7725·Actual
3	H_eff	4	avo_intercept, spectral_decomp_20Hz, q_factor	3	100	2.9531	0.7844	0.8856	35.0263	0.2257	-1.4529	да	Predicted = 1.866 + 0.7404·Actual
4	H_eff	5	rms_amplitude, inst_frequency, spectral_decomp_20Hz	3	100	2.9896	0.7762	0.881	35.1224	0.1983	-1.4164	да	Predicted = 1.558 + 0.7848·Actual

Скачать в Excel

Коэффициенты: H_eff, ранг 1

Коэффициенты: H_eff, ранг 2

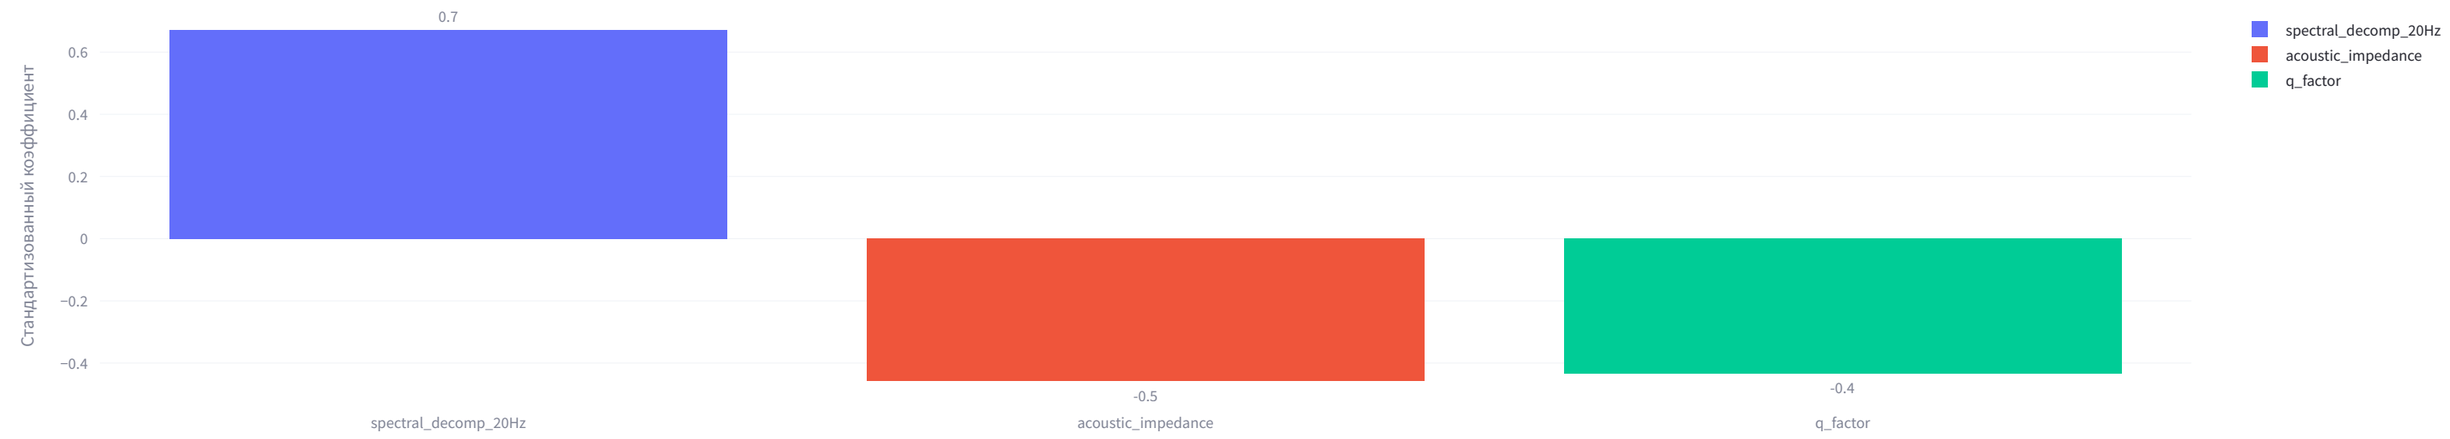
Коэффициенты: H_eff, ранг 3

Коэффициенты: H_eff, ранг 4

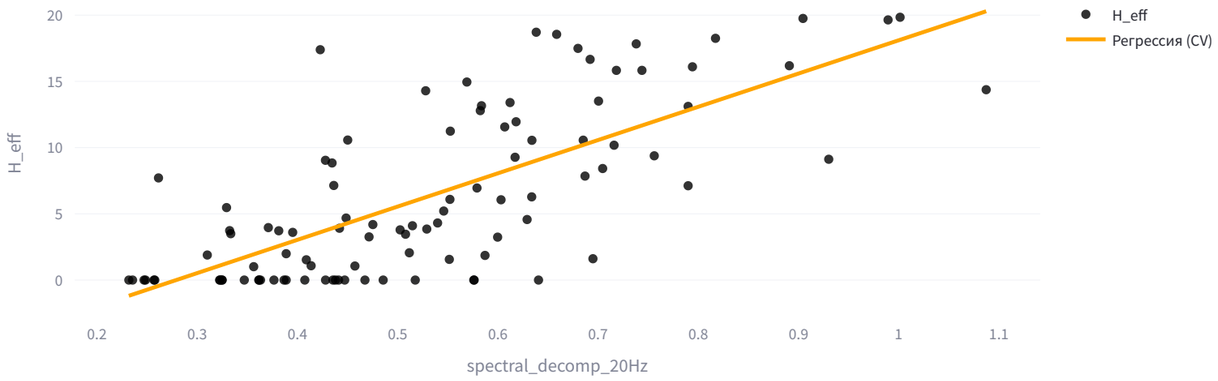
Коэффициенты: H_eff, ранг 5

Скачать в Excel

Вклад атрибутов (стандартизованные коэффициенты): H_eff, LOWO

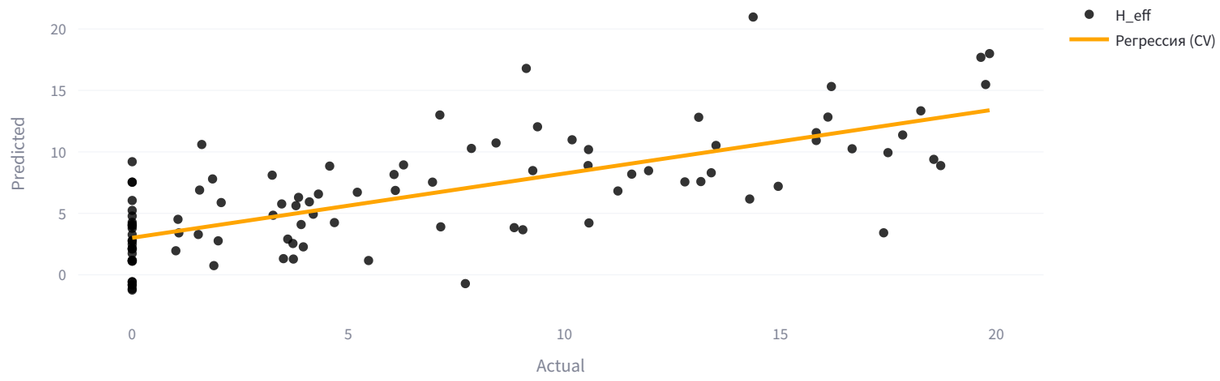


Cross-plot In-sample: H_eff vs spectral_decomp_20Hz (лучший одноатрибутный): LOWO



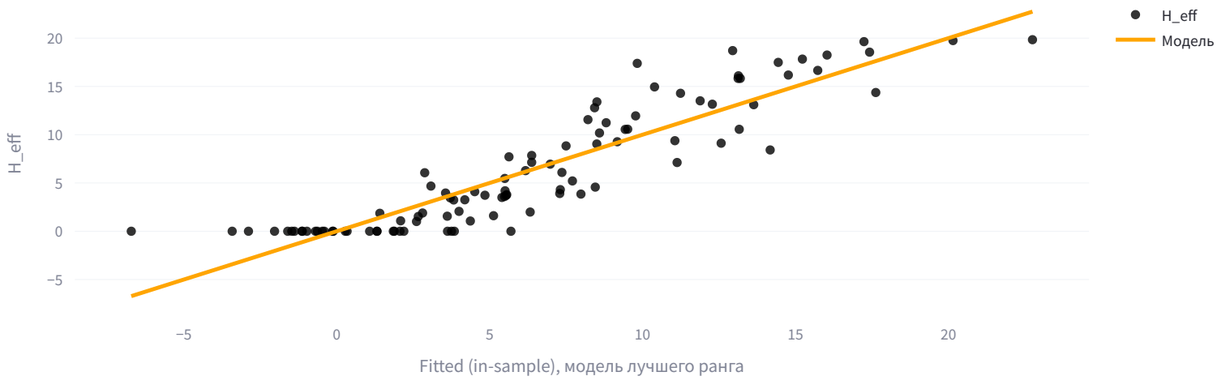
Equation: H_eff = -7.004 + 25.11·spectral_decomp_20Hz

Cross-plot Out-of-sample: H_eff vs spectral_decomp_20Hz (лучший одноатрибутный): LOWO



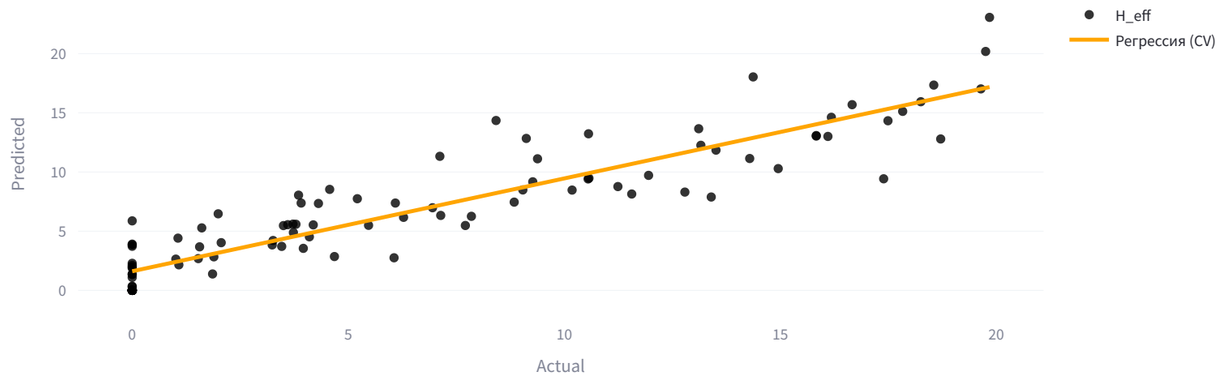
Equation: Predicted = 3.014 + 0.5229·Actual

Cross-plot In-sample: H_eff vs лучший многоатрибутный набор: LOWO



Equation: H_eff = 27.51 + 23.13·spectral_decomp_20Hz - 2.694·acoustic_impedance - 0.1442·q_factor

Cross-plot Out-of-sample: H_eff vs лучший многоатрибутный набор: LOWO



Equation: Predicted = 1.614 + 0.7842·Actual

Топ-5 моделей: K-fold по скважинам

Одноатрибутные модели — базовый уровень для сравнения Out-of-sample (RMSE_cv, R^2_cv)

	Параметр	Ранг	Атрибуты	k	n	RMSE_cv	R^2_cv (Pearson, Predicted vs Actual)	r_cv (Pearson, Predicted vs Actual)	Bias_cv	ΔRMSE к лучшей одноатрибутной	Equation
0	H_eff	1	spectral_decomp_20Hz	1	100	4.3803	0.5174	0.7193	-0.0032	0	Predicted = 3.011 + 0.5229·Actual
1	H_eff	2	rms_amplitude	1	100	4.5401	0.4897	0.6998	0.073	0.1598	Predicted = 2.899 + 0.5527·Actual
2	H_eff	3	sweetness	1	100	4.8154	0.4171	0.6458	0.017	0.4351	Predicted = 3.615 + 0.4304·Actual
3	H_eff	4	acoustic_impedance	1	100	5.4715	0.2478	0.4978	-0.0137	1.0912	Predicted = 4.641 + 0.2631·Actual
4	H_eff	5	envelope	1	100	5.5322	0.2302	0.4797	-0.0078	1.1519	Predicted = 4.827 + 0.2347·Actual
5	H_eff	6	avo_intercept	1	100	5.6947	0.1848	0.4299	0.009	1.3144	Predicted = 5.087 + 0.1962·Actual
6	H_eff	7	inst_frequency	1	100	6.1033	0.0652	0.2553	-0.0058	1.723	Predicted = 5.823 + 0.07731·Actual
7	H_eff	8	coherence	1	100	6.1463	0.052	0.2281	-0.0088	1.766	Predicted = 5.909 + 0.06318·Actual
8	H_eff	9	avo_gradient	1	100	6.2016	0.0358	0.1891	0.0392	1.8214	Predicted = 6.062 + 0.0466·Actual
9	H_eff	10	q_factor	1	100	6.2432	0.025	0.158	0.0005	1.8629	Predicted = 6.085 + 0.03676·Actual

Скачать в Excel

Топ-5 многоатрибутных моделей In-sample (RMSE_in, R^2_in)

	Параметр	Ранг	Атрибуты	k	n	RMSE_in	R^2_in (Pearson)	r_in (Pearson, Predicted vs Actual)	Bias_in	Equation
0	H_eff	1	spectral_decomp_20Hz, acoustic_impedance, q_factor	3	100	2.589	0.8314	0.9118	0	H_eff = 27.51 + 23.13·spectral_decomp_20Hz - 2.694·acoustic_impedance - 0.1442·q_facto
1	H_eff	2	rms_amplitude, spectral_decomp_20Hz, acoustic_impedance	3	100	2.8106	0.8013	0.8951	0	H_eff = 8.353 + 68.08·rms_amplitude + 15.13·spectral_decomp_20Hz - 1.765·acoustic_imp
2	H_eff	3	avo_intercept, spectral_decomp_20Hz, q_factor	3	100	2.9417	0.7823	0.8845	0	H_eff = 1.303 - 20.11·avo_intercept + 24.61·spectral_decomp_20Hz - 0.1282·q_factor
3	H_eff	4	rms_amplitude, inst_frequency, acoustic_impedance	3	100	2.7302	0.8125	0.9014	0	H_eff = 18.01 + 114.4·rms_amplitude - 0.1861·inst_frequency - 1.62·acoustic_impedance
4	H_eff	5	rms_amplitude, inst_frequency, spectral_decomp_20Hz	3	100	2.8007	0.8027	0.8959	0	H_eff = -2.437 + 100.1·rms_amplitude - 0.1514·inst_frequency + 10.75·spectral_decomp_20

Скачать в Excel

Топ-5 многоатрибутных моделей Out-of-sample (RMSE_cv, R^2_cv)

	Параметр	Ранг	Атрибуты	k	n	RMSE_cv	R^2_cv (Pearson, Predicted vs Actual)	r_cv (Pearson, Predicted vs Actual)	WAPE_cv, %	Bias_cv	ΔRMSE к лучшей одноатрибутной	Принята	Equation
0	H_eff	1	spectral_decomp_20Hz, acoustic_impedance, q_factor	3	100	2.5267	0.8457	0.9196	30.328	0.2543	-1.8536	да	Predicted = 1.625 + 0.783·Actual
1	H_eff	2	rms_amplitude, spectral_decomp_20Hz, acoustic_impedance	3	100	2.9007	0.7898	0.8887	35.1441	0.2253	-1.4796	да	Predicted = 1.64 + 0.776·Actual
2	H_eff	3	avo_intercept, spectral_decomp_20Hz, q_factor	3	100	2.9342	0.7877	0.8875	34.9844	0.2401	-1.4461	да	Predicted = 1.88 + 0.7404·Actual
3	H_eff	4	rms_amplitude, inst_frequency, acoustic_impedance	3	100	2.9379	0.7847	0.8858	35.2574	0.2657	-1.4424	да	Predicted = 1.595 + 0.7896·Actual
4	H_eff	5	rms_amplitude, inst_frequency, spectral_decomp_20Hz	3	100	3.0421	0.7695	0.8772	35.4788	0.2297	-1.3382	да	Predicted = 1.512 + 0.797·Actual

Скачать в Excel

Коэффициенты: H_eff, ранг 1

Коэффициенты: H_eff, ранг 2

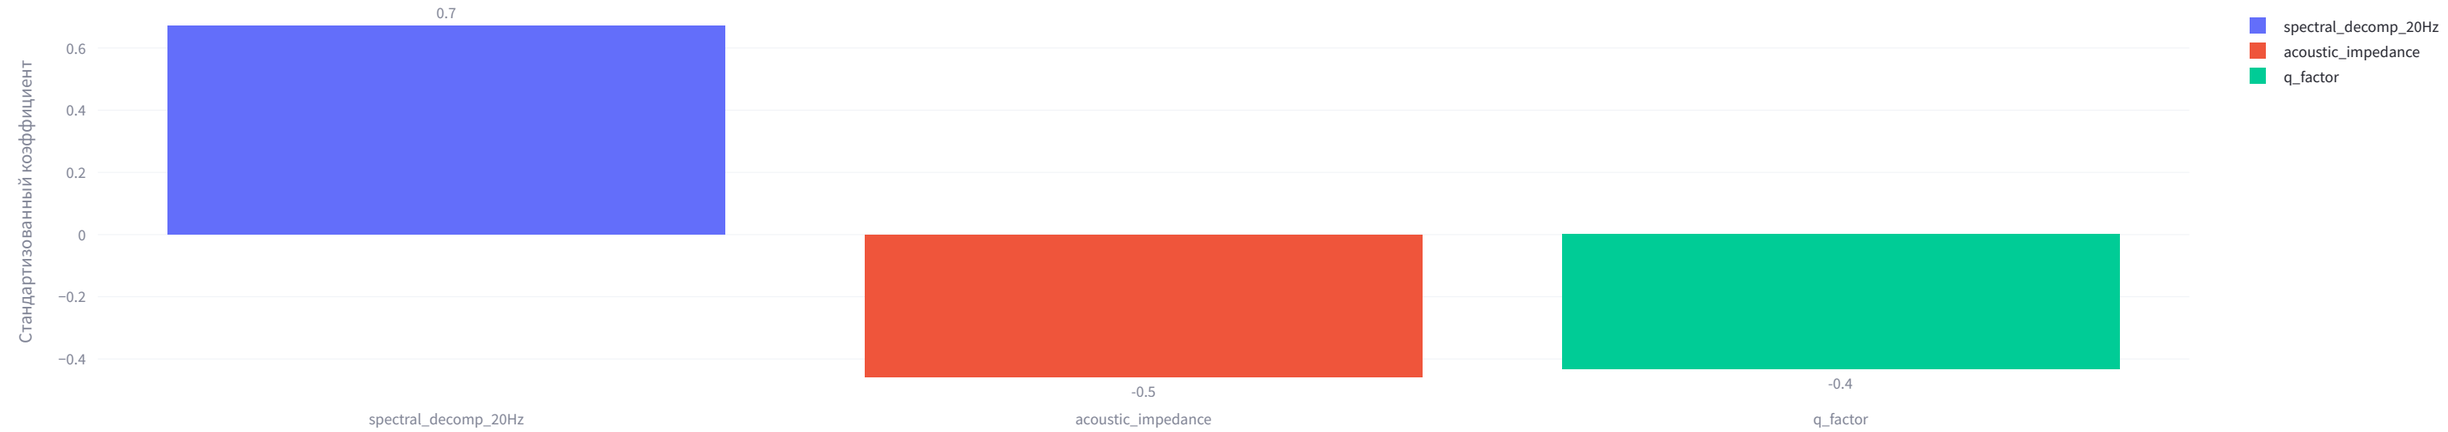
Коэффициенты: H_eff, ранг 3

Коэффициенты: H_eff, ранг 4

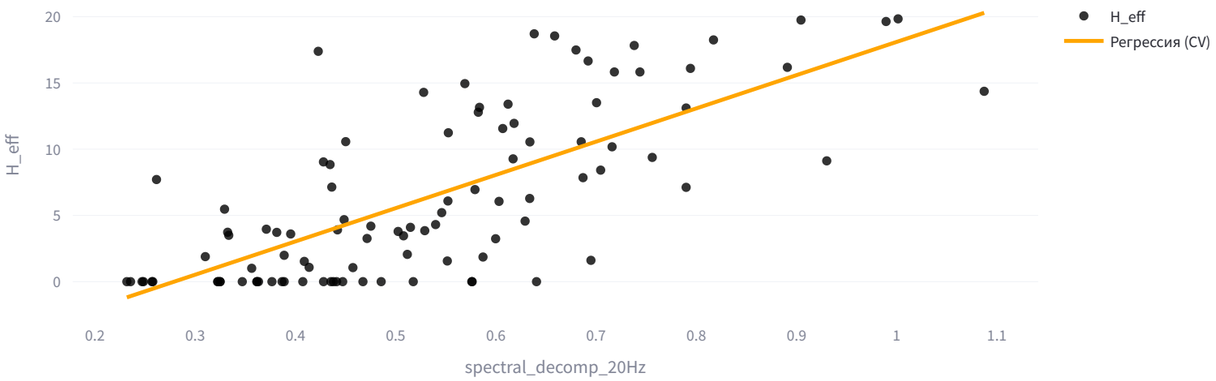
Коэффициенты: H_eff, ранг 5

Скачать в Excel

Вклад атрибутов (стандартизованные коэффициенты): H_eff, K-fold

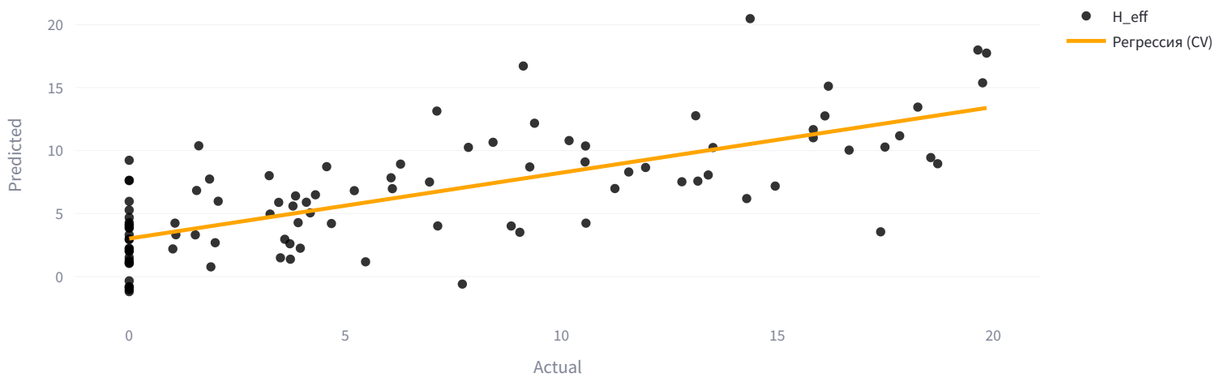


Cross-plot In-sample: H_eff vs spectral_decomp_20Hz (лучший одноатрибутный): K-fold



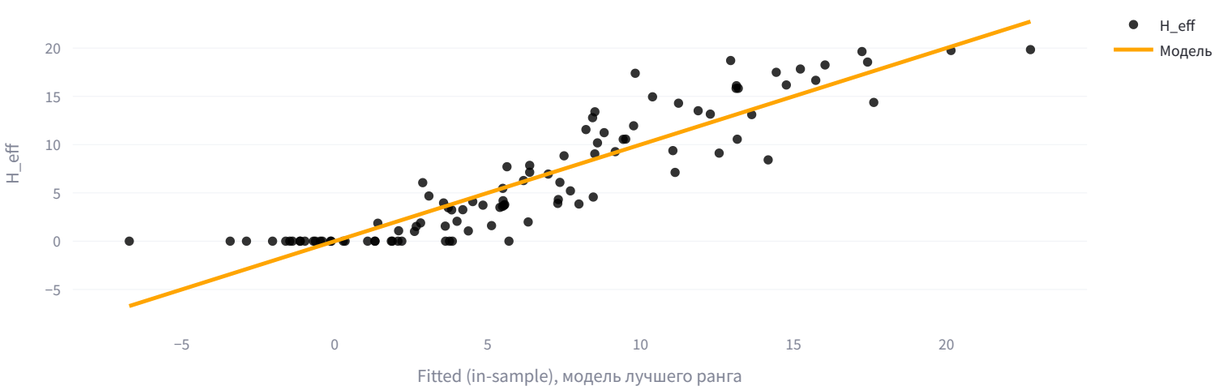
Equation: H_eff = -7.004 + 25.11·spectral_decomp_20Hz

Cross-plot Out-of-sample: H_eff vs spectral_decomp_20Hz (лучший одноатрибутный): K-fold

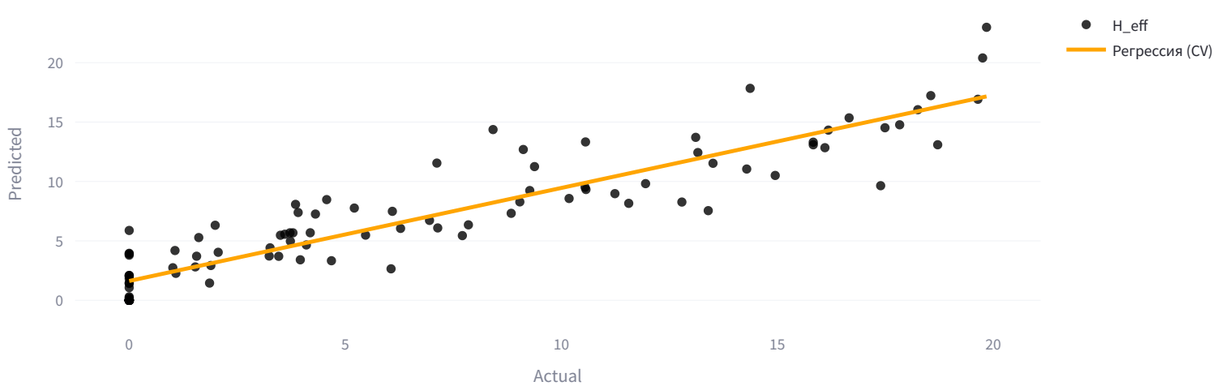


Equation: Predicted = 3.011 + 0.5229·Actual

Cross-plot In-sample: H_eff vs лучший многоатрибутный набор: K-fold



Cross-plot Out-of-sample: H_eff vs лучший многоатрибутный набор: K-fold



Equation: H_eff = 27.51 + 23.13·spectral_decomp_20Hz - 2.694·acoustic_impedance - 0.1442·q_factor

Equation: Predicted = 1.625 + 0.783·Actual

Phi

Одноатрибутные модели — базовый уровень для сравнения In-sample (RMSE_in, R^2_in)

	Параметр	Ранг	Атрибуты	k	n	RMSE_in	R^2_in (Pearson)	r_in (Pearson, Predicted vs Actual)	Bias_in	Equation
10	Phi	1	acoustic_impedance	1	100	0.0466	0.5349	-0.7314	0	Phi = 0.5759 - 0.04665·acoustic_impedance
11	Phi	2	avo_intercept	1	100	0.0467	0.5332	-0.7302	0	Phi = 0.153 - 0.4181·avo_intercept
12	Phi	3	sweetness	1	100	0.0556	0.3392	0.5824	0	Phi = -0.01652 + 0.9744·sweetness
13	Phi	4	rms_amplitude	1	100	0.0585	0.2678	0.5175	0	Phi = 0.07771 + 0.8644·rms_amplitude
14	Phi	5	envelope	1	100	0.0622	0.1731	0.4161	0	Phi = 0.01142 + 1.388·envelope
15	Phi	6	spectral_decomp_20Hz	1	100	0.0626	0.1609	0.4011	0	Phi = 0.07344 + 0.15·spectral_decomp_20Hz
16	Phi	7	avo_gradient	1	100	0.0627	0.1583	-0.3979	0	Phi = 0.153 - 0.1823·avo_gradient
17	Phi	8	inst_frequency	1	100	0.0655	0.0828	-0.2877	0	Phi = 0.2059 - 0.001412·inst_frequency
18	Phi	9	coherence	1	100	0.0662	0.0618	-0.2487	0	Phi = 0.1932 - 0.07095·coherence
19	Phi	10	q_factor	1	100	0.067	0.0402	-0.2004	0	Phi = 0.1984 - 0.0007239·q_factor

Скачать в Excel

Топ-5 моделей: Leave-One-Well-Out

Одноатрибутные модели — базовый уровень для сравнения Out-of-sample (RMSE_cv, R^2_cv)

	Параметр	Ранг	Атрибуты	k	n	RMSE_cv	R^2_cv (Pearson, Predicted vs Actual)	r_cv (Pearson, Predicted vs Actual)	Bias_cv	ΔRMSE к лучшей одноатрибутной	Equation
10	Phi	1	acoustic_impedance	1	100	0.0474	0.5197	0.7209	0	0	Predicted = 0.0722 + 0.5281·Actual
11	Phi	2	avo_intercept	1	100	0.0475	0.5171	0.7191	-0.0001	0.0001	Predicted = 0.0723 + 0.527·Actual
12	Phi	3	sweetness	1	100	0.0568	0.3115	0.5581	0.0001	0.0094	Predicted = 0.1031 + 0.3267·Actual
13	Phi	4	rms_amplitude	1	100	0.0609	0.2165	0.4653	0.0006	0.0135	Predicted = 0.1136 + 0.2616·Actual
14	Phi	5	envelope	1	100	0.0634	0.1429	0.378	0	0.016	Predicted = 0.1289 + 0.158·Actual
15	Phi	6	spectral_decomp_20Hz	1	100	0.0638	0.13	0.3605	0.0001	0.0165	Predicted = 0.1308 + 0.1462·Actual
16	Phi	7	avo_gradient	1	100	0.064	0.1267	0.356	0.0002	0.0166	Predicted = 0.1315 + 0.1416·Actual
17	Phi	8	inst_frequency	1	100	0.0668	0.05	0.2236	0	0.0194	Predicted = 0.1432 + 0.06471·Actual
18	Phi	9	coherence	1	100	0.0676	0.0283	0.1682	0	0.0202	Predicted = 0.1466 + 0.04198·Actual
19	Phi	10	q_factor	1	100	0.0686	0.0084	0.0919	-0.0002	0.0212	Predicted = 0.1499 + 0.01926·Actual

Скачать в Excel

Топ-5 многоатрибутных моделей In-sample (RMSE_in, R^2_in)

	Параметр	Ранг	Атрибуты	k	n	RMSE_in	R^2_in (Pearson)	r_in (Pearson, Predicted vs Actual)	Bias_in	Equation
5	Phi	1	avo_intercept, acoustic_impedance, q_factor	3	100	0.0318	0.7837	0.8852	0	Phi = 0.5515 - 0.2452·avo_intercept - 0.03434·acoustic_impedance - 0.001391·q_factor
6	Phi	2	spectral_decomp_20Hz, acoustic_impedance, q_factor	3	100	0.0345	0.7448	0.863	0	Phi = 0.634 + 0.09866·spectral_decomp_20Hz - 0.0485·acoustic_impedance - 0.001494·q_fa
7	Phi	3	sweetness, avo_intercept, acoustic_impedance	3	100	0.0345	0.7459	0.8636	0	Phi = 0.2872 + 0.5745·sweetness - 0.1958·avo_intercept - 0.02583·acoustic_impedance
8	Phi	4	avo_gradient, acoustic_impedance, q_factor	3	100	0.0359	0.7249	0.8514	0	Phi = 0.6838 - 0.1023·avo_gradient - 0.0483·acoustic_impedance - 0.001483·q_factor
9	Phi	5	rms_amplitude, acoustic_impedance, q_factor	3	100	0.0351	0.7359	0.8579	0	Phi = 0.6146 + 0.4272·rms_amplitude - 0.04708·acoustic_impedance - 0.001149·q_factor

Скачать в Excel

Топ-5 многоатрибутных моделей Out-of-sample (RMSE_cv, R^2_cv)

	Параметр	Ранг	Атрибуты	k	n	RMSE_cv	R^2_cv (Pearson, Predicted vs Actual)	r_cv (Pearson, Predicted vs Actual)	WAPE_cv, %	Bias_cv	ΔRMSE к лучшей одноатрибутной	Принята	Equation
5	Phi	1	avo_intercept, acoustic_impedance, q_factor	3	100	0.0331	0.7655	0.8749	16.5015	-0.0002	-0.0143	да	Predicted = 0.0339 + 0.7773·Actual
6	Phi	2	spectral_decomp_20Hz, acoustic_impedance, q_factor	3	100	0.0357	0.7277	0.8531	18.8663	0.0001	-0.0117	да	Predicted = 0.04091 + 0.7333·Actual
7	Phi	3	sweetness, avo_intercept, acoustic_impedance	3	100	0.0358	0.7259	0.852	18.502	0.0001	-0.0116	да	Predicted = 0.03995 + 0.7397·Actual
8	Phi	4	avo_gradient, acoustic_impedance, q_factor	3	100	0.0367	0.7118	0.8437	18.7224	0.0001	-0.0107	да	Predicted = 0.04452 + 0.7097·Actual
9	Phi	5	rms_amplitude, acoustic_impedance, q_factor	3	100	0.0369	0.7089	0.842	19.2697	0.0001	-0.0105	да	Predicted = 0.04123 + 0.7315·Actual

Скачать в Excel

Коэффициенты: Phi, ранг 1

Коэффициенты: Phi, ранг 2

Коэффициенты: Phi, ранг 3

Коэффициенты: Phi, ранг 4

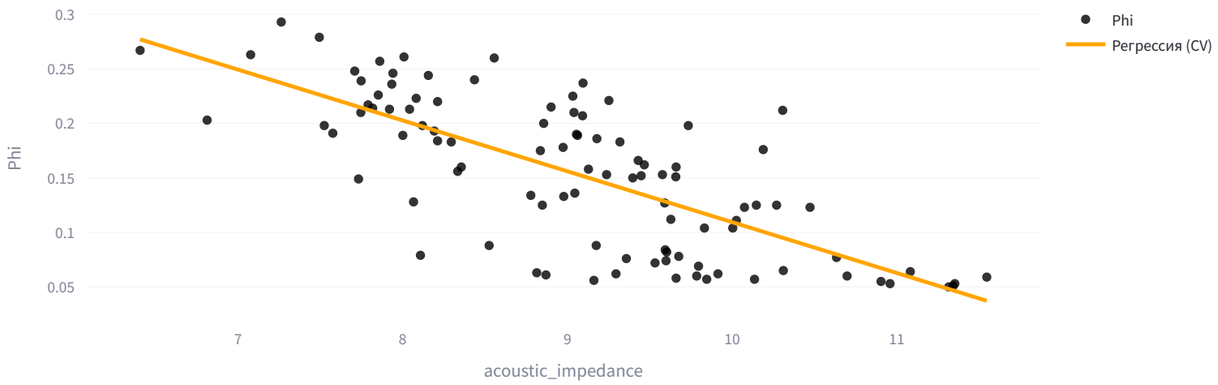
Коэффициенты: Phi, ранг 5

Скачать в Excel

Вклад атрибутов (стандартизованные коэффициенты): Phi, LOWO

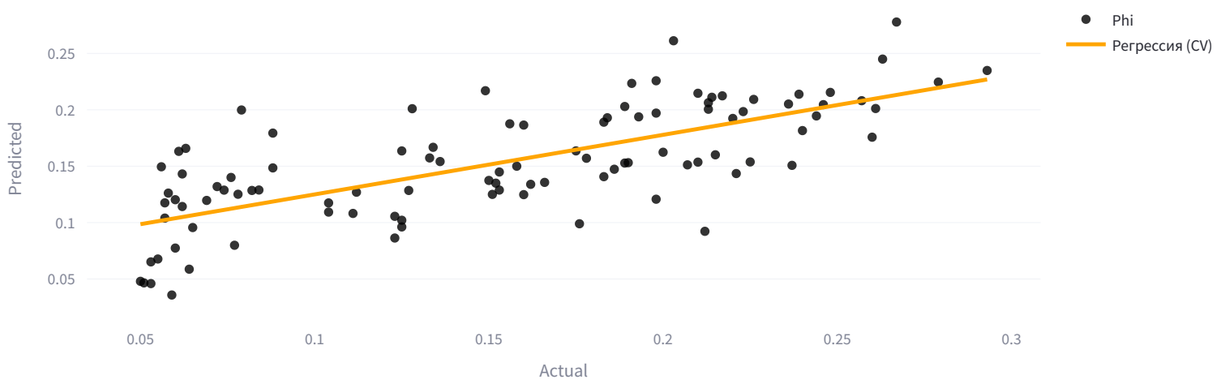


Cross-plot In-sample: Phi vs acoustic_impedance (лучший одноатрибутный): LOWO



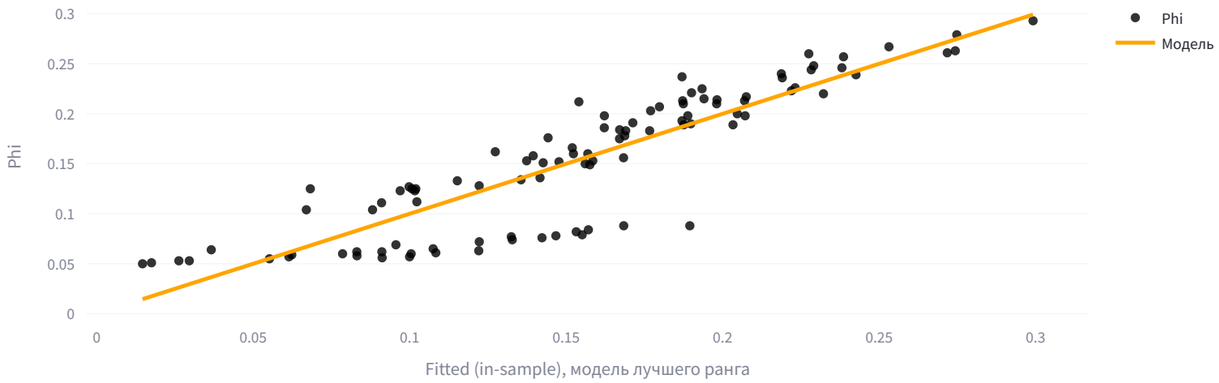
Equation: Phi = 0.5759 - 0.04665·acoustic_impedance

Cross-plot Out-of-sample: Phi vs acoustic_impedance (лучший одноатрибутный): LOWO



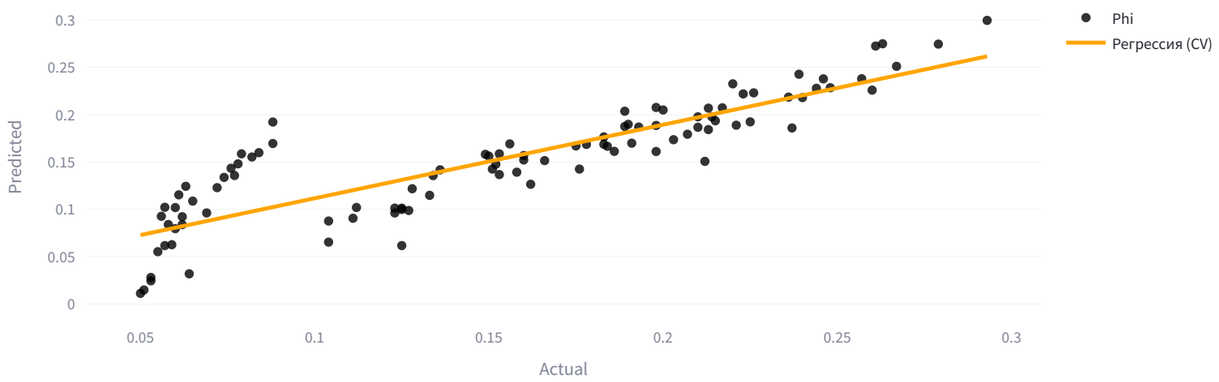
Equation: Predicted = 0.0722 + 0.5281·Actual

Cross-plot In-sample: Phi vs лучший многоатрибутный набор: LOWO



Equation: Phi = 0.5515 - 0.2452·avo_intercept - 0.03434·acoustic_impedance - 0.001391·q_factor

Cross-plot Out-of-sample: Phi vs лучший многоатрибутный набор: LOWO



Equation: Predicted = 0.0339 + 0.7773·Actual

Топ-5 моделей: K-fold по скважинам

Одноатрибутные модели — базовый уровень для сравнения Out-of-sample (RMSE_cv, R^2_cv)

	Параметр	Ранг	Атрибуты	k	n	RMSE_cv	R^2_cv (Pearson, Predicted vs Actual)	r_cv (Pearson, Predicted vs Actual)	Bias_cv	ΔRMSE к лучшей одноатрибутной	Equation
10	Phi	1	acoustic_impedance	1	100	0.0472	0.5238	0.7238	-0.0001	0	Predicted = 0.0719 + 0.5298·Actual
11	Phi	2	avo_intercept	1	100	0.0472	0.5237	0.7237	0	0	Predicted = 0.07191 + 0.5299·Actual
12	Phi	3	sweetness	1	100	0.0567	0.3126	0.5591	0.0002	0.0096	Predicted = 0.1021 + 0.3338·Actual
13	Phi	4	rms_amplitude	1	100	0.0614	0.2116	0.4599	0.0011	0.0142	Predicted = 0.1127 + 0.2708·Actual
14	Phi	5	envelope	1	100	0.0628	0.1564	0.3955	0.0002	0.0156	Predicted = 0.1279 + 0.1652·Actual
15	Phi	6	spectral_decomp_20Hz	1	100	0.0636	0.1353	0.3679	0	0.0164	Predicted = 0.1304 + 0.1478·Actual
16	Phi	7	avo_gradient	1	100	0.0637	0.134	0.3661	0.0005	0.0165	Predicted = 0.1313 + 0.145·Actual
17	Phi	8	inst_frequency	1	100	0.0663	0.0609	0.2468	-0.0001	0.0191	Predicted = 0.1419 + 0.0718·Actual
18	Phi	9	coherence	1	100	0.067	0.0415	0.2037	0	0.0199	Predicted = 0.145 + 0.05236·Actual
19	Phi	10	q_factor	1	100	0.068	0.0169	0.1301	-0.0001	0.0208	Predicted = 0.1488 + 0.02686·Actual

Скачать в Excel

Топ-5 многоатрибутных моделей In-sample (RMSE_in, R^2_in)

	Параметр	Ранг	Атрибуты	k	n	RMSE_in	R^2_in (Pearson)	r_in (Pearson, Predicted vs Actual)	Bias_in	Equation
5	Phi	1	avo_intercept, acoustic_impedance, q_factor	3	100	0.0318	0.7837	0.8852	0	Phi = 0.5515 - 0.2452·avo_intercept - 0.03434·acoustic_impedance - 0.001391·q_factor
6	Phi	2	spectral_decomp_20Hz, acoustic_impedance, q_factor	3	100	0.0345	0.7448	0.863	0	Phi = 0.634 + 0.09866·spectral_decomp_20Hz - 0.0485·acoustic_impedance - 0.001494·q_fa
7	Phi	3	sweetness, avo_intercept, acoustic_impedance	3	100	0.0345	0.7459	0.8636	0	Phi = 0.2872 + 0.5745·sweetness - 0.1958·avo_intercept - 0.02583·acoustic_impedance
8	Phi	4	sweetness, acoustic_impedance, q_factor	3	100	0.0356	0.7284	0.8535	0	Phi = 0.5447 + 0.4487·sweetness - 0.04543·acoustic_impedance - 0.0009234·q_factor
9	Phi	5	avo_gradient, acoustic_impedance, q_factor	3	100	0.0359	0.7249	0.8514	0	Phi = 0.6838 - 0.1023·avo_gradient - 0.0483·acoustic_impedance - 0.001483·q_factor

Скачать в Excel

Топ-5 многоатрибутных моделей Out-of-sample (RMSE_cv, R^2_cv)

	Параметр	Ранг	Атрибуты	k	n	RMSE_cv	R^2_cv (Pearson, Predicted vs Actual)	r_cv (Pearson, Predicted vs Actual)	WAPE_cv, %	Bias_cv	ΔRMSE к лучшей одноатрибутной	Принята	Equation
5	Phi	1	avo_intercept, acoustic_impedance, q_factor	3	100	0.0329	0.7682	0.8764	16.348	0.0002	-0.0143	да	Predicted = 0.03434 + 0.7772·Actual
6	Phi	2	spectral_decomp_20Hz, acoustic_impedance, q_factor	3	100	0.0354	0.7321	0.8556	18.4875	0.0001	-0.0118	да	Predicted = 0.04089 + 0.7333·Actual
7	Phi	3	sweetness, avo_intercept, acoustic_impedance	3	100	0.0359	0.7241	0.8509	18.6337	0.0004	-0.0112	да	Predicted = 0.0403 + 0.7391·Actual
8	Phi	4	sweetness, acoustic_impedance, q_factor	3	100	0.0365	0.7145	0.8453	18.6826	-0.0001	-0.0106	да	Predicted = 0.04247 + 0.722·Actual
9	Phi	5	avo_gradient, acoustic_impedance, q_factor	3	100	0.0366	0.7127	0.8442	18.6988	0.0004	-0.0105	да	Predicted = 0.04455 + 0.7118·Actual

Скачать в Excel

Коэффициенты: Phi, ранг 1

Коэффициенты: Phi, ранг 2

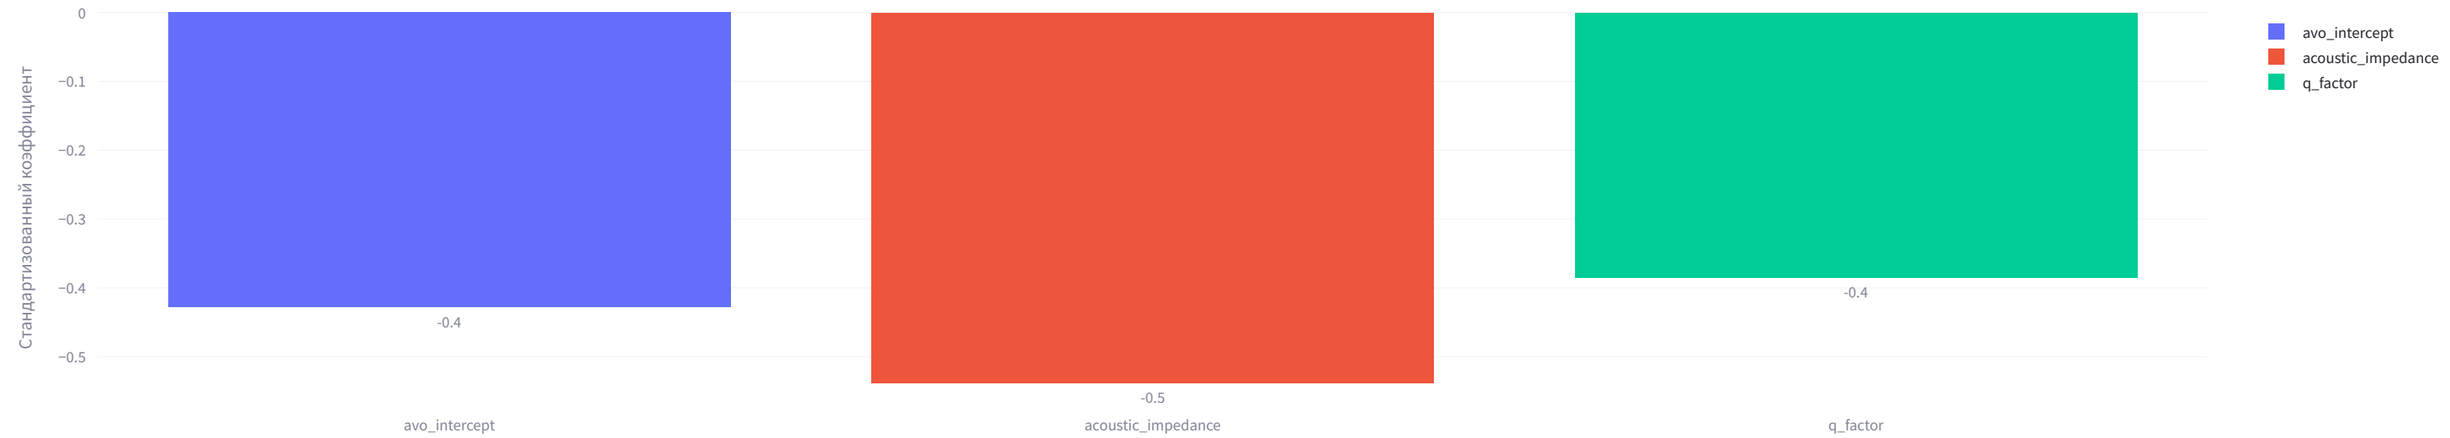
Коэффициенты: Phi, ранг 3

Коэффициенты: Phi, ранг 4

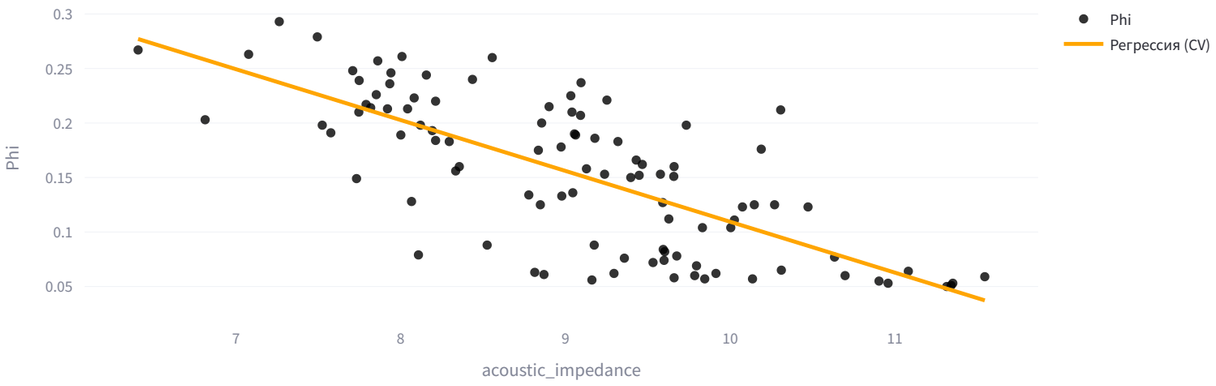
Коэффициенты: Phi, ранг 5

Скачать в Excel

Вклад атрибутов (стандартизованные коэффициенты): Phi, K-fold

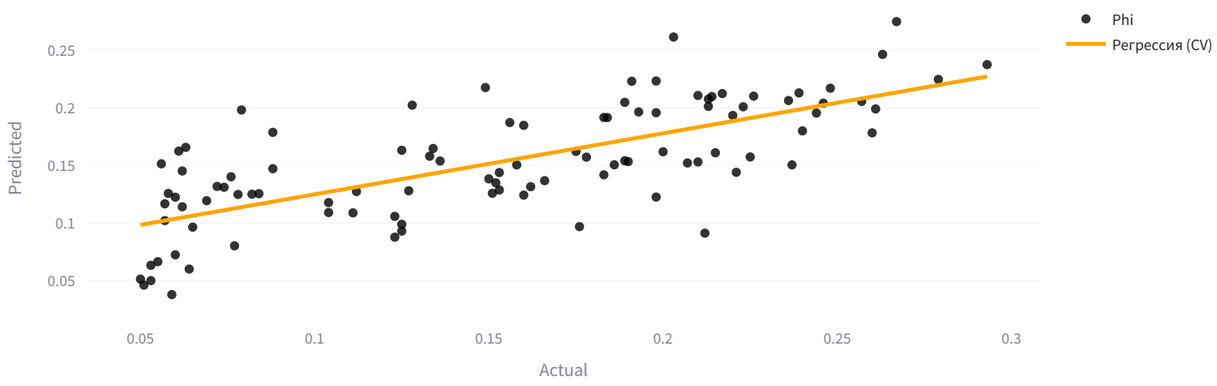


Cross-plot In-sample: Phi vs acoustic_impedance (лучший одноатрибутный): K-fold



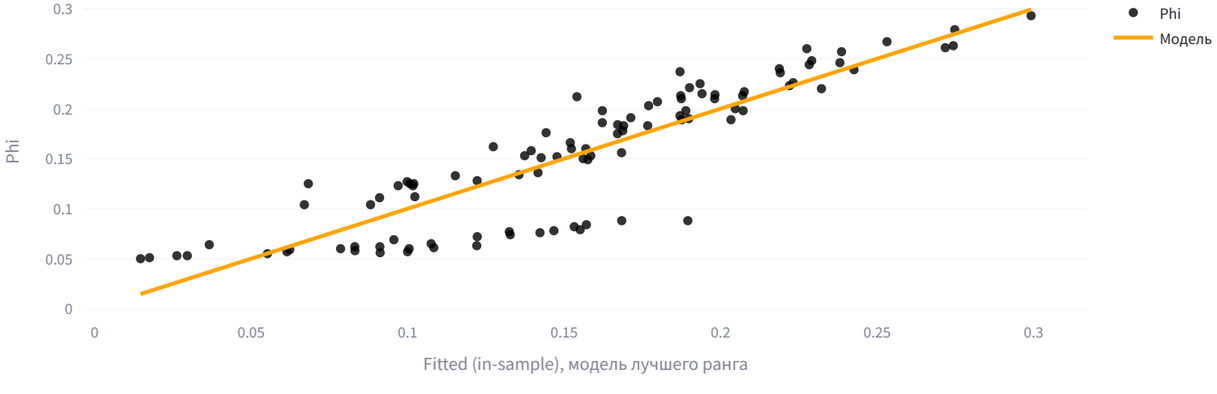
Equation: Phi = 0.5759 - 0.04665·acoustic_impedance

Cross-plot Out-of-sample: Phi vs acoustic_impedance (лучший одноатрибутный): K-fold

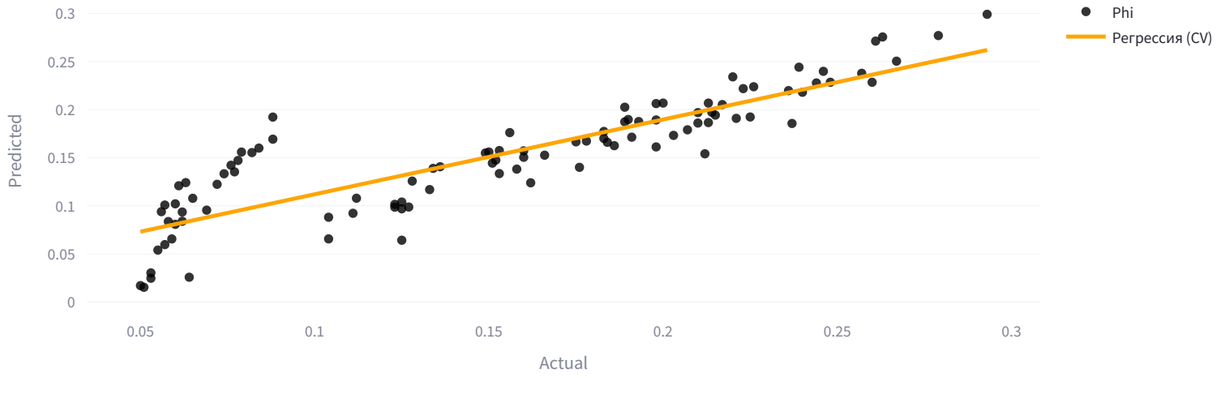


Equation: Predicted = 0.0719 + 0.5298·Actual

Cross-plot In-sample: Phi vs лучший многоатрибутный набор: K-fold



Cross-plot Out-of-sample: Phi vs лучший многоатрибутный набор: K-fold



Equation: Phi = 0.5515 - 0.2452·avo_intercept - 0.03434·acoustic_impedance - 0.001391·q_factor

Equation: Predicted = 0.03434 + 0.7772·Actual

CROSSPL✳T↔CROSS⊗VALIDATION

Данные обрабатываются в памяти сессии и не записываются на диск приложения.

© А.С.Поздняков 2026